第三章　科学智能的测评数据构建与可信评价

学习目标：区分科学任务、研究工作流与科学发现的测评目标，能够设计测试数据、选择评价依据，并审查测评结论的适用条件。
先修知识：基础机器学习、科学数据与实验设计。

摘要

科学智能系统正在从知识问答和性质预测扩展到数据分析、实验设计与研究任务执行，其能力判断也需要从单一测试集得分转向与科学目标相对应的证据。本文围绕测评对象、测试数据、评价方法和运行协议，梳理科学基础模型、大语言模型及科学智能体的测评研究。首先区分科学数据的一般质量与数据作为测量工具时的质量要求；其次分析任务定义、参考答案建立、数据划分、污染控制与动态更新的主要方法；随后比较客观指标、可执行验证、专家评价和模型评委的适用范围，并讨论不确定性、资源成本和实验安全。通过化学问答、材料筛选、分子对接、物理模拟、单细胞扰动预测及科学研究复现等案例，本文指出，基准得分的解释依赖目标任务、可用信息和验证条件，平均性能提升并不自动等于科学发现能力提升。未来测评应加强面向真实使用场景的外部验证，建立可追溯的参考证据、可复现的运行协议及可审计的评价过程，使测评结论能够明确说明系统在何种条件下可用、何时可能失效以及还需要何种验证。
关键词：科学智能；测评数据；基准构建；评价方法；科学智能体；测评可信性

3.1　引言

在科学研究中，模型输出的用途决定了应当怎样评价模型。一个系统可能准确回答专业问题，却无法在给定数据上完成统计分析；也可能得到较低的预测误差，却无法有效筛选值得实验验证的候选对象。模型是否具有实用价值，取决于测评任务能否对应研究中的实际决策，以及评分过程能否检验这些决策所依据的证据。REFORMS 将研究设计、数据处理、模型评价与结果报告共同纳入机器学习科学研究的规范，说明评价质量与完整研究过程密切相关 [60]。针对人工智能基

准的跨学科综述则指出，数据偏差、构念效度不足及结果解释失当都会削弱基准结论 [61]。

现有测评研究呈现两条相互关联的发展线索。一条从特定科学任务出发，研究怎样使预测指标对应材料筛选、扰动响应和物理模拟等实际目标；另一条从通用模型及智能体出发，将评价扩展到能力维度、交互环境、工具使用和资源约束。近期智能体测评综述分别从能力、评分方式与环境，以及数据整理、接口、指标和评测框架等角度进行组织 [62, 63]。生物医学基础模型的讨论进一步提出，应区分模型在具体任务上的效用与其对科学现象的表征和解释能力 [64]。这些研究共同要求明确：一次测评究竟支持了哪一种能力主张。

本文将科学智能测评界定为：在明确的科学任务、信息条件和资源约束下，利用测试数据或交互环境获取模型行为，并根据可说明的参考依据和评分规则，对其能力、可靠性及应用边界作出判断。这里的测评对象既包括直接预测结构、性质或场演化的科学模型，也包括以语言为主要接口的模型，以及通过工具执行研究任务的智能体。通用评价概念可以在这些对象之间共享，但具体任务、指标和证据要求需要按领域确定。

3.2 科学智能测评的能力对象：从单项任务到科学发现（测什么）

科学智能测评首先需要明确模型被要求完成什么科研任务，以及任务表现能够支持何种能力判断。同样是获得正确结果，回答科学问题、预测材料性质、完成研究复现和提出经验证的新发现，所反映的能力并不相同。因此，测评对象的组织应从科研任务及其产出出发，建立模型表现与科学能力之间的对应关系。

Zheng 等的综述将大语言模型在科研中的角色划分为工具、分析者和科学家，揭示了其参与范围由具体任务向多阶段研究过程扩展的趋势 [65]。借鉴这一思路，本节按照任务覆盖范围，将科学智能的测评对象组织为三个方面：单项科学任务能力、研究工作流执行能力，以及科学发现能力。其中，单项科学任务进一步包括科学知识与推理、科学预测与生成。该组织方式用于区分测评所支持的能力判断，并不意味着三者构成统一的智能等级，也不意味着自主程度更高的系统必然具有更可靠的科学能力。

Autonomy Levels	LLMs' Role	Human's Role	Task Scope	Agentic Workflow
Level 1 *LLM as Tool*	Task Automation Tool	Task Allocation	Explicitly Defined	Simple & Static
Level 2 *LLM as Analyst*	Data Modeling & Analytical Agent	Problem Definition & Output Validation	Goal-Oriented	Advanced
Level 3 *LLM as Scientist*	Open Exploratory & Discovery Agent	Minimal Intervention	Open-Ended	Strategic & Iterative

Table 1: Three levels of autonomy in LLM-based scientific discovery.

图 3.1 科研中大语言模型的自主程度与角色分工 [65]。

3.2.1 单项科学任务能力

3.2.1.1 科学知识与推理

科学知识与推理测评关注模型能否理解科学概念、识别对象之间的关系，并在给定条件下运用知识完成判断、计算或解释。知识掌握主要体现为对事实、定义和规律的正确调用；科学推理则要求模型结合问题条件，经过必要的计算或逻辑步骤形成结论。两者在具体任务中经常同时出现，但测评结果的解释需要区分事实记忆、知识应用和多步推理。

ChemBench 为这一类测评提供了领域化实例。Mirza 等围绕化学知识与推理构建评价框架，并将模型表现与化学专业人员进行比较 [66]。其意义在于把笼统的“化学能力”落实到具体问题及其知识要求，使研究者能够观察模型在不同化学任务上的表现差异，而不仅依赖一个综合得分判断其专业水平。

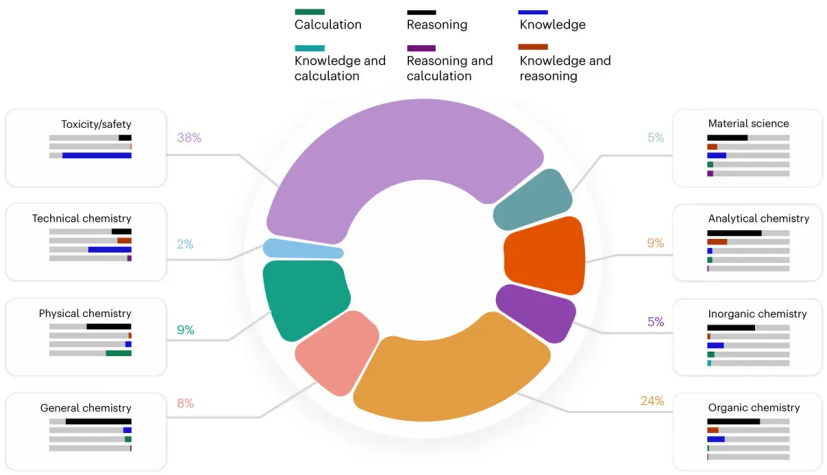


Fig. 2 | Distribution of topics and required skills. The distribution of questions across various chemistry topics, along with the primary skills required to address them. The topics were manually classified, showing a varied representation across different aspects of chemistry. Each topic is associated with a combination of three key skills: calculation, reasoning and knowledge, as indicated by the coloured bars. ChemBench samples encompass diverse topics and diverse skills, setting a high bar for LLMs to demonstrate human-competitive performance across a wide range of chemistry tasks.

图 3.2 ChemBench 的化学问题类型与知识技能分布 [66]。

2026 年发表于 Nature 的 Humanity’s Last Exam（HLE）进一步提高了学术问答的难度，通过涵盖数学、自然科学等领域的专家级问题，考察模型处理复杂、可核验问题的能力 [67]。但是，问题难度的提高并不改变其测评对象的基本性质：HLE 仍然主要评价具有已知答案的学术问题求解。论文明确指出，高分本身不能证明模型具备自主开展研究的能力。因而，科学知识与推理测评能够说明模型是否具备相应的知识基础和问题求解能力，却不足以判断其能否组织实验或形成新发现。

3.2.1.2 科学预测与生成

科学预测与生成测评直接面向科学对象及其性质。预测任务要求模型根据给定结构、状态或实验条件，估计未知性质或系统响应；生成任务则要求模型根据目标性质与约束，提出符合要求的候选对象。以材料研究为例，前者可以表现为由晶体结构预测稳定性，后者则可以表现为根据目标性质生成晶体结构。

预测能力的测评需要与具体科学用途相联系。Riebesell 等提出的 Matbench Discovery 将评价目标置于稳定无机晶体的筛选场景，考察模型能否从候选结构中识别值得进一步研究的材料 [68]。该研究指出，较小的能量回归误差并不必然意味着更准确的稳定性判断。因此，预测测评不仅需要回答 “数值预测是否准确”，还需要明确这种准确性是否能够支持预期的科学判断。

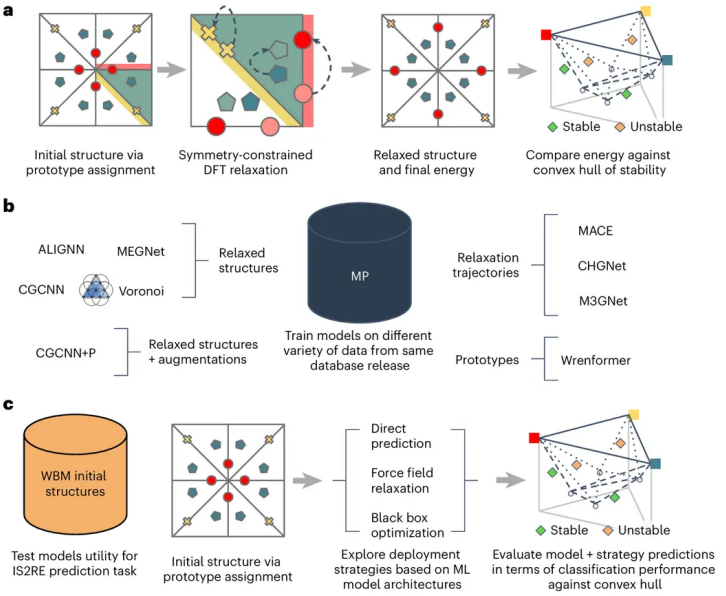


Fig. 1 | An overview of how data are used in Matbench Discovery. **a**, A conventional prototype-based discovery workflow where different elemental assignments to the sites in a known prototype are used to create a candidate structure. This candidate is relaxed using DFT to arrive at a relaxed structure that can be compared against a reference convex hull. This sort of workflow was used to construct the WBM dataset. **b**, Databases such as the MP provide a rich set of data that different academic groups have used to explore different types of models. While earlier work tended to focus on individual modalities, our framework enables consistent model comparisons across modalities. **c**, The proposed test evaluation framework where the end user takes an ML model and uses it to predict a relaxed energy given an initial structure (IS2RE). This energy is then used to make a prediction as to whether the material will be stable or unstable with respect to a reference convex hull. From an applications perspective, this classification performance is better aligned with intended use cases in screening workflows.

图 3.3 Matbench Discovery 的晶体稳定性筛选与评价流程 [68]。

生成能力则需要同时考虑候选对象的有效性、差异性和目标符合程度。2025 年发表于 Nature 的 MatterGen 展示了这一评价方向：模型生成无机晶体结构，并通过条件控制面向不同目标性质开展材料设计 [69]。在这一场景中，生成结果是否具有合理结构、是否满足稳定性与目标性质要求，以及能否得到后续计算或实验验证，分别对应不同层面的能力证据。

据此，本章将候选对象生成与科学发现分别讨论。一个结构未出现在已有数据集中，能够说明其相对于参照集合具有新颖性；要将其进一步认定为有科学价值的新材料，还需要验证其性质与适用条件。生成测评主要评价提出合格候选对象的能力，发现测评则进一步考察围绕这些对象建立科学证据的能力。

3.2.2 研究工作流执行能力

研究工作流测评关注系统能否围绕给定研究目标，协调多个相互依赖的任务。与单项任务相比，其评价单位由一次回答或一个预测结果，扩展为包含数据处理、

方法选择、程序实现、运行调试和结果分析的连续过程。本节将研究工作流执行能力界定为：系统能够在规定条件下完成这些操作，并形成可检查的研究产出。

现有研究可以从工作流中的具体任务和跨阶段研究复现两个尺度理解。ScienceAgentBench 从同行评审论文中提取真实科研任务，要求智能体提交可独立运行的 Python 程序，并检查程序及其执行结果 [70]。这一设计使评价能够检验系统是否实际完成所要求的分析，而不只是生成看似合理的方法描述。但其测评单位仍是研究工作流中的具体任务，不能将任务完成率直接解释为端到端科学发现能力。

PaperBench 则将评价范围扩展到研究复现，要求智能体理解论文、实现代码并执行实验，以检验其能否重新实现既有研究成果 [71]。与单个程序生成任务相比，这类测评增加了任务分解、阶段衔接和持续执行的要求。它所考察的不仅是某一步能否完成，还包括多项操作能否共同服务于明确的研究目标。

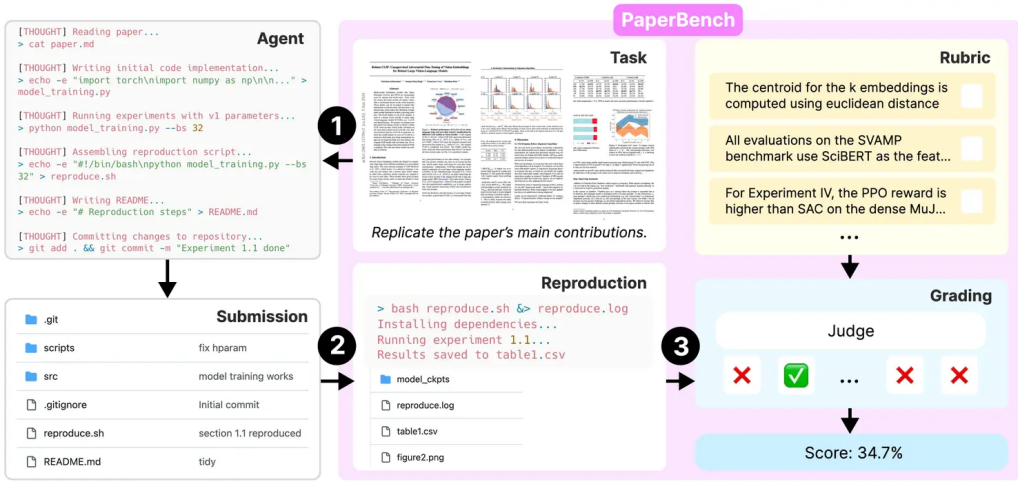


Figure 1. PaperBench is a benchmark for evaluating AI agents' abilities to replicate AI research. Each sample includes a research paper and a grading rubric that specifies the assessment criteria for a complete replication. Agents create a codebase from scratch as their submission (1), which is then executed to verify result reproduction (2) and graded against the rubric by an LLM-based judge (3).

图 3.4 PaperBench 的论文复现任务与评分流程 [71]。

这两类研究提示，工作流测评需要区分操作完成、结果正确和结论成立。程序成功运行只能说明操作层面的完成；输出符合要求，还需要检查其科学含义；形成研究结论，则进一步要求结论能够由实际执行的分析支持。因此，研究工作流能力应通过代码、运行记录、数据产物及其关联进行判断。对于具有人机协作的系统，还应明确研究者提供了哪些目标、方法和纠错帮助，以界定结果所反映的是模型能力还是整个协作系统的能力。

3.2.3 科学发现能力

科学发现测评进一步关注系统能否围绕尚待解决的问题形成有证据支持的认识。其评价对象包括提出可检验的假设、选择能够区分不同解释的研究方案、解释所得证据，以及在证据不足或与预期不符时修正结论。本章据此将科学发现能力理解为形成和更新科学认识的能力，而不以生成论文文本或完成一套操作流程作为充分判据。

这一领域首先需要区分已知结论的再发现与面向未知问题的原创发现。前者将已有研究成果作为参照，考察系统能否通过研究过程重新获得相应认识；后者则涉及尚无确定答案的问题，需要对新颖性、有效性和科学价值作进一步判断。两类任务能够提供不同程度的可核验性，其结果不宜直接等同。

ICML 2026 的 FIRE-Bench 采用了再发现路径：系统获得高层次研究问题后，需要自行设计并运行实验，再依据所得证据形成结论，评价时参照已有论文记录的研究发现 [72]。这种设计将测评重点从报告是否完整推进到研究结论是否得到实验支持。同时，已有发现为结果核验提供了参照。因此，FIRE-Bench 可以用于检验实验设计、执行与证据推理的综合表现，但其结果仍应解释为既有科学结论的再发现能力，而非直接证明系统能够持续作出原创发现。

近期研究还开始检验正确结论是否确实来自任务提供的证据。Zhang 和 Li 于 2026 年 10 月公开的预印本，通过保留、撤除或反转数据中的关键信息，观察智能体的回答是否相应变化 [73]。在其测试的有限单细胞分析任务和合成问题中，答对标准答案与根据数据证据调整结论并不总是一致。该结果提示，发现能力的评价还应关注结论对证据的依赖关系；不过，该研究覆盖范围有限，应作为前沿方法探索，而不宜据此概括所有科学智能体的表现。

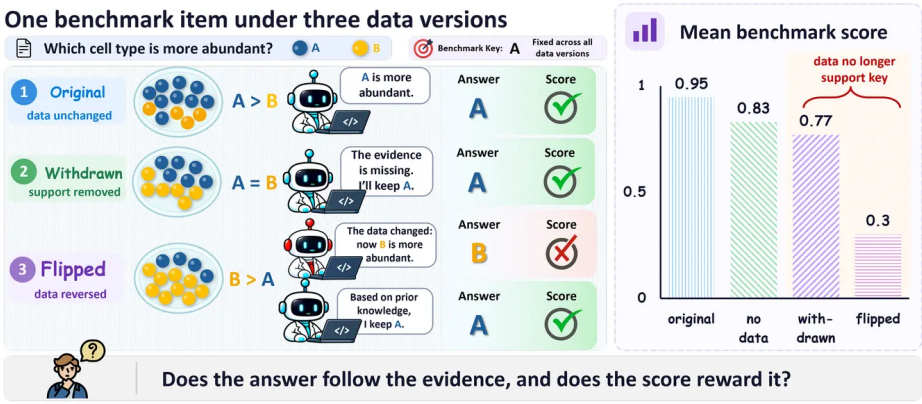


Figure 1: **Does the answer follow the evidence, and does the score reward it?** Left: a conceptual benchmark item under its original, withdrawn and flipped data. The benchmark keeps its original key (A), so an agent that retains A keeps full credit, whereas an agent that follows the flipped evidence and answers B receives zero. Right: mean benchmark score of the Claude agents on our 18 BAIS-SD tasks, graded against the original key. App. B follows a real item through the same data versions.

图 3.5 数据证据变化与智能体答案变化的对照 [73]。

对于面向未知问题的发现任务，本章进一步区分提出候选假设、获得初步支持和形成经独立检验的新认识。假设在表述上具有新颖性，仅能说明系统提出了不同于既有表述的解释；计算或实验结果提供支持后，才能进一步讨论其成立条件；经过独立验证，才形成更强的发现证据。这些区别决定了测评需要识别系统贡献发生在哪个环节，以及该贡献已经获得何种程度的验证。

由此，科学知识与推理、预测与生成、研究工作流以及科学发现构成相互关联的测评对象：前两者评价具体科学任务，工作流评价多项任务的组织与执行，发现评价研究过程形成认识的能力。后续测评数据与方法的设计，应据此确定任务输入、预期产出及其核验依据，避免将某一类基准上的表现扩大解释为普遍的科学研究能力。

3.3 科学智能测试的构建：从任务定义到质量验证

科学智能测评需要将抽象的能力目标转化为可执行、可核验的测试。上一节明确了科学知识、预测与生成、研究工作流和科学发现等测评对象，本节进一步讨论：应当提供什么问题和输入，依据什么判断结果，以及如何保证测试能够支持预期的能力判断。

Eriksson 等 [61] 指出，基准测评的重要风险之一是构念效度不足，即测试实际测量的内容与其声称测量的能力不一致。数据来源不清、标注依据不足和测试污染，都可能削弱从测试表现推断模型能力的合理性。因此，测试构建需要同时设计任务、参考依据、数据划分和执行条件。

这一视角也明确了科学数据质量与测评数据适用性的区别：科学数据作为研究资源的一般质量包括准确性、完整性、组织方式和可复用性；本章讨论这些数据作为能力测量工具是否合适。例如，一组实验记录可以真实、完整且格式规范，但如果训练集与测试集包含来自同一样本的重复测量，就未必适合用于评价模型对新样本的泛化能力。

3.3.1 任务定义：将能力目标转化为可执行问题

任务定义首先需要明确测试所要支持的能力主张。“能够分析科学数据”“能够发现新材料”等表述涉及多种能力，难以直接作为测试说明。构建者需要进一步限定科学对象、待解决问题、可用信息、预期产物和完成条件，使被测系统与评价者对任务边界形成一致理解。

在具体设计中，可以围绕四个问题展开：模型需要完成什么科学操作；能够获得哪些数据和背景知识；允许使用哪些工具及计算资源；最终应提交哪些能够核验的结果。例如，科学数据分析任务可以要求提交分析程序、结果文件及解释报告，并说明是否允许联网、安装软件、查询文献或接受人工帮助。这些条件共同界定了测试对应的能力范围。

ScienceAgentBench[70] 提供了任务操作化的实例。它将科学工作流中的任务表述为程序生成问题，每个实例包含任务指令、数据集信息、可选的专家知识以及参考程序。这里需要区分面向模型的输入与面向评价者的参考材料：参考程序用于建立完成任务的依据，专家知识是否提供则构成不同的测试条件。

科学任务的输入还应符合实际应用时的信息可得性。Matbench Discovery[68] 以未弛豫晶体结构作为测试输入，评价模型对弛豫后结构稳定性的预测能力。由此可以看到，任务定义不能只规定预测目标，还要说明预测发生在研究流程的哪个阶段。若提前提供实际应用中尚不可获得的信息，测试所对应的科学问题就发生了改变。

因此，任务定义的产物应是一份明确的任务说明，能够将能力目标落实到输入、操作条件、输出和判定要求，并限定测试结果可以支持的结论。

3.3.2 参考答案：建立与任务性质相适应的判定依据

科学任务的参考答案具有不同形态。对于知识问答，参考依据可以是经核验的答案及其推导；对于预测任务，可以是实验测量或特定计算方法产生的数值；对于生成与研究工作流任务，则往往需要由约束条件、执行结果和证据要求共同构成判定依据。参考答案的设计应与任务性质相适应。

对于具有明确答案的科学问题，需要同时保存答案来源、必要条件和求解说明。数值答案还应规定单位、精度及允许误差；数学表达式、分子表示等则需要考虑等价表达。HLE 的正式论文 [67] 要求题目提交者提供答案及详细解答，并设置多阶段专家审查。这说明，可核验的参考答案需要伴随能够检查其正确性的依据。

对于预测与生成任务，需要明确参考值的证据层级。实验测量值受实验条件和测量误差影响，模拟计算值则依赖所采用的理论近似和计算设置。例如，Matbench Discovery[68] 使用密度泛函理论计算结果建立参考目标，同时指出计算稳定性与实际可合成性之间仍存在距离。因此，与计算参考值一致能够支持相应的预测能力判断，但其科学含义应限定在该参考体系之内。对于允许多种有效解的生成任务，本章建议预先规定有效性、目标属性和验证要求，避免将与某一个已知样本相似作为唯一成功条件。

对于研究工作流任务，参考依据应进一步落实到可检查的产物与执行证据。PaperBench[71] 将论文复现要求分解为层级化的判定条目，区分代码实现、执行过程和结果复现，并在新的运行环境中重新执行提交内容。这种设计使复杂任务能够获得细粒度的参考要求，也避免仅凭报告中的结果陈述判断任务是否完成。

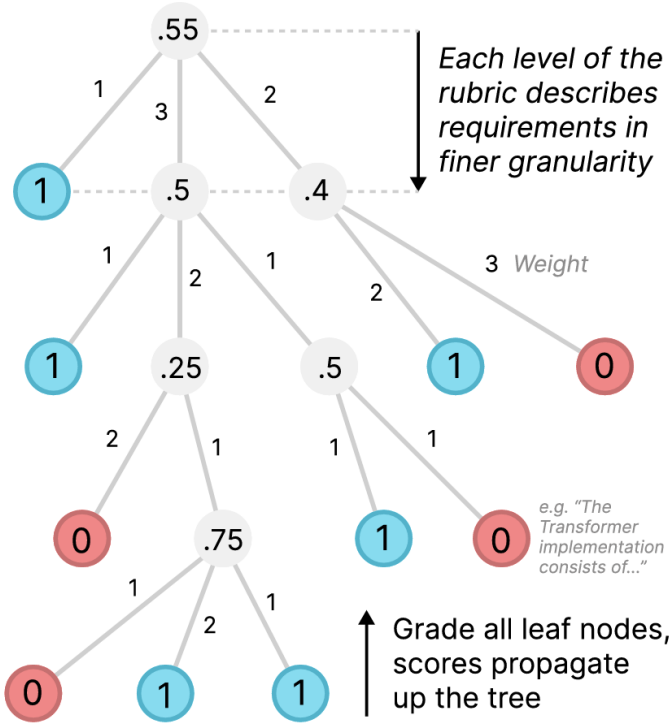


Figure 2. Rubrics hierarchically decompose the replication task into a tree of increasingly granular requirements. Leaf nodes are graded for binary pass/fail criteria, and a parent's score is the weighted average of its children. In the example above, the final Replication Score is 55%.

图 3.6 复杂研究任务的层级化判定要求：以 PaperBench 为例 [71]。

参考依据还需要设置争议处理机制。对于专家意见不一致、实验条件不充分或存在多种合理解释的样本，应记录分歧并进行复核，必要时修改题目、接受多个有效答案或暂时移出正式测试集。本节关注这些判定依据如何建立；具体评分函数、权重和评价者一致性的计算，可在后续评估方法部分展开。

3.3.3 数据划分：使测试条件对应预期泛化场景

数据划分决定了测试所模拟的应用场景。随机划分主要用于估计模型在相近数据分布中的表现；当研究目标是预测新的分子骨架、蛋白家族、实验批次或未来观测时，则需要围绕这些差异组织测试集。划分方式的选择应由泛化主张决定。

科学数据往往存在样本之间的依赖关系。同一实验对象的重复测量、同一结构的不同构象以及同一研究数据的派生版本，都可能使训练集与测试集共享信息。构建者因此需要识别合适的划分单位，并检查重复、近重复及相关实体跨集合出现的情况。下表归纳了几类典型对应关系。

表 3.1 测试划分方式与泛化主张的对应关系（本章归纳）

预期评价的泛化能力	主要划分依据	需要检查的问题
对相同采样机制下新观测的预测	在独立性条件成立时随机划分	重复记录及同一对象的多次测量是否跨集合出现
对新分子或新蛋白类别的预测	分子骨架、结构相似性或序列相似性分组	测试对象是否与训练对象高度相似
对新实验条件或新研究来源的适应	实验批次、实验室、研究项目等分组	是否主要依赖来源特征或批次特征完成预测
对未来观测的预测	按时间划分并限制信息可得时间	是否使用了预测时点之后产生的数据或注释
对新实体组合的预测	明确组合双方哪些已见、哪些未见	“新组合”是否被误写成“两类实体均未见”

DataSAIL[74] 针对生物分子数据中的相似性问题，将划分建模为优化任务，通过聚类和整数线性规划减少集合间的相似性信息泄漏。其研究表明，随机划分与相似性感知划分可能产生明显不同的模型表现，提示测试难度与所要求的泛化距离密切相关。

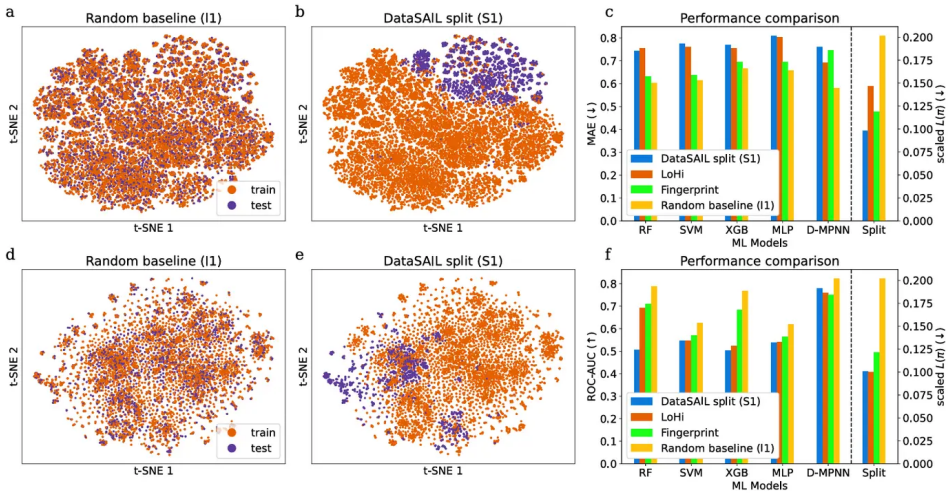


Fig. 3 | One-dimensional datasets QM8 and Tox21. We show QM8 (**a**, **c**, **e**) and Tox21 (**b**, **d**, **f**) from the MoleculeNet benchmark collection. **a**, **d** show the t-SNE embeddings for random split and **b**, **e** for DataSAIL's S1 split. **c**, **f** show ML model performances and information leakages for the different splits, quantified using mean absolute errors (MAE, lower is better) for QM8 and area under the receiver operating characteristic (ROC-AUC, higher is better) for Tox21.

图 3.7 随机划分与相似性感知划分对科学模型评估结果的影响 [74]。

2026 年的补遗 [75] 进一步将 DataSAIL 与数据集原有的划分进行比较。在 LP-PDBBind 的比较中，仅按配体或蛋白一侧进行相似性划分，并未获得低于原有划分的泄漏分数，而同时考虑双方的划分取得了更低的分数。这说明，对于由多类实体共同构成的科学任务，需要明确独立性约束施加在哪些维度，不能仅依据划分方法的名称判断其充分性。

在测试使用过程中，还应区分开发数据与最终测试数据。模型选择、提示词调整、工具配置和阈值确定应使用开发集；最终测试集用于对已确定的系统进行评价。涉及从数据学习参数的预处理，也应遵循相应的训练边界。测试结果一旦被反复用于修改系统，该测试集就已参与开发过程，需要在报告中说明。

3.3.4 污染控制：覆盖训练、更新与测试执行过程

数据划分主要处理当前任务中的信息独立性，而基础模型可能在进入该任务之前就接触过测试题、参考答案或相关代码。因而，即使下游训练集与测试集已经分离，仍需要考虑模型此前的训练暴露。

Chen 等 [76] 的综述指出，测试污染可能发生于预训练、微调和后训练等阶段，重复内容也可能以改写等形式出现。对于训练数据不公开的模型，污染状态通常难以得到完整验证。因此，污染控制需要结合数据来源记录、暴露风险检查和测试设计共同开展。

已有研究表明，题目改写不能被视为可靠的去污染保证。Sun 等 [77] 在 ICML 2025 发表的研究比较了多种缓解策略，发现保持原有语义的改写未能在所有测试中稳定提高抗污染能力，而改变语义的策略又可能牺牲与原任务的评价一致性。对于科学测试而言，替换变量、数值或实验条件之后，还需要重新核验答案、难度和所测能力。

污染检测本身也存在适用边界。Wang 等 [78] 在 ICLR 2026 的研究发现，在其考察的推理模型训练情境中，强化学习后训练可能削弱已有污染检测方法依赖的信号。这一结果提示，检测工具未发现污染，并不能单独作为测试独立性的证明；检测方法及其适用条件也应成为测评报告的一部分。

结合上述研究，科学智能测试可以从三个环节降低污染风险。在数据进入测试集时，记录来源、首次公开时间及与已有基准的重叠关系；在测试发布与维护时，保留受控的测试部分，并记录模型版本、数据版本和测试时间；在测试执行时，明确可访问的文件、检索资源与参考材料，防止系统通过测试标签或原始解答直接获得结果。这些措施降低的是可识别的风险，并不构成对未知训练数据的完全保证。

动态更新为维持测试独立性提供了另一条路径。LiveBench[79] 利用近期信息来源持续更新问题，并以可核验的参考值进行评价。不过，更新测试也会改变题目构成和难度。为保持可比性，本章建议同一轮模型比较使用相同的测试快照；跨版本比较则应说明题目替换规则，并检查能力覆盖和难度变化。

Dynamic Mechanisms	Benchmark Name	Evaluation Criteria					
		Correctness	Scalability	Collision	Stability of Complexity	Diversity	Interpretability
Temporal Cutoff	LiveBench (White et al., 2024)	●	◐	◐	○	○	●
	AcademicEval (Zhang et al., 2024a)	●	◐	◐	○	○	●
	LiveCodeBench (Jain et al., 2024)	●	◐	◐	○	○	●
	LiveAoPSBench (Mahdavi et al., 2025)	●	◐	◐	○	○	●
	AntiLeak-Bench (Wu et al., 2025)	●	●	◐	●	○	●
Rule-Based	S3Eval (Lei et al., 2024)	●	●	◐	●	◐	●
	DyVal (Zhu et al., 2024a)	●	●	●	●	◐	●
	MMLU-CF (Zhao et al., 2025)	●	◐	○	●	◐	◐
	NPHardEval (Fan et al., 2024)	●	●	●	●	◐	●
	GSM-Symbolic (Mirzadeh et al., 2025)	●	○	◐	●	◐	●
	PPM (Chen et al., 2024a)	●	●	●	◐	◐	●
	GSM-Infinite (Zhou et al., 2025)	●	●	●	●	◐	●
LLM-Based	Auto-Dataset (Ying et al., 2024)	◐	●	◐	●	●	○
	LLM-as-an-Interviewer (Kim et al., 2024)	◐	●	◐	◐	●	○
	TreeEval (Li et al., 2024c)	◐	●	◐	◐	◐	○
	BeyondStatic (Li et al., 2023a)	◐	●	◐	○	●	○
	StructEval (Cao et al., 2024)	◐	●	●	●	●	○
	Dynabench (Kiela et al., 2021)	◐	◐	◐	◐	●	○
	Self-Evolving (Wang et al., 2025)	◐	●	◐	●	●	○
Hybrid	DARG (Zhang et al., 2024b)	◐	●	◐	●	●	◐
	LatestEval (Li et al., 2023c)	●	◐	◐	○	○	●
	C2LEVA (Li et al., 2025)	◐	●	◐	◐	●	◐

Table 2: Existing dynamic benchmarks and their quality on our summarized criteria. ● represents support, ◐ represents partial support, and ○ represents no support.

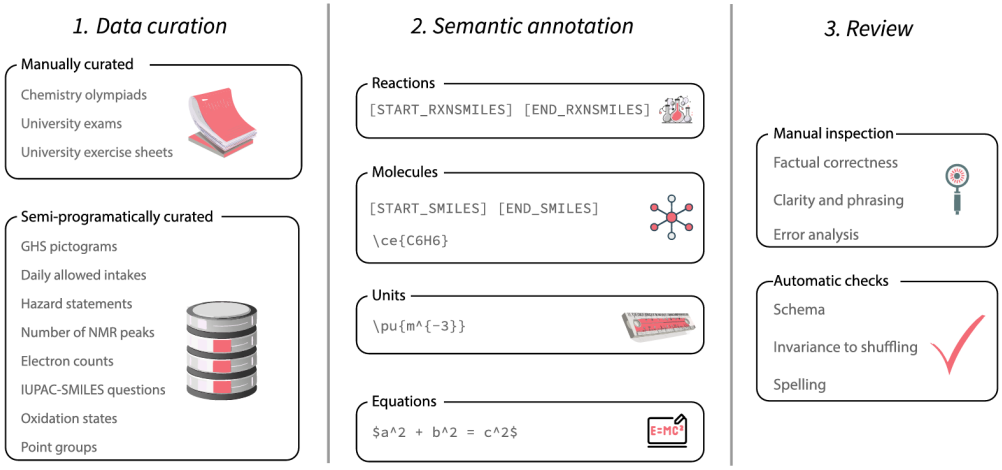
图 3.8 动态测试基准及其质量维度比较 [76]。

因此，污染控制需要同时维护两个目标：减少模型事先接触测试内容的机会，并保持测试所测能力及其难度的可解释性。持续产生新题，需要与答案核验和版本管理共同实施。

3.3.5 质量要求：验证测试能否支持预期的能力判断

完成任务编制、参考依据和数据划分之后，还需要对测试本身进行验证。本章将测试质量落实为五方面要求：任务是否具有科学代表性，参考依据是否可信，测试信息是否充分独立，执行过程是否能够复现，以及结果是否能够追溯到明确的数据和协议版本。

质量审查可以贯穿样本进入测试集的全过程。ChemBench[66] 将多来源题目整理、语义标注、人工审查和自动检查结合起来；除原始整理者外，所有问题还经过至少两名科学家的审查。这种流程兼顾科学内容与技术格式，使自动化检查能够处理格式问题，专家审查能够处理专业判断问题。



Extended Data Fig. 1 | Overview of the workflow for the assembly of the ChemBench Corpus. To assemble the ChemBench corpus, we first collected questions from various sources. Some tasks were manually curated, others semi-programmatically. We added semantic annotations for all questions to make them compatible with systems that use special processing for modalities that are not conventional natural text. We reviewed the questions using manual and automatic methods before adding them to the corpus.

图 3.9 科学测试题的整理、语义标注与质量审查流程：以 ChemBench 为例 [66]。

测试还应经过试运行和针对性检查。本章建议使用参考实现验证任务是否可完成，并构造典型错误结果，检查评价程序能否识别单位错误、输出缺失或无效计算。对于声称依赖实验数据完成的任务，可以进一步检查移除关键输入后是否仍能轻易得到预期答案。这类检查的目的，是识别任务中的信息捷径及判定漏洞。

模型得分低本身不能证明测试质量高，因为题意模糊、答案错误或运行环境失效也可能导致低分。

发布后的纠错同样属于质量管理。HLE[67] 在多轮专家审查之外，还设置了发布后的社区反馈及错误复核流程，其正式论文亦报告了专家分歧。这提示高难度科学题目需要持续审查，修订记录应与测试版本关联，避免不同版本的结果在没有说明的情况下直接比较。

最终交付的测试应包括任务说明、输入数据、参考依据、划分标识、执行环境、污染检查记录及修订历史。对于暂不公开的答案或测试样本，可以公开构建原则和审查程序，同时通过受控评测维护结果的可复核性。由此，测试构建形成一套能够被执行、检查和维护的测评协议，为后续的评分、统计分析和能力解释提供基础。

3.4 评价方法与指标选择（如何评价）

3.4.1 客观指标与科学决策目标

对于具有明确答案的任务，可以采用准确率、精确匹配或规范化后的等价判断；对于连续预测，可采用平均绝对误差、均方根误差及其他与量纲和分布相适应的指标。选择指标时需要先说明科学决策。例如，研究者若只验证排序最前的候选对象，前若干名的命中率可能比总体误差更接近实际需求；若漏检和误报的代价不同，则需要分别报告相应错误。Matbench Discovery 揭示了能量回归误差与稳定性筛选表现之间的不一致，说明低误差并不必然带来有效的候选筛选 [68]。

多个任务或领域的分数也不能直接无条件相加。指标尺度、样本数量和任务难度不同，宏平均与按样本数加权平均会突出不同方面。如果给出总分，应同时提供分任务结果、权重来源及对权重变化的敏感性分析。对于科学智能系统，较稳妥的比较是报告准确性、资源成本、可靠性等多个维度，并说明模型之间的取舍。总分可以服务于特定选择目标，但其权重本身也是评价设计的一部分 [61, 80]。

3.4.2 可执行验证与科学约束

可执行验证将输出转换为可以独立检查的对象，例如运行程序、检查生成结构、验证单位和边界条件，或重新计算关键统计量。ScienceAgentBench 将程序、执行结果和成本共同纳入评价，使代码文本与实际运行行为能够分别检查 [70]。但

程序能够执行，只能说明其满足部分计算条件；错误的数据过滤、统计假设或目标变量选择仍可能产生看似合理的结果。执行测试需要同时检查输出数值、数据来源和任务约束。

科学约束用于检验常规相似度指标未覆盖的错误。PoseBusters 在分子对接评价中检查化学与几何合理性，包括立体化学、键长及分子间碰撞等 [81]。其方法学启示是，生成结果接近参考结构与满足基本科学条件需要分别评价。对于物理代理模型，本文建议结合长期演化误差、边界条件和守恒关系检验；具体检验应根据模型目标和近似假设确定，不应机械要求所有模型满足同一约束。The Well 的多物理系统数据为比较不同动力学情境下的表现提供了基础 [82]。

3.4.3 专家评价与模型评委

当输出涉及研究假设、解释或完整报告时，参考答案可能存在多种合理形式，需要使用明确的评价量表。专家评价应说明专业背景、盲评方式、评分维度和分歧处理，并尽量要求判断关联具体证据。例如，对假设的评价可以分别检查是否与已有证据矛盾、能否提出可区分的实验预测，以及是否具备验证条件。不同维度应单独报告，避免让语言流畅度掩盖证据不足。

模型评委能够降低开放式评价的成本，但其可靠性需要独立检验。Gu 等的综述讨论了评分一致性、偏差控制以及评委自身的评价方法 [83]。在科学场景中，应使用有专家参照的样本检验评委，并关注选项顺序、答案长度、表述风格与专业细节是否改变判断。多个模型意见一致不能单独证明结果正确，因为它们可能共享偏差。对于可计算的内容，应优先使用独立计算或执行结果；模型评委可辅助处理语义、证据组织及量表映射。

PaperBench 另设评委评价任务来检查自动评分，体现了“对被测系统评分”与“验证评分器”需要分开进行 [71]。本文据此建议，将规则验证、运行检查、专家审查和模型评分组合为可追溯的过程：每一项分数应能够定位到被检查的输出或证据，而不是只保留一段总体评价。

3.4.4 不确定性、校准与选择性使用

科学预测需要说明何时值得信任。模型给出的置信度与实际正确率相匹配，称为校准；分类任务可通过可靠性图、Brier 分数等方式分析，连续预测则可检查区间覆盖率和区间宽度。LLM 不确定性综述将不同置信估计方法及其局限进行了归

纳 [84]。不过，输出概率、语言化置信表述和多次采样的一致程度并不等价，需要针对实际任务验证。

SciPredict 同时检查实验预测是否正确及模型能否识别可靠预测，展示了平均性能与可靠性判断可能分离 [85]。因此，测评可进一步考察系统在不确定时能否请求信息、转交专家或选择不回答，并报告拒答后覆盖的任务比例与剩余错误率。高拒答率可以降低错误，却可能削弱实际效用；评价需要同时展示二者。这里的单次预测不确定性还应与测评分数的统计不确定性区分，后者关注有限测试样本和重复运行造成的估计波动。

3.4.5 成本、效率与实验安全

科学任务的成本可能主要来自模拟、数据库查询、仪器运行或材料消耗，模型令牌费用只占其中一部分。SimulCost 将物理模拟参数调节中的计算成本纳入评价，并与传统扫描方法比较 [86]。这一设计说明，增加重试次数带来的成功率提升应与全部尝试的成本共同报告。对于相同预算下的比较，可以考察完成任务数、达到目标精度所需资源或单位验证成本对应的有效发现数量。

当系统参与实验建议或操作时，还需评价危险识别、风险判断和不安全行为。LabSafety Bench 覆盖实验室危险识别、风险评估与后果预测等任务 [87]。这类评价为安全推理提供了测试证据，但回答安全题与在真实环境中持续安全操作仍有距离。测评报告应明确是否只验证了文字或图像判断，是否涉及执行层检查，以及哪些异常条件尚未覆盖；安全通过率不能直接写成整个实验系统的安全保证。

3.5 测评协议与结论可信性（如何保证结论可信）

3.5.1 比较条件与基线选择

公平比较需要先明确比较目的。若问题是“哪种模型更适合相同资源下的任务”，应统一数据访问范围、工具、调参和推理预算；若问题是“哪套完整方法最有应用价值”，则可以允许不同工具组合，但需要把额外资源计入成本。固定模型名称而不报告提示、检索库、工具版本和重试策略，难以复现智能体结果。近期智能体综述将评测环境及框架作为独立维度，正是因为环境配置会影响能力的实际表现 [62, 63]。

基线应包含能够检验任务价值的简单方法和领域方法，而不仅是上一代复杂模型。Ahlmann-Eltze 等比较多种基础模型及其他深度学习方法后发现，在其所考察的未见遗传扰动预测设置中，模型未能稳定超过刻意设计的简单线性基线 [88]。这一结果不意味着所有生物基础模型均无效，而是说明新方法的增益需要在明确任务和强基线下成立。任务中若存在不改变状态、预测训练均值、最近邻检索或传统求解器等自然参照，应说明为何纳入或排除。

3.5.2 随机性与统计比较

同一任务在不同运行中可能得到不同结果。采样策略、工具反馈、环境状态和服务端变化都可能引入波动。Song 等专门讨论了语言模型评价中的非确定性，说明单次输出难以刻画模型行为的变异 [89]。Wadi 和 Fredette 提出使用重复采样估计模型表现，为将运行波动纳入评价提供了方法参考 [90]。因此，应分别报告任务之间的差异和同一任务多次运行的差异，并说明重复次数及其资源代价。

统计分析的单位必须与数据生成过程一致。来自同一研究、受试对象或实验批次的多个样本往往相关，不能简单视为完全独立的观测。作为实践建议，模型比较可以在相同任务上计算配对差异，并按独立对象或任务组进行重采样；对于多次运行的数据，应保留任务和运行的层级结构。置信区间应说明估计的是任务总体、给定任务集上的随机运行，还是两者共同引起的不确定性。不能仅凭两个模型各自区间是否重叠判断配对差异是否成立。

多模型、多指标比较还需要控制选择性报告。应预先说明主要指标、次要分析和异常处理规则；不能从大量设置中只选择最有利的结果，也不能剔除无法执行的样本后把剩余样本准确率视为整体能力。对任务失败，应同时报告失败比例和有效输出上的质量。REFORMS 对透明分析和结果报告的要求，为这些实践提供了研究规范基础 [60]。

3.5.3 外部验证与前瞻性验证

内部测试、外部测试与前瞻性验证支持不同强度的应用结论。内部测试关注既定来源和划分下的泛化；外部测试使用不同时间、机构、数据生成流程或对象群体检验可迁移性；前瞻性验证在模型输出被固定后采集结果，减少事后筛选成功案例的空间。对具有资源消耗的发现任务，还需比较模型辅助流程与合理替代流程在相同条件下的效用。

科学模型的参考体系本身也需要验证。模拟环境中的成功首先表示模型适应该环境，真实实验中的表现还可能受到测量误差、设备差异和未建模机制影响。生物医学基础模型的评价讨论强调，任务效用、模型对现象的解释以及可检验性不能混为一谈 [64]。因此，报告应明确结论停留在数据回顾、计算再验证还是独立实验阶段。真实发现的证据积累通常需要时间，不能用一次自动评分替代后续科学验证。

3.5.4 版本管理与可审计报告

测评发布应同时固定数据、划分、模型标识、代码、环境、评分器和运行配置。对持续更新的基准，应提供冻结版本用于复现，并通过新的测试轮次观察泛化；否则同名基准在不同时点可能不再对应同一任务集合。数据污染综述揭示了持续更新的价值，也提示动态评价需要可比较的设计原则 [76]。更新机制应保留任务替换理由、难度变化和分数可比范围，而非只更换题目后延续原排行榜。

一个可审计的科学测评报告应让读者重建“输入—操作—结果—评分”的对应关系。最低信息包括任务定义、样本来源与独立单位、参考依据、评价条件、主要指标、统计不确定性、全部运行成本及失败类型。对于专家或模型评委，还应披露量表、评委配置、验证样本和分歧处理方式。数据或模型因授权限制无法完全公开时，应清楚说明可复现范围与受限部分，避免把部分开放描述为完整复现。

3.6 代表性研究的比较与主题演进

3.6.1 封闭式知识测评正在补充专业任务维度

HLE 和 ChemBench 代表了专家知识测评的两种组织方式：前者通过跨学科高难度问题提高对前沿系统的区分，后者围绕化学知识和推理建立领域比较 [66, 67]。二者提供了可自动化和可重复的入口，但任务仍以给定问题的回答为主。对科学智能研究而言，更有价值的延伸是说明这些成绩与真实任务之间的关系，例如题目中检验的符号理解是否有助于读懂实验条件，知识正确率是否能够预测工具选择和结果解释的成功。

因此，“专业问答得分提升”与“科研能力提升”之间需要额外证据。模型与人类专家的比较也应保留时间、工具和题目范围等条件。跨学科题集中的平均专家表现不一定对应某一细分领域专家的上限，单次人机比较不能无条件推广为全

面的专家替代。将能力主张限制在被测试的对象和条件内，可以使知识基准继续发挥作用，同时避免对其解释过度扩张。

3.6.2 科学预测测评转向任务相关指标与条件泛化

材料、分子与细胞研究呈现出共同变化：平均预测精度开始与下游决策、科学约束和未见条件分别讨论。Matbench Discovery 将材料筛选目标与评价指标对应；PoseBusters 检验几何相似之外的物理合理性 [68, 81]。这两类研究提示，应检查指标优化是否真正改善目标研究步骤，并保留对结果有效性的独立验证。

在单细胞扰动预测中，简单基线比较、零样本表征评价和跨细胞背景测试提供了互补证据。线性基线研究检验复杂模型的增益，PertEval-scFM 聚焦基础表征的可迁移用途，较大范围的方法比较则检验新扰动和新情境下的表现 [88, 91, 92]。它们不能被压缩成一张脱离设置的模型排名。更合适的综合方式是分别记录训练条件、适配方法、留出单位和评价指标，识别哪些能力已经得到支持、哪些结论仍依赖特定数据。

物理与气象评价具有类似需求。The Well 提供多种时空动力学任务，WeatherBench 2 则强调统一预报评价框架及基线数据 [82, 93]。本文据此认为，跨领域通用性应通过多种任务分别建立，而不能仅依靠将所有误差压缩为一个总数。变量尺度、预报时效和参考系统不同，都会影响误差的实际意义。

3.6.3 智能体测评从任务产物扩展到证据生成过程

ScienceAgentBench、PaperBench 和 FIRE-Bench 对研究活动进行了不同程度的展开。前者关注具体科学数据分析任务能否完成，PaperBench 聚焦既有研究复现，FIRE-Bench 进一步要求从研究问题出发形成由实验支持的结论 [70–72]。这种变化使评价能够观察实验设计、执行和解释之间的衔接，但测试范围仍受到参考研究、工具环境和预算的约束。复现、再发现与原创发现应作为不同目标报告。

领域工作流研究能够补充通用智能体基准的不足。Liu 等围绕单细胞组学建立 50 项真实分析任务和多维指标，并区分结果一致性与生物学指标 [94]。其意义在于将可执行程序进一步连接到领域结果。评价中的过程信息应优先使用实际工具调用、执行日志、中间产物和来源记录；模型生成的计划或推理说明可以辅助分析，但其表述不能单独证明操作已发生或推理具有因果忠实性。

3.6.4 可靠性与资源约束成为科学效用的一部分

SciPredict、SimulCost 和 LabSafety Bench 分别将预测可靠性、模拟成本和实验风险纳入测试 [85–87]。这些工作扩大了测评的解释范围：即使系统有时能得到正确结果，仍需要知道它能否识别失败风险、需要付出多少资源，以及是否满足使用约束。面向实际部署的比较，应按任务目标联合展示这些因素，不宜用增加尝试次数后的最高成功率替代完整效用评价。

表 3.2 汇总部分代表性研究的方法贡献及解释边界。表中不汇总模型得分，因为各研究的数据、模型版本和执行条件不同，横向拼接原始数值不能形成公平比较。

表 3.2 代表性研究对科学测评设计的启示

研究	年份及来源	主要测评对象	关键方法问题	解释边界
ChemBench[66]	2025 Nature Chemistry	化学知识与推理	领域问题与专家参照	答题能力与实验执行不同
Matbench Discovery[68]	2025 Nature Machine Intelligence	稳定晶体筛选	指标对应筛选目标	计算稳定性不保证可合成性
PertEval-scFM[91]	2025 ICML	单细胞基础表征	零样本与分布变化	结论依赖适配和测试设置
ScienceAgent Bench[70]	2025 ICLR	科学数据分析	程序与执行结果验证	单项任务完成不等于全流程自主研究
PaperBench[71]	2025 ICML	论文复现	分层量表与评委检验	复现能力不等于原创能力
FIRE-Bench[72]	2026 ICML	已知科学结论再发现	实验与结论证据对应	已知发现的可控近似
SciPredict[85]	2026 ICML	实验结果预测	准确性与校准	已发表结果预测仍需独立外部验证
SimulCost[86]	2026 ICML	物理模拟参数调节	成功率与工具成本	效用取决于模拟器和预算

3.7 主要不足与研究方向

3.7.1 建立能力主张与验证证据的对应关系

当前研究中，一个常见问题是测评名称涵盖的能力范围大于实际证据范围。解决这一问题需要在设计阶段写明能力主张，并逐项对应可观测任务、评分依据和外推条件。Zhou 等关于任务需求和能力画像的研究为这种对应提供了测量思路 [80]。在科学领域，还应继续研究哪些题目或任务特征与实际科研表现相关，并通过外部数据检验，而不能仅由设计者命名能力维度。

3.7.2 在开放发现任务中保留可检验性

原创科学问题往往没有即时可用的标准答案。若完全依赖专家印象或模型评委，可能把合理表达误判为有效发现；若只使用已知结果，又会限制对新颖性的评价。FIRE-Bench 选择已知结论再发现，为可验证研究任务提供了可操作的折中 [72]。未来可将评价分为假设质量、证据获取、独立验证和后续复现等阶段，并明确每一阶段尚不能证明的内容。本文建议对新颖性、科学正确性和实际效用分别收集证据，避免用一项综合主观评分同时代表三者。

3.7.3 改善测评数据与评分器的共同治理

随着任务生成和自动评分增加，数据生成器、被测模型和评分模型之间可能形成共享偏差。后续研究应检查生成任务的覆盖差异、错误参考的传播，以及评委在不同专业和输出形式下的稳定性。污染控制与评委可靠性研究分别处理了测试信息独立性和评分可信性问题 [76, 83]，二者需要在完整测评流程中结合。动态基准也应保留可审计版本和长期比较机制，使更新后的结果仍可解释。

3.7.4 评价人机协作与真实实验收益

科研中的许多系统承担辅助角色，其价值可能表现为减少专家时间、降低重复操作、提高候选验证效率或帮助识别失败条件。面向这些用途，未来可以在固定任务和资源条件下，比较人类独立、模型独立与人机协作的结果，同时记录人工纠错和监督成本。这是本文提出的评价方向，不能由现有单模型基准分数直接推导。与自主实验室研究衔接时，测评章节应给出成本、风险、失败恢复和外部验证的判断方法；设备集成及闭环控制实现则属于具体实验系统研究。

3.8 结论

科学智能测评的核心，是为明确的科学能力主张建立与之相称的证据。测试数据只有与任务定义、参考依据、评分方法和运行协议共同设计，才能支持可信判断。本文梳理表明，知识问答、科学预测、工作流执行及发现导向任务分别需要不同验证方式；数据治理质量、测试独立性、科学有效性和结果稳定性也应分别检验。近年来的代表性研究正将评价推进到任务相关指标、未见条件泛化、可执行证据以及成本和可靠性的联合分析。

因此，科学智能测评章节应以测评数据与任务构建、评价方法和可信协议为主体，并通过领域案例说明这些设计如何改变结果解释。写作中应始终保留结论的适用条件：能答对专业问题、能完成特定程序、能复现研究和能产生经独立验证的新发现，分别需要不同证据。只有把这些证据层次说明清楚，测评才能为模型改进和实际科研使用提供可检验的依据。

文献与延伸阅读

以下介绍代表性文献的研究主题与发表信息，完整条目统一列于书末。

- Eriksson 等的综述 [61]：科学智能测评的参考综述。
- Chen 等的数据污染综述 [76]：“污染控制部分的补充综述”。
- ScienceAgentBench、PaperBench 和 FIRE-Bench[70–72]：文献信息注明为会议论文。
- Zhang 和 Li[73]：预印本；2026-10-04 公开，访问日期 2026-10-18。
- Nageshwaran 等 [62]：2026-09-15 提前上线录用稿，访问日期 2026-10-18。
- Saez-Rodriguez 等 [64]：Perspective。
- Shorinwa 等 [84]：2025-09-09 在线发表，访问日期 2026-10-18。

参考文献

[1] DING K, ZHU Z, et al. Bridging data and discovery: a survey on knowledge graphs in AI for science[J/OL]. National Science Review, 2026, 13(8): nwag140. DOI: 10.1093/nsr/nwag140.

[2] CHALK S J. SciData: a data model and ontology for semantic representation of scientific data[J/OL]. Journal of Cheminformatics, 2016, 8: 54. DOI: 10.1186/s13321-016-0168-9.

[3] ZHANG Q, DING K, LV T, et al. Scientific Large Language Models: A Survey on Biological & Chemical Domains[J/OL]. ACM Computing Surveys, 2025, 57(6): 161. DOI: 10.1145/3715318.

[4] The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods[J/OL]. Nucleic Acids Research, 2024. DOI: 10.1093/nar/gkad1004.

[5] BindingDB in 2024: a FAIR knowledgebase of protein-small molecule binding data[J/OL]. Nucleic Acids Research, 2025. DOI: 10.1093/nar/gkae1075.

[6] A review of biomedical datasets relating to drug discovery: a knowledge graph perspective [J/OL]. Briefings in Bioinformatics, 2022. DOI: 10.1093/bib/bbac404.

[7] KEARNES S M, et al. The Open Reaction Database[J/OL]. Journal of the American Chemical Society, 2021, 143: 18820-18826. DOI: 10.1021/jacs.1c09820.

[8] ABEYRUWAN S, et al. Evolving BioAssay Ontology (BAO): modularization, integration and applications[J/OL]. Journal of Biomedical Semantics, 2014, 5(Suppl 1): S5. DOI: 10.1186/2041-1480-5-S1-S5.

[9] GLENNY-PESCOV J, CHUNG C, et al. Advancing the bioassay ontology through integrated PK/PD and safety pharmacology representation[J/OL]. Journal of Biomedical Semantics, 2026, 17: 6. DOI: 10.1186/s13326-025-00342-5.

[10] FU F, LI Q Q, WANG F, et al. Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation[J/OL]. National Science Review, 2025, 12: nwaf271. DOI: 10.1093/nsr/nwaf271.

[11] CHANDAK P, HUANG K, ZITNIK M. Building a knowledge graph to enable precision medicine[J/OL]. Scientific Data, 2023, 10: 67. DOI: 10.1038/s41597-023-01960-3.

[12] iKraph: A comprehensive large-scale biomedical knowledge graph for AI-powered data-driven biomedical research[J/OL]. Nature Machine Intelligence, 2025. DOI: 10.1038/s42256-025-01014-w.

[13] Accessing scientific data through knowledge graphs with Ontop[J/OL]. Patterns, 2021. DOI: 10.1016/j.patter.2021.100346.

[14] PROV-O: The PROV Ontology[EB/OL]. W3C Recommendation, 2013. https://www.w3.org/TR/prov-o/.

[15] RAO J, QIU Y, ZHANG J, et al. SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery[EB/OL]. 2026. arXiv: 2602.09132. https://arxiv.org/abs/2602.09132.

[16] DING K, YU J, HUANG J, et al. SciToolAgent: a knowledge-graph-driven scientific agent for multitool integration[J/OL]. Nature Computational Science, 2025, 5: 962-972. DOI: 10.1038/s43588-025-00849-y.

[17] JIANG Y, LOU W, WANG L, et al. SCP: Accelerating Discovery with a Global Web of Autonomous Scientific Agents[EB/OL]. 2025. arXiv: 2512.24189. https://arxiv.org/abs/2512.24189.

[18] SciGraph-Bio SCP Server[EB/OL]. SCP Hub 官方项目技术文档, 2026. https://scphub.intern-ai.org.cn/detail/38.

[19] HUANG X, LONG Q, DU X, et al. Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale[EB/OL]. 2026. arXiv: 2608.19625v2. https://arxiv.org/abs/2608.19625v2.

[20] FANG Y, LIANG X, ZHANG N, et al. Mol-Instructions: A Large-Scale Biomolecular Instruction Dataset for Large Language Models[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/d346d91999074dd8d6073d4c3b13733b-Abstract-Conference.html.

[21] FENG K, DING K, et al. SciKnowEval: Evaluating Multi-level Scientific Knowledge of Large Language Models[EB/OL]. 2024. arXiv: 2406.09098. https://arxiv.org/abs/2406.09098.

[22] LUO Y, LIU X Y, YANG K, et al. KEDD: Toward Unified AI Drug Discovery with Multimodal Knowledge[J/OL]. Health Data Science, 2024, 4: 0113. DOI: 10.34133/hds.0113.

[23] LUO Y, YANG K, HONG M, et al. Learning Multi-view Molecular Representations with Structured and Unstructured Knowledge[C/OL]//KDD. 2024: 2082-2093. DOI: 10.1145/3637528.3672043.

[24] DAGDELEN J, DUNN A, et al. Structured information extraction from scientific text with large language models[J/OL]. Nature Communications, 2024, 15: 1418. DOI: 10.1038/s41467-024-45563-x.

[25] MO B, YU K, KAZDAN J, et al. KGGen: Extracting Knowledge Graphs from Plain Text with Language Models[C/OL]//NeurIPS. 2025. https://neurips.cc/virtual/2025/poster/117386.

[26] VAN WEESEP L, TEDOLDI R, et al. Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?[EB/OL]. 2026. arXiv: 2610.01616. https://arxiv.org/abs/2610.01616.

[27] SOMAN K, ROSE P W, et al. Biomedical knowledge graph-optimized prompt generation for large language models[J/OL]. Bioinformatics, 2024, 40: btae560. DOI: 10.1093/bioinformatics/btae560.

[28] LUO L, LI Y F, HAFFARI G, et al. Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/3e2aeb66481dd63a32421bf032b70384-Abstract-Conference.html.

[29] LUO L, ZHAO Z, HAFFARI G, et al. Graph-constrained Reasoning: Faithful Reasoning on Knowledge Graphs with Large Language Models[C/OL]//Proceedings of Machine Learning Research: Vol. 267 ICML. 2025: 41540-41565. https://proceedings.mlr.press/v267/luo25t.html.

[30] DENG Y, ERICKSEN S S, GITTER A. Assay2Mol: Large Language Model-based Drug Design Using BioAssay Context[C/OL]//EMNLP. 2025: 27337-27362. https://aclanthology.org/2025.emnlp-main.1390/.

[31] MATSUMOTO N, MORAN J, CHOI H, et al. KRAGEN: a knowledge graph-enhanced RAG framework for biomedical problem solving using large language models[J/OL]. Bioinformatics, 2024, 40: btae353. DOI: 10.1093/bioinformatics/btae353.

[32] MATSUMOTO N, CHOI H, MORAN J, et al. ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning[J/OL]. Bioinformatics, 2025, 41: btaf031. DOI: 10.1093/bioinformatics/btaf031.

[33] HUANG K, CHANDAK P, WANG Q, et al. A foundation model for clinician-centered drug repurposing[J/OL]. Nature Medicine, 2024, 30: 3601-3613. DOI: 10.1038/s41591-024-03233-x.

[34] LEE H, YOO H J, JANG H S, et al. Toward self-driving laboratory 2.0 for chemistry and materials discovery[J/OL]. Materials Horizons, 2026. DOI: 10.1039/D5MH01984B.

[35] PILON S, SAVINO E, BAYLEY O M, et al. A flexible and affordable self-driving laboratory for automated reaction optimization[J/OL]. Nature Synthesis, 2026. DOI: 10.1038/s44160-026-01053-0.

[36] BENNETT J A, OROUJI N, VELAYATI A, et al. An autonomous lab for data-driven homogeneous catalysis[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-74425-x.

[37] BURGER B, MAFFETTONE P M, GUSEV V V, et al. A mobile robotic chemist[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-2442-2.

[38] SZYMANSKI N J, RENDY B, FEI Y, et al. An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06734-w.

[39] FEI Y, RENDY B, YANG X, et al. Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2604.11957.

[40] SUPONYA A, DI MARE E, RAMÍREZ C, et al. Self-driving lab for the data-driven design of single-chain polymer nanoparticles[J/OL]. Cell Press Blue, 2026. DOI: 10.1016/j.cpblue.2026.100033.

[41] LOH X J. Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery[J/OL]. Macromolecular Rapid Communications, 2026. DOI: 10.1002/marc.70420.

[42] STRIETH-KALTHOFF F, HAO H, RATHORE V, et al. Delocalized, asynchronous, closed-loop discovery of organic laser emitters[J/OL]. Science, 2024. DOI: 10.1126/science.adk9227.

[43] PARK H S, MAZAHERI M, CHOI C, et al. Discovery of tunable and soluble organic emitters for solid-state lasers with a self-driving laboratory[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69233-2.

[44] LEE J, NOH J, LEE H, et al. Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories[J/OL]. InfoMat, 2026. DOI: 10.1002/inf2.70124.

[45] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-1994-5.

[46] SHIBUKAWA R, MATSUDA S, NAKAMURA K, et al. Collecting diverse near-optimal samples via nested Thompson sampling[J/OL]. npj Computational Materials, 2026. DOI: 10.1038/s41524-026-02067-0.

[47] RAPP J T, BREMER B J, ROMERO P A. Self-driving laboratories to autonomously navigate the protein fitness landscape[J/OL]. Nature Chemical Engineering, 2024. DOI: 10.1038/s44286-023-00002-4.

[48] BROOKS C, NOTIN P, ROMERO P A. Learning protein function through autonomous experimental interaction[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.08.14.744985.

[49] HAMEDIRAD M, CHAO R, WEISBERG S, et al. Towards a fully automated algorithm driven platform for biosystems design[J/OL]. Nature Communications, 2019. DOI: 10.1038/s41467-019-13189-z.

[50] COCHRANE R R, DOS SANTOS L V, CAI Y. The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103503.

[51] CHEN J, VOLK M, SHAFAEI S, et al. An AI-powered cloud biofoundry for autonomous biological research[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.30.750244.

[52] KANDA G N, TSUZUKI T, TERADA M, et al. Robotic search for optimal cell culture in regenerative medicine[J/OL]. eLife, 2022. DOI: 10.7554/eLife.77007.

[53] BIELAWSKI K, SRINIVASAN K, GAYLINN N, et al. A Closed-Loop Robot Scientist for Autonomous Biological Discovery[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.11.751076.

[54] LIU S, KAUR N, SONG D H, et al. Self-driving bioprinting laboratories[J/OL]. Biofabrication, 2026. DOI: 10.1088/1758-5090/ae3645.

[55] PITICARI A S, GRIGGS S D, CRAWFORD L, et al. Algorithm-driven, phenotype-directed bioactive molecular discovery[J/OL]. Communications Chemistry, 2026. DOI: 10.1038/s42004-026-02066-8.

[56] RAMADURAI K, BANERJEE A. TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry[J/OL]. npj Drug Discovery, 2026. DOI: 10.1038/s44386-026-00078-x.

[57] XU Y, CUI H, PANG K, et al. LUMI-lab: A foundation model-driven autonomous platform enabling discovery of ionizable lipid designs for mRNA delivery[J/OL]. Cell, 2026. DOI: 10.1016/j.cell.2026.01.012.

[58] SAGMEISTER P, UDEPURKAR A, DEVOS C, et al. Autonomous Lipid Nanoparticle Engineering[J/OL]. ACS Nano, 2026. DOI: 10.1021/acsnano.6c15600.

[59] PANAGIOTAKOPOULOU M, GOREN A, REKER D, et al. Artificial intelligence and machine learning in nanoparticle drug delivery systems[J/OL]. Nature Reviews Bioengineering, 2026. DOI: 10.1038/s44222-026-00495-7.

[60] KAPOOR S, CANTRELL E M, PENG K, et al. REFORMS: Consensus-based Recommendations for Machine-learning-based Science[J/OL]. Science Advances, 2024, 10(18): eadk3452. DOI: 10.1126/sciadv.adk3452.

[61] ERIKSSON M, PURIFICATO E, NOROOZIAN A, et al. Can We Trust AI Benchmarks? An Interdisciplinary Review of Current Issues in AI Evaluation[C/OL]//Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society: Vol. 8. 2025: 850-864. DOI: 10.1609/aies.v8i1.36595.

[62] NAGESHWARAN V, EZEKIEL S, TRAN T T, et al. Large language model agent evaluation and benchmarking: a systematic survey, meta-taxonomy, and critical research roadmap [J/OL]. Artificial Intelligence Review, 2026. DOI: 10.1007/s10462-026-11678-4.

[63] YEHUDAI A, EDEN L, LI A, et al. A Survey on Evaluation of LLM-based Agents[C/OL]// Findings of the Association for Computational Linguistics: ACL 2026. 2026: 26690-26714. DOI: 10.18653/v1/2026.findings-acl.1330.

[64] SAEZ-RODRIGUEZ J, SCHÄFER P S L, KALAVROS N, et al. Benchmarking biomedical foundation models[J/OL]. Nature Methods, 2026, 23: 1724-1733. DOI: 10.1038/s41592-026-03182-y.

[65] ZHENG T, DENG Z, TSANG H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 17733-17750. DOI: 10.18653/v1/2025.emnlp-main.895.

[66] MIRZA A, ALAMPARA N, KUNCHAPU S, et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists[J/OL]. Nature Chemistry, 2025, 17: 1027-1034. DOI: 10.1038/s41557-025-01815-x.

[67] Center for AI Safety, Scale AI, HLE Contributors Consortium. A benchmark of expert-level academic questions to assess AI capabilities[J/OL]. Nature, 2026, 649: 1139-1146. DOI: 10.1038/s41586-025-09962-4.

[68] RIEBESELL J, GOODALL R E A, BENNER P, et al. A framework to evaluate machine learning crystal stability predictions[J/OL]. Nature Machine Intelligence, 2025, 7: 836-847. DOI: 10.1038/s42256-025-01055-1.

[69] ZENI C, PINSLER R, ZÜGNER D, et al. A generative model for inorganic materials design [J/OL]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[70] CHEN Z, CHEN S, NING Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/f12b4df26344f3be803c06b555252efe-Abstract-Conference.html.

[71] STARACE G, JAFFE O, SHERBURN D, et al. PaperBench: Evaluating AI's Ability to Replicate AI Research[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 56843-56873. https://proceedings.mlr.press/v267/starace25a.html.

[72] WANG Z, BAI F, LUO Z, et al. FIRE-Bench: Evaluating AI Agents on the Rediscovery of Scientific Insights[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 124896-124929. https://proceedings.mlr.press/v306/wang26d.html.

[73] ZHANG K, LI Y. Are We Measuring Scientific Intelligence? Rethinking the Evaluation of AI Scientists[EB/OL]. (2026-10-04)[2026-10-18]. https://arxiv.org/abs/2610.04915.

[74] JOERES R, BLUMENTHAL D B, KALININA O V. Data splitting to avoid information leakage with DataSAIL[J/OL]. Nature Communications, 2025, 16: 3337. DOI: 10.1038/s41467-025-58606-8.

[75] JOERES R, BLUMENTHAL D B, KALININA O V. Addendum: Data splitting against information leakage with DataSAIL[J/OL]. Nature Communications, 2026, 17: 1597. DOI: 10.1038/s41467-025-67495-w.

[76] CHEN S, CHEN Y, LI Z, et al. Benchmarking Large Language Models Under Data Contamination: A Survey from Static to Dynamic Evaluation[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. 2025: 10080-10098. DOI: 10.18653/v1/2025.emnlp-main.511.

[77] SUN Y, WANG H, LI D, et al. The emperor's new clothes in benchmarking? A rigorous examination of mitigation strategies for LLM benchmark data contamination[C/OL]// Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 57728-57753. https://proceedings.mlr.press/v267/sun25t.html.

[78] WANG H, LI H, KO B, et al. On the fragility of benchmark contamination detection in reasoning models[C/OL]//International Conference on Learning Representations. 2026. https://proceedings.iclr.cc/paper_files/paper/2026/hash/a3860475ddbfb8c644c43f0dcd266b66-Abstract-Conference.html.

[79] WHITE C, DOOLEY S, ROBERTS M, et al. LiveBench: A challenging, contamination-limited LLM benchmark[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/e4a46394ba5378b3f9a186a5b4c650d1-Abstract-Conference.html.

[80] ZHOU L, PACCHIARDI L, MARTÍNEZ-PLUMED F, et al. General scales unlock AI evaluation with explanatory and predictive power[J/OL]. Nature, 2026, 652: 58-67. DOI: 10.1038/s41586-026-10303-2.

[81] BUTTENSCHOEN M, MORRIS G M, DEANE C M. PoseBusters: AI-based docking methods fail to generate physically valid poses or generalise to novel sequences[J/OL]. Chemical Science, 2024, 15: 3130-3139. DOI: 10.1039/D3SC04185A.

[82] OHANA R, MCCABE M, MEYER L, et al. The Well: a Large-Scale Collection of Diverse Physics Simulations for Machine Learning[C/OL]//Advances in Neural Information Processing Systems 37, Datasets and Benchmarks Track. 2024. DOI: 10.52202/079017-1430.

[83] GU J, JIANG X, SHI Z, et al. A survey on LLM-as-a-judge[J/OL]. The Innovation, 2026, 7(6): 101253. DOI: 10.1016/j.xinn.2025.101253.

[84] SHORINWA O, MEI Z, LIDARD J, et al. A Survey on Uncertainty Quantification of Large Language Models: Taxonomy, Open Research Challenges, and Future Directions[J/OL]. ACM Computing Surveys, 2025, 58(3): 63. DOI: 10.1145/3744238.

[85] SEHWAG U M, LAU E, OSKOUIE H E, et al. SciPredict: Can LLMs Predict the Outcomes of Scientific Experiments in Natural Sciences?[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 108784-108827. https://proceedings.mlr.press/v306/sehwag26a.html.

[86] CAO Y, LAI S, HUANG J, et al. SimulCost: A Cost-Aware Benchmark and Toolkit for Automating Physics Simulations with LLMs[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 11206-11254. https://proceedings.mlr.press/v306/cao26g.html.

[87] ZHOU Y, YANG J, HUANG Y, et al. Benchmarking large language models on safety risks in scientific laboratories[J/OL]. Nature Machine Intelligence, 2026, 8: 20-31. DOI: 10.1038/s42256-025-01152-1.

[88] AHLMANN-ELTZE C, HUBER W, ANDERS S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines[J/OL]. Nature Methods, 2025, 22: 1657-1661. DOI: 10.1038/s41592-025-02772-6.

[89] SONG Y, WANG G, LI S, et al. The Good, The Bad, and The Greedy: Evaluation of LLMs Should Not Ignore Non-Determinism[C/OL]//Proceedings of NAACL-HLT 2025, Volume 1: Long Papers. 2025: 4195-4206. DOI: 10.18653/v1/2025.naacl-long.211.

[90] WADI D, FREDETTE M. A Monte-Carlo Sampling Framework For Reliable Evaluation of Large Language Models Using Behavioral Analysis[C/OL]//Findings of the Association for Computational Linguistics: EMNLP 2025. 2025: 9414-9432. DOI: 10.18653/v1/2025.findings-emnlp.500.

[91] WENTELER A, OCCHETTA M, BRANSON N, et al. PertEval-scFM: Benchmarking Single-Cell Foundation Models for Perturbation Effect Prediction[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 66633-66677. https://proceedings.mlr.press/v267/wenteler25a.html.

[92] WEI Z, WANG Y, GAO Y, et al. Benchmarking algorithms for generalizable single-cell perturbation response prediction[J/OL]. Nature Methods, 2026, 23: 451-464. DOI: 10.1038/s41592-025-02980-0.

[93] RASP S, HOYER S, MEROSE A, et al. WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models[J/OL]. Journal of Advances in Modeling Earth Systems, 2024, 16: e2023MS004019. DOI: 10.1029/2023MS004019.

[94] LIU Y, ZHOU L, DU X, et al. Benchmarking LLM-based agents for single-cell omics analysis[J/OL]. Genome Biology, 2026, 27: 123. DOI: 10.1186/s13059-026-03998-z.

[95] TOM G, SCHMID S P, BAIRD S G, et al. Self-Driving Laboratories for Chemistry and Materials Science[J/OL]. Chemical Reviews, 2024. DOI: 10.1021/acs.chemrev.4c00055.

[96] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06792-0.

[97] SZYMANSKI N J, RENDY B, FEI Y, et al. Author Correction: An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2026. DOI: 10.1038/s41586-025-09992-y.

[98] ZHANG T, LIN H, CHEN Y, et al. SALSA: a low-cost self-driving lab modular add-on for salt solubility assessment for battery electrolytes[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00516G.

[99] ALLU S G, HASNAIN R, VOS A, et al. AI-driven approaches for navigating battery complexity[J/OL]. EES Batteries, 2026. DOI: 10.1039/D6EB00101G.

[100] VOLK M, KAUSHIK PILLALAMARRI V, GUO R, et al. Artificial intelligence tools for enzyme engineering and metabolic engineering[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103522.

[101] OATMAN H R, LAD B C, NGUYEN L, et al. An optogenetic smart microscopy platform reveals signaling dynamics-dependent control over collective cell migration[J/OL]. Cell Systems, 2026. DOI: 10.1016/j.cels.2026.101674.

[102] HWANG J, KIM S, LIM S, et al. Self-driving laboratories in Korea: a new era of autonomous discovery[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D6DD00024J.

[103] ZHU Q, ZHANG F, HUANG Y, et al. An all-round AI-Chemist with a scientific mind [J/OL]. National Science Review, 2022. DOI: 10.1093/nsr/nwac190.

[104] FENG S, MA R, et al. InternAgent-1.5: A Unified Agentic Framework for Long-Horizon Autonomous Scientific Discovery[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2602.08990.

[105] ADESIJI A D, WANG J, KUO C S, et al. Benchmarking self-driving labs[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00337G.

[106] CANTY R B, ABOLHASANI M. The past, present and future of self-driving laboratories [J/OL]. Nature Reviews Chemistry, 2026. DOI: 10.1038/s41570-026-00847-2.

[107] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for scientific data management and stewardship[J/OL]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.

[108] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for datasets[J/OL]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.

[109] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J/OL]. Patterns, 2023, 4(9): 100804. DOI: 10.1016/j.patter.2023.100804.