第一章　科学知识建模与大模型推理

学习目标：理解结构化记录、本体与知识图谱的分工，能够组织保留实验条件和来源的科学知识，并评价其在检索、推理和候选设计中的作用。
先修知识：科学数据组织与大语言模型基础。

摘要

科学数据进入大模型的上下文，并不意味着模型已经获得了可用于科学判断的知识。文献、专业数据库和实验记录常用不同方式描述同一对象，也可能省略结果成立的条件。科学知识建模的任务，是明确研究对象、实验过程、测量结果及其依据，并用可计算的形式表达它们的关系。本文以小分子药物研发为重点，梳理结构化记录、领域本体、知识图谱和大模型辅助抽取等主要方法，比较代表团队的研究进展，并讨论建模后的知识如何支持检索、关系推理和分子设计。现有研究已经证明这些方法能够改善数据组织和部分下游任务，但实验条件的完整表达、跨来源一致性和真实实验验证仍是主要限制。

1.1　科学知识建模的定义与范围

科学知识建模定义为，把科学资料中的研究对象、过程、观测、结论及其依据，用含义明确、相互关联、可以计算和追溯的形式组织起来。它既规定数据怎样记录，也说明不同记录有什么关系，以及这些关系在什么条件下成立。这是本文采用的工作定义，主要参考《Bridging data and discovery》（National Science Review，2026）[1] 和 SciData（Journal of Cheminformatics，2016）[2]。

前一篇综述讨论科学知识图谱怎样组织资料，并与大模型共同支持科学任务。后一篇论文提出科学数据的表示框架，把数据与研究对象、方法和条件一起描述。两篇文章的关注点不同，但都强调不能把科学数据与产生它的背景分开。

比如，在小分子药物研发中，化合物、样品、蛋白和细胞都是研究对象。合成、纯化和生物测定是研究过程。光谱和活性测量是观测结果。要判断一个化合物是否具有某种作用，就需要把对象、过程和结果联系起来，并保留实验条件。

科学知识建模与知识图谱有关，但范围更大。数据模式规定记录的字段和结构，本体规定概念及关系的含义，知识图谱保存具体对象及其联系。关系表、JSON记录、图谱和文件索引都可以承载建模结果。知识图谱是其中一种重要表示，不能代替全部原始数据，也不能代替领域定义。

它也不同于分子表示学习。分子指纹、分子图和向量表示主要编码分子结构或相关特征。科学知识建模还需要回答某个样品怎样制备、在哪种体系中测量、结果由谁报告，以及原始证据在哪里。文本向量可以帮助找到相关段落，但向量距离本身不说明两条活性记录能否比较。

大模型出现后，这项工作的目标增加了新的要求。模型不仅要找到资料，还要把资料用于解释、比较和提出研究建议。因此，外部知识需要能够按问题返回，并保留条件和来源。同时，大模型也成为整理文献和补充元数据的工具。下文先通过两篇综述说明这些变化，再讨论具体方法。

1.1.1 从科学数据走向科学知识

Ding 等的 Bridging data and discovery: a survey on knowledge graphs in AI for science（National Science Review，2026）[1] 系统梳理了科学知识图谱的定义、构建方法、应用和局限。

这篇综述把科学知识图谱理解为具有明确科学含义的实体和关系网络。作者特别强调来源、实验条件、定量属性及外部数据的联系。比如，分子图中的节点和边主要表示原子和化学键，而科学知识图谱还会连接化合物、实验、靶点和论文。前者描述分子结构，后者描述不同研究记录之间的知识，两者可以共同使用。

该综述把图谱的作用归纳为知识组织、知识嵌入、推断和可解释性 [1]。知识组织让分散资料能够被统一查找。知识嵌入把图中的结构和语义转成模型可学习的表示。推断根据已有关系寻找新的联系。可解释性则让研究人员检查结果涉及哪些对象和证据。这个分类也说明，建图只是开始，图谱的价值最终要通过使用任务体现。

在表示方式上，这篇综述特别区分了科学数据本身与解释数据所需的知识。分子结构、光谱或显微图像可以保留各自的表示，图谱通过对象标识把它们与实验、性质和文献连接起来。这样，模型既能找到某个对象的数值特征，也能知道这些特征来自哪次测量。时间信息则用于区分不同版本的报道和认识变化。作者讨论的是一种可扩展的组织方式，并没有要求把所有文件内容都拆成三元组 [1]。

在应用上，综述覆盖药物开发、组学分析、化学反应和材料设计。不同领域共享身份对齐、来源管理和关系查询等问题，但需要的科学对象不同。药物研究常连接化合物、靶点与疾病，反应研究还要表示反应条件和催化剂。本文据此采用的阅读顺序是，先看研究任务，再看数据模式，最后看模型如何使用。综述提供了这个比较框架，具体系统是否有效仍要看各自的实验 [1]。

1.1.2 大模型带来了什么变化

从发展过程看，该综述梳理了早期科学数据目录、语义网与本体、机器学习表示，以及近年的大模型辅助发现 [1]。这些做法持续共存。今天使用大模型，仍需要数据库标识、领域模式和质量检查。变化主要在于模型可以帮助读取大量文字，也可以把自然语言问题转成检索、计算和工具调用。

Scientific Large Language Models: A Survey on Biological & Chemical Domains（ACM Computing Surveys，2025）[3] 从科学大模型的角度讨论了同一问题。

这篇综述梳理了科学文本、分子、蛋白质和生物序列等数据表示及相关模型。它帮助我们分清两类目标。一类是让模型学会科学对象的表示和任务规律，另一类是让模型在回答时访问可更新、可追溯的外部知识。前者常涉及预训练或指令微调，后者常涉及数据库、图谱和检索增强。

这篇科学大模型综述进一步说明，科学信息进入模型有不同方式。文本可以直接表示研究描述，分子可以写成 SMILES 或表示为图，蛋白质则可以用序列等形式表达。不同输入需要相应的编码和训练任务。研究者还需要安排科学对象与文字之间的对应关系，否则模型即使分别读懂两种输入，也未必知道文字描述的是哪个对象 [3]。

1.2 为什么需要科学知识建模

1.2.1 数据能够读取并不代表含义已经统一

首先，同一对象在不同来源中可能有不同名称。比如，同一个化合物可能以系统命名、项目编号或数据库标识出现。相似名称又可能对应不同盐型、立体异构体或样品批次。如果不先确认对象身份，系统可能漏掉属于同一对象的信息，也可能把本应区分的记录错误合并。

ChEMBL（Nucleic Acids Research，2024）[4] 提供了一个具体例子。它的数据库论文介绍如何把分子、实验、靶点、活性结果与文献组织成可以持续维护的资源。

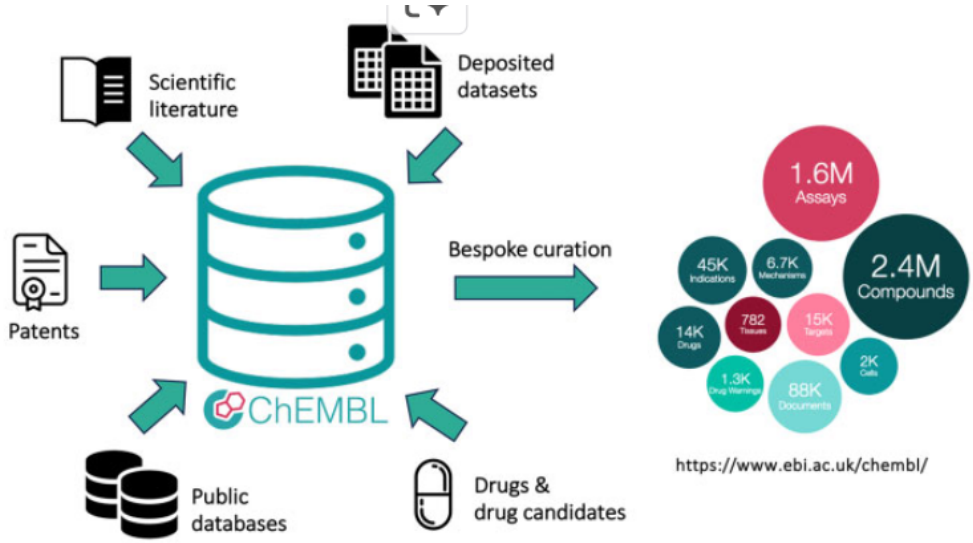


图 1.1 ChEMBL 的数据来源与生物活性数据组织 [4]。

这篇论文中的 ChEMBL 覆盖多种生物活性数据，既有从文献人工整理的记录，也有外部机构提交的数据。建模时，化合物、测定和靶点分别具有标识，一条活性记录将它们联系起来。实验描述用于说明怎样测量，活性类型、数值和单位用于说明测量结果。论文还介绍了蛋白变体、体内实验分类等整理工作。这些细节使使用者能选择所需的数据子集，而不是只按化合物名称汇总所有数值 [4]。

比如，为模型准备某个靶点的活性数据时，可以先确定靶点及其变体，再选取相应实验与结果，最后保留文献和实验标识。对 LLM 系统，更合适的输出是带实验背景的记录。

BindingDB（Nucleic Acids Research，2025）[5] 更集中地讨论蛋白与小分子的实验结合数据。与覆盖多种活性类型的资源相比，它把定量亲和力及其出处放在更突出的位置。

这篇论文说明，数据库通常按一篇论文或一份专利组织一个条目，同一条目中的数据往往来自相同机构和相近的测量流程。记录关联蛋白、配体、亲和力类型与数值，并提供文献或专利出处。该次更新报告约 290 万条结合测量和 130 万个化合物，专利整理是数据增长的重要来源 [5]。

按原始文献组织数据，对比较同一系列化合物尤其有用。论文指出，同一方法和实验室内测得的相对亲和力，可能比跨方法比较的绝对数值更稳定。因此，建立模型数据集时可以保留条目归属，用于检查实验来源差异。BindingDB 解决了重要的结构化整理问题，但不同测量类型和实验条件仍需要使用者进一步判断 [5]。

1.2.2 科学结果依赖实验条件

其次，科学结果需要结合实验条件理解。比如，我们想知道某个化合物是否容易溶于水。查资料时发现，两份实验记录给出的溶解度差别很大。进一步查看才发现，一次是在水中测量，另一次是在乙醇中测量。因为使用的溶剂不同，这两个结果不能直接用于判断哪份数据有问题，也不能都用来回答它是否容易溶于水。因此，记录溶解度时，除了化合物名称、数值和单位，还需要保存溶剂、温度等实验条件。大模型拿到这些信息后，才能选出与问题相关的记录，再进行比较和解释。

药物数据综述 A review of biomedical datasets relating to drug discovery: a knowledge graph perspective（Briefings in Bioinformatics，2022）[6] 也讨论了这一问题。

这篇综述从知识图谱角度梳理药物发现相关数据资源，并讨论如何表达定量信息和实验背景。对本文的问题，它提醒我们，建模不能只把文字改成简单的实体关系。比如，精确测得的活性值、低于检测限的结果、没有检测到作用，以及尚未做过实验，是不同情况，应当分别记录。

这篇综述还讨论了构建知识图谱时如何选择和组织数据。作者整理了基因与蛋白、疾病、药物等数据源，并比较已有图谱收录了哪些对象和关系 [6]。这些比较提醒我们，建图时需要根据研究问题决定保留哪些信息。比如，如果只想查找某个蛋白有哪些已知抑制剂，可以记录化合物与蛋白之间的抑制关系。如果还想比较这些化合物的抑制效果，就需要进一步保存测量结果和实验条件。只记录“是否抑制”，无法支持后面这些判断 [6]。

综述没有主张用一个大图解决所有药物问题。它提出图谱组成、定量信息、数据偏差和评价方式等挑战。对团队而言，可以先根据任务选择资源，再核对关系含义、更新频率和使用条件。图谱规模较大只说明收集了较多信息，不能单独说明更适合某项预测或推理任务 [6]。

1.2.3 模型的回答需要能够核查和更新

最后，模型的回答需要能够核查。比如，模型说某个化合物的活性更好时，研究人员应能找到支撑比较的实验、数值和原始出处。旧结果被修订后，也应能查到哪些记录和回答受到影响。具有稳定标识和版本的外部记录可以被单独检查和更新，因此能为模型提供可追溯的依据。

这里也应保留一个边界。不是所有任务都需要复杂图谱。如果问题只涉及单篇论文的摘要，文献检索可能已经足够。如果任务需要跨数据库连接对象、比较实验或检查多步关系，明确的数据模式才更有价值。建设方式应由任务决定，而不应由节点数量或图数据库产品决定。

1.3 现有研究怎样组织科学知识

《Bridging data and discovery》（National Science Review，2026）[1] 将科学图谱的建设分为数据获取、知识抽取、整合与表示、动态维护，并另外讨论评价。图 1.2 给出了这一过程。数据库记录、论文和多模态资料可以共同进入系统。抽取后的实体还要进行身份对齐，记录也要匹配领域概念。新论文和修订信息进入后，图谱仍需要更新。

同一综述也指出，抽取方式不只包括大模型。规则和词典适合定义明确的术语，领域模型适合相对固定的标注任务，大模型更容易处理变化较多的自然语言[1]。实际建设常把这些方法组合起来，再由专家检查重要字段。因此，方法选择应先回答记录需要表达什么，再决定怎样把原始内容转成记录。

1.3.1 用结构化记录保存一次实验

第一类方法以实验记录为中心。它把样品、方法、条件、测量结果和来源分别记录，再通过标识关联。一个化合物可以有多个样品，一个样品可以参加多次实验，一次实验可以产生多个结果。这样既能保留重复测量，也能避免把不同实验的条件与数值错误配对。

SciData（Journal of Cheminformatics，2016）[2] 提出了通用科学数据框架，讨论怎样把数值与研究背景共同保存。

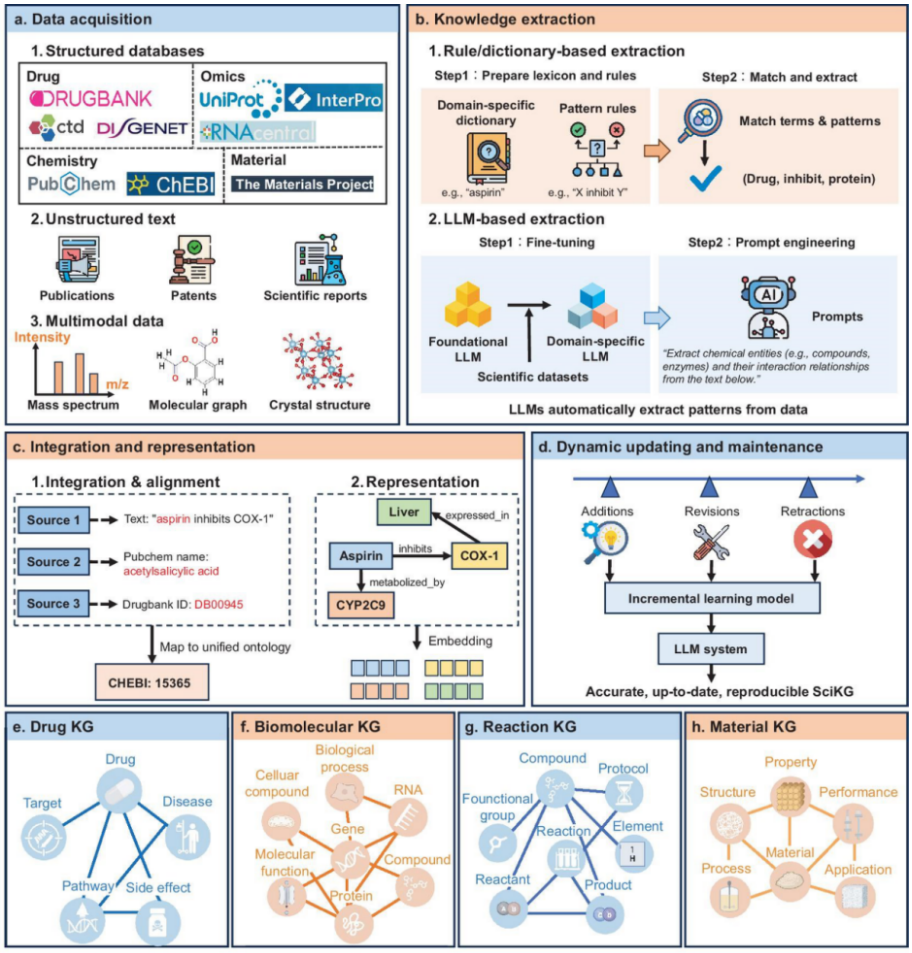


图 1.2 科学知识图谱的构建过程。

小贴士（图 1.2：科学知识图谱的构建过程）

上半部分说明来源、抽取、整合与维护，下半部分列出药物、生物分子、反应和材料等图谱类型。读图时应关注各步骤怎样保留含义与来源。

原图出处 Ding 等，National Science Review，2026，Figure 4。原文注明部分图标来自 BioRender。论文原文。许可 CC BY 4.0。

这篇论文把研究方法、研究系统和数据集组织在一起，并用 JSON-LD 说明字段含义。比如，一个测量值不仅有数值和单位，还需要关联它描述的对象及测量方法。这种表示适合跨来源交换数据，也方便系统判断字段的含义。

具体来说，SciData 把描述研究方法的 methodology、描述研究对象及条件的 system，以及承载数据的 dataset 组织在同一框架中。单个数据点可以保留数值、单位和相关属性，连续测量则可以组织成数据系列。JSON-LD 中的上下文把字段名对应到明确的概念标识。这样，两个文件即使采用不同的本地命名，仍有机会依据共同定义理解字段，而不只靠字符串相似性匹配 [2]。

原论文展示了溶液 pH、文献中的折射率和柠檬烯核磁共振谱等例子。核磁谱需要保存一组对应的数据系列，并关联样品和测量背景。它不能被一条简单的分子属性关系完整替代。对小分子研发，这一思路适合组织仪器文件与测量结果。论文的主要贡献是表示方法及示例，并没有评价大模型回答效果。

Open Reaction Database（JACS，2021）[7]，也就是 ORD，进一步面向化学反应设计了具体的数据模式。

这篇论文介绍了反应记录模式、校验工具、数据仓库和提交界面。记录分为标识、输入、装置、条件、备注、观察、后处理、结果和来源九个主要部分。与 SciData 相比，ORD 更直接地面向一次反应实验，便于保存反应物、操作条件和结果之间的对应关系。

ORD 的输入记录还会继续细分。一个输入可以包含多个组分，每个组分有身份、用量和反应角色。结果记录则连接产物与分析数据。模式采用 Protocol Buffers 定义对象和字段，配套程序检查必要字段、数据类型和部分数值合理性。比如，百分数写成小数时可能产生歧义，校验程序会给出提示。字段之外仍可保存自由文本，以容纳暂时无法标准化的实验细节 [7]。

作者强调，ORD 首先描述实验室里实际做过的操作，而不是理想化实验步骤。它也允许不同完整程度的记录，文献整理可能只有输入与产出，实验者直接提交则可以保留更多细节。因此，符合 ORD 格式只能说明记录满足相应结构要求，不能证明信息完整或反应一定可复现。对大模型系统，这种模式的价值是提供稳定的读取对象，使检索和计算能够明确地指向一次反应。

1.3.2 用本体统一概念并表达分类条件

第二类方法解决记录中的词究竟是什么意思。BioAssay Ontology（Journal of Biomedical Semantics，2014 医学 SCI IF 11+ 1 区）[8]，也就是 BAO，是生物测定领域的代表工作。

这篇 BAO 论文介绍了生物测定本体的模块、整合方式和应用。它把实验体系、方法、研究对象、检测方式和结果终点等概念分别描述。比如，两项实验都使用细胞，但检测方法可能不同。通过分别记录这些概念，系统就能按明确条件分类，而不必只依赖笼统的实验名称。

BAO 2.0 把概念拆成生物测定、实验中的生物学对象、被测实体、方法、实验体系和结果终点等主要部分。比如，细胞实验描述的是体系，荧光描述的是检测方式，半数抑制浓度描述的是结果终点。这几个维度可以共同描述一次实验，却不能互相替代。把它们分别建模后，检索器就能区分使用相同检测技术的不同实验，也能找到用不同技术研究同一生物过程的实验 [8]。

论文的另一个重点是模块化。术语、逻辑公理和外部本体映射分别维护，再组合成可使用的本体。这样既能复用外部生物学概念，也能减少外部资源变化对核心定义的影响。对数据团队，这意味着本体建设包含持续的定义管理。把模型抽出的名称贴上一个标签只是起点，还需要检查标签是否符合实验含义 [8]。

BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 进一步把本体扩展到药代、药效和安全药理。图 1.3 是这篇论文中的一个例子。

这篇论文既扩展了领域概念，也展示了怎样依据逻辑定义对实验分类。比如，图中的 BCRP 抑制实验与方法、细胞系、物种、实验体系和底物相连。some 和 only 表示本体中的逻辑限定，不表示实验频率或置信度。图中描述的是一类实验，而不是某次真实实验的完整记录。

本体的作用也不仅是提供标签。BAO 更新（Journal of Biomedical Semantics，2026）[9] 展示了依据已定义的逻辑条件，将符合要求的实验自动归入通透性或主动外排等类别。这属于基于明确公理的分类推理。它与大模型生成一段解释不同，判断能否成立取决于输入事实和逻辑定义是否正确。

这次 BAO 更新针对药物研发中的具体实验扩展概念，并通过数据库、术语生成和外部本体导入等步骤维护本体。图 1.3 中的转运体抑制实验说明，系统需要同时知道实验研究的过程、采用的体系和相关参与物，才能给出有依据的分类。只出现某个蛋白名称，并不足以判断实验属于哪一类 [9]。

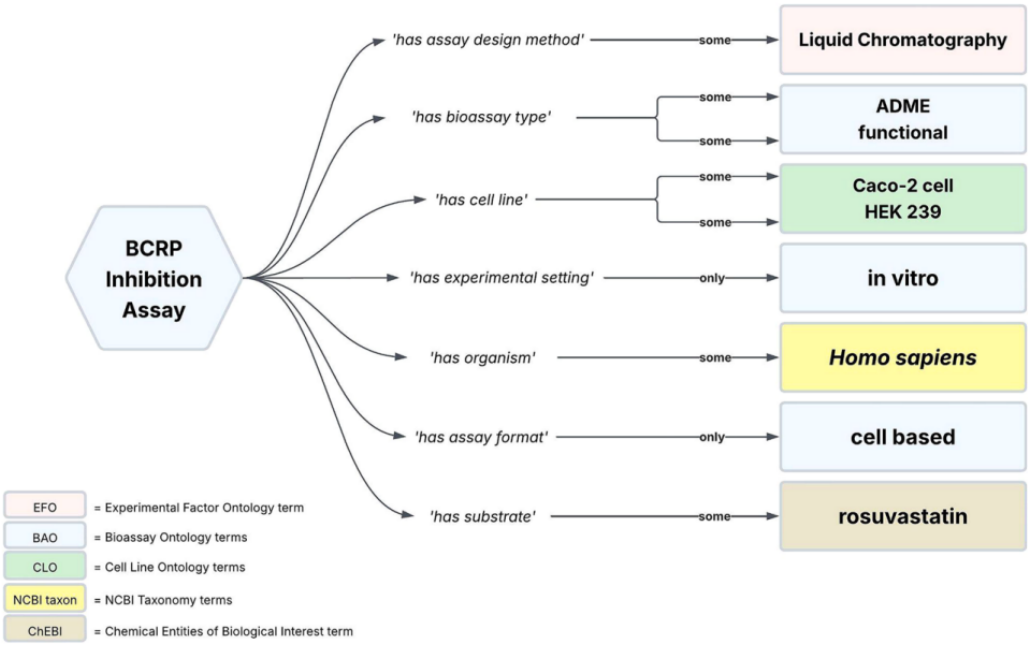


图 1.3 BAO 怎样描述一种生物测定。

小贴士（图 1.3：BAO 的生物测定表示）

图中把 BCRP 抑制实验与方法、细胞和底物等概念关联，说明本体除了统一名称，也可以表达实验类别的逻辑条件。

原图出处 Glenny-Pescov 等，Journal of Biomedical Semantics，2026，Figure 6。论文原文。许可 CC BY-NC-ND 4.0。

它与大模型辅助标注可以配合使用。模型从实验描述中提出候选概念，本体提供概念定义和关系限制，审核人员再检查文本是否支持这些标注。这是本文根据两类方法归纳的使用方式，并非本体论文已经实现完整的自动建库系统。逻辑分类可以发现部分不一致，但无法替代缺失的实验事实。

1.3.3 用知识图谱连接对象和过程

第三类方法把不同记录连接成知识图谱。在药物领域，常见对象包括化合物、靶点、疾病和通路。但若研究问题涉及活性比较或合成条件，实验、反应和测量也需要成为独立对象。否则，一条简单的关联很难表达它出现于哪次实验，以及有哪些适用限制。

Cat-KG（National Science Review，2025）[10] 提供了一个以反应为中心的建模例子，图 1.4 展示了它的数据模式。

这篇论文把反应作为独立对象，将反应物、产物、催化剂和溶剂连接起来，并分别保存属性。这样，系统既能查到哪些物质参与反应，也能查到相关条件。论文随后利用这些记录推荐接力催化路线，第 1.5.1 节会详细说明。这里需要注意，原模式面向热催化，其字段不能直接当成所有药物合成任务的标准。

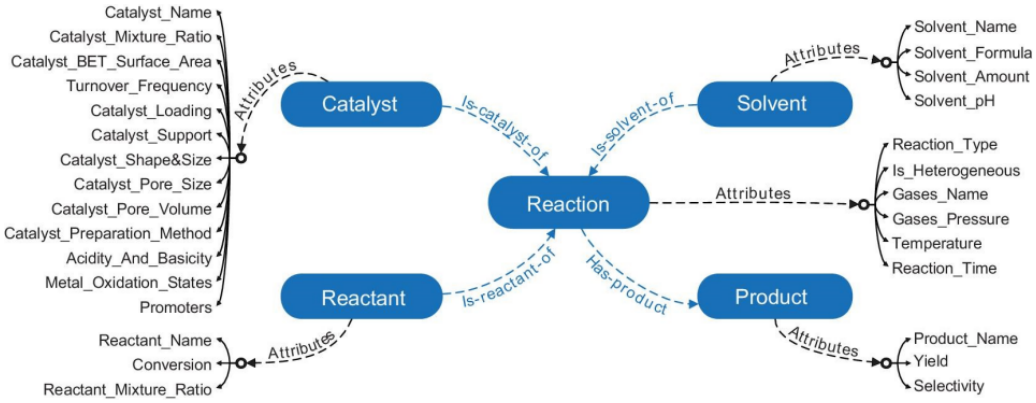


图 1.4 Cat-KG 的反应数据模式。

小贴士（图 1.4：Cat-KG 的反应数据模式）

原文用五类核心对象和 29 项属性描述催化反应。它说明科学图谱可以把一次过程及其参与对象共同建模，而不仅保存反应物与产物之间的联系。

原图出处 Fu 等，National Science Review，2025，Figure 2。论文原文。许可 CC BY 4.0。

PrimeKG（Scientific Data，2023）[11] 展示了怎样把多个专业数据库组织为一个生物医学知识图谱。

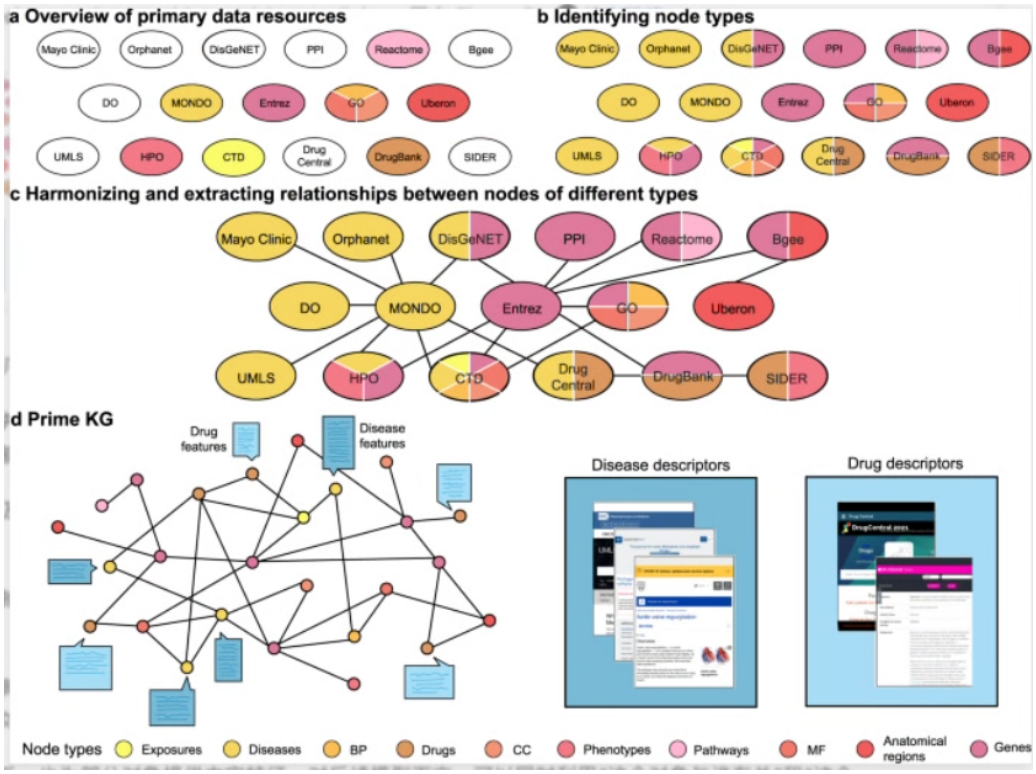


图 1.5 PrimeKG 的数据来源、节点类型与知识整合 [11]。

这篇论文由 Chandak、Huang 和 Zitnik 完成。作者整合 20 个来源，构建包含 129,375 个节点和约 405 万条关系的图谱，连接药物、疾病、蛋白、通路和表型。图谱还区分适应证、禁忌证等关系，并保留临床文本描述。它适合跨来源关联查询，但不能据此假定每条药物关系都包含完整实验条件。

PrimeKG 的重点是把不同来源中的对象映射到共同标识，再形成有类型的关系。例如，疾病的分子信息、表型和药物信息原本属于不同数据库，统一后可以围绕疾病查询相关对象。药物适应证与禁忌证使用不同关系表达，避免把意义相反的联系合并为笼统的药物疾病关联。作者同时发布构建所需的数据处理材料，使研究者能够理解图谱由哪些资源组成 [11]。

从使用方式看，PrimeKG 适合作为图学习和跨来源查询的数据基础。它的主要产物是整合后的数据资源。对小分子研发，可以在这类图谱中寻找药物、靶点

和疾病的研究背景，再回到具体活性数据库与原论文核查实验。临床关系、文献关联和测量证据属于不同层次，不宜放在同一可靠性等级下使用。

iKraph（Nature Machine Intelligence，2025）[12] 则研究怎样把文献抽取结果与数据库记录放入同一个图谱。

这篇论文从 PubMed 摘要中抽取生物医学实体和关系，再结合 40 个数据库及基因组资料，并研究间接关系推断。它说明，文献中尚未进入标准数据库的信息也可以被组织起来。其抽取过程包含专门的实体与关系模型，因此不能把全部工作都称为生成式大模型建图。

iKraph 把文本中的提及转成可识别的实体，再判断实体之间的关系。因此，两个名称在同一篇摘要出现，并不自动成为一条有意义的关系。系统还整合数据库记录和从高通量基因组数据得到的关系，使文献知识与其他证据能够共同查询。作者用人工标注比较信息抽取表现，并研究图谱对间接关系发现的支持 [12]。

1.3.4 保留来源并组合多种存储方式

这些表示方式可以共同使用。比如，论文和仪器文件可以保存在文件系统中，数值和实验字段可以保存在关系表中，图谱表达跨对象联系，文本索引定位相关段落。统一标识让它们相互对应。Ontop（Patterns，2021 cell 子刊）[13] 的科学数据访问研究给出了一个例子。

这篇教程介绍虚拟知识图谱。原始数据仍留在关系数据库中，本体定义对外使用的概念，映射规则说明哪些表、列和连接对应这些概念。用户提交 SPARQL 查询后，Ontop 结合映射和本体生成底层查询，再从数据库读取结果。图谱因此是一种访问和理解数据的方式，不一定是一份另外存储的完整数据副本 [13]。

论文用生物医学数据演示如何配置本体、映射和查询，并说明领域知识如何帮助得到更丰富的结果。对已有多个专业数据库的团队，这条路线允许先统一访问含义，再逐步改进底层数据。它的难点是映射本身需要正确，数据库字段变化后也要维护。若一个库记录的是实验结果，另一个库记录的是预测值，即使字段类型相同，也不能映射成完全相同的含义。

来源信息让不同表示能够回到同一份依据。PROV-O（W3C 技术标准，2013）[14] 是描述数据来源的技术标准。

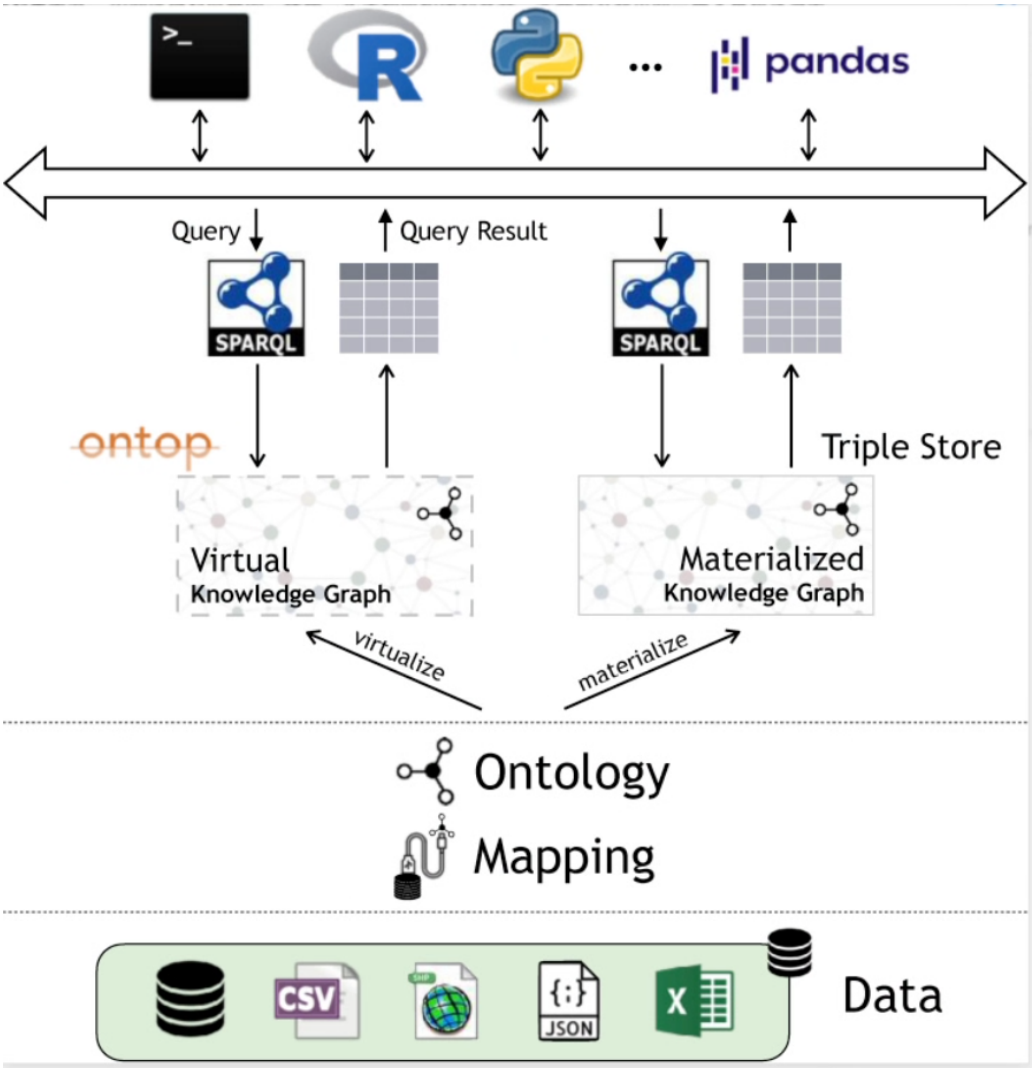


图 1.6 Ontop 的虚拟知识图谱访问方式 [13]。

1.3.5 把数据整理、工具知识和访问接口分别建模

科学知识还包括怎样准备数据、怎样使用工具，以及怎样访问已有资源。相关工作包括 SciDataCopilot（arXiv 预印本，2026）[15]、SciToolAgent（Nature Computational Science，2025）[16]、SCP（arXiv 技术报告，2025）[17] 和 SciGraph-Bio（项目技术文档，2026）[18]。

SciDataCopilot 讨论原始数据怎样整理成适合计算的数据单元。SciToolAgent 把工具的功能、输入输出和依赖建成图谱。SCP 技术报告讨论资源描述和调用方式，SciGraph-Bio 技术文档介绍生命科学图谱的查询服务。它们分别解决数据准备、工具选择和资源访问问题。只有访问接口而没有清楚的数据含义，仍然难以比较跨来源结果。后面会分别展开这些工作。

1.3.6 用 skill 理解和使用一个数据集

Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale（arXiv 预印本，2026）[19] 提出 SciDSK，研究智能体怎样找到并理解科学数据集。

这篇论文把数据集相关知识组织成技能包，原始数据仍保存在原仓库。技能包记录数据身份、版本、科学背景、文件与字段含义、使用步骤、质量检查和来源。模型先根据简短说明选择资源，再读取详细指引。它将数据说明与操作知识放在一起，补充了图谱和查询接口难以单独解决的问题。

SciDSK 具体使用 SKILL.md 作为入口。文件开头的结构化元数据记录名称、简短描述、来源、访问位置和版本等信息，正文再解释数据内容、文件字段、使用步骤、质量检查与引用方式。模型先用简短描述判断是否需要该数据集，选择后才读取完整指引。这种分步读取减少了把全部文档一次放入上下文的需求 [19]。

论文还把技能包与某个数据集快照明确关联。说明文件对应的是哪一版数据，需要单独记录。构建过程中，作者先收集权威数据说明、字段字典和版本资料，再按规定结构整理，并检查说明是否有依据。对药物数据，一个可借鉴的例子是把实验表的样本单位、活性列含义和缺失值处理规则写在数据集说明中。这是应用示例，论文的检索与理解测试没有直接覆盖该药物场景。

这项工作来自中科院计算机网络信息中心和中国科学院大学。2026 年 9 月的修订版报告，数据集检索 Hit@1 为 80.77%，比原始资料条件高 9.62 个百分点。受控理解案例中，技能包满足 24 项检查中的 23 项，网页条件满足 22 项 [19]。结果

支持这种表示帮助寻找和理解数据，但并未证明小分子药物研发任务因此获得改善。

1.4 哪些团队在做以及进展到了哪里

1.4.1 浙江大学知识引擎实验室及相关合作团队

浙江大学陈华钧所在的知识引擎研究团队，与张强、丁克炎等合作者，在科学知识图谱、科学大模型和工具使用方面形成了一组相关工作。《Bridging data and discovery》（National Science Review，2026）[1] 由浙大研究者与上海人工智能实验室等单位合作者共同完成。

在具体系统方面，这个团队的相关工作包括 SciToolAgent（Nature Computational Science，2025）[16]、Mol-Instructions（ICLR，2024）[20] 和 SciKnowEval（arXiv 预印本，2024）[21]。

这三篇论文解决不同问题。SciToolAgent 介绍工具图谱和多步操作的安排，把工具的功能、输入输出和依赖建成图谱。Mol-Instructions 把分子、蛋白质和生物医学文本任务整理为指令数据，用于微调模型。SciKnowEval 从记忆、理解、推理、辨析和应用等层次评估模型能力。因此，它们分别对应工具知识、训练数据和能力评价。

1.4.2 上海人工智能实验室及与浙江大学的合作

上海人工智能实验室的 SciDataCopilot（arXiv 预印本，2026）[15] 直接关注原始实验数据的准备问题。论文提出，科学数据是否可用于 AI，应结合任务意图、科学约束和下游计算要求来判断。这一视角补充了文献知识抽取。谱图、序列或实验矩阵即使可以读取，也不一定已经具备模型需要的样本定义、字段说明和处理记录。第 1.5 节将进一步展开它的表示方式。

SCP（arXiv 技术报告，2025）[17] 关注科学资源怎样被智能体发现和调用。它试图把分散的软件、模型、数据库和实验设备组织为有统一描述的服务。

技术报告采用 Hub、Server 与 Client 的组织方式。Server 说明自己提供什么能力、需要什么参数并负责执行，Hub 维护资源注册信息、实验上下文和任务状态，Client 供研究人员或智能体发起请求。报告还把实验标识、输入输出位置和操作日

志纳入上下文，使多个步骤能够围绕同一次任务工作。这里建模的重点是资源和执行过程 [17]。

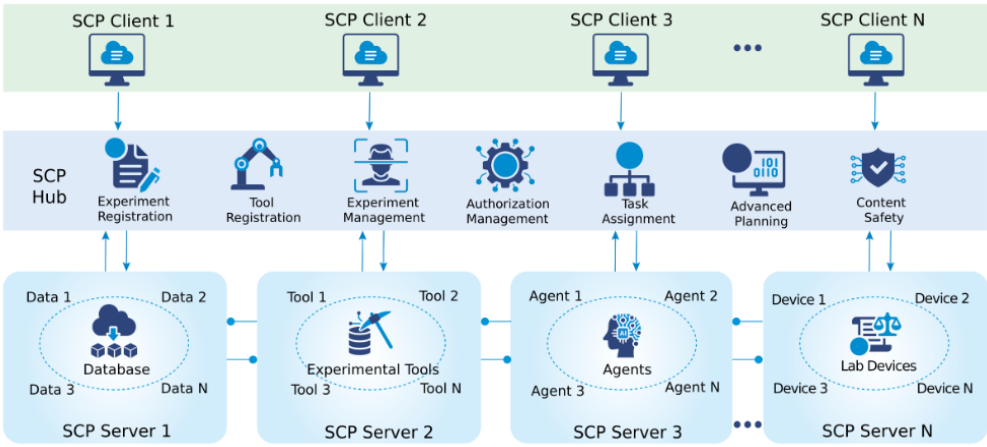


图 1.7 SCP 的 Client、Hub 与 Server 组织方式 [17]。

报告提出用结构化任务图保存操作、参数和先后依赖，并报告系统包含 1,600 多个工具资源。资源数量反映接入范围，不能直接说明这些资源采用了统一化学定义，也不能证明跨实验结论可靠。对小分子团队，SCP 类接口可以承载数据查询和计算服务，但化合物身份、实验条件与证据来源仍需要在服务返回的数据中明确表示。

SciGraph-Bio（项目技术文档，2026）[18] 进一步提供面向生命科学图谱的统一查询服务。它是技术文档，适合了解已有图谱如何开放给智能体调用。

官方页面列出 39 个可查询图谱，并提供图查询、统计、节点类型和关系类型四类工具。节点与关系类型工具可以先告诉调用方某个图谱保存了什么，再据此组织查询。统计工具帮助了解资源范围，图查询工具返回具体记录。页面也致谢浙江大学对整理、部署与发布的支持 [18]。

比如，智能体准备查询某种药物与疾病的联系，可以先检查所选图谱是否具有对应节点和关系，再执行查询。

1.4.3 清华大学、厦门大学与中科院相关团队

清华大学智能产业研究院聂再清、周浩等相关团队关注分子结构、文本和图谱的联合表示。代表工作包括 KEDD（Health Data Science，2024）[22] 和 MV-Mol（KDD，2024）[23]。

KEDD 这篇论文把结构、图谱和文本信息共同用于药物发现任务。MV-Mol 这篇论文进一步研究，同一分子在不同语义视角下应怎样表示。它们说明，建好的知识也可以用来训练分子模型，而不只是在大模型推理时提供文字上下文。第 1.6.4 节会说明这两种使用方式的差别。

厦门大学程俊、王野与爱丁堡大学 Jeff Z. Pan 等人的 Cat-KG（National Science Review，2025）[10]，则把催化领域模式、文献抽取、图查询和规则评分放入同一个系统。其优势是能够清楚观察原始资料怎样变成可操作的知识，以及这些知识如何产生路线推荐。虽然研究对象是热催化，方法对药物合成数据组织仍有参考意义。中科院计算机网络信息中心朱恒术、周园春等人的 SciDSK（arXiv 预印本，2026）[19] 则把数据集的使用知识组织为技能包，强调智能体怎样选择和理解资源。

1.4.4 国际数据资源与领域模型团队

EMBL-EBI 的 ChEMBL（Nucleic Acids Research，2024）[4] 团队持续整理药物样分子的活性数据。其价值在于长期维护分子、实验、靶点和文献之间的对应关系，并向外部提供可查询的数据。这类资源已经支持实际的数据分析与模型训练，但成熟数据库仍会存在条件缺失和记录粒度不一致的问题。它们为大模型提供基础资料，却不会解决跨实验推理。

北佛罗里达大学 Stuart Chalk 提出的 SciData（Journal of Cheminformatics，2016）[2] 关注跨领域数据表达。迈阿密大学 Stephan Schürer 及合作者推进的 BAO（Journal of Biomedical Semantics，2014）[8] 则深入到生物测定的具体概念。BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 与 Pistoia Alliance 牵头的电子实验记录语义整理项目合作，扩展药代、药效和安全药理内容，并展示实验自动分类。这些工作完善了领域概念和记录方式，其成果不能直接换算为大模型问答准确率。

ORD（JACS，2021）[7] 由 Steven Kearnes、MIT 的 Connor Coley 及学术界和企业合作者共同提出，参与单位包括 Relay Therapeutics、MIT、Merck 和 Google 等。其贡献同时包括反应模式、校验工具、数据仓库和提交界面。

1.4.5 自动抽取与知识使用团队

劳伦斯伯克利国家实验室与加州大学伯克利分校的 Dagdelen、Dunn、Jain 等人发表了 Structured information extraction from scientific text with large language models（Nature Communications，2024）[24]，研究大模型能否直接生成科学结构化记录。

这篇论文比较了传统实体与关系抽取，以及用 GPT-3、Llama-2 生成层次化记录的方式，图 1.8 展示了其中差别。比如，模型可以把同一种材料的名称、组成、形态和用途放进同一条 JSON 记录。这样能够保留字段之间的对应关系，减少拆成孤立关系造成的信息损失。

这项研究把抽取任务写成从科学文本到指定输出格式的生成问题，并用标注样本训练模型完成任务。输入是原始描述，输出可以是列表或 JSON 对象。层次化输出允许一个主体同时关联多个属性，也允许不同主体各自保留属性。比如，一段文字同时描述几种材料时，把用途直接放进对应材料对象，比列出所有名称和所有用途更容易检查归属是否正确 [24]。

从药物文献整理的角度，可以借鉴这种记录级输出。模型先形成按化合物或实验分组的候选记录，再由程序检查结构、字段类型和来源是否完整。这里的药物场景属于方法迁移，原论文主要在材料与化学文本任务上评价。生成合法 JSON 只是格式正确，字段有无遗漏、数值是否属于该对象，还需要独立核查。

该研究也给出了清楚的能力边界。在 JSON 输出设置下，Llama-2 对主体材料与掺杂物关系的精确匹配 F1 为 0.821，而对材料化学式与用途关系的 F1 为 0.516[24]。两项任务的内容和难度不同，不能只看一个最高分来判断建库能力。论文证明了结构化抽取的可行性，也说明字段识别、关系归属和完整记录仍需要分别评价。

斯坦福大学 Sanmi Koyejo 等人与多伦多大学等合作者提出了 KGGen（NeurIPS，2025）[25]，探索从普通文本自动生成知识图谱。

这篇论文不仅抽取实体与关系，还通过聚类和去重减少重复实体造成的图谱分散，并用 MINE 评价知识保留情况。它提供了通用建图工具。

KGGen 的流程包括局部抽取、跨文本汇总和实体关系归并。它先从每份文本识别实体，再抽取关系，然后把多份文本的结果合在一起。归并阶段结合向量检索与语言模型判断，寻找同一对象的不同写法，并为含义相同的关系选择较统一的表述。这样可以减少同一个对象分散成多个节点，也避免几乎每条边都有一个独特关系名 [25]。

它的 MINE 评价关注从文本转成图谱后，重要信息是否仍被保留，并另用检索任务检查图谱的可用性。这个设计提醒我们，建图质量不能只看抽出了多少三元组。对化学资料，通用归并方法仍需领域检查。比如，同一母体的盐型可以建立联系，但不应仅因名称相近就把实验样品完全合并。减少重复与保留科学差异需要同时考虑。

阿斯利康 Molecular AI 与乌普萨拉大学、KTH 等团队的 Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?（arXiv 预印本，2026）[26] 更接近小分子数据整理问题。

这篇论文比较七种大模型从 BioAssay 文本中预测和审查实验元数据的表现。作者报告，生化实验和细胞实验格式的召回率至少为 0.96，但稀有类别的分歧更大，参考标签也存在不一致。这支持模型辅助整理，并不说明可以省去审核。该工作为预印本，作者注明获 NeurIPS AIDaR 研讨会录用。

这项生物测定元数据研究分别处理实验体系与物理检测技术，并把模型输出与现有数据库标签比较。作者把这些参考标签视为可能有错误的已有标注，而不是绝对正确的答案。模型与标签不一致时，还通过人工检查分析分歧来自模型、文本信息不足，还是数据库原标签。这个评价方式比只统计模型与数据库一致率更适合数据整理任务 [26]。

因此，论文支持的使用方式是让模型提出候选标注，并把有分歧或少见的类型送去重点审核。对数据团队，最值得借鉴的是同时保存预测类别和判断依据，再按类别检查可靠性。总体表现较高时，少数类别仍可能不稳定。若把模型标签直接覆盖原有标签，就会丢失后续查错所需的信息。

1.4.6 图谱推理与候选设计团队

加州大学旧金山分校 Sergio Baranzini、Karthik Soman 等人与加州大学圣迭戈分校等合作者，基于 SPOKE 生物医学图谱开展了 KG-RAG（Bioinformatics，2024）[27] 研究。

这篇论文讨论怎样围绕问题检索图谱，再选择适合放入大模型上下文的内容。它主要验证生物医学问答。Monash 大学与 Griffith 大学等团队的 RoG（ICLR，2024）[28] 和 GCR（ICML，2025）[29] 则更关注一般知识图谱上的多步推理。

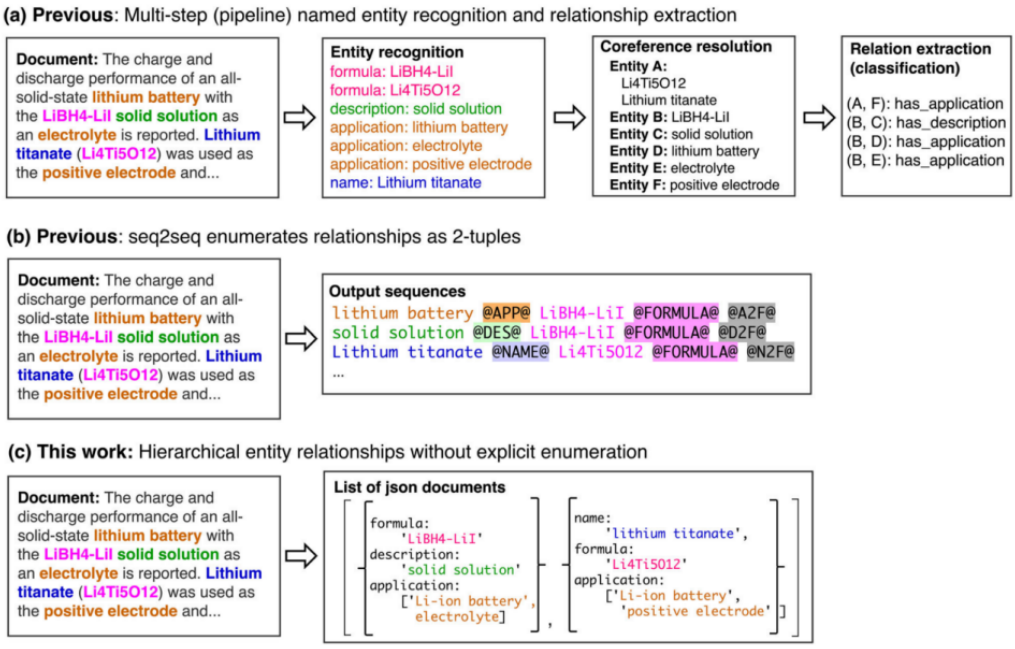


图 1.8 科学信息抽取方式的比较。

小贴士（图 1.8：科学信息抽取方式）

上方先识别实体再抽取关系，中间将关系写成序列，下方直接生成层次化 JSON 记录。本文保留原图全部三个部分，用于说明输出结构本身也是模型设计的一部分。

原图出处 Dagdelen 等，Nature Communications，2024，Figure 1。论文原文。许可 CC BY 4.0。

RoG 这篇论文先生成关系计划，再检索真实路径并组织回答。GCR 这篇论文进一步限制生成过程，使模型只能沿给定图谱中的路径输出。两者主要在通用知识图谱问答任务上验证，不能直接等同于药物实验推理能力。

威斯康星大学麦迪逊分校与 Morgridge 研究所的 Yifan Deng、Spencer Ericksen、Anthony Gitter 团队提出 Assay2Mol（EMNLP，2025）[30]，研究怎样利用生物测定背景指导小分子生成。

这篇论文从 PubChem 检索实验描述和活性记录，为模型提供与新靶点有关的背景及分子示例。它没有把所有资料改成知识图谱，但同样在研究科学数据怎样组织成模型能够使用的输入。其主要证据来自计算评估，仍需要后续合成与活性实验验证。

1.5 怎样把数据变成可用知识

下面选择三个互补案例展开。Cat-KG 最完整地展示领域事实如何建模并用于路线推荐。SciToolAgent 说明工具的使用条件本身也可以成为知识。SciDataCopilot 则回到原始数据，讨论怎样形成适合计算的数据单元。三者回答的问题不同，放在一起更容易看清科学知识建模的范围。

1.5.1 Cat-KG 从催化文献到接力反应路线

Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation（National Science Review，2025）[10] 介绍了 Cat-KG，目标是从分散文献中寻找可以连续完成目标转化的反应。

这篇论文先定义催化领域的数据模式，再从文献抽取记录、建立图谱，最后搜索并筛选反应路线。比如，前一步的产物能够作为后一步的反应物，只说明两步在物质上可以连接。温度、气氛、催化剂和溶剂是否相容，还需要另外检查。图 1.9 展示了论文怎样把这些问题放进同一流程。

在表示上，作者设计了反应、反应物、产物、催化剂和溶剂五类核心对象、四类关系及 29 项属性，具体模式见图 1.4[10]。反应不再只是两个分子之间的一条边，而成为连接参与物与条件的对象。催化剂的制备和表征信息也进入记录。这样，系统才能同时查询反应是否存在和条件是否接近。

把反应作为独立对象后，同一种反应物与产物之间可以保留多条不同条件的记录。比如，同一转化分别使用两种催化剂时，系统不必把温度、收率和催化剂都挤在一条无区别的关系上。它可以先定位具体反应记录，再读取该记录的条件。这是对图 1.4 模式的解释，也说明为什么保存实验过程会直接影响后续路线比较。

在抽取上，作者使用 Gemini 1.5 Flash 处理较长的论文内容，并采用两阶段方式。先获得反应概况，再补充各反应的详细字段。这样做是因为催化剂制备、条件与性能结果常散落在论文不同位置 [10]。模型按指定格式输出 JSON，随后用程序校验、标准化和消除实体歧义，再写入 Neo4j。文献与反应标识让结果可以返回原始来源。

两阶段抽取还有一个实际作用，就是先区分论文中存在的不同反应，再围绕每个反应补齐细节。否则，模型可能从全文找到一个正确的温度和一个正确的收率，却把它们配到不同反应上。原文随后使用规则处理遗漏、重复和格式差异。图谱中的物质名称经过归并后可以用于搜索，反应记录仍需关联具体文献以供核查 [10]。

最终图谱包含 15,881 篇论文中的 27,760 条热催化反应，其中 18,174 条为非均相反应。作者另选 10 条化合物合成路线涉及的 44 个反应，评价抽取结果。平均精确率为 91.49%，召回率为 91.18%，F1 为 0.9113[10]。这支持该抽取方式在所选样本上的有效性，但不是对全部图谱记录逐条验证后的正确率。

在使用上，研究人员给定起点、目标产物和路径长度，系统先执行图查询。以合成气中的氢气和一氧化碳为起点、巴豆醛为目标、最多三步为条件，作者报告一分钟内检索到超过 93,000 条候选路径 [10]。大量路径说明搜索空间需要进一步筛选，不能把候选数量当成有效路线数量。

筛选采用人工设计的规则，分别评价单步反应、相邻反应的匹配和整体路径。图 1.10 展示了温度、压力、气氛、催化剂和溶剂等评分内容。程序排序后，把选出的结构化路线交给 GPT-4 生成说明 [10]。因此，本文的推荐结果来自图谱搜索、领域规则和语言模型的共同作用。图中的期刊影响因子、引用量等也是原作者评分项，但这些信息本身不能证明某个反应可靠。

这里可以把系统的三个判断分别理解。图查询判断记录之间能否按反应物与产物连接。领域规则判断这些组合是否更值得优先考察。大模型把入选路线及其条件转成可读说明。前两个步骤产生的结构化数据及标识会交给模型，因此读者可以沿标识返回原始记录。语言描述即使流畅，也仍需要与这些记录逐项对应 [10]。

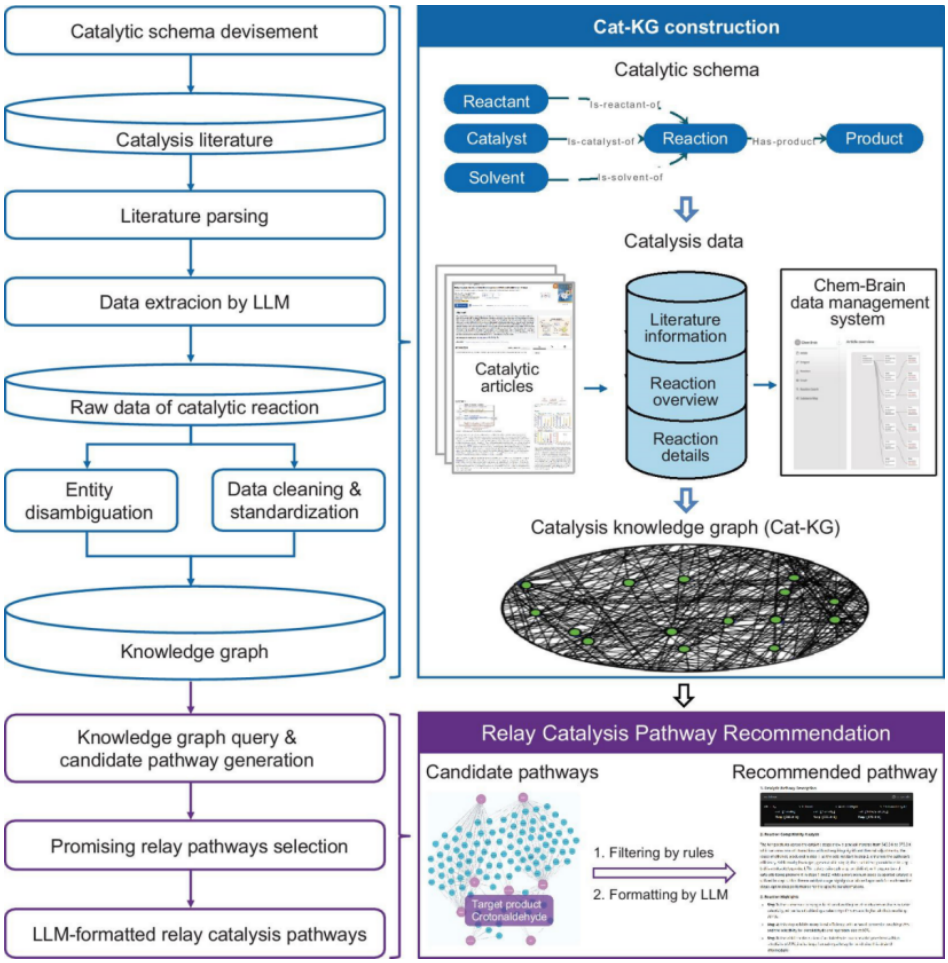


图 1.9 Cat-KG 的完整流程。

小贴士（图 1.9：Cat-KG 的完整流程）

上半部分先规定模式，再抽取、清理和整合文献数据。下半部分先查询候选路线，再按规则筛选，最后由大模型整理说明。

原图出处 Fu 等，National Science Review，2025，Figure 1。论文原文。许可 CC BY 4.0。

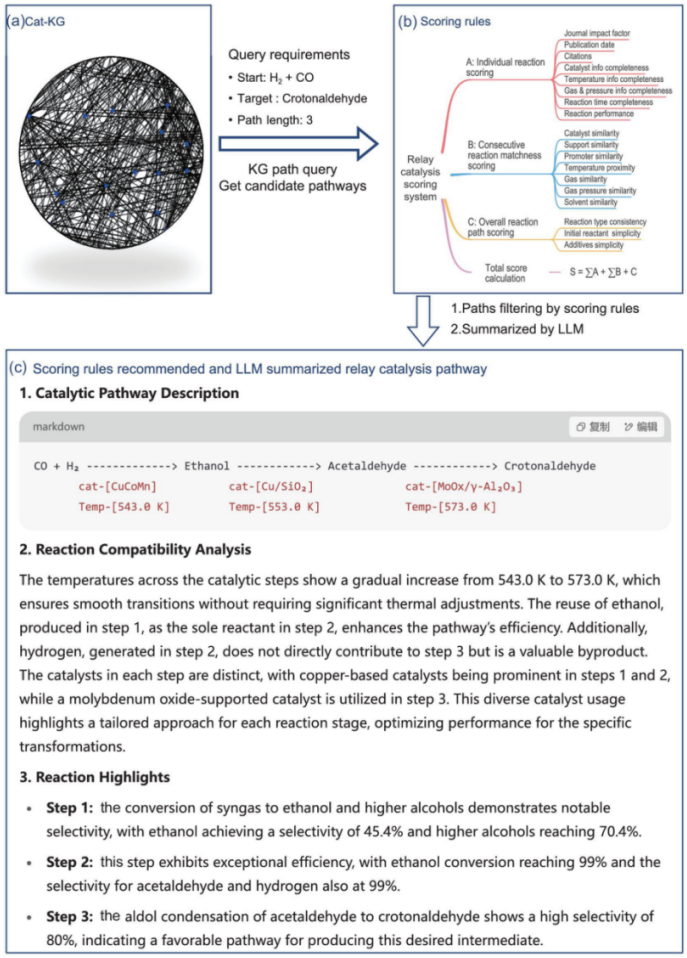


图 1.10 Cat-KG 怎样查询与筛选候选路线。

小贴士（图 1.10：候选路线的查询与筛选）

上方是图查询和规则评分，下方为大模型整理的路线与解释。图中文字中的相容性判断属于系统输出，仍需实验检查。

原图出处 Fu 等，National Science Review，2025，Figure 4。论文原文。许可 CC BY 4.0。

作者用四条已报道的接力催化路线检查系统推荐，并针对十个目标提出二十条此前未报道的路线 [10]。前者表明系统能够找回与已有研究一致的组合思路，但具体条件和催化剂可能不同。后者是待验证建议，不能表述为二十条新路线已经成功完成实验。副产物、催化剂失活和多步动力学等问题仍可能影响实际结果。

因此，阅读结果时应区分抽取评价、搜索评价和实验验证。44 个反应上的 F1 检查的是数据抽取。已报道路线的找回检查的是搜索与筛选能否恢复已有组合。20 条新建议则说明系统能够提出尚待研究的方案。这几项结果对应不同问题，不能合并成一个发现成功率。对拟开展的药物项目，也可以采用这种分层评价方式。

对小分子药物研发，可以借鉴三点。首先，以实验或反应作为独立对象，保留条件。其次，按概况与细节分阶段抽取，减少字段错配。最后，让搜索与计算在明确的数据和规则上执行，再由模型解释结果。这是从该研究得到的方法启发，不能直接把热催化领域的 29 个属性和评分规则照搬到药物合成。

1.5.2 SciDataCopilot 把原始数据组织为可计算的数据单元

SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery（arXiv 预印本，2026）[15] 研究原始科学数据怎样整理成适合下游任务的输入。

这篇论文提出 Scientific AI-Ready 概念，强调数据准备取决于具体任务。作者把知识基础分成数据、工具和案例三部分。一个数据单元限定于一种模态、一个时空范围和一个目标对象，并附上模式、来源、质量和统计等描述。工具记录可以执行的操作，案例记录问题及处理经验。

数据单元可以是一个文件或可定位的数据对象，并不要求把全部内容转成自然语言。系统记录文件位置、模态、字段或张量形状、数据类型、取值范围及缺失情况等说明。工具说明再给出允许的输入输出与运行条件。案例则保存某个问题使用了哪些数据单元、分别怎样处理，以及最后怎样整合。数据、操作与历史经验因此可以被分别检索 [15]。

在执行前，意图理解模块把自然语言要求转成研究对象、变量、限制和任务类型，并检查所需数据是否存在。系统随后参考相似案例制定计划，安排每个数据单元的处理，再确定跨单元的整合方式。处理脚本与摘要也会保存，以便复现和检查。这里的建模同时覆盖数据内容和使用数据的条件，而不只是给文件增加关键词 [15]。

系统安排接入、意图理解、处理和整合等智能体完成数据准备。酶学案例中，作者报告整理了约 21.4 万条酶与反应记录 [15]。论文还在地球科学和神经科学中评价效率，其中最高 30 倍加速来自地球科学案例，不能作为药物数据准备的普遍收益。该工作目前按预印本引用，其贡献是明确数据准备的表示和流程，不能据此认定原始数据已经自动转成经过科学验证的结论。

对小分子项目，可以据此设计一个应用例子。若任务是比较同一批化合物的活性，实验结果表、化合物映射表和实验说明应当作为可定位的数据单元。系统先确认样品能否对应、活性字段代表什么，再决定筛选和整合方式。这个例子是本文对方法的借鉴。原论文的酶学案例支持跨来源数据准备能力，但并未证明所有小分子测定条件都能自动对齐。

1.6 建模后的知识怎样被大模型使用

《Bridging data and discovery》（National Science Review，2026）[1] 进一步区分了知识图谱和大模型的角色。图谱提供事实依据、科学限制和多模态信息的联系。模型提供自然语言访问、分析、假设生成、知识整理及任务安排。

1.6.1 提供带来源的检索上下文

最直接的用途是检索增强。系统先识别问题中的对象，再从数据库或图谱中取出相关记录，最后把必要信息和来源交给模型组织回答。图 1.12 中的 KG-RAG（Bioinformatics，2024）[27] 就是这一方式。图谱承担对象定位和关系查询，模型承担自然语言解释。若问题涉及数值筛选、单位换算或统计比较，则可以由程序执行后再交给模型说明。

这篇 KG-RAG 论文具体从问题中识别疾病对象，并将其对应到 SPOKE 图谱中的节点。随后提取相关图关系及可用的来源信息，把它们转成简短自然语言陈述。系统再比较问题与这些陈述的语义相关性，保留适合当前问题的内容。模型读到的因此是经过选择的局部上下文，而不是整个图谱或全部数据库模式 [27]。

这一步选择同时影响成本与答案。相关性筛选可以减少提示长度，但如果关键信息没有被检索到，后面的模型也无法依据它回答。原文因此分别检查对象识别、上下文检索和最终问答，并与其他检索方式比较。对药物记录，还应加入数值类型与实验条件筛选，因为文字相似并不能代替测量可比性检查。

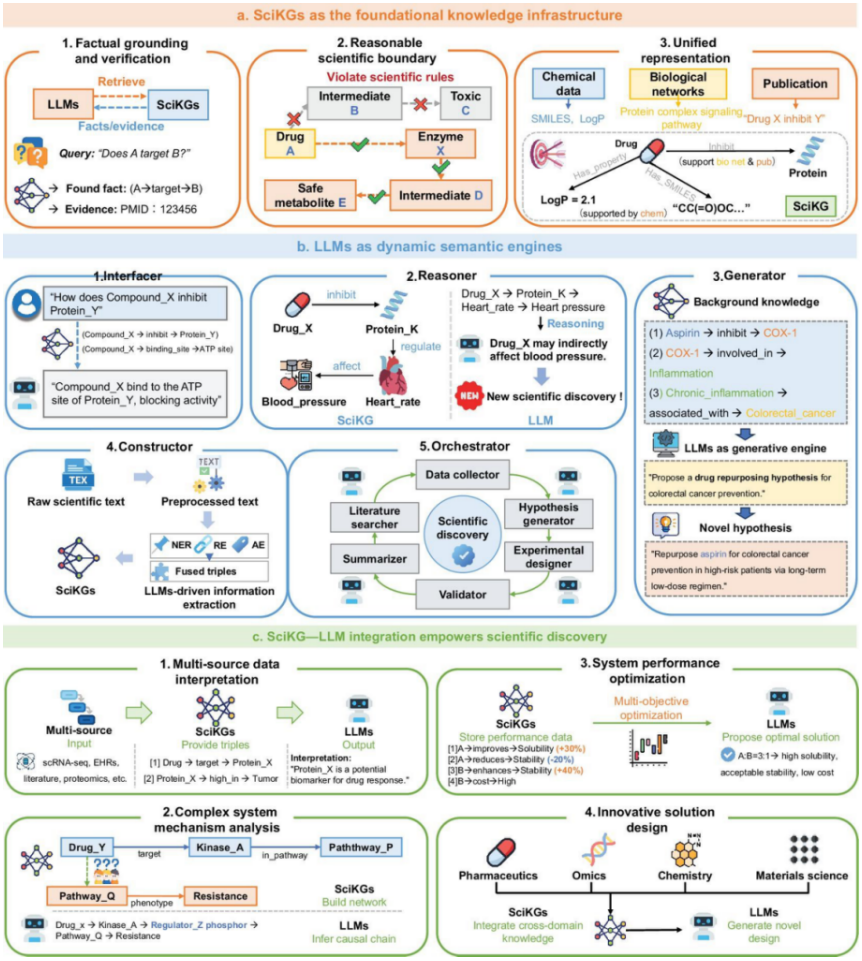


图 1.11 科学知识图谱与大模型的分工。

小贴士（图 1.11：图谱与大模型的分工）

上方为图谱作用，中间为模型角色，下方为资料解释、机制分析、性能优化和新方案设计四类任务。原图中的因果推断与新发现文字应按概念示意理解。

原图出处 Ding 等，National Science Review，2026，Figure 7。论文原文。许可 CC BY 4.0。

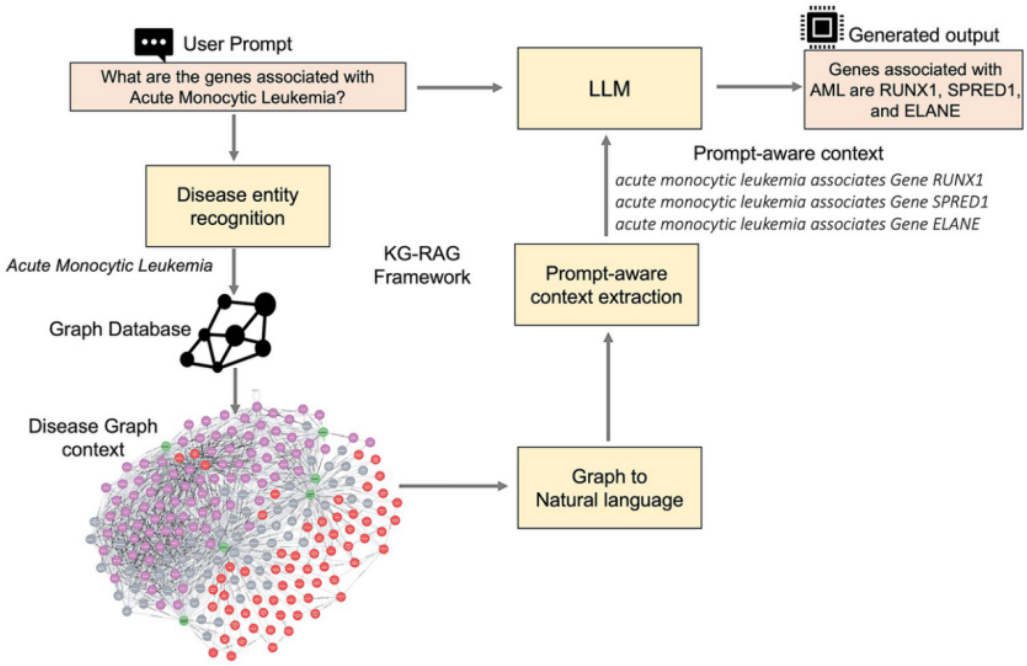


图 1.12 KG-RAG 如何把图谱知识交给语言模型。

小贴士（图 1.12：KG-RAG 的检索与生成）

系统从问题识别疾病对象，检索相关图谱内容，将其转成文字，并选择与问题相关的部分作为上下文。图中为原论文的生物医学问答示例。

原图出处 Soman 等，Bioinformatics，2024，Figure 1。论文原文。许可 CC BY 4.0。

Soman 等人的实验中，GPT-3.5-Turbo 在人工整理的生物医学选择题上的平均准确率由 0.63 提高到 0.79，GPT-4 由 0.68 提高到 0.74[27]。这些结果说明特定图谱上下文对该测试有效，也显示不同基础模型的收益不同。它们不能直接推导出小分子活性比较或机制判断会获得相同提升，因为后者还需要检查实验条件和数值含义。

面向药物项目时，返回给模型的内容应是一组可定位的证据记录。化合物标识、实验体系、结果终点、数值、单位和来源应尽量一起返回。原始条件缺失时，需要明确标记。这样，模型可以说明当前记录是否可比，而不必从一条简化关系中猜测实验背景。

1.6.2 规划并检查多步关系

第二种用途是帮助模型处理多步查询。RoG（ICLR，2024）[28] 先让模型决定需要依次查询哪些关系，再从图谱寻找符合这一计划的真实路径。

这篇论文把关系类型序列作为计划。训练时，作者利用问题对象与答案对象之间的图路径构造监督信号，并同时训练计划生成和基于检索结果回答两种能力。使用时，模型先提出关系计划，系统从问题实体出发执行检索，再把找到的具体对象和关系交给模型生成答案。计划可以复用到不同实体，实际事实则由图谱提供 [28]。

比如，在药物场景中，可以先查询与某靶点有关的化合物，再查询这些化合物的实验记录。这个例子说明如何借鉴关系计划，并不是原论文已经验证了该药物任务。RoG 主要在通用知识图谱问答中测试。它有助于暴露中间查询步骤，但如果问题实体没有正确映射到图谱，或关系本身缺失，计划仍可能无法得到正确答案。

GCR（ICML，2025）[29] 进一步研究怎样在生成过程中直接限制路径，使模型不能随意写出图谱里不存在的连接。

这篇论文把可使用的图路径编码为 KG-Trie，也就是按路径序列组织的前缀树索引。模型生成到某个前缀时，只允许继续选择索引中合法的后续内容。一个较轻量的图谱专用模型负责产生受约束路径，通用大模型再综合多条路径进行回答。作者在知识图谱问答基准上检查效果，并测试对未见图谱的迁移 [29]。

这种方法限制的是给定图谱中的路径合法性。论文所说的消除路径幻觉，应在这个范围内理解。图中的关系若有错误、缺少条件，或者只表示相关性，合法

路径仍不能变成可靠的因果证明。对科学数据，GCR 说明图结构可以进入解码约束，但还需要另外规定哪些类型的证据可以参与某种判断。

Cat-KG（National Science Review，2025）[10] 展示了领域规则参与其中的方式。系统先从反应图谱搜索候选路线，再用人工设计的化学规则评分，最后由大模型把结构化路线和条件转成说明。在这种分工中，语言模型不必独自完成搜索、计算和化学限制判断。图谱及规则提供可执行的操作对象，模型负责整合结果并与研究人员交流。

KRAGEN（Bioinformatics，2024）[31] 研究怎样把图谱检索与问题分解结合起来。

这篇论文先把生物医学图谱中的关系转成自然语言陈述，再建立向量索引用于检索。它结合 Graph of Thoughts 提示方法，把复杂问题分为相关子问题，分别获取依据，最后汇总回答。图界面展示的是问题分解及答案组织过程，使用户可以检查模型引用了哪些知识。它并不要求每一步都直接生成数据库查询 [31]。

比如，寻找同时与两个基因有关的药物时，可以分别取回相关知识，再比较结果。作者在阿尔茨海默病知识库上的测试中，报告两步选择题准确率由 53.1% 提高到 71.8%，但两步判断题仅由 62.4% 提高到 62.9%。结果说明复杂问题分解在部分题型上有帮助。由于图关系被转成文字再检索，事实遗漏和语言整合错误仍可能出现 [31]。

同一研究方向的 ESCARGOT（Bioinformatics，2025）[32] 进一步研究怎样让模型生成可执行代码，并安排图查询和计算。

这篇论文把查询和计算进一步写成可执行的 Python 步骤，再用动态任务图保存步骤及其依赖。一个节点可以执行一段代码，前一步结果能够传给后一步。比如，比较两个查询结果的交集时，可以让程序实际计算，而不是要求语言模型在长列表里自行挑选。作者结合生物医学知识库和推理任务检查这种安排的效果 [32]。

这里有两张作用不同的图。生物医学图谱保存药物、基因等对象及关系，动态任务图保存当前问题要执行什么操作。前者提供数据，后者组织使用数据的过程。这一区分对工程实现很有用。即使代码成功执行，查询条件也可能错误，因此仍要检查模型是否选对关系、输入与计算方式。可执行过程让错误更容易定位，但不能单独保证科学结论正确。

1.6.3 用实验背景指导候选设计

第三种用途是把已有实验转成生成任务的上下文。图 1.13 中的 Assay2Mol（EMNLP，2025）[30] 先根据新靶点检索相关 BioAssay 描述，再利用实验编号取得测试分子与结果。模型随后同时看到研究背景、实验摘要以及有活性和无活性的分子示例。因此，真正起作用的输入不只是分子结构，也包括这些结构是在什么任务中被测试的。

这篇论文保留了 BioAssay 描述与实验结果表之间的编号对应。文本检索先找到可能相关的实验，筛选与整理后，再读取其中被测试分子的结构及活性结果。上下文同时包含有活性和无活性的示例，使模型能够参考已有测定中的差别来生成候选。它利用的是实验描述与定量记录之间的联系，而不只是检索包含靶点名称的段落 [30]。

从建模角度看，这里的关键对象是一次测定及其测试结果。实验描述说明任务背景，实验编号连接结果表，分子结构与结果保持配对。向量索引负责发现相关描述，编号关联负责找到对应数据，两者承担不同工作。原论文说明，即使不预先建设大型知识图谱，也可以通过合理组织实验记录，为大模型设计任务提供更有用的上下文。

在 CrossDocked 测试中，使用 Gemma-3-27B 的 Assay2Mol（EMNLP，2025）[30] 平均 Vina Dock 分数为负 8.064，不使用这一上下文流程的同一模型为负 7.050。该指标通常以更低值表示更有利的对接评分，但它只是计算代理指标，不能当作实验亲和力。论文还讨论了分子尺寸、可合成性和其他性质，因此不能只靠这一项分数评价候选的药物价值。

从这三种用途可以看出，建模结果既可以被转成提示中的文字，也可以成为查询、搜索和计算工具的输入。对 AI 团队，重点是让模型能够可靠地选择并使用这些操作。对数据团队，重点是保证操作返回的内容含义明确、身份一致，而且能回到原始依据。两者需要围绕具体科学任务共同设计。

1.6.4 用知识训练分子模型并调用专门的预测模型

知识还可以进入训练。Mol-Instructions（ICLR，2024）[20] 研究如何把分子、蛋白质和生物医学文本资源转换成大模型能够学习的指令样本。

这篇论文先定义任务，再把已有数据转换成指令、输入和输出。比如，分子性质预测把结构作为输入、性质作为目标，反应任务组织反应物与产物，文本任务

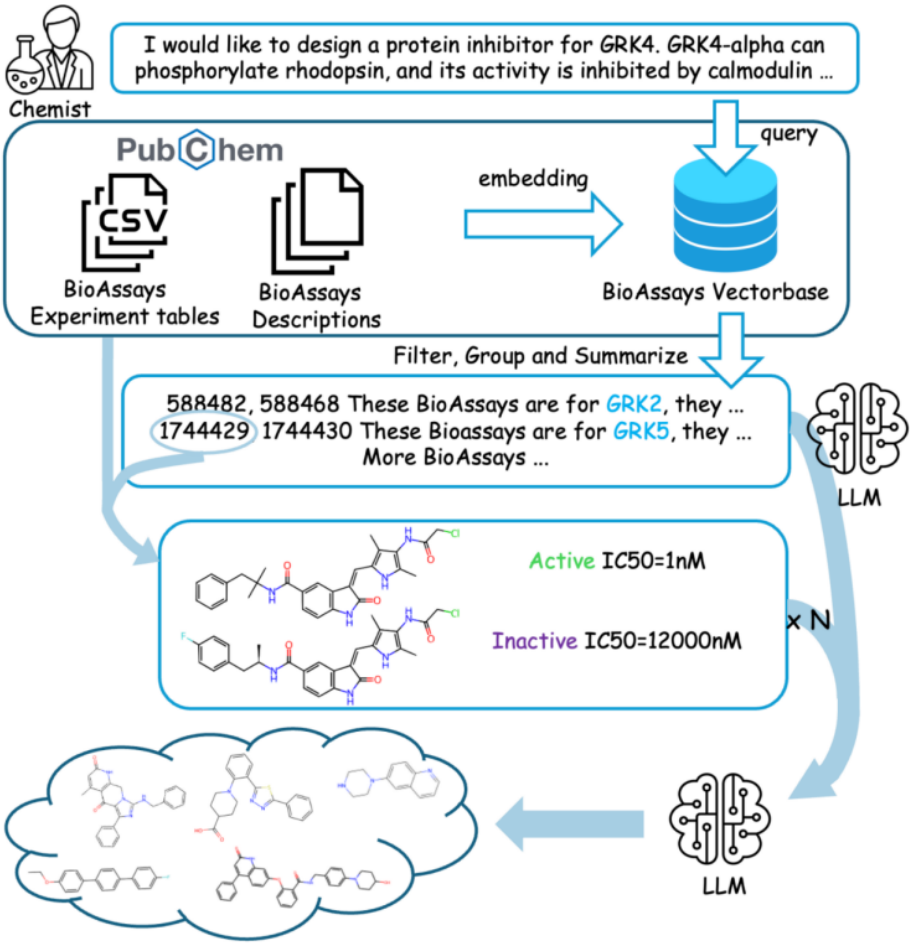


图 1.13 Assay2Mol 如何使用已有生物测定指导分子生成。

小贴士（图 1.13：Assay2Mol 的测定信息）

系统结合实验描述检索、BioAssay 编号、测试分子和活性结果。原图图标来源按原论文标注为Flaticon.com与svgrepo.com。

原图出处 Deng 等，EMNLP，2025，Figure 1。论文原文。许可 CC BY 4.0。

则使用实体或关系标注。作者结合人工设计、模型辅助生成任务描述和模板转换，使相同科学任务能够以多种自然语言方式表达，并通过质量检查控制样本 [20]。

论文用指令微调实验检查这些样本能否改善模型的生物分子任务表现。它提供的主要产物是训练数据及相应模型能力。这里需要保留科学对象与监督目标的对应，但推理时未必还能返回某次原始测定。因此，若任务要求说明证据出处，仍应另外保留训练样本来源或接入外部记录。

KEDD（Health Data Science，2024）[22] 研究的是怎样把分子结构、知识图谱和生物医学文字共同转成预测模型可使用的特征。

这篇论文分别编码不同模态，再将相关表示组合起来完成药物发现任务。它特别考虑新分子缺少图谱关系或文本说明的情况。作者采用多头稀疏注意力，从相关生物分子中寻找可用信息，并在训练时遮蔽部分模态，让模型学习在信息不完整时工作。因此，知识图谱既是额外信息来源，也是帮助补充缺失表示的资源 [22]。

作者在药物与靶点相互作用、分子性质和相关关系预测等任务中评价框架。其结果支持多种知识共同参与学习，但被重建的是模型特征，不是新做出的实验观察。对药物项目，KEDD 适合说明建模后的知识如何改善预测输入。模型获得更好的向量表示，并不意味着每项预测都有一条可直接核查的原始实验记录。

MV-Mol（KDD，2024）[23] 进一步提出，同一分子需要随研究视角形成不同表示。分子的结构没有变化，但研究问题可能关注化学性质，也可能关注生物作用。

这篇论文用文字提示描述视角，并通过融合网络共同读取分子结构和视角信息。训练分为两个阶段。第一阶段把结构与规模较大的文本对齐，学习共同信息。第二阶段使用知识图谱中的关系，把关系描述当作具体视角继续学习。这样既利用文字覆盖面，也利用结构化知识中较明确的关系含义 [23]。

论文用分子性质预测、分子与文本的相互检索及生成任务评价表示效果。它对本文的意义是，建模后的关系可以成为训练时控制信息选择的条件。对于同一个化合物，不必假定一个固定向量能够同样充分地表达全部问题。不过，表示随视角变化依然不能代替真实测量条件，模型性能也应在对应任务上判断。

TxGNN（Nature Medicine，2024）[33] 展示了怎样使用知识图谱训练专门的药物重定位模型。

这篇论文在包含 17,080 种疾病和 7,957 种药物的图谱上学习关系，预测药物适应证和禁忌证，并提供解释性子图。TxGNN 是图学习模型，并非大语言模型，但其预测结果可以作为工具输出供大模型使用。论文中的跨疾病评价和专家分析支持研究用途，候选适应证仍需要后续验证。

TxGNN 重点处理缺少已知治疗药物的疾病。模型利用疾病之间共享的通路、表型和其他生物信息，把相关疾病中的知识用于目标疾病的候选预测。评价因此不只是在随机留出的药物疾病关系上测试，也关注训练中没有相应治疗信息的疾病。这个问题比单纯找回已知药物关系更接近数据稀少疾病的研究需要 [33]。

论文还用解释性子图向专家展示预测涉及的关系，并结合医疗记录与专家评估检查候选结果。解释子图帮助检查模型依据，但不是药物有效性的实验确认。对 LLM 系统，可以把这类专业模型作为候选排序工具，再要求语言模型说明依据与限制。预测分数、图谱关系和实际疗效证据应分别呈现。

1.7 局限性与仍需解决的问题

1.7.1 原始证据不完整会限制一切后续步骤

科学知识建模不能恢复从未记录的条件，也不能自动纠正存在问题的实验。文献通常更容易获得成功结果，失败实验和阴性观察则可能缺失。内部记录的细节较多，但写法和质量未必统一。即使抽取模型完全复述了原文，最终知识仍可能受到原始报道范围的限制。

因此，应把抽取的可靠性与实验的可靠性分别评价。模型准确识别了一个数值，不代表实验已经被独立重复。同一结果被多个数据库收录，也不能自动算作多份独立证据。评价和检索都需要尽量识别这些重复来源。

1.7.2 领域差异很难被一个通用模式完全覆盖

不同实验需要不同的条件描述。比如，BAO（Journal of Biomedical Semantics，2014）[8] 主要讨论生物测定概念，BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 又加入药代和安全药理内容。领域模型因此需要持续修订。跨项目复用时，还要检查概念粒度是否一致，以及旧记录是否需要转换。

多模态资料还会增加记录对应的难度。比如，同一化合物的结构可能在图片中，编号在正文中，活性值在表格中，实验条件又在补充材料中。分别识别这些

内容以后，还要确认它们是否属于同一个样品和同一次实验。现有文本抽取分数不能证明这些对应关系都已重建正确。

1.7.3 图谱路径和语言解释都不等同于科学证据

知识图谱通常擅长表达关联，但关联不必然说明因果。疾病与基因相关、化合物作用于蛋白、某个通路参与疾病，这些信息可以帮助提出假设，却不足以独立证明治疗机制。图约束生成限制了模型怎样沿图取用知识，但不会提高图中事实本身的证据等级 [28][29]。

因此，系统应区分已经报告的实验、对多条记录的综合判断，以及待验证的研究假设。模型生成的解释如果重新写入知识库，也必须保留其来源和推断状态。否则，后续检索可能把上一次生成的文字误认为新的外部证据。

1.7.4 现有评估距离实际研发成效仍有差距

评价时应设置简单而公平的比较方案。在同一批资料、相同基础模型和相近上下文预算下，比较直接文献检索、结构化数据库查询与图谱增强方法。测试资料还应按文献、时间或化合物系列适当划分，避免同一实验的重复收录造成过高估计。只有这样，才能判断改进来自数据整理、更多上下文，还是图结构本身。

《Bridging data and discovery》（National Science Review，2026）[1] 建议分层评价。第一层检查组成过程，例如实体识别、关系抽取和对象对齐。第二层检查图谱本身，例如覆盖、结构及关系预测表现。第三层检查可信程度和实际用途，包括来源、时间信息和下游任务效果。前两层有较高分数，并不自动意味着第三层可靠。

SciKnowEval（arXiv 预印本，2024）[21] 把科学知识能力区分为记忆、理解、推理、辨析和应用，为评价提供了另一个参考。对小分子任务，可以进一步分别测试模型能否找回结果、判断实验是否可比、识别证据冲突，以及调用计算工具完成分析。

这篇论文构建了覆盖生物、化学、物理和材料的约 7 万道问题，并用零样本和少样本方式评价 26 个模型。五个层次分别检查模型是否掌握事实、理解含义、完成推理、辨析问题并应用知识。作者观察到，即使总体较强的模型，在科学推理和应用层面仍有明显改进空间 [21]。

它对知识建模的启发是，不要只用事实问答来证明系统会使用科学数据。比如，找回某个 IC_{50} 数值与判断两组 IC_{50} 能否比较，是不同能力。这个例子是本文

提出的药物场景评价建议。SciKnowEval 本身主要是模型能力基准，并未直接证明某一种图谱或数据模式能提高实验决策质量。

1.7.5 知识维护与数据偏差仍需长期处理

《Bridging data and discovery》（National Science Review，2026）[1] 还讨论了文献偏差和动态更新。比如，热门靶点与成功实验的记录更多，模型可能因此偏向这些对象。新结果、勘误和撤稿也要求系统保留版本并更新证据。由智能体持续整理和校验知识是论文提出的未来方向，可靠更新与实验验证仍需研究。

1.8 结语

科学知识建模把散落的资料整理为含义明确、保留条件、能够追溯的研究记录。结构化模式解决怎样记录，本体解决怎样理解概念，知识图谱解决怎样连接不同对象，大模型则为抽取和使用这些知识提供新的方法。它们各有作用，也需要共同接受任务和证据的检验。

对小分子药物研发，现阶段较有依据的方向，是围绕明确任务组织分子、样品、实验、结果和来源，再逐步加入模型检索与推理。已有工作已经能改善若干数据处理和计算任务。接下来的关键，是让这些改进转化为可重复验证的研究判断，并证明它们确实帮助研究人员做出了更好的实验选择。

文献与延伸阅读

以下为正文引用的代表性工作。期刊与会议说明用于帮助跨领域读者理解发表背景，不作为单篇研究可靠性的评分。

完整文献条目统一列在全书末尾；以下补充文献的发表背景说明与项目入口。

- [1] 科学知识图谱主题综述。
- [2] 化学信息学专业期刊。
- [3] 计算机领域重要综述期刊。
- [4] 2024 卷期，2023 在线发表。生物信息资源领域的重要数据库专刊论文。
- [5] 2025 卷期，2024 在线发表。
- [7] JACS 为美国化学会旗舰综合化学期刊。
- [8] 领域本体与生物医学语义专业期刊。
- [9] 2026 年 3 月正式发表，DOI 中含 2025 不代表发表年份。
- [10] 综合性研究期刊，本文属于催化领域。
- [11] Nature 旗下数据资源专业期刊，论文重点是 PrimeKG 数据集。
- [12] Nature 旗下人工智能专业研究期刊。
- [13] 数据科学专业期刊。
- [14] 技术标准。
- [15] 预印本，本文未核实到正式期刊或会议发表。官方项目。
- [16] Nature 旗下计算科学专业研究期刊。官方项目。
- [17] 预印本技术报告。
- [18] 非同行评议论文，服务范围以所引页面版本为准。
- [19] 预印本，本文采用 2026 年 9 月 7 日修订版。
- [20] 机器学习主要国际会议，文献信息注明为主会论文。
- [21] 预印本，配套基准后续更新。
- [22] Science Partner Journal 体系中的健康数据科学专业期刊，并非 Science 主刊。
- [23] 数据挖掘主要国际会议。
- [24] 综合性研究期刊。
- [25] 机器学习主要国际会议，文献信息注明为主会论文。
- [26] 预印本，作者注明 NeurIPS AIDaR 研讨会录用，不是主会论文。
- [27] 生物信息学主要专业期刊。
- [28] 机器学习主要国际会议，文献信息注明为主会论文。
- [29] 文献信息注明为 ICML 主会论文，收入 PMLR 第 267 卷。
- [30] 自然语言处理主要国际会议，文献信息注明为主会论文。
- [31] 生物信息学主要专业期刊。
- [32] 生物信息学主要专业期刊。
- [33] 医学领域重要研究期刊，本文方法名为 TxGNN。

参考文献

[1] DING K, ZHU Z, et al. Bridging data and discovery: a survey on knowledge graphs in AI for science[J/OL]. National Science Review, 2026, 13(8): nwag140. DOI: 10.1093/nsr/nwag140.

[2] CHALK S J. SciData: a data model and ontology for semantic representation of scientific data[J/OL]. Journal of Cheminformatics, 2016, 8: 54. DOI: 10.1186/s13321-016-0168-9.

[3] ZHANG Q, DING K, LV T, et al. Scientific Large Language Models: A Survey on Biological & Chemical Domains[J/OL]. ACM Computing Surveys, 2025, 57(6): 161. DOI: 10.1145/3715318.

[4] The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods[J/OL]. Nucleic Acids Research, 2024. DOI: 10.1093/nar/gkad1004.

[5] BindingDB in 2024: a FAIR knowledgebase of protein-small molecule binding data[J/OL]. Nucleic Acids Research, 2025. DOI: 10.1093/nar/gkae1075.

[6] A review of biomedical datasets relating to drug discovery: a knowledge graph perspective [J/OL]. Briefings in Bioinformatics, 2022. DOI: 10.1093/bib/bbac404.

[7] KEARNES S M, et al. The Open Reaction Database[J/OL]. Journal of the American Chemical Society, 2021, 143: 18820-18826. DOI: 10.1021/jacs.1c09820.

[8] ABEYRUWAN S, et al. Evolving BioAssay Ontology (BAO): modularization, integration and applications[J/OL]. Journal of Biomedical Semantics, 2014, 5(Suppl 1): S5. DOI: 10.1186/2041-1480-5-S1-S5.

[9] GLENNY-PESCOV J, CHUNG C, et al. Advancing the bioassay ontology through integrated PK/PD and safety pharmacology representation[J/OL]. Journal of Biomedical Semantics, 2026, 17: 6. DOI: 10.1186/s13326-025-00342-5.

[10] FU F, LI Q Q, WANG F, et al. Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation[J/OL]. National Science Review, 2025, 12: nwaf271. DOI: 10.1093/nsr/nwaf271.

[11] CHANDAK P, HUANG K, ZITNIK M. Building a knowledge graph to enable precision medicine[J/OL]. Scientific Data, 2023, 10: 67. DOI: 10.1038/s41597-023-01960-3.

[12] iKraph: A comprehensive large-scale biomedical knowledge graph for AI-powered data-driven biomedical research[J/OL]. Nature Machine Intelligence, 2025. DOI: 10.1038/s42256-025-01014-w.

[13] Accessing scientific data through knowledge graphs with Ontop[J/OL]. Patterns, 2021. DOI: 10.1016/j.patter.2021.100346.

[14] PROV-O: The PROV Ontology[EB/OL]. W3C Recommendation, 2013. https://www.w3.org/TR/prov-o/.

[15] RAO J, QIU Y, ZHANG J, et al. SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery[EB/OL]. 2026. arXiv: 2602.09132. https://arxiv.org/abs/2602.09132.

[16] DING K, YU J, HUANG J, et al. SciToolAgent: a knowledge-graph-driven scientific agent for multitool integration[J/OL]. Nature Computational Science, 2025, 5: 962-972. DOI: 10.1038/s43588-025-00849-y.

[17] JIANG Y, LOU W, WANG L, et al. SCP: Accelerating Discovery with a Global Web of Autonomous Scientific Agents[EB/OL]. 2025. arXiv: 2512.24189. https://arxiv.org/abs/2512.24189.

[18] SciGraph-Bio SCP Server[EB/OL]. SCP Hub 官方项目技术文档, 2026. https://scphub.intern-ai.org.cn/detail/38.

[19] HUANG X, LONG Q, DU X, et al. Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale[EB/OL]. 2026. arXiv: 2608.19625v2. https://arxiv.org/abs/2608.19625v2.

[20] FANG Y, LIANG X, ZHANG N, et al. Mol-Instructions: A Large-Scale Biomolecular Instruction Dataset for Large Language Models[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/d346d91999074dd8d6073d4c3b13733b-Abstract-Conference.html.

[21] FENG K, DING K, et al. SciKnowEval: Evaluating Multi-level Scientific Knowledge of Large Language Models[EB/OL]. 2024. arXiv: 2406.09098. https://arxiv.org/abs/2406.09098.

[22] LUO Y, LIU X Y, YANG K, et al. KEDD: Toward Unified AI Drug Discovery with Multimodal Knowledge[J/OL]. Health Data Science, 2024, 4: 0113. DOI: 10.34133/hds.0113.

[23] LUO Y, YANG K, HONG M, et al. Learning Multi-view Molecular Representations with Structured and Unstructured Knowledge[C/OL]//KDD. 2024: 2082-2093. DOI: 10.1145/3637528.3672043.

[24] DAGDELEN J, DUNN A, et al. Structured information extraction from scientific text with large language models[J/OL]. Nature Communications, 2024, 15: 1418. DOI: 10.1038/s41467-024-45563-x.

[25] MO B, YU K, KAZDAN J, et al. KGGen: Extracting Knowledge Graphs from Plain Text with Language Models[C/OL]//NeurIPS. 2025. https://neurips.cc/virtual/2025/poster/117386.

[26] VAN WEESEP L, TEDOLDI R, et al. Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?[EB/OL]. 2026. arXiv: 2610.01616. https://arxiv.org/abs/2610.01616.

[27] SOMAN K, ROSE P W, et al. Biomedical knowledge graph-optimized prompt generation for large language models[J/OL]. Bioinformatics, 2024, 40: btae560. DOI: 10.1093/bioinformatics/btae560.

[28] LUO L, LI Y F, HAFFARI G, et al. Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/3e2aeb66481dd63a32421bf032b70384-Abstract-Conference.html.

[29] LUO L, ZHAO Z, HAFFARI G, et al. Graph-constrained Reasoning: Faithful Reasoning on Knowledge Graphs with Large Language Models[C/OL]//Proceedings of Machine Learning Research: Vol. 267 ICML. 2025: 41540-41565. https://proceedings.mlr.press/v267/luo25t.html.

[30] DENG Y, ERICKSEN S S, GITTER A. Assay2Mol: Large Language Model-based Drug Design Using BioAssay Context[C/OL]//EMNLP. 2025: 27337-27362. https://aclanthology.org/2025.emnlp-main.1390/.

[31] MATSUMOTO N, MORAN J, CHOI H, et al. KRAGEN: a knowledge graph-enhanced RAG framework for biomedical problem solving using large language models[J/OL]. Bioinformatics, 2024, 40: btae353. DOI: 10.1093/bioinformatics/btae353.

[32] MATSUMOTO N, CHOI H, MORAN J, et al. ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning[J/OL]. Bioinformatics, 2025, 41: btaf031. DOI: 10.1093/bioinformatics/btaf031.

[33] HUANG K, CHANDAK P, WANG Q, et al. A foundation model for clinician-centered drug repurposing[J/OL]. Nature Medicine, 2024, 30: 3601-3613. DOI: 10.1038/s41591-024-03233-x.

[34] LEE H, YOO H J, JANG H S, et al. Toward self-driving laboratory 2.0 for chemistry and materials discovery[J/OL]. Materials Horizons, 2026. DOI: 10.1039/D5MH01984B.

[35] PILON S, SAVINO E, BAYLEY O M, et al. A flexible and affordable self-driving laboratory for automated reaction optimization[J/OL]. Nature Synthesis, 2026. DOI: 10.1038/s44160-026-01053-0.

[36] BENNETT J A, OROUJI N, VELAYATI A, et al. An autonomous lab for data-driven homogeneous catalysis[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-74425-x.

[37] BURGER B, MAFFETTONE P M, GUSEV V V, et al. A mobile robotic chemist[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-2442-2.

[38] SZYMANSKI N J, RENDY B, FEI Y, et al. An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06734-w.

[39] FEI Y, RENDY B, YANG X, et al. Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2604.11957.

[40] SUPONYA A, DI MARE E, RAMÍREZ C, et al. Self-driving lab for the data-driven design of single-chain polymer nanoparticles[J/OL]. Cell Press Blue, 2026. DOI: 10.1016/j.cpblue.2026.100033.

[41] LOH X J. Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery[J/OL]. Macromolecular Rapid Communications, 2026. DOI: 10.1002/marc.70420.

[42] STRIETH-KALTHOFF F, HAO H, RATHORE V, et al. Delocalized, asynchronous, closed-loop discovery of organic laser emitters[J/OL]. Science, 2024. DOI: 10.1126/science.adk9227.

[43] PARK H S, MAZAHERI M, CHOI C, et al. Discovery of tunable and soluble organic emitters for solid-state lasers with a self-driving laboratory[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69233-2.

[44] LEE J, NOH J, LEE H, et al. Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories[J/OL]. InfoMat, 2026. DOI: 10.1002/inf2.70124.

[45] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-1994-5.

[46] SHIBUKAWA R, MATSUDA S, NAKAMURA K, et al. Collecting diverse near-optimal samples via nested Thompson sampling[J/OL]. npj Computational Materials, 2026. DOI: 10.1038/s41524-026-02067-0.

[47] RAPP J T, BREMER B J, ROMERO P A. Self-driving laboratories to autonomously navigate the protein fitness landscape[J/OL]. Nature Chemical Engineering, 2024. DOI: 10.1038/s44286-023-00002-4.

[48] BROOKS C, NOTIN P, ROMERO P A. Learning protein function through autonomous experimental interaction[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.08.14.744985.

[49] HAMEDIRAD M, CHAO R, WEISBERG S, et al. Towards a fully automated algorithm driven platform for biosystems design[J/OL]. Nature Communications, 2019. DOI: 10.1038/s41467-019-13189-z.

[50] COCHRANE R R, DOS SANTOS L V, CAI Y. The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103503.

[51] CHEN J, VOLK M, SHAFAEI S, et al. An AI-powered cloud biofoundry for autonomous biological research[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.30.750244.

[52] KANDA G N, TSUZUKI T, TERADA M, et al. Robotic search for optimal cell culture in regenerative medicine[J/OL]. eLife, 2022. DOI: 10.7554/eLife.77007.

[53] BIELAWSKI K, SRINIVASAN K, GAYLINN N, et al. A Closed-Loop Robot Scientist for Autonomous Biological Discovery[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.11.751076.

[54] LIU S, KAUR N, SONG D H, et al. Self-driving bioprinting laboratories[J/OL]. Biofabrication, 2026. DOI: 10.1088/1758-5090/ae3645.

[55] PITICARI A S, GRIGGS S D, CRAWFORD L, et al. Algorithm-driven, phenotype-directed bioactive molecular discovery[J/OL]. Communications Chemistry, 2026. DOI: 10.1038/s42004-026-02066-8.

[56] RAMADURAI K, BANERJEE A. TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry[J/OL]. npj Drug Discovery, 2026. DOI: 10.1038/s44386-026-00078-x.

[57] XU Y, CUI H, PANG K, et al. LUMI-lab: A foundation model-driven autonomous platform enabling discovery of ionizable lipid designs for mRNA delivery[J/OL]. Cell, 2026. DOI: 10.1016/j.cell.2026.01.012.

[58] SAGMEISTER P, UDEPURKAR A, DEVOS C, et al. Autonomous Lipid Nanoparticle Engineering[J/OL]. ACS Nano, 2026. DOI: 10.1021/acsnano.6c15600.

[59] PANAGIOTAKOPOULOU M, GOREN A, REKER D, et al. Artificial intelligence and machine learning in nanoparticle drug delivery systems[J/OL]. Nature Reviews Bioengineering, 2026. DOI: 10.1038/s44222-026-00495-7.

[60] KAPOOR S, CANTRELL E M, PENG K, et al. REFORMS: Consensus-based Recommendations for Machine-learning-based Science[J/OL]. Science Advances, 2024, 10(18): eadk3452. DOI: 10.1126/sciadv.adk3452.

[61] ERIKSSON M, PURIFICATO E, NOROOZIAN A, et al. Can We Trust AI Benchmarks? An Interdisciplinary Review of Current Issues in AI Evaluation[C/OL]//Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society: Vol. 8. 2025: 850-864. DOI: 10.1609/aies.v8i1.36595.

[62] NAGESHWARAN V, EZEKIEL S, TRAN T T, et al. Large language model agent evaluation and benchmarking: a systematic survey, meta-taxonomy, and critical research roadmap [J/OL]. Artificial Intelligence Review, 2026. DOI: 10.1007/s10462-026-11678-4.

[63] YEHUDAI A, EDEN L, LI A, et al. A Survey on Evaluation of LLM-based Agents[C/OL]// Findings of the Association for Computational Linguistics: ACL 2026. 2026: 26690-26714. DOI: 10.18653/v1/2026.findings-acl.1330.

[64] SAEZ-RODRIGUEZ J, SCHÄFER P S L, KALAVROS N, et al. Benchmarking biomedical foundation models[J/OL]. Nature Methods, 2026, 23: 1724-1733. DOI: 10.1038/s41592-026-03182-y.

[65] ZHENG T, DENG Z, TSANG H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 17733-17750. DOI: 10.18653/v1/2025.emnlp-main.895.

[66] MIRZA A, ALAMPARA N, KUNCHAPU S, et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists[J/OL]. Nature Chemistry, 2025, 17: 1027-1034. DOI: 10.1038/s41557-025-01815-x.

[67] Center for AI Safety, Scale AI, HLE Contributors Consortium. A benchmark of expert-level academic questions to assess AI capabilities[J/OL]. Nature, 2026, 649: 1139-1146. DOI: 10.1038/s41586-025-09962-4.

[68] RIEBESELL J, GOODALL R E A, BENNER P, et al. A framework to evaluate machine learning crystal stability predictions[J/OL]. Nature Machine Intelligence, 2025, 7: 836-847. DOI: 10.1038/s42256-025-01055-1.

[69] ZENI C, PINSLER R, ZÜGNER D, et al. A generative model for inorganic materials design [J/OL]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[70] CHEN Z, CHEN S, NING Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/f12b4df26344f3be803c06b555252efe-Abstract-Conference.html.

[71] STARACE G, JAFFE O, SHERBURN D, et al. PaperBench: Evaluating AI's Ability to Replicate AI Research[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 56843-56873. https://proceedings.mlr.press/v267/starace25a.html.

[72] WANG Z, BAI F, LUO Z, et al. FIRE-Bench: Evaluating AI Agents on the Rediscovery of Scientific Insights[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 124896-124929. https://proceedings.mlr.press/v306/wang26d.html.

[73] ZHANG K, LI Y. Are We Measuring Scientific Intelligence? Rethinking the Evaluation of AI Scientists[EB/OL]. (2026-10-04)[2026-10-18]. https://arxiv.org/abs/2610.04915.

[74] JOERES R, BLUMENTHAL D B, KALININA O V. Data splitting to avoid information leakage with DataSAIL[J/OL]. Nature Communications, 2025, 16: 3337. DOI: 10.1038/s41467-025-58606-8.

[75] JOERES R, BLUMENTHAL D B, KALININA O V. Addendum: Data splitting against information leakage with DataSAIL[J/OL]. Nature Communications, 2026, 17: 1597. DOI: 10.1038/s41467-025-67495-w.

[76] CHEN S, CHEN Y, LI Z, et al. Benchmarking Large Language Models Under Data Contamination: A Survey from Static to Dynamic Evaluation[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. 2025: 10080-10098. DOI: 10.18653/v1/2025.emnlp-main.511.

[77] SUN Y, WANG H, LI D, et al. The emperor's new clothes in benchmarking? A rigorous examination of mitigation strategies for LLM benchmark data contamination[C/OL]// Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 57728-57753. https://proceedings.mlr.press/v267/sun25t.html.

[78] WANG H, LI H, KO B, et al. On the fragility of benchmark contamination detection in reasoning models[C/OL]//International Conference on Learning Representations. 2026. https://proceedings.iclr.cc/paper_files/paper/2026/hash/a3860475ddbfb8c644c43f0dcd266b66-Abstract-Conference.html.

[79] WHITE C, DOOLEY S, ROBERTS M, et al. LiveBench: A challenging, contamination-limited LLM benchmark[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/e4a46394ba5378b3f9a186a5b4c650d1-Abstract-Conference.html.

[80] ZHOU L, PACCHIARDI L, MARTÍNEZ-PLUMED F, et al. General scales unlock AI evaluation with explanatory and predictive power[J/OL]. Nature, 2026, 652: 58-67. DOI: 10.1038/s41586-026-10303-2.

[81] BUTTENSCHOEN M, MORRIS G M, DEANE C M. PoseBusters: AI-based docking methods fail to generate physically valid poses or generalise to novel sequences[J/OL]. Chemical Science, 2024, 15: 3130-3139. DOI: 10.1039/D3SC04185A.

[82] OHANA R, MCCABE M, MEYER L, et al. The Well: a Large-Scale Collection of Diverse Physics Simulations for Machine Learning[C/OL]//Advances in Neural Information Processing Systems 37, Datasets and Benchmarks Track. 2024. DOI: 10.52202/079017-1430.

[83] GU J, JIANG X, SHI Z, et al. A survey on LLM-as-a-judge[J/OL]. The Innovation, 2026, 7(6): 101253. DOI: 10.1016/j.xinn.2025.101253.

[84] SHORINWA O, MEI Z, LIDARD J, et al. A Survey on Uncertainty Quantification of Large Language Models: Taxonomy, Open Research Challenges, and Future Directions[J/OL]. ACM Computing Surveys, 2025, 58(3): 63. DOI: 10.1145/3744238.

[85] SEHWAG U M, LAU E, OSKOUIE H E, et al. SciPredict: Can LLMs Predict the Outcomes of Scientific Experiments in Natural Sciences?[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 108784-108827. https://proceedings.mlr.press/v306/sehwag26a.html.

[86] CAO Y, LAI S, HUANG J, et al. SimulCost: A Cost-Aware Benchmark and Toolkit for Automating Physics Simulations with LLMs[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 11206-11254. https://proceedings.mlr.press/v306/cao26g.html.

[87] ZHOU Y, YANG J, HUANG Y, et al. Benchmarking large language models on safety risks in scientific laboratories[J/OL]. Nature Machine Intelligence, 2026, 8: 20-31. DOI: 10.1038/s42256-025-01152-1.

[88] AHLMANN-ELTZE C, HUBER W, ANDERS S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines[J/OL]. Nature Methods, 2025, 22: 1657-1661. DOI: 10.1038/s41592-025-02772-6.

[89] SONG Y, WANG G, LI S, et al. The Good, The Bad, and The Greedy: Evaluation of LLMs Should Not Ignore Non-Determinism[C/OL]//Proceedings of NAACL-HLT 2025, Volume 1: Long Papers. 2025: 4195-4206. DOI: 10.18653/v1/2025.naacl-long.211.

[90] WADI D, FREDETTE M. A Monte-Carlo Sampling Framework For Reliable Evaluation of Large Language Models Using Behavioral Analysis[C/OL]//Findings of the Association for Computational Linguistics: EMNLP 2025. 2025: 9414-9432. DOI: 10.18653/v1/2025.findings-emnlp.500.

[91] WENTELER A, OCCHETTA M, BRANSON N, et al. PertEval-scFM: Benchmarking Single-Cell Foundation Models for Perturbation Effect Prediction[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 66633-66677. https://proceedings.mlr.press/v267/wenteler25a.html.

[92] WEI Z, WANG Y, GAO Y, et al. Benchmarking algorithms for generalizable single-cell perturbation response prediction[J/OL]. Nature Methods, 2026, 23: 451-464. DOI: 10.1038/s41592-025-02980-0.

[93] RASP S, HOYER S, MEROSE A, et al. WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models[J/OL]. Journal of Advances in Modeling Earth Systems, 2024, 16: e2023MS004019. DOI: 10.1029/2023MS004019.

[94] LIU Y, ZHOU L, DU X, et al. Benchmarking LLM-based agents for single-cell omics analysis[J/OL]. Genome Biology, 2026, 27: 123. DOI: 10.1186/s13059-026-03998-z.

[95] TOM G, SCHMID S P, BAIRD S G, et al. Self-Driving Laboratories for Chemistry and Materials Science[J/OL]. Chemical Reviews, 2024. DOI: 10.1021/acs.chemrev.4c00055.

[96] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06792-0.

[97] SZYMANSKI N J, RENDY B, FEI Y, et al. Author Correction: An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2026. DOI: 10.1038/s41586-025-09992-y.

[98] ZHANG T, LIN H, CHEN Y, et al. SALSA: a low-cost self-driving lab modular add-on for salt solubility assessment for battery electrolytes[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00516G.

[99] ALLU S G, HASNAIN R, VOS A, et al. AI-driven approaches for navigating battery complexity[J/OL]. EES Batteries, 2026. DOI: 10.1039/D6EB00101G.

[100] VOLK M, KAUSHIK PILLALAMARRI V, GUO R, et al. Artificial intelligence tools for enzyme engineering and metabolic engineering[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103522.

[101] OATMAN H R, LAD B C, NGUYEN L, et al. An optogenetic smart microscopy platform reveals signaling dynamics-dependent control over collective cell migration[J/OL]. Cell Systems, 2026. DOI: 10.1016/j.cels.2026.101674.

[102] HWANG J, KIM S, LIM S, et al. Self-driving laboratories in Korea: a new era of autonomous discovery[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D6DD00024J.

[103] ZHU Q, ZHANG F, HUANG Y, et al. An all-round AI-Chemist with a scientific mind [J/OL]. National Science Review, 2022. DOI: 10.1093/nsr/nwac190.

[104] FENG S, MA R, et al. InternAgent-1.5: A Unified Agentic Framework for Long-Horizon Autonomous Scientific Discovery[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2602.08990.

[105] ADESIJI A D, WANG J, KUO C S, et al. Benchmarking self-driving labs[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00337G.

[106] CANTY R B, ABOLHASANI M. The past, present and future of self-driving laboratories [J/OL]. Nature Reviews Chemistry, 2026. DOI: 10.1038/s41570-026-00847-2.

[107] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for scientific data management and stewardship[J/OL]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.

[108] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for datasets[J/OL]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.

[109] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J/OL]. Patterns, 2023, 4(9): 100804. DOI: 10.1016/j.patter.2023.100804.