第二章　自主实验室与干湿闭环

学习目标：理解自主实验室如何连接计算决策、实验执行和测量反馈，比较不同领域的闭环指标。

先修知识：机器学习、实验设计与科研工作流基础。

2.1　自主实验室是什么

科学研究通常需要反复实验。一个初始设想往往只能确定大致方向，具体方案还要根据结果调整。例如，制备一种材料时，需要不断改变原料和加热条件。寻找一种酶时，需要构建不同序列，再比较它们的功能。研究能否有效推进，既取决于实验能否顺利完成，也取决于下一次实验是否选得合适。自动移液器、机械臂和高通量检测设备已经能够承担许多重复操作。但是，按照预设方案连续执行实验，只解决了操作问题。实验结果出现后，怎样判断哪些方案值得继续尝试，通常仍需要研究者分析和决定。

自主实验室是在研究者给定的目标和约束下，能够自动执行实验、分析结果，并据此选择后续实验的系统。

2.2　自主实验室中的干湿闭环

2.2.1　一轮干湿闭环怎样完成

第一步，干实验提出本轮方案。模型利用已有数据，比较不同候选的预期表现和不确定性，再选择值得测试的对象。输出必须足够具体，例如一组反应条件、一条蛋白质序列或一套培养参数，使实验设备能够执行。

第二步，湿实验产生真实结果。设备按方案制备样品并测量性能。实验得到的产率、活性或细胞状态，可能符合预测，也可能与预测不同。这些差异是修正后续判断的重要依据。

第三步，实验结果返回干实验。系统将实测结果与对应的候选、实际操作条件和质量检查记录放在一起。经过检查的数据被用于更新模型、候选排序或实验选择策略。仪器故障与候选本身表现较差，需要分别处理。

2.2.2 闭环怎样才能可靠运行

干湿闭环需要同时满足三个要求：计算提出的方案能够执行，实验返回的数据能够解释，更新后的判断能够实际改变后续安排。任何一个步骤缺失，计算与实验之间的往返都会中断。

这也是为什么自主实验室需要实验管理软件。它必须记录样品身份和实际条件，协调设备顺序，并把测量结果交给正确的模型或选择程序。Lee 等人的综述《Toward self-driving laboratory 2.0 for chemistry and materials discovery》（Materials Horizons，2026）将模块化硬件、决策算法与实验调度和数据管理放在一起讨论，强调这些组成需要共同支持持续实验 [34]。

闭环也不要求每轮都重新训练一个大型模型。新结果可以用于更新预测模型，也可以用于调整候选排序、选择策略或控制动作。

2.3 化学研究中的干湿闭环

化学研究中的一个常见问题是，同一种反应可以在许多不同条件下进行，但哪些条件更有效，往往需要实验才能确定。改变原料比例、催化剂或反应时间，都可能影响产率和产物组成。

干实验可以利用已有数据比较这些方案，湿实验则负责完成反应并测量结果。当实测结果返回模型，并进一步影响下一次反应的安排时，反应研究就形成了干湿闭环。

有机合成与催化研究都采用这种方式。两者的区别主要在于优化对象。有机合成通常围绕目标产物的制备条件展开，催化研究还需要比较催化体系本身，以及它对反应活性和产物选择性的影响。

2.3.1 有机合成

Pilon 等人的 RoboChem-Flex（Nature Synthesis，2026）将实验设备、控制软件和贝叶斯优化结合，用于自动寻找反应条件。其中的光催化案例明确展示了干湿实验如何闭环 [35]。

- 干实验首先选择条件。算法在预先规定的范围内，选择反应浓度、原料用量、停留时间，以及光催化剂等变量。

- 湿实验随后完成加料与流动反应，并通过在线氟核磁分析得到实测产率。
- 实测产率返回后，算法重新判断哪些条件值得尝试。新选择再次交给设备执行，下一次测量又进入计算端。研究在 15 次初始实验后，继续进行了 35 轮反馈优化，因此后续实验的条件持续受到新测量的影响。

实验结果还会改变探索方式。当连续三次实验的产率相近时，算法会增加对不确定区域的探索。这说明反馈不仅能调整某个参数，也能改变系统接下来搜索哪些区域。

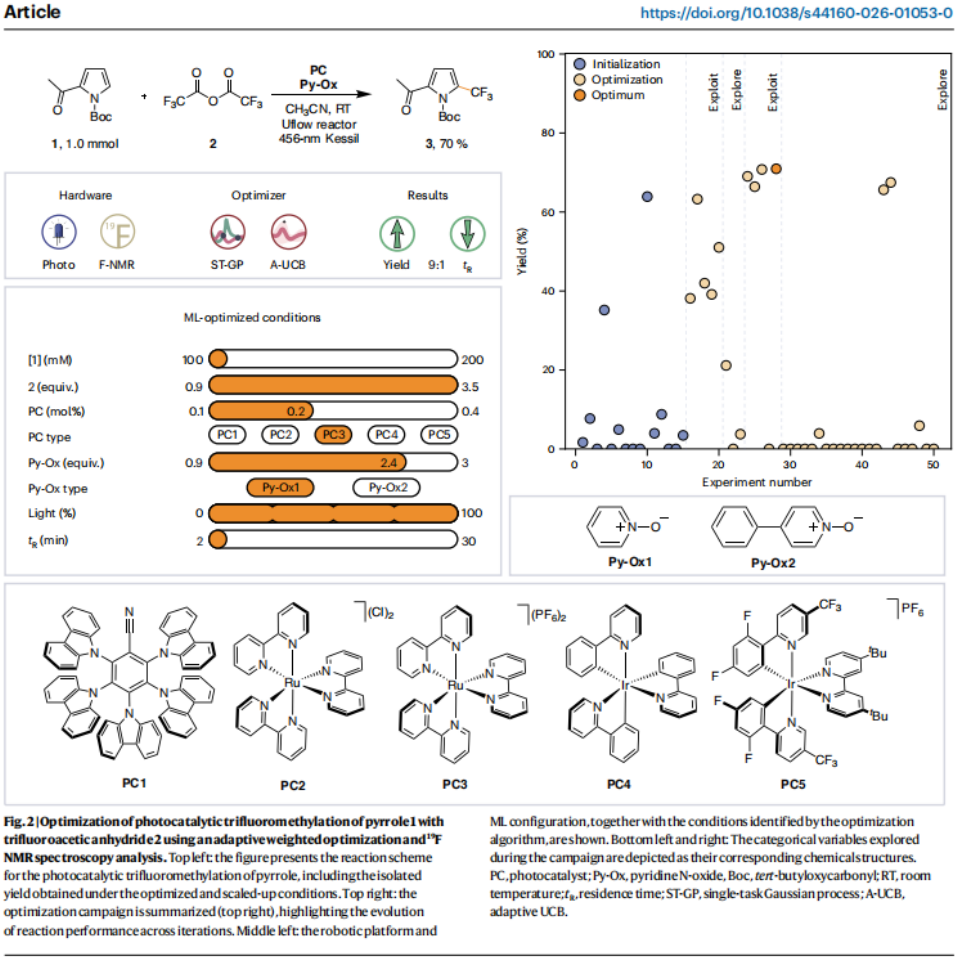


Fig. 2 | Optimization of photocatalytic trifluoromethylation of pyrrole 1 with trifluoroacetic anhydride 2 using an adaptive weighted optimization and ^{19}F NMR spectroscopy analysis. Top left: the figure presents the reaction scheme for the photocatalytic trifluoromethylation of pyrrole, including the isolated yield obtained under the optimized and scaled-up conditions. Top right: the optimization campaign is summarized (top right), highlighting the evolution of reaction performance across iterations. Middle left: the robotic platform and ML configuration, together with the conditions identified by the optimization algorithm, are shown. Bottom left and right: The categorical variables explored during the campaign are depicted as their corresponding chemical structures. PC, photocatalyst; Py-Ox, pyridine N-oxide, Boc, *tert*-butyloxycarbonyl; RT, room temperature; t_R, residence time; ST-GP, single-task Gaussian process; A-UCB, adaptive UCB.

图 2.1 利用自适应加权优化和核磁共振（NMR）光谱分析，对吡咯 1 与三氟乙酸酐 2 的光催化三氟甲基化反应进行优化。原文图 2。

来源：所提供资料第 3 页；保留原始图片。

小贴士（图 2.1：RoboChem-Flex 读图指南）

图的左上角是反应示意图

- 1：起始原料，是一种吡咯衍生物。
- 2：提供三氟甲基（$-CF_3$）的试剂。
- PC：光催化剂（Photocatalyst）。
- Py-Ox：氧化剂。
- 3：希望得到的目标产物，产率为 70%。

反应在乙腈（CH_3CN）中进行，室温（RT）下使用 456 nm 的 Kessil 光源照射。

产率（Yield）：反应后实际获得的目标产物有多少。通常产率越高越好。

光催化剂（PC）：帮助光照驱动化学反应的物质。不同催化剂可能会让反应表现出很大差异。

因此，研究人员要解决的问题是：怎样选择实验条件，才能让这个反应更高效地进行？

左下角：机器学习到底优化了哪些条件？

这部分是整张图的核心之一。研究人员把化学反应中能够调整的因素交给机器学习，让算法决定接下来应该怎么做实验。

1. 原料 1 的浓度（[1]）100–200 mM

决定反应物的浓度，可能影响反应速率和产物生成量。

2. 试剂 2 的当量（equiv.）

0.9–3.5

表示试剂 2 相对于基准反应物的用量比例。比如 2 当量通常表示用量是基准物质的 2 倍。

3. 光催化剂用量与种类

PC 用量：0.1%–0.4%；PC1–PC5

不仅要选择催化剂，还要决定加入多少。底部画出了五种候选催化剂的分子结构。

4. 氧化剂 Py-Ox 的用量与种类

0.9–3 equiv.；Py-Ox1 或 Py-Ox2

两种氧化剂的结构也在图中给出。算法需要判断哪一种更适合当前反应。

小贴士（图 2.1：RoboChem-Flex 读图指南，续）

5. 光照强度与反应时间

光照：0–100%；t_R：2–30 min

光照强度和停留时间都会影响反应结果。t_R 表示反应停留时间。

这不是只调一个参数，而是同时考虑连续变量和类别变量：

- 连续变量：浓度、用量、光照强度、反应时间。
- 类别变量：催化剂 PC1–PC5、氧化剂 Py-Ox1/Py-Ox2。

右上角：机器学习如何找到最优实验条件？

Initialization（初始化）

先做一些初始实验，获得基础数据，让模型初步了解哪些条件有效。

Optimization（优化）

根据已有实验结果，由算法继续选择实验条件，探索更好的反应表现。

Optimum（最优条件）

标记算法找到的最优条件对应的结果。

可以分三步理解。

第一步：先尝试一些条件。

最开始的实验结果有高有低，很多实验的产率很低，甚至接近 0%。这很正常，因为研究人员还不知道哪些参数组合最有效。

第二步：算法根据结果调整下一次实验。

例如，某些催化剂和氧化剂的组合效果较好，算法就可以利用这些信息，决定下一次实验应该尝试什么条件。同时，它也需要探索尚不确定的区域，避免过早认定某个条件就是最优的。

第三步：逐步找到高产率条件。

图中部分后续实验的产率达到约 60%–70%，说明算法找到了表现较好的实验条件。不过，优化过程中仍然有一些实验产率很低，说明机器学习并不是每次都能预测正确，而是在一轮轮实验中逐步改进。

图中标注的 Explore（探索）或 Exploit（利用），对应的就是优化算法中两类不同的决策思路：一类尝试新的条件，另一类利用目前已经发现的有效条件继续改进。

小贴士（图 2.1：RoboChem-Flex 读图指南，续）

底部：为什么要展示这么多催化剂结构？

底部列出了五种候选光催化剂 PC1–PC5 的分子结构，以及两种氧化剂 Py-Ox1、Py-Ox2。

这些结构不是装饰，而是告诉读者：算法搜索的空间包含了真实的化学选择。

例如，算法可能需要判断：

- 使用 PC1 还是 PC3？
- 使用 Py-Ox1 还是 Py-Ox2？
- 催化剂的用量应该是多少？
- 在选定催化剂后，什么光照强度和反应时间更合适？

这些选择组合起来，就形成了一个复杂的实验条件搜索空间。

2.3.2 催化研究

反应进行得快，并不一定意味着目标产物所占比例高。干实验因此需要同时考虑催化活性与选择性，湿实验也必须返回能够分别评价这两个目标的数据。

Bennett 等人的 Flex-Cat（Nature Communications，2026）研究铑催化反应中的配体与条件组合。配体是与金属配合、影响催化表现的分子。平台用并行反应装置测试不同组合，再用气相色谱分析产物 [36]。

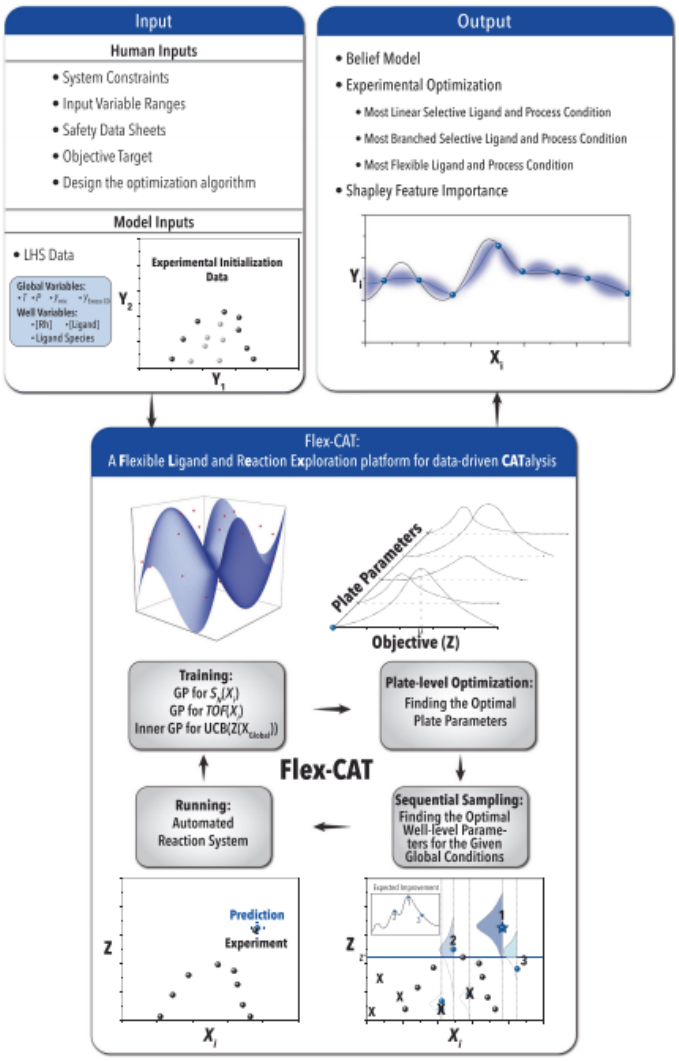


图 2.2 Flex-Cat 的 AI 驱动决策工作流。原文图 5。

来源：所提供资料第 6 页；保留原始图片。

小贴士（图 2.2：Flex-Cat 的决策流程）

利用预先定义的系统约束、输入参数范围和初始化实验数据，训练用于预测区域选择性（S_N）和周转频率（TOF）的高斯过程（GP）模型。其中，内层 GP 模型负责优化微孔板层面的实验参数，包括温度、压力和气体混合比例。

通过序贯采样与自动化反应执行，系统能够识别出分别具有最高直链选择性、最高支链选择性，以及兼具灵活性的配体–工艺条件组合。

小贴士（图 2.2：Flex-Cat 的决策流程，续）

各变量的取值范围、安全边界以及初始化实验设计均在实验开始前预先设定。在这些约束条件下，分层决策策略能够自主选择微孔板层面的设定参数和微孔层面的配方，执行实验、更新代理模型，并提出下一批实验方案。

干实验决定下一块反应板怎样安排。算法既选择各孔的配体和配方，也选择整块板共享的温度、压力等条件。湿实验随后完成配料、反应与检测，得到催化活性和不同产物的比例。

这些结果返回高斯过程模型，更新对配体与条件组合的判断。算法再结合两个目标和设备限制，安排下一块反应板。新的反应结果继续进入模型，形成多轮选择。论文在三组优化任务中完成了 680 次实验 [36]。

2.3.3 移动机器人怎样把不同实验站接入闭环

干湿闭环也可以通过移动机器人连接已有设备来实现。Burger 等人的移动机器人化学家（Nature，2020）在实验室中操作不同工作站，寻找更有效的光催化制氢配方 [37]。

在干实验一侧，批量贝叶斯搜索方法选择下一批配方。在湿实验一侧，机器人配制样品、执行光照实验并完成检测。测得的制氢表现返回算法后，算法据此调整各组分的选择，再让机器人测试新的配方。

系统在 8 天中完成了 688 次实验，找到的混合物活性达到初始配方的六倍。这里的自主性同时体现在实验操作和后续选择中。机器人负责让实验连续进行，算法负责根据新结果改变下一批实验。

这一方式使已有仪器能够参与连续研究。相应地，样品在不同工作站之间转移时，编号、操作条件和检测结果也必须保持对应，才能让数据准确返回计算端。

2.4 材料研究中的干湿闭环

2.4.1 无机材料与固态合成

计算能够筛选可能稳定的晶体，却不能直接保证实验能够制得这些材料。原料选择和加热过程都会影响实际产物。因此，无机材料的干湿闭环首先要解决从计算候选到真实样品的问题。

Szymanski 等人的 A-Lab（Nature，2023）展示了这一过程。干实验先根据文献中的合成经验和计算信息，为目标材料选择前驱体与加热方案。湿实验由机器人完成粉末处理、混合和加热，再通过 X 射线衍射判断实际形成了哪些晶体物质。如果目标产物不足，系统就结合观察到的产物和热力学信息，提出新的合成方案并继续实验。失败结果因此也能成为下一轮选择的依据 [38]。

这里返回计算端的信息，包含目标产物是否出现，以及同时生成了哪些其他物质。这些结果可以帮助系统判断原先的合成方案为什么没有达到目标。干实验据此修改后续方案，湿实验再检验修改是否有效。

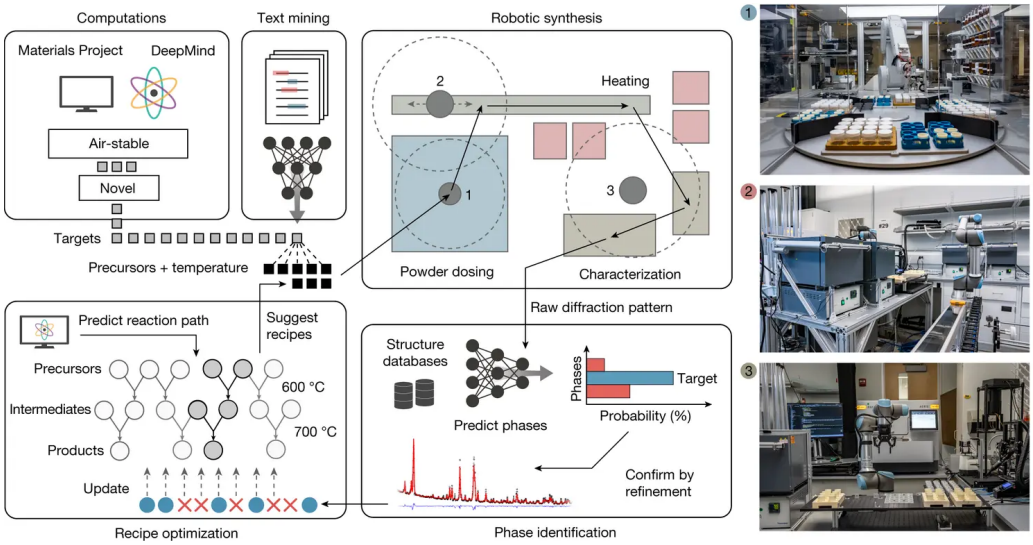


图 2.3 利用 A-Lab 实现自主材料合成。原文图 1。

来源：所提供资料第 8 页；保留原始图片。

小贴士（图 2.3：A-Lab 的材料合成流程）

左上角：Computations，计算筛选目标材料

图中对应文字：Materials Project、DeepMind、Air-stable、Novel、Targets

这部分回答的是：我们要合成哪些材料？

- Materials Project 和 DeepMind：提供材料晶体结构等计算数据。
- DFT（密度泛函理论）与凸包计算：用于判断哪些材料在热力学上具有稳定性或值得进一步研究。
- Air-stable：筛选在空气中能够保持稳定的目标材料。
- Novel：强调筛选具有新颖性的目标材料。

小贴士（图 2.3：A-Lab 的材料合成流程，续）

筛选后形成一批 Targets（目标材料），它们是后续实验需要尝试合成的对象。

上方中间：Text mining，文献挖掘

这部分回答的是：已有研究中有哪些合成经验可以借鉴？

研究团队从文献中提取材料合成数据，并用这些数据训练机器学习模型。模型可以利用已有的合成经验，为目标材料提出候选合成方案。

这里的关键是，文献不是直接告诉机器人“下一步做什么”，而是提供训练数据，让模型学会从原料和合成条件推测可能的合成路径与方案。

左下角：Predict reaction path + Suggest recipes，预测反应路径并提出配方

这是图中很重要的一部分，也是主动学习优化的起点。

图里的反应路径由三层节点组成：

- Precursors：前驱体，即最初投入的原料。
- Intermediates：中间产物，即反应过程中可能形成的物质。
- Products：最终产物。

旁边的 600 °C、700 °C 表示不同反应阶段或候选合成方案对应的温度条件。图中被灰色填充的节点和加粗箭头，表示模型重点选择的候选反应路径。

模型据此执行 Suggest recipes（提出合成配方），把候选方案转化为机器人可执行的实验任务。实验任务通常包括前驱体组合、各原料用量及温度等合成条件。

你可以把它理解为：

目标材料 + 已有合成知识 + 反应路径预测 → 候选实验配方。

上方中间：Robotic synthesis，机器人自动合成

这里的数字 1、2、3 与最右侧三张实景照片对应。

1. Powder dosing（粉末加料）

根据配方，自动称量并向样品容器中加入相应的前驱体粉末。这里是将算法提出的配方真正转化为实体实验。

2. Heating（加热）

机器人将样品送至加热设备，按照预设条件进行反应。图中的箭头表示样品在自动化实验流程中移动。

小贴士（图 2.3：A-Lab 的材料合成流程，续）

3. Characterization（产物表征）

合成后的样品被转移到 X 射线衍射（XRD）设备中，测量其衍射图谱，为后续的物相识别提供数据。

图中上方的箭头和机械臂表示样品在不同操作站之间流转。也就是说，机器人不仅负责某一个单独动作，还把加料、加热、表征等步骤连接成连续的自动化流程。

右侧三张照片主要是这三个环节的实际设备照片，不是额外的三个算法模块。

右下角：Phase identification，物相识别

这部分回答的是：机器人做出来的东西，到底是不是我们想要的材料？

图中的流程是：

Raw diffraction pattern → Predict phases → Confirm by refinement

可以这样理解：

- Raw diffraction pattern（原始衍射图谱）：XRD 设备测得的实验数据。
- Predict phases（预测物相）：模型结合 Materials Project、ICSD 等结构数据库中的信息，预测样品中可能存在的物相以及相应概率。
- Confirm by refinement（通过精修确认）：采用 Rietveld 精修等方法，对物相判断进行进一步验证。

2026 年的 A-Lab GPSS 将这一方法扩展到对空气敏感的锂卤化物导体。Fei 等人的研究《Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors》（arXiv 预印本，2026）让智能体根据已有的物相和离子电导率数据，提出新的组成或合成条件。机器人在保护气氛中完成合成，后续测量得到的数据再交给智能体，支持下一轮设计 [39]。

这项研究共涉及 352 个样品，其中 263 个由智能体提出。与早期 A-Lab 相比，反馈同时考虑了材料结构和导电性能。它展示的是自动合成、半自动测量和计算决策共同参与的干湿闭环 [39]。

2.4.2 高分子与软材料

高分子研究还需要考虑分子链的长度、组成和排列方式。即使使用相同的单体，得到的材料也可能因为制备过程不同而表现不同。

Suponya 等人的 PolyCraft（Cell Press Blue，2026）选择了一个较明确的任务，优化单链聚合物纳米颗粒在溶液中的尺寸。这类颗粒由聚合物链形成，其尺寸会随单体组成和链长等因素变化 [40]。

干实验利用已有的聚合物设计与尺寸数据，预测新候选的表现，再选择下一批需要合成的配方。湿实验由液体操作机器人配制样品并完成光聚合，然后通过动态光散射测量颗粒尺寸。新获得的配方和尺寸数据加入训练集，更新后的模型继续选择下一批候选。论文通过多轮主动学习，使实测尺寸不断影响后续分子设计 [40]。

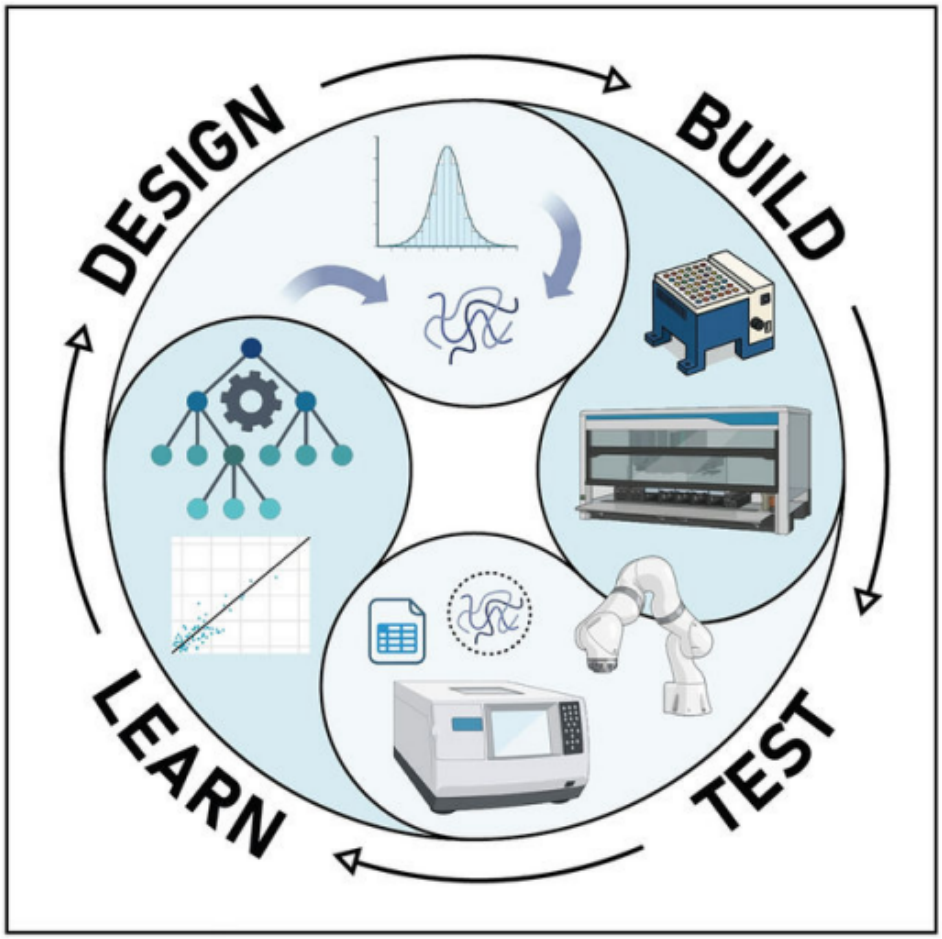


图 2.4 PolyCraft 的设计、构建、测试与学习流程。

来源：所提供资料第 11 页；保留原始图片。

这一工作的反馈目标比较清楚，模型判断某个设计可能得到更小的颗粒，实验检验这一判断，新的结果再修正模型对其他设计的预测。它验证了尺寸优化这一任务。材料的力学表现、长期稳定性和生物功能，还需要各自对应的实验。

从尺寸优化走向更广泛的软材料性能时，困难会明显增加。Loh 的观点文章《Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery》（Macromolecular Rapid Communications，2026）指出，材料制备和验证的速度，已经成为自主软材料研究的重要限制。文章特别关注那些受到加工过程影响、或者需要长时间才能确认的性质 [41]。

作者用热塑性材料和超分子水凝胶作比较。前者的表现受到熔融流动和加热冷却过程影响，后者则与水中分子的聚集过程有关。因此，干实验需要知道样品经历了什么加工，湿实验也需要记录相应条件。否则，即使最终性能数据返回了模型，模型仍可能无法解释同一配方为什么得到不同结果。这篇文章提出的是今后的研究重点，并非已经完成的平台验证 [41]。

2.4.3 光电材料与器件

光电研究尤其需要区分分子在溶液中的性质、形成薄膜后的表现，以及完整器件的性能。

Strieth-Kalthoff 等人的研究《Delocalized, asynchronous, closed-loop discovery of organic laser emitters》（Science，2024）以有机激光材料为目标，将不同地点的实验室连接起来。干实验根据已有数据对候选分子排序，湿实验在不同地点完成合成、纯化和光学测量。新结果返回后，模型更新对候选的判断，再生成新的实验优先顺序 [42]。

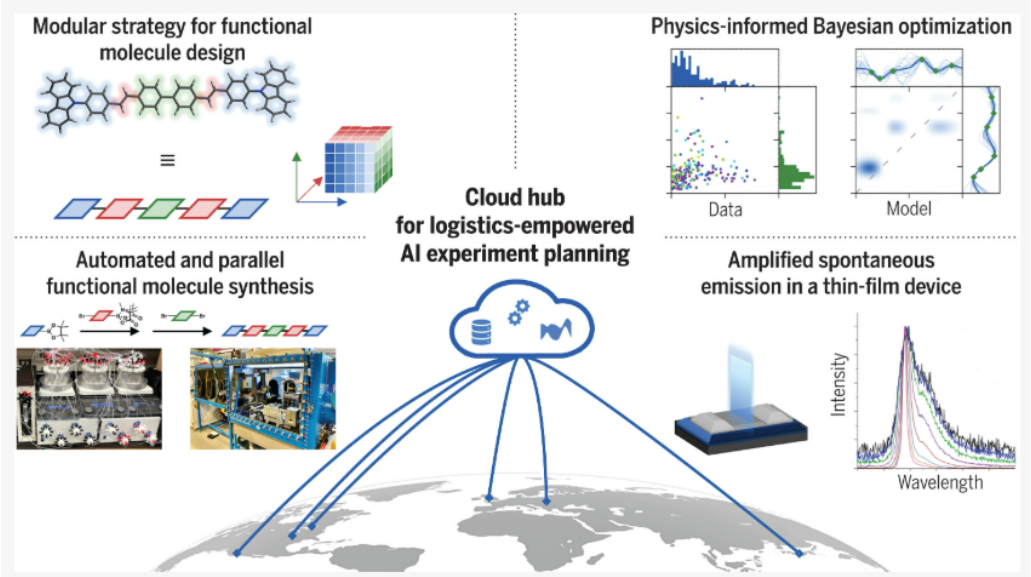


图 2.5 有机激光材料的分布式、异步闭环发现流程。

来源：所提供资料第 12 页；保留原始图片。

小贴士（图 2.5：有机激光材料的发现流程）

1. 左上：模块化功能分子设计

把分子看作由不同功能片段组合而成，通过改变分子片段及其组合，生成一系列候选分子。

2. 左下：自动化并行合成

利用自动化设备并行制备多个候选分子，减少人工操作，提高实验效率。

3. 右下：薄膜器件的 ASE 性能测试

将功能分子用于薄膜器件，测量其发射光谱，以实验数据评价材料的光学性能。

4. 右上：物理信息引导的贝叶斯优化

利用已有实验数据和物理知识，预测候选方案的表现与不确定性，辅助选择下一轮值得开展的实验。

这一过程也暴露出新的实际问题。候选分子即使具有较好的光学性质，如果难以溶解，就会增加纯化、检测和成膜的难度。Park 等人的后续研究（Nature Communications，2026）因此进一步关注有机发光分子的溶解性与发射颜色。研究通过计算预筛选和自动实验，考察了 51 个候选。它补充了材料能否加工这一要求 [43]。

从有机发光分子进一步走向太阳能电池，实验目标会更加复杂。Lee 等人的综述《Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories》（InfoMat，2026）先介绍可用的实验数据，再讨论性能预测、材料设计和表征分析，最后介绍自动实验与自主实验室。这样的安排说明，计算模型需要逐步进入真实的制备和测量过程 [44]。

这一方向的评价需要特别注意反馈指标。如果模型只接收薄膜发光强度，系统直接优化的就是这一指标。只有将器件效率、稳定性等结果纳入后续选择，才能进一步讨论器件层面的优化。该综述指出，已有工作仍较多集中在部分材料或制备步骤，多个步骤共同影响完整器件性能的问题仍然难以处理 [44]。

2.4.4 电池与电化学

光学测量通常能较快提供结果，电池寿命则可能需要数月甚至更长时间才能确认。因此，电池方向除了决定下一轮测什么，还要决定在最终结果尚未得到时，哪些早期数据可以支持下一轮选择。

Attia 等人的研究《Closed-loop optimization of fast-charging protocols for batteries with machine learning》（Nature，2020）研究快速充电策略。干实验先选择需要测试的充电方案，真实电池按这些方案运行。系统利用前期充放电数据预测最终循环寿命，再把预测结果交给优化算法，选择下一批需要测试的方案 [45]。

这里的干湿闭环包含两项计算任务。寿命预测模型负责把早期实测数据转化为寿命估计，实验选择算法负责利用这些估计安排下一批测试。论文在 16 天内从 224 个候选策略中识别出表现较好的方案，并进行了后续验证。提前预测减少了等待，但返回优化算法的寿命仍然是估计值，需要与最终测得的寿命区分 [45]。

充电策略之外，电解液研究也可以形成更直接的材料反馈。Shibukawa 等人的研究《Collecting diverse near-optimal samples via nested Thompson sampling》（npj Computational Materials，2026）将实验选择算法接入机器人电化学平台。计算端选择电解液添加剂组合，实验端配制样品并进行电化学测试，实测结果再用于选择下一批组合 [46]。

这项研究使用规定测试条件下的放电时间作为优化指标。它希望找到多个表现较好、组成又有所不同的候选。因此，新结果除了影响性能预测，也影响下一批实验是否继续探索不同的配方。这样获得的候选集合，可以为后续考虑成本、稳定性等要求保留更多选择 [46]。

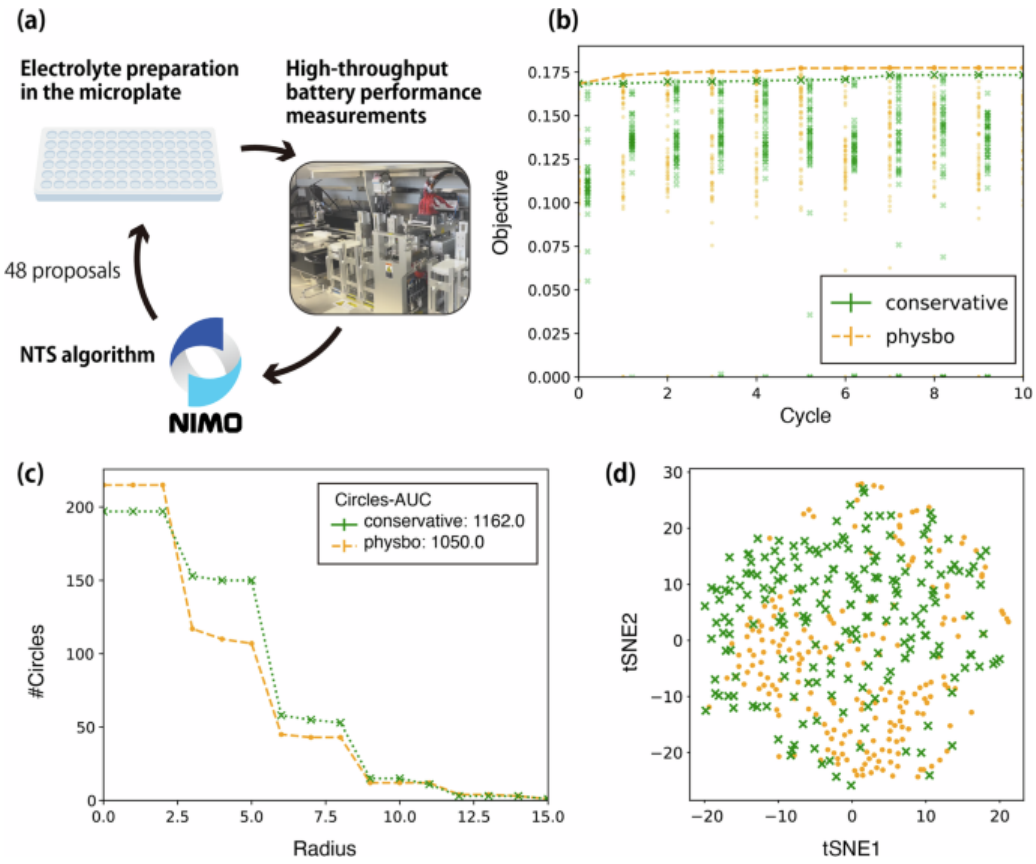


图 2.6 嵌套 Thompson 采样与电解液机器人实验平台。

来源：所提供资料第 14 页；保留原始图片。

小贴士（图 2.6：电解液配方的闭环优化）

1. 干实验：NTS 算法提出方案

根据已有的实验数据和优化目标，算法选择下一轮要测试的电解液配方。

图中标注：NTS algorithm、48 proposals

将候选方案转化为实验任务

2. 湿实验：微孔板配制电解液

按照候选配方自动配制多组电解液，为后续性能测试做准备。

图中标注：Electrolyte preparation in the microplate

进行真实电池实验

3. 湿实验：高通量电池性能测试

自动测量不同电解液对应的电池性能，图中采用的优化目标是放电时间（秒）。

小贴士（图 2.6：电解液配方的闭环优化，续）

图中标注：High-throughput battery performance measurements

将性能测量结果反馈给算法

4. 干实验：更新决策并提出新方案

算法利用最新实验数据继续选择候选配方，再次交给机器人实验平台。

循环迭代，持续优化电解液性能

2.5 生命科学中的干湿闭环

生命科学进一步涉及蛋白质的表达、细胞的生长和组织的形成。计算提出一个序列或培养方案之后，还需要观察它在真实生物系统中的表现，才能判断设计是否有效。

因此，生命科学中的干湿闭环需要把计算设计与生物功能测量连接起来。随着研究对象从单个蛋白质扩展到细胞和组织，实验返回的信息会更加复杂，验证所需的时间也往往更长。

2.5.1 蛋白质与酶工程

蛋白质设计首先面对的问题是，序列发生变化之后，功能会怎样改变。计算模型可以预测哪些序列更有希望，但蛋白质是否能够表达、是否具有活性，以及能否耐受特定条件，仍然需要实验测量。

Rapp 等人的 SAMPLE 平台（Nature Chemical Engineering，2024）以提高酶的耐热性为目标，展示了完整的干湿实验反馈过程。干实验学习已有的序列与功能数据，选择下一批需要测试的蛋白质。湿实验随后完成基因组装、蛋白质表达和生化检测，得到这些候选的实际功能数据 [47]。

实测结果返回后，系统更新对序列与耐热性关系的判断，再选择新的序列进行构建和测试。因此，下一轮实验对象会受到上一轮测量结果的影响。论文中四个独立运行的智能体最终都找到了耐热性更好的酶，相关热稳定性指标比起始序列至少提高了 12 摄氏度 [47]。

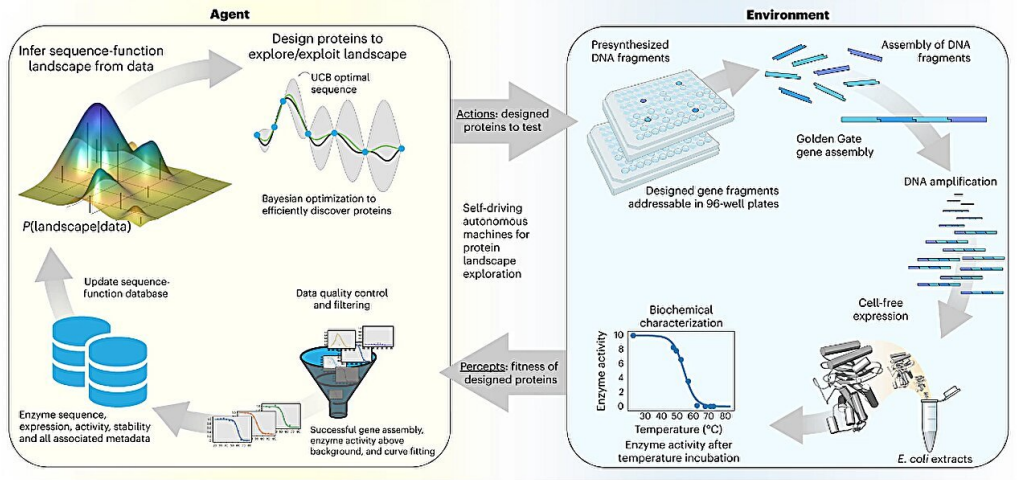


图 2.7 SAMPLE 平台中计算智能体与蛋白质实验环境的交互。

来源：所提供资料第 15 页；保留原始图片。

SAMPLE 选择了比较明确的优化目标。对于更复杂的功能，系统需要持续获得与当前任务直接相关的数据。Brooks 等人的 PRAXIS 研究《Learning protein function through autonomous experimental interaction》（bioRxiv 预印本，2026）进一步将蛋白质语言模型与机器人实验结合。模型提出蛋白质变体，实验室完成构建和功能检测，新的测量再参与后续序列设计 [48]。

这项研究让多个智能体针对不同糖底物的酶活性进行探索，并通过共享的学习模型利用彼此产生的数据。作者报告系统连续运行约一个月，获得了底物偏好明显改变的酶。这里，预训练模型提供序列设计的起点，持续开展的湿实验则帮助模型适应具体功能目标。

2.5.2 合成生物学与代谢工程

细胞生产某种物质，通常需要多个反应共同完成。不同基因的表达水平也会影响细胞生长和产物积累。因此，这一方向的干实验常常选择多个基因的组合，湿实验则测量构建后的细胞实际表现。

HamediRad 等人的 BioAutomata（Nature Communications，2019）以提高番茄红素生产表现为例，将计算选择与自动实验结合。干实验选择控制通路基因表达的组合。iBioFAB 自动实验设施随后完成 DNA 组装、导入细胞、培养和产物检测。返回计算端的是实际培养得到的番茄红素生产数据 [49]。

这些产量数据用于更新模型对基因组合的判断，再由算法选择下一批组合，交给实验平台继续构建和培养。后续实验因此可以集中到更有希望的方案，也可以测试模型尚不确定的组合。BioAutomata 展示了在预先规定的设计范围内，利用多轮实验逐步改进细胞生产表现的方法 [49]。

当多个研究项目需要重复使用构建、培养和检测设备时，可以由生物铸造厂集中提供这些能力。Cochrane 等人的综述《The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries》（Current Opinion in Biotechnology，2026）讨论了这些设施怎样进一步支持自主实验。文章将 AI 设计、细胞模拟、自动操作和小体积实验放在同一研究流程中。

从干湿闭环来看，这些技术分别解决不同问题。计算设计和模拟帮助选择值得测试的方案，自动化设备负责把方案转成真实样品，小体积实验减少测试消耗，实验数据再支持后续学习。综述还强调数据标准、设备协作和结果比较的重要性。作者同时指出，许多 AI 方法仍停留在概念验证阶段，尚未进入大规模生物铸造厂的实际运行流程 [50]。

2026 年的 iCloudBiofoundry 研究《An AI-powered cloud biofoundry for autonomous biological research》（bioRxiv 预印本，2026）提供了一个近期平台案例。其 BiofoundryAI 将研究设计转成机器人可以执行的实验任务，并收集实验数据供后续设计使用。它将计算设计和实验执行组织为可通过云端访问的服务。评价这类平台时，仍需结合具体任务，检查返回的数据是否实际改变了后续实验，以及能够持续完成多少轮研究 [51]。

2.5.3 细胞培养与组织制造

代谢工程可以通过目标产物的数量评价菌株。细胞培养则可能希望获得特定的细胞类型或状态，需要通过成像、分子标志和功能实验进行判断。因此，这一方向的干湿闭环不仅要安排实验，还需要把复杂的生物表现转成可用于选择培养条件的反馈。

Kanda 等人的研究《Robotic search for optimal cell culture in regenerative medicine》（eLife，2022）使用机器人优化诱导多能干细胞向视网膜色素上皮细胞分化的条件。干实验通过贝叶斯优化选择培养参数，湿实验由机器人执行培养和分化，再利用图像中的色素区域形成评分 [52]。

培养条件与实测评分返回计算端之后，模型更新对不同条件的预测，并选择下一批培养方案。研究在 111 天内测试了 143 种条件，色素评分比原有优化条件提高了 88%。这个结果说明实验反馈能够改进分化条件，但其中的色素评分仍是一项评价指标，需要后续生物学检测确认细胞的其他特征 [52]。

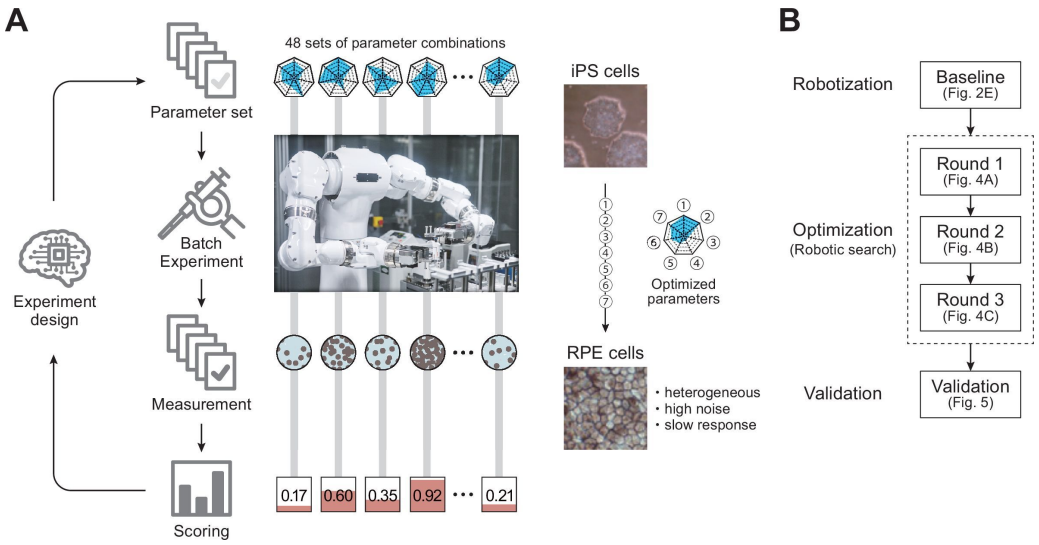


图 2.8 机器人细胞培养与条件优化。

小贴士（图 2.8：图像评分与生物学检测）

培养后的图像评分参与下一轮条件选择，进一步的生物学检测用于评价得到的细胞。

图片来自 Kanda 等（eLife，2022），原文 Figure 1。所提供 PDF 的原图号为 5.2。来源：所提供资料第 17 页；保留原始图片。

这一案例也体现了细胞实验的时间限制。每次修改培养条件之后，都需要等待细胞产生可观察的变化。因此，计算端不能只追求单次预测准确，还需要考虑一轮实验能够测试多少条件，以及什么时间能够获得足够可靠的结果。

除了选择培养方案，干湿闭环还可以用于研究生物样品对外部干预的反应。MOMbot 的研究《A Closed-Loop Robot Scientist for Autonomous Biological Discovery》（bioRxiv 预印本，2026）将刺激装置、成像系统与主动学习算法结合。在其电刺激实验中，干实验选择刺激持续时间，实验平台施加刺激并记录运动类器官的反应，算法再根据观察结果选择后续条件 [53]。

从细胞培养进一步走向组织制造，需要增加空间结构和组织成熟过程。Liu 等人的前瞻文章《Self-driving bioprinting laboratories》（Biofabrication，2026）讨论了

这一扩展。作者提出，将细胞培养、生物墨水配制、打印、后续培养和功能评价组织成能够持续反馈的平台。生物墨水是用于打印的含细胞和支撑材料的制剂 [54]。

在这一设想中，干实验选择配方、打印参数和培养条件，湿实验制备组织结构，并测量形状、细胞状态和功能。测量结果再帮助计算端调整后续打印或培养方案。与单次打印相比，这种设计将打印后的成熟过程也纳入反馈。文章讨论的是实现这一目标所需的技术和困难，并未报告已经完成全程自主组织制造的平台 [54]。

2.6 药物研发中的干湿闭环

2.6.1 药物发现与表型筛选

药物发现中的计算方法可以预测分子与靶点的相互作用，也可以根据已有实验结果选择候选。表型筛选则直接观察分子作用于细胞后产生的变化，例如细胞形态和内部结构的改变。这种实验能够为后续分子选择提供功能信息。

Piticari 等人的《Algorithm-driven, phenotype-directed bioactive molecular discovery》（Communications Chemistry，2026）将分子合成与细胞表型筛选结合。研究中的 PlatePicker 算法先从可执行的原料组合中选择一批反应。实验平台随后完成合成和产物处理，再通过 Cell Painting 检测细胞变化。Cell Painting 利用染色和成像，将细胞的不同特征转成可比较的数据 [55]。

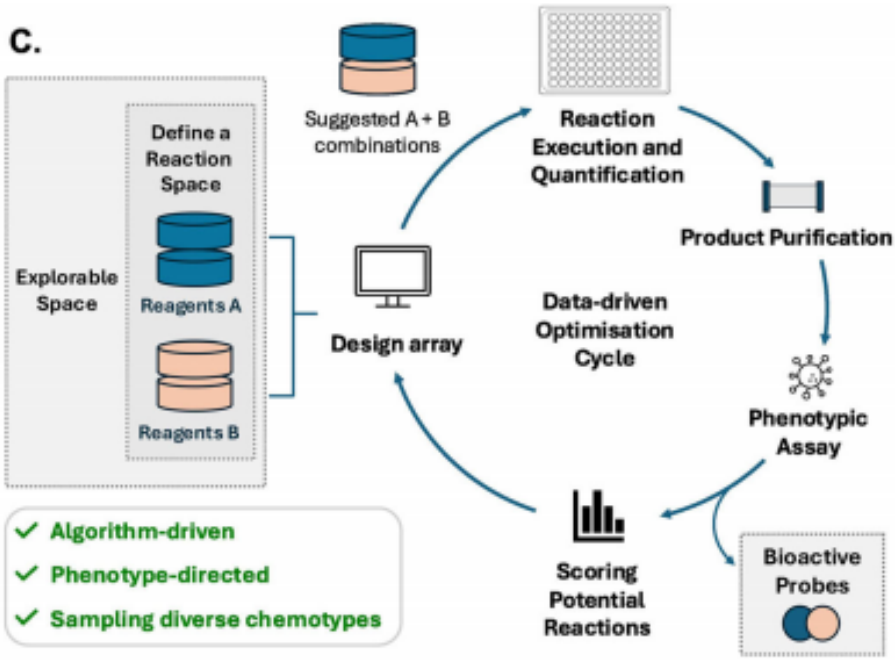


图 2.9 算法驱动的候选反应选择、自动化合成与细胞表型筛选。

来源：所提供资料第 18 页；保留原始图片。

小贴士（图 2.9：合成与表型筛选的闭环）

1. 算法设计候选反应（干实验）

算法从预先构建的虚拟反应空间中，选择合适的底物与共反应物组合，形成待执行的反应批次。这里的算法不只是分析已有数据，还会决定接下来应该做哪些实验。

2. 自动化执行化学反应（湿实验）

实验系统按照算法提出的组合执行反应，制备候选分子。自动化实验能够批量处理不同反应组合，并对反应产物进行分析。

3. 开展细胞表型筛选（湿实验）

研究人员利用 Cell Painting 等细胞表型分析方法，观察不同反应产物引起的细胞形态变化，从中识别具有潜在生物活性的候选分子。

4. 根据实验结果指导后续发现（干湿反馈）

实验筛选得到的活性结果会反馈给算法。算法根据已发现的活性分子及其对应反应组合，调整候选空间中的评分，并据此设计下一轮反应。

这里的干实验选择下一批原料组合，湿实验检验这些组合产生的分子会怎样影响细胞。获得结果后，算法根据实验评分重新评价相关原料组合，再安排下一批合成与筛选。细胞实验因此直接影响后续化学实验，而不是只在所有分子合成完成后进行一次评价 [55]。

这个案例也说明，干湿闭环中的计算端不一定需要复杂的生成模型。只要实测结果能够改变候选评分和下一轮实验选择，就可以形成有效反馈。评价系统时，需要具体检查反馈改变了哪些反应或分子的优先顺序。

Ramadurai 和 Banerjee 的综述《TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry》（npj Drug Discovery，2026）进一步讨论了如何把这类反馈扩展到生成式分子设计。文章先介绍分子结构、三维信息和细胞反应等数据，再讨论生成模型怎样设计候选，最后分析实验反馈、应用案例和现有困难 [56]。

在这一框架中，干实验综合已有数据提出候选，并考虑活性、毒性和其他性质。湿实验完成合成与生物检测，新数据再更新模型的预测和不确定性，帮助选择下一批分子 [56]。

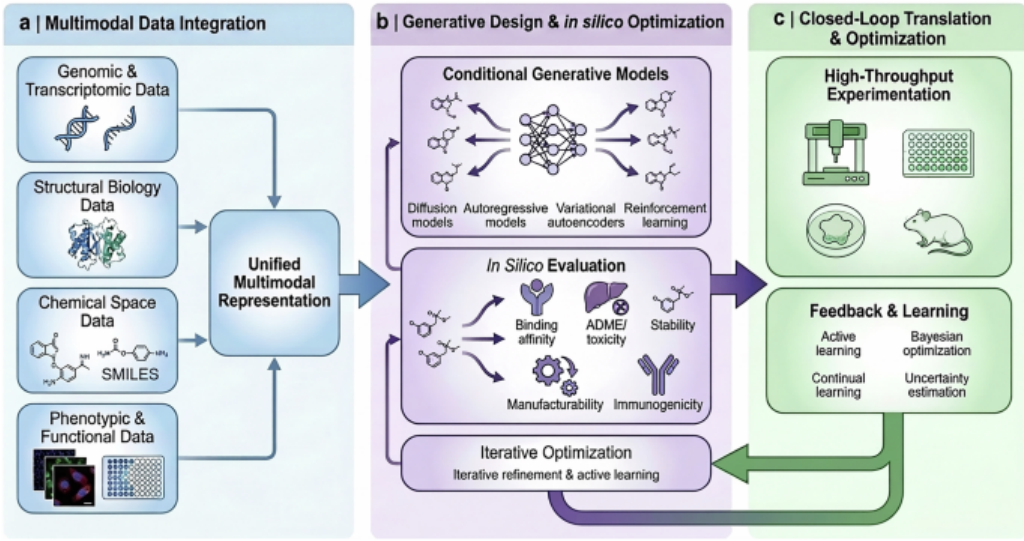


图 2.10 多模态数据、生成式分子设计与实验反馈构成的发现流程。

来源：所提供资料第 20 页；保留原始图片。

小贴士（图 2.10：多模态药物发现流程）

整体逻辑是：多种数据提供模型所需的信息 → 生成模型提出候选分子 → 计算筛选 → 实验验证 → 实验结果指导下一轮设计。

药物发现还需要避免把容易获得的实验评分直接当成最终目标。细胞出现明显变化，可能代表有用的生物作用，也可能与非特异性损伤有关。因此，下一轮选择既需要考虑是否出现目标效果，也需要逐步加入能够区分不同原因的实验。反馈指标越接近真正的研究目标，计算端的选择才越有意义。

2.6.2 药物递送与纳米制剂

具有生物活性的成分，还需要到达合适的位置并发挥作用。递送研究因此把设计对象扩展到载体分子和制剂。例如，脂质纳米颗粒可以包载核酸，但颗粒能够制成，并不保证核酸进入细胞后能够有效发挥作用。

Xu 等人的 LUMI-lab（Cell，2026）以用于 mRNA 递送的可离子化脂质为设计对象。平台将分子基础模型、主动学习与机器人实验结合。干实验利用预训练得到的分子表示和已有功能数据，选择下一批脂质候选。湿实验随后合成脂质、制备纳米颗粒，并在细胞中检测 mRNA 转染表现 [57]。

细胞实验结果返回后，模型利用这些数据进行更新，主动学习算法再选择新的脂质，进入下一轮合成、制剂和测试。因此，反馈改变的是载体分子的选择。论文报告合成和筛选了超过 1,700 种脂质纳米颗粒，并获得了在人支气管细胞中递送表现更好的候选 [57]。

LUMI-lab 的多轮选择主要由细胞实验提供反馈，优选候选之后再进行动物验证。两者承担不同任务。细胞筛选帮助较快比较候选，动物实验进一步检查体内表现。不能把后续动物验证写成每一轮自动优化都包含的步骤。

与选择载体分子相比，制剂研究还需要回答另一个问题。同一种材料在不同制备条件下，能否稳定得到符合要求的颗粒?

Sagmeister 等人的《Autonomous Lipid Nanoparticle Engineering》（ACS Nano，2026）针对这一问题建立了自主工艺开发平台。干实验选择制备参数，湿实验按这些参数生产颗粒，并通过在线动态光散射测量粒径。新测量结果随后参与优化，指导下一次制备条件的选择 [58]。

这项研究把颗粒尺寸相关指标作为反馈，用于寻找满足要求的生产条件。与 LUMI-lab 相比，两者改变的对象不同。LUMI-lab 根据细胞递送表现选择脂质分子，这个平台根据粒径测量调整制备工艺。它们可以支持同一类产品研发，但需要分别评价各自完成的任务 [57, 58]。

Panagiotakopoulou 等人的综述《Artificial intelligence and machine learning in nanoparticle drug delivery systems》（Nature Reviews Bioengineering，2026）为这些不同任务提供了较完整的分类。文章从纳米颗粒的配方设计讲到临床前评价，既讨论脂质颗粒，也讨论聚合物和其他自组装颗粒 [59]。

在制备阶段，模型可以预测粒径和药物包封情况。在细胞实验阶段，需要评价摄取、转染和毒性。进入动物研究后，还需要分析颗粒在不同器官和组织中的分布。每个阶段需要的实验数据不同，也决定了干湿闭环能够优化什么 [59]。

综述还指出，模型选择受到数据规模限制。纳米制剂研究常常只有较少样本，树模型和高斯过程等方法具有实际价值，深度学习则更依赖规模较大且记录一致的数据。因此，平台建设需要同时考虑实验能产生多少可靠数据，以及这些数据是否足以支持所选择的模型 [59]。

从这些研究可以看出，药物递送中的实验反馈至少需要区分制备质量、细胞功能和体内表现。粒径符合要求，是后续评价的基础。细胞中的递送效果改善，则提供了进一步开展体内研究的理由。每增加一层验证，都需要新的实验依据。

教学补充：本章小结

自主实验室将候选选择、实验执行和结果回传组织为持续迭代的研究过程。不同领域的反馈指标、实验时长和可执行约束不同，评价时需要分别检查实验是否可靠完成、结果是否可解释，以及新结果是否实际改变了后续选择。

教学补充：实践任务

为一个案例绘制候选—执行—测量—更新图，并列出样品标识、质量控制、成本与停止条件。

思考与练习

1. 原文案例采用的代理评分，和最终科学目标之间还差哪一层验证？
2. 选择两个领域案例，比较其决策变量、测量指标、模型更新方式与停止条件。
3. 如果一次测试失败，如何判断是样品性能不佳还是实验执行故障？

参考文献

[1] DING K, ZHU Z, et al. Bridging data and discovery: a survey on knowledge graphs in AI for science[J/OL]. National Science Review, 2026, 13(8): nwag140. DOI: 10.1093/nsr/nwag140.

[2] CHALK S J. SciData: a data model and ontology for semantic representation of scientific data[J/OL]. Journal of Cheminformatics, 2016, 8: 54. DOI: 10.1186/s13321-016-0168-9.

[3] ZHANG Q, DING K, LV T, et al. Scientific Large Language Models: A Survey on Biological & Chemical Domains[J/OL]. ACM Computing Surveys, 2025, 57(6): 161. DOI: 10.1145/3715318.

[4] The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods[J/OL]. Nucleic Acids Research, 2024. DOI: 10.1093/nar/gkad1004.

[5] BindingDB in 2024: a FAIR knowledgebase of protein-small molecule binding data[J/OL]. Nucleic Acids Research, 2025. DOI: 10.1093/nar/gkae1075.

[6] A review of biomedical datasets relating to drug discovery: a knowledge graph perspective [J/OL]. Briefings in Bioinformatics, 2022. DOI: 10.1093/bib/bbac404.

[7] KEARNES S M, et al. The Open Reaction Database[J/OL]. Journal of the American Chemical Society, 2021, 143: 18820-18826. DOI: 10.1021/jacs.1c09820.

[8] ABEYRUWAN S, et al. Evolving BioAssay Ontology (BAO): modularization, integration and applications[J/OL]. Journal of Biomedical Semantics, 2014, 5(Suppl 1): S5. DOI: 10.1186/2041-1480-5-S1-S5.

[9] GLENNY-PESCOV J, CHUNG C, et al. Advancing the bioassay ontology through integrated PK/PD and safety pharmacology representation[J/OL]. Journal of Biomedical Semantics, 2026, 17: 6. DOI: 10.1186/s13326-025-00342-5.

[10] FU F, LI Q Q, WANG F, et al. Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation[J/OL]. National Science Review, 2025, 12: nwaf271. DOI: 10.1093/nsr/nwaf271.

[11] CHANDAK P, HUANG K, ZITNIK M. Building a knowledge graph to enable precision medicine[J/OL]. Scientific Data, 2023, 10: 67. DOI: 10.1038/s41597-023-01960-3.

[12] iKraph: A comprehensive large-scale biomedical knowledge graph for AI-powered data-driven biomedical research[J/OL]. Nature Machine Intelligence, 2025. DOI: 10.1038/s42256-025-01014-w.

[13] Accessing scientific data through knowledge graphs with Ontop[J/OL]. Patterns, 2021. DOI: 10.1016/j.patter.2021.100346.

[14] PROV-O: The PROV Ontology[EB/OL]. W3C Recommendation, 2013. https://www.w3.org/TR/prov-o/.

[15] RAO J, QIU Y, ZHANG J, et al. SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery[EB/OL]. 2026. arXiv: 2602.09132. https://arxiv.org/abs/2602.09132.

[16] DING K, YU J, HUANG J, et al. SciToolAgent: a knowledge-graph-driven scientific agent for multitool integration[J/OL]. Nature Computational Science, 2025, 5: 962-972. DOI: 10.1038/s43588-025-00849-y.

[17] JIANG Y, LOU W, WANG L, et al. SCP: Accelerating Discovery with a Global Web of Autonomous Scientific Agents[EB/OL]. 2025. arXiv: 2512.24189. https://arxiv.org/abs/2512.24189.

[18] SciGraph-Bio SCP Server[EB/OL]. SCP Hub 官方项目技术文档, 2026. https://scphub.intern-ai.org.cn/detail/38.

[19] HUANG X, LONG Q, DU X, et al. Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale[EB/OL]. 2026. arXiv: 2608.19625v2. https://arxiv.org/abs/2608.19625v2.

[20] FANG Y, LIANG X, ZHANG N, et al. Mol-Instructions: A Large-Scale Biomolecular Instruction Dataset for Large Language Models[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/d346d91999074dd8d6073d4c3b13733b-Abstract-Conference.html.

[21] FENG K, DING K, et al. SciKnowEval: Evaluating Multi-level Scientific Knowledge of Large Language Models[EB/OL]. 2024. arXiv: 2406.09098. https://arxiv.org/abs/2406.09098.

[22] LUO Y, LIU X Y, YANG K, et al. KEDD: Toward Unified AI Drug Discovery with Multimodal Knowledge[J/OL]. Health Data Science, 2024, 4: 0113. DOI: 10.34133/hds.0113.

[23] LUO Y, YANG K, HONG M, et al. Learning Multi-view Molecular Representations with Structured and Unstructured Knowledge[C/OL]//KDD. 2024: 2082-2093. DOI: 10.1145/3637528.3672043.

[24] DAGDELEN J, DUNN A, et al. Structured information extraction from scientific text with large language models[J/OL]. Nature Communications, 2024, 15: 1418. DOI: 10.1038/s41467-024-45563-x.

[25] MO B, YU K, KAZDAN J, et al. KGGen: Extracting Knowledge Graphs from Plain Text with Language Models[C/OL]//NeurIPS. 2025. https://neurips.cc/virtual/2025/poster/117386.

[26] VAN WEESEP L, TEDOLDI R, et al. Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?[EB/OL]. 2026. arXiv: 2610.01616. https://arxiv.org/abs/2610.01616.

[27] SOMAN K, ROSE P W, et al. Biomedical knowledge graph-optimized prompt generation for large language models[J/OL]. Bioinformatics, 2024, 40: btae560. DOI: 10.1093/bioinformatics/btae560.

[28] LUO L, LI Y F, HAFFARI G, et al. Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/3e2aeb66481dd63a32421bf032b70384-Abstract-Conference.html.

[29] LUO L, ZHAO Z, HAFFARI G, et al. Graph-constrained Reasoning: Faithful Reasoning on Knowledge Graphs with Large Language Models[C/OL]//Proceedings of Machine Learning Research: Vol. 267 ICML. 2025: 41540-41565. https://proceedings.mlr.press/v267/luo25t.html.

[30] DENG Y, ERICKSEN S S, GITTER A. Assay2Mol: Large Language Model-based Drug Design Using BioAssay Context[C/OL]//EMNLP. 2025: 27337-27362. https://aclanthology.org/2025.emnlp-main.1390/.

[31] MATSUMOTO N, MORAN J, CHOI H, et al. KRAGEN: a knowledge graph-enhanced RAG framework for biomedical problem solving using large language models[J/OL]. Bioinformatics, 2024, 40: btae353. DOI: 10.1093/bioinformatics/btae353.

[32] MATSUMOTO N, CHOI H, MORAN J, et al. ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning[J/OL]. Bioinformatics, 2025, 41: btaf031. DOI: 10.1093/bioinformatics/btaf031.

[33] HUANG K, CHANDAK P, WANG Q, et al. A foundation model for clinician-centered drug repurposing[J/OL]. Nature Medicine, 2024, 30: 3601-3613. DOI: 10.1038/s41591-024-03233-x.

[34] LEE H, YOO H J, JANG H S, et al. Toward self-driving laboratory 2.0 for chemistry and materials discovery[J/OL]. Materials Horizons, 2026. DOI: 10.1039/D5MH01984B.

[35] PILON S, SAVINO E, BAYLEY O M, et al. A flexible and affordable self-driving laboratory for automated reaction optimization[J/OL]. Nature Synthesis, 2026. DOI: 10.1038/s44160-026-01053-0.

[36] BENNETT J A, OROUJI N, VELAYATI A, et al. An autonomous lab for data-driven homogeneous catalysis[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-74425-x.

[37] BURGER B, MAFFETTONE P M, GUSEV V V, et al. A mobile robotic chemist[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-2442-2.

[38] SZYMANSKI N J, RENDY B, FEI Y, et al. An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06734-w.

[39] FEI Y, RENDY B, YANG X, et al. Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2604.11957.

[40] SUPONYA A, DI MARE E, RAMÍREZ C, et al. Self-driving lab for the data-driven design of single-chain polymer nanoparticles[J/OL]. Cell Press Blue, 2026. DOI: 10.1016/j.cpblue.2026.100033.

[41] LOH X J. Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery[J/OL]. Macromolecular Rapid Communications, 2026. DOI: 10.1002/marc.70420.

[42] STRIETH-KALTHOFF F, HAO H, RATHORE V, et al. Delocalized, asynchronous, closed-loop discovery of organic laser emitters[J/OL]. Science, 2024. DOI: 10.1126/science.adk9227.

[43] PARK H S, MAZAHERI M, CHOI C, et al. Discovery of tunable and soluble organic emitters for solid-state lasers with a self-driving laboratory[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69233-2.

[44] LEE J, NOH J, LEE H, et al. Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories[J/OL]. InfoMat, 2026. DOI: 10.1002/inf2.70124.

[45] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-1994-5.

[46] SHIBUKAWA R, MATSUDA S, NAKAMURA K, et al. Collecting diverse near-optimal samples via nested Thompson sampling[J/OL]. npj Computational Materials, 2026. DOI: 10.1038/s41524-026-02067-0.

[47] RAPP J T, BREMER B J, ROMERO P A. Self-driving laboratories to autonomously navigate the protein fitness landscape[J/OL]. Nature Chemical Engineering, 2024. DOI: 10.1038/s44286-023-00002-4.

[48] BROOKS C, NOTIN P, ROMERO P A. Learning protein function through autonomous experimental interaction[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.08.14.744985.

[49] HAMEDIRAD M, CHAO R, WEISBERG S, et al. Towards a fully automated algorithm driven platform for biosystems design[J/OL]. Nature Communications, 2019. DOI: 10.1038/s41467-019-13189-z.

[50] COCHRANE R R, DOS SANTOS L V, CAI Y. The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103503.

[51] CHEN J, VOLK M, SHAFAEI S, et al. An AI-powered cloud biofoundry for autonomous biological research[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.30.750244.

[52] KANDA G N, TSUZUKI T, TERADA M, et al. Robotic search for optimal cell culture in regenerative medicine[J/OL]. eLife, 2022. DOI: 10.7554/eLife.77007.

[53] BIELAWSKI K, SRINIVASAN K, GAYLINN N, et al. A Closed-Loop Robot Scientist for Autonomous Biological Discovery[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.11.751076.

[54] LIU S, KAUR N, SONG D H, et al. Self-driving bioprinting laboratories[J/OL]. Biofabrication, 2026. DOI: 10.1088/1758-5090/ae3645.

[55] PITICARI A S, GRIGGS S D, CRAWFORD L, et al. Algorithm-driven, phenotype-directed bioactive molecular discovery[J/OL]. Communications Chemistry, 2026. DOI: 10.1038/s42004-026-02066-8.

[56] RAMADURAI K, BANERJEE A. TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry[J/OL]. npj Drug Discovery, 2026. DOI: 10.1038/s44386-026-00078-x.

[57] XU Y, CUI H, PANG K, et al. LUMI-lab: A foundation model-driven autonomous platform enabling discovery of ionizable lipid designs for mRNA delivery[J/OL]. Cell, 2026. DOI: 10.1016/j.cell.2026.01.012.

[58] SAGMEISTER P, UDEPURKAR A, DEVOS C, et al. Autonomous Lipid Nanoparticle Engineering[J/OL]. ACS Nano, 2026. DOI: 10.1021/acsnano.6c15600.

[59] PANAGIOTAKOPOULOU M, GOREN A, REKER D, et al. Artificial intelligence and machine learning in nanoparticle drug delivery systems[J/OL]. Nature Reviews Bioengineering, 2026. DOI: 10.1038/s44222-026-00495-7.

[60] KAPOOR S, CANTRELL E M, PENG K, et al. REFORMS: Consensus-based Recommendations for Machine-learning-based Science[J/OL]. Science Advances, 2024, 10(18): eadk3452. DOI: 10.1126/sciadv.adk3452.

[61] ERIKSSON M, PURIFICATO E, NOROOZIAN A, et al. Can We Trust AI Benchmarks? An Interdisciplinary Review of Current Issues in AI Evaluation[C/OL]//Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society: Vol. 8. 2025: 850-864. DOI: 10.1609/aies.v8i1.36595.

[62] NAGESHWARAN V, EZEKIEL S, TRAN T T, et al. Large language model agent evaluation and benchmarking: a systematic survey, meta-taxonomy, and critical research roadmap [J/OL]. Artificial Intelligence Review, 2026. DOI: 10.1007/s10462-026-11678-4.

[63] YEHUDAI A, EDEN L, LI A, et al. A Survey on Evaluation of LLM-based Agents[C/OL]// Findings of the Association for Computational Linguistics: ACL 2026. 2026: 26690-26714. DOI: 10.18653/v1/2026.findings-acl.1330.

[64] SAEZ-RODRIGUEZ J, SCHÄFER P S L, KALAVROS N, et al. Benchmarking biomedical foundation models[J/OL]. Nature Methods, 2026, 23: 1724-1733. DOI: 10.1038/s41592-026-03182-y.

[65] ZHENG T, DENG Z, TSANG H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 17733-17750. DOI: 10.18653/v1/2025.emnlp-main.895.

[66] MIRZA A, ALAMPARA N, KUNCHAPU S, et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists[J/OL]. Nature Chemistry, 2025, 17: 1027-1034. DOI: 10.1038/s41557-025-01815-x.

[67] Center for AI Safety, Scale AI, HLE Contributors Consortium. A benchmark of expert-level academic questions to assess AI capabilities[J/OL]. Nature, 2026, 649: 1139-1146. DOI: 10.1038/s41586-025-09962-4.

[68] RIEBESELL J, GOODALL R E A, BENNER P, et al. A framework to evaluate machine learning crystal stability predictions[J/OL]. Nature Machine Intelligence, 2025, 7: 836-847. DOI: 10.1038/s42256-025-01055-1.

[69] ZENI C, PINSLER R, ZÜGNER D, et al. A generative model for inorganic materials design [J/OL]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[70] CHEN Z, CHEN S, NING Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/f12b4df26344f3be803c06b555252efe-Abstract-Conference.html.

[71] STARACE G, JAFFE O, SHERBURN D, et al. PaperBench: Evaluating AI's Ability to Replicate AI Research[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 56843-56873. https://proceedings.mlr.press/v267/starace25a.html.

[72] WANG Z, BAI F, LUO Z, et al. FIRE-Bench: Evaluating AI Agents on the Rediscovery of Scientific Insights[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 124896-124929. https://proceedings.mlr.press/v306/wang26d.html.

[73] ZHANG K, LI Y. Are We Measuring Scientific Intelligence? Rethinking the Evaluation of AI Scientists[EB/OL]. (2026-10-04)[2026-10-18]. https://arxiv.org/abs/2610.04915.

[74] JOERES R, BLUMENTHAL D B, KALININA O V. Data splitting to avoid information leakage with DataSAIL[J/OL]. Nature Communications, 2025, 16: 3337. DOI: 10.1038/s41467-025-58606-8.

[75] JOERES R, BLUMENTHAL D B, KALININA O V. Addendum: Data splitting against information leakage with DataSAIL[J/OL]. Nature Communications, 2026, 17: 1597. DOI: 10.1038/s41467-025-67495-w.

[76] CHEN S, CHEN Y, LI Z, et al. Benchmarking Large Language Models Under Data Contamination: A Survey from Static to Dynamic Evaluation[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. 2025: 10080-10098. DOI: 10.18653/v1/2025.emnlp-main.511.

[77] SUN Y, WANG H, LI D, et al. The emperor's new clothes in benchmarking? A rigorous examination of mitigation strategies for LLM benchmark data contamination[C/OL]// Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 57728-57753. https://proceedings.mlr.press/v267/sun25t.html.

[78] WANG H, LI H, KO B, et al. On the fragility of benchmark contamination detection in reasoning models[C/OL]//International Conference on Learning Representations. 2026. https://proceedings.iclr.cc/paper_files/paper/2026/hash/a3860475ddbfb8c644c43f0dcd266b66-Abstract-Conference.html.

[79] WHITE C, DOOLEY S, ROBERTS M, et al. LiveBench: A challenging, contamination-limited LLM benchmark[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/e4a46394ba5378b3f9a186a5b4c650d1-Abstract-Conference.html.

[80] ZHOU L, PACCHIARDI L, MARTÍNEZ-PLUMED F, et al. General scales unlock AI evaluation with explanatory and predictive power[J/OL]. Nature, 2026, 652: 58-67. DOI: 10.1038/s41586-026-10303-2.

[81] BUTTENSCHOEN M, MORRIS G M, DEANE C M. PoseBusters: AI-based docking methods fail to generate physically valid poses or generalise to novel sequences[J/OL]. Chemical Science, 2024, 15: 3130-3139. DOI: 10.1039/D3SC04185A.

[82] OHANA R, MCCABE M, MEYER L, et al. The Well: a Large-Scale Collection of Diverse Physics Simulations for Machine Learning[C/OL]//Advances in Neural Information Processing Systems 37, Datasets and Benchmarks Track. 2024. DOI: 10.52202/079017-1430.

[83] GU J, JIANG X, SHI Z, et al. A survey on LLM-as-a-judge[J/OL]. The Innovation, 2026, 7(6): 101253. DOI: 10.1016/j.xinn.2025.101253.

[84] SHORINWA O, MEI Z, LIDARD J, et al. A Survey on Uncertainty Quantification of Large Language Models: Taxonomy, Open Research Challenges, and Future Directions[J/OL]. ACM Computing Surveys, 2025, 58(3): 63. DOI: 10.1145/3744238.

[85] SEHWAG U M, LAU E, OSKOUIE H E, et al. SciPredict: Can LLMs Predict the Outcomes of Scientific Experiments in Natural Sciences?[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 108784-108827. https://proceedings.mlr.press/v306/sehwag26a.html.

[86] CAO Y, LAI S, HUANG J, et al. SimulCost: A Cost-Aware Benchmark and Toolkit for Automating Physics Simulations with LLMs[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 11206-11254. https://proceedings.mlr.press/v306/cao26g.html.

[87] ZHOU Y, YANG J, HUANG Y, et al. Benchmarking large language models on safety risks in scientific laboratories[J/OL]. Nature Machine Intelligence, 2026, 8: 20-31. DOI: 10.1038/s42256-025-01152-1.

[88] AHLMANN-ELTZE C, HUBER W, ANDERS S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines[J/OL]. Nature Methods, 2025, 22: 1657-1661. DOI: 10.1038/s41592-025-02772-6.

[89] SONG Y, WANG G, LI S, et al. The Good, The Bad, and The Greedy: Evaluation of LLMs Should Not Ignore Non-Determinism[C/OL]//Proceedings of NAACL-HLT 2025, Volume 1: Long Papers. 2025: 4195-4206. DOI: 10.18653/v1/2025.naacl-long.211.

[90] WADI D, FREDETTE M. A Monte-Carlo Sampling Framework For Reliable Evaluation of Large Language Models Using Behavioral Analysis[C/OL]//Findings of the Association for Computational Linguistics: EMNLP 2025. 2025: 9414-9432. DOI: 10.18653/v1/2025.findings-emnlp.500.

[91] WENTELER A, OCCHETTA M, BRANSON N, et al. PertEval-scFM: Benchmarking Single-Cell Foundation Models for Perturbation Effect Prediction[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 66633-66677. https://proceedings.mlr.press/v267/wenteler25a.html.

[92] WEI Z, WANG Y, GAO Y, et al. Benchmarking algorithms for generalizable single-cell perturbation response prediction[J/OL]. Nature Methods, 2026, 23: 451-464. DOI: 10.1038/s41592-025-02980-0.

[93] RASP S, HOYER S, MEROSE A, et al. WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models[J/OL]. Journal of Advances in Modeling Earth Systems, 2024, 16: e2023MS004019. DOI: 10.1029/2023MS004019.

[94] LIU Y, ZHOU L, DU X, et al. Benchmarking LLM-based agents for single-cell omics analysis[J/OL]. Genome Biology, 2026, 27: 123. DOI: 10.1186/s13059-026-03998-z.

[95] TOM G, SCHMID S P, BAIRD S G, et al. Self-Driving Laboratories for Chemistry and Materials Science[J/OL]. Chemical Reviews, 2024. DOI: 10.1021/acs.chemrev.4c00055.

[96] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06792-0.

[97] SZYMANSKI N J, RENDY B, FEI Y, et al. Author Correction: An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2026. DOI: 10.1038/s41586-025-09992-y.

[98] ZHANG T, LIN H, CHEN Y, et al. SALSA: a low-cost self-driving lab modular add-on for salt solubility assessment for battery electrolytes[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00516G.

[99] ALLU S G, HASNAIN R, VOS A, et al. AI-driven approaches for navigating battery complexity[J/OL]. EES Batteries, 2026. DOI: 10.1039/D6EB00101G.

[100] VOLK M, KAUSHIK PILLALAMARRI V, GUO R, et al. Artificial intelligence tools for enzyme engineering and metabolic engineering[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103522.

[101] OATMAN H R, LAD B C, NGUYEN L, et al. An optogenetic smart microscopy platform reveals signaling dynamics-dependent control over collective cell migration[J/OL]. Cell Systems, 2026. DOI: 10.1016/j.cels.2026.101674.

[102] HWANG J, KIM S, LIM S, et al. Self-driving laboratories in Korea: a new era of autonomous discovery[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D6DD00024J.

[103] ZHU Q, ZHANG F, HUANG Y, et al. An all-round AI-Chemist with a scientific mind [J/OL]. National Science Review, 2022. DOI: 10.1093/nsr/nwac190.

[104] FENG S, MA R, et al. InternAgent-1.5: A Unified Agentic Framework for Long-Horizon Autonomous Scientific Discovery[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2602.08990.

[105] ADESIJI A D, WANG J, KUO C S, et al. Benchmarking self-driving labs[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00337G.

[106] CANTY R B, ABOLHASANI M. The past, present and future of self-driving laboratories [J/OL]. Nature Reviews Chemistry, 2026. DOI: 10.1038/s41570-026-00847-2.

[107] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for scientific data management and stewardship[J/OL]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.

[108] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for datasets[J/OL]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.

[109] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J/OL]. Patterns, 2023, 4(9): 100804. DOI: 10.1016/j.patter.2023.100804.