AI FOR SCIENCE

科学智能

原理与实践

鄂海红　徐坤　著



Copyright © 2026 BUPT AI4S

前　言

《科学智能原理与实践》面向理工科高年级本科生、研究生和从事跨学科研究的科研人员，关注人工智能如何参与科学问题的提出、建模、验证与迭代。

本书以科学问题为起点，强调从观测到证据、从预测到验证、从单次建模到持续反馈的联系。数据和知识的组织决定了模型能够读取什么证据，实验执行与测量反馈则决定了候选方案能否接受真实检验。

第一章“科学知识建模与大模型推理”讨论结构化记录、本体、知识图谱及其在模型推理中的作用；第二章“自主实验室与干湿闭环”讨论计算决策、实验执行和结果回传在不同领域的实现；第三章“科学智能的测评数据构建与可信评价”讨论能力目标、测试构建、评价指标与可信测评协议。

各章结合研究案例、图表与学习目标展开讨论，参考文献统一列于书末，便于读者延伸阅读。

鄂海红　徐坤

2026 年 10 月

阅读指南

建议具备基础机器学习、数据管理和实验设计知识。阅读具体案例时，可按研究需要补充化学、生命科学或材料科学背景。

内容与阅读顺序

第一章“科学知识建模与大模型推理”介绍如何组织科学对象、实验条件和来源，并将知识用于检索、推理与候选设计。第二章“自主实验室与干湿闭环”进一步讨论如何把计算提出的候选交给实验系统，以及如何用实测结果改变下一轮决策。第三章“科学智能的测评数据构建与可信评价”讨论如何设计任务和测试数据，以及如何用评价方法与运行协议支持可靠的能力判断。

三章可以依次阅读，也可从关注的主题切入。阅读知识建模案例时，应区分事实记录、逻辑推理与模型生成的解释；阅读自主实验室案例时，应检查实验反馈是否实际改变了后续选择；阅读测评案例时，应检查能力主张、测试条件和验证证据是否对应。章末和书末的来源信息可用于回到原文核查。

符号表

a, b	标量
$\boldsymbol{x} \in \mathbb{R}^d$	d 维实向量
$\boldsymbol{X} \in \mathbb{R}^{n \times d}$	包含 n 个样本的特征矩阵
$\boldsymbol{X}^\top$	矩阵的转置
$\mathcal{D}$	数据集
f_θ	参数为 θ 的模型
$\hat{y}$	模型预测值
$\mathcal{L}$	损失函数
∇_θ	关于参数 θ 的梯度
$\lVert \cdot \rVert_2$	向量的二范数
$\mathbb{E}[\cdot]$	数学期望
$\mathbb{P}(\cdot)$	概率
$\arg\min$	使目标函数达到最小值的自变量

本表用于统一全书记号。正式写作时，请在首次使用一个符号的地方说明其含义、单位及取值范围。

目录

第一章 科学知识建模与大模型推理 1

1.1 科学知识建模的定义与范围 1

1.1.1 从科学数据走向科学知识 2

1.1.2 大模型带来了什么变化 3

1.2 为什么需要科学知识建模 3

1.2.1 数据能够读取并不代表含义已经统一 3

1.2.2 科学结果依赖实验条件 5

1.2.3 模型的回答需要能够核查和更新 6

1.3 现有研究怎样组织科学知识 6

1.3.1 用结构化记录保存一次实验 6

1.3.2 用本体统一概念并表达分类条件 9

1.3.3 用知识图谱连接对象和过程 11

1.3.4 保留来源并组合多种存储方式 13

1.3.5 把数据整理、工具知识和访问接口分别建模 15

1.3.6 用 skill 理解和使用一个数据集 15

1.4 哪些团队在做以及进展到了哪里 16

1.4.1 浙江大学知识引擎实验室及相关合作团队 16

1.4.2 上海人工智能实验室及与浙江大学的合作 16

1.4.3 清华大学、厦门大学与中科院相关团队 18

1.4.4 国际数据资源与领域模型团队 18

1.4.5 自动抽取与知识使用团队 19

1.4.6 图谱推理与候选设计团队 20

1.5 怎样把数据变成可用知识 22

1.5.1 Cat-KG 从催化文献到接力反应路线 22

1.5.2 SciDataCopilot 把原始数据组织为可计算的数据单元 26

1.6 建模后的知识怎样被大模型使用 27

1.6.1 提供带来源的检索上下文 27

1.6.2 规划并检查多步关系 30

1.6.3 用实验背景指导候选设计 32

1.6.4 用知识训练分子模型并调用专门的预测模型 32

1.7 局限性与仍需解决的问题 35
1.7.1 原始证据不完整会限制一切后续步骤 35
1.7.2 领域差异很难被一个通用模式完全覆盖 35
1.7.3 图谱路径和语言解释都不等同于科学证据 36
1.7.4 现有评估距离实际研发成效仍有差距 36
1.7.5 知识维护与数据偏差仍需长期处理 37
1.8 结语 37

第二章 自主实验室与干湿闭环 39
2.1 自主实验室是什么 39
2.2 自主实验室中的干湿闭环 39
2.2.1 一轮干湿闭环怎样完成 39
2.2.2 闭环怎样才能可靠运行 40
2.3 化学研究中的干湿闭环 40
2.3.1 有机合成 40
2.3.2 催化研究 44
2.3.3 移动机器人怎样把不同实验站接入闭环 46
2.4 材料研究中的干湿闭环 46
2.4.1 无机材料与固态合成 46
2.4.2 高分子与软材料 49
2.4.3 光电材料与器件 51
2.4.4 电池与电化学 53
2.5 生命科学中的干湿闭环 55
2.5.1 蛋白质与酶工程 55
2.5.2 合成生物学与代谢工程 56
2.5.3 细胞培养与组织制造 57
2.6 药物研发中的干湿闭环 59
2.6.1 药物发现与表型筛选 59
2.6.2 药物递送与纳米制剂 62

第三章 科学智能的测评数据构建与可信评价 65
3.1 引言 65
3.2 科学智能测评的能力对象：从单项任务到科学发现（测什么） 66
3.2.1 单项科学任务能力 67
3.2.2 研究工作流执行能力 69
3.2.3 科学发现能力 71

3.3 科学智能测试的构建：从任务定义到质量验证 72
3.3.1 任务定义：将能力目标转化为可执行问题 73
3.3.2 参考答案：建立与任务性质相适应的判定依据 74
3.3.3 数据划分：使测试条件对应预期泛化场景 75
3.3.4 污染控制：覆盖训练、更新与测试执行过程 77
3.3.5 质量要求：验证测试能否支持预期的能力判断 79
3.4 评价方法与指标选择（如何评价） 80
3.4.1 客观指标与科学决策目标 80
3.4.2 可执行验证与科学约束 80
3.4.3 专家评价与模型评委 81
3.4.4 不确定性、校准与选择性使用 81
3.4.5 成本、效率与实验安全 82
3.5 测评协议与结论可信性（如何保证结论可信） 82
3.5.1 比较条件与基线选择 82
3.5.2 随机性与统计比较 83
3.5.3 外部验证与前瞻性验证 83
3.5.4 版本管理与可审计报告 84
3.6 代表性研究的比较与主题演进 84
3.6.1 封闭式知识测评正在补充专业任务维度 84
3.6.2 科学预测测评转向任务相关指标与条件泛化 85
3.6.3 智能体测评从任务产物扩展到证据生成过程 85
3.6.4 可靠性与资源约束成为科学效用的一部分 86
3.7 主要不足与研究方向 87
3.7.1 建立能力主张与验证证据的对应关系 87
3.7.2 在开放发现任务中保留可检验性 87
3.7.3 改善测评数据与评分器的共同治理 87
3.7.4 评价人机协作与真实实验收益 87
3.8 结论 88

参考文献 **89**

第一章　科学知识建模与大模型推理

学习目标：理解结构化记录、本体与知识图谱的分工，能够组织保留实验条件和来源的科学知识，并评价其在检索、推理和候选设计中的作用。
先修知识：科学数据组织与大语言模型基础。

摘要

科学数据进入大模型的上下文，并不意味着模型已经获得了可用于科学判断的知识。文献、专业数据库和实验记录常用不同方式描述同一对象，也可能省略结果成立的条件。科学知识建模的任务，是明确研究对象、实验过程、测量结果及其依据，并用可计算的形式表达它们的关系。本文以小分子药物研发为重点，梳理结构化记录、领域本体、知识图谱和大模型辅助抽取等主要方法，比较代表团队的研究进展，并讨论建模后的知识如何支持检索、关系推理和分子设计。现有研究已经证明这些方法能够改善数据组织和部分下游任务，但实验条件的完整表达、跨来源一致性和真实实验验证仍是主要限制。

1.1　科学知识建模的定义与范围

科学知识建模定义为，把科学资料中的研究对象、过程、观测、结论及其依据，用含义明确、相互关联、可以计算和追溯的形式组织起来。它既规定数据怎样记录，也说明不同记录有什么关系，以及这些关系在什么条件下成立。这是本文采用的工作定义，主要参考《Bridging data and discovery》（National Science Review，2026）[1] 和 SciData（Journal of Cheminformatics，2016）[2]。

前一篇综述讨论科学知识图谱怎样组织资料，并与大模型共同支持科学任务。后一篇论文提出科学数据的表示框架，把数据与研究对象、方法和条件一起描述。两篇文章的关注点不同，但都强调不能把科学数据与产生它的背景分开。

比如，在小分子药物研发中，化合物、样品、蛋白和细胞都是研究对象。合成、纯化和生物测定是研究过程。光谱和活性测量是观测结果。要判断一个化合物是否具有某种作用，就需要把对象、过程和结果联系起来，并保留实验条件。

科学知识建模与知识图谱有关，但范围更大。数据模式规定记录的字段和结构，本体规定概念及关系的含义，知识图谱保存具体对象及其联系。关系表、JSON记录、图谱和文件索引都可以承载建模结果。知识图谱是其中一种重要表示，不能代替全部原始数据，也不能代替领域定义。

它也不同于分子表示学习。分子指纹、分子图和向量表示主要编码分子结构或相关特征。科学知识建模还需要回答某个样品怎样制备、在哪种体系中测量、结果由谁报告，以及原始证据在哪里。文本向量可以帮助找到相关段落，但向量距离本身不说明两条活性记录能否比较。

大模型出现后，这项工作的目标增加了新的要求。模型不仅要找到资料，还要把资料用于解释、比较和提出研究建议。因此，外部知识需要能够按问题返回，并保留条件和来源。同时，大模型也成为整理文献和补充元数据的工具。下文先通过两篇综述说明这些变化，再讨论具体方法。

1.1.1 从科学数据走向科学知识

Ding 等的 Bridging data and discovery: a survey on knowledge graphs in AI for science（National Science Review，2026）[1] 系统梳理了科学知识图谱的定义、构建方法、应用和局限。

这篇综述把科学知识图谱理解为具有明确科学含义的实体和关系网络。作者特别强调来源、实验条件、定量属性及外部数据的联系。比如，分子图中的节点和边主要表示原子和化学键，而科学知识图谱还会连接化合物、实验、靶点和论文。前者描述分子结构，后者描述不同研究记录之间的知识，两者可以共同使用。

该综述把图谱的作用归纳为知识组织、知识嵌入、推断和可解释性 [1]。知识组织让分散资料能够被统一查找。知识嵌入把图中的结构和语义转成模型可学习的表示。推断根据已有关系寻找新的联系。可解释性则让研究人员检查结果涉及哪些对象和证据。这个分类也说明，建图只是开始，图谱的价值最终要通过使用任务体现。

在表示方式上，这篇综述特别区分了科学数据本身与解释数据所需的知识。分子结构、光谱或显微图像可以保留各自的表示，图谱通过对象标识把它们与实验、性质和文献连接起来。这样，模型既能找到某个对象的数值特征，也能知道这些特征来自哪次测量。时间信息则用于区分不同版本的报道和认识变化。作者讨论的是一种可扩展的组织方式，并没有要求把所有文件内容都拆成三元组 [1]。

在应用上，综述覆盖药物开发、组学分析、化学反应和材料设计。不同领域共享身份对齐、来源管理和关系查询等问题，但需要的科学对象不同。药物研究常连接化合物、靶点与疾病，反应研究还要表示反应条件和催化剂。本文据此采用的阅读顺序是，先看研究任务，再看数据模式，最后看模型如何使用。综述提供了这个比较框架，具体系统是否有效仍要看各自的实验 [1]。

1.1.2 大模型带来了什么变化

从发展过程看，该综述梳理了早期科学数据目录、语义网与本体、机器学习表示，以及近年的大模型辅助发现 [1]。这些做法持续共存。今天使用大模型，仍需要数据库标识、领域模式和质量检查。变化主要在于模型可以帮助读取大量文字，也可以把自然语言问题转成检索、计算和工具调用。

Scientific Large Language Models: A Survey on Biological & Chemical Domains（ACM Computing Surveys，2025）[3] 从科学大模型的角度讨论了同一问题。

这篇综述梳理了科学文本、分子、蛋白质和生物序列等数据表示及相关模型。它帮助我们分清两类目标。一类是让模型学会科学对象的表示和任务规律，另一类是让模型在回答时访问可更新、可追溯的外部知识。前者常涉及预训练或指令微调，后者常涉及数据库、图谱和检索增强。

这篇科学大模型综述进一步说明，科学信息进入模型有不同方式。文本可以直接表示研究描述，分子可以写成 SMILES 或表示为图，蛋白质则可以用序列等形式表达。不同输入需要相应的编码和训练任务。研究者还需要安排科学对象与文字之间的对应关系，否则模型即使分别读懂两种输入，也未必知道文字描述的是哪个对象 [3]。

1.2 为什么需要科学知识建模

1.2.1 数据能够读取并不代表含义已经统一

首先，同一对象在不同来源中可能有不同名称。比如，同一个化合物可能以系统命名、项目编号或数据库标识出现。相似名称又可能对应不同盐型、立体异构体或样品批次。如果不先确认对象身份，系统可能漏掉属于同一对象的信息，也可能把本应区分的记录错误合并。

ChEMBL（Nucleic Acids Research，2024）[4] 提供了一个具体例子。它的数据库论文介绍如何把分子、实验、靶点、活性结果与文献组织成可以持续维护的资源。

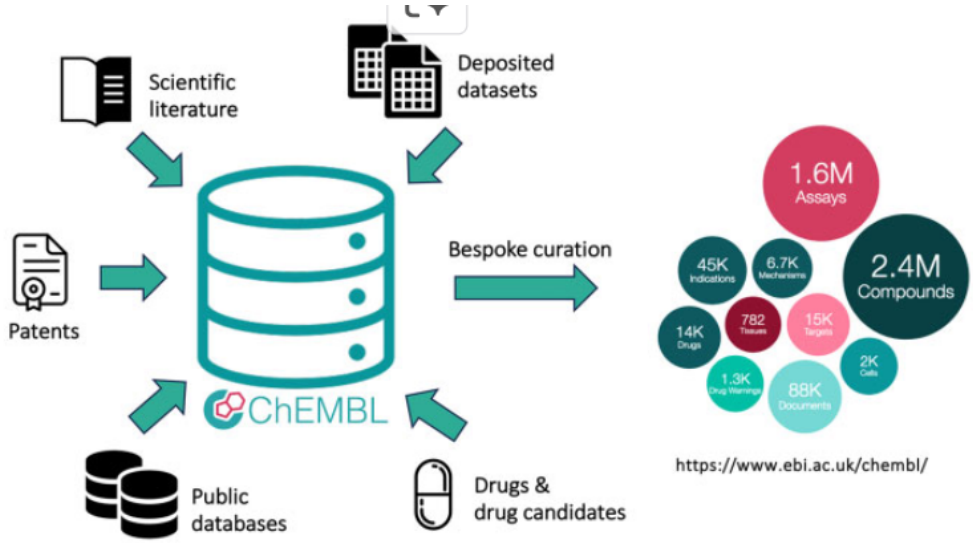


图 1.1 ChEMBL 的数据来源与生物活性数据组织 [4]。

这篇论文中的 ChEMBL 覆盖多种生物活性数据，既有从文献人工整理的记录，也有外部机构提交的数据。建模时，化合物、测定和靶点分别具有标识，一条活性记录将它们联系起来。实验描述用于说明怎样测量，活性类型、数值和单位用于说明测量结果。论文还介绍了蛋白变体、体内实验分类等整理工作。这些细节使使用者能选择所需的数据子集，而不是只按化合物名称汇总所有数值 [4]。

比如，为模型准备某个靶点的活性数据时，可以先确定靶点及其变体，再选取相应实验与结果，最后保留文献和实验标识。对 LLM 系统，更合适的输出是带实验背景的记录。

BindingDB（Nucleic Acids Research，2025）[5] 更集中地讨论蛋白与小分子的实验结合数据。与覆盖多种活性类型的资源相比，它把定量亲和力及其出处放在更突出的位置。

这篇论文说明，数据库通常按一篇论文或一份专利组织一个条目，同一条目中的数据往往来自相同机构和相近的测量流程。记录关联蛋白、配体、亲和力类型与数值，并提供文献或专利出处。该次更新报告约 290 万条结合测量和 130 万个化合物，专利整理是数据增长的重要来源 [5]。

按原始文献组织数据，对比较同一系列化合物尤其有用。论文指出，同一方法和实验室内测得的相对亲和力，可能比跨方法比较的绝对数值更稳定。因此，建立模型数据集时可以保留条目归属，用于检查实验来源差异。BindingDB 解决了重要的结构化整理问题，但不同测量类型和实验条件仍需要使用者进一步判断 [5]。

1.2.2 科学结果依赖实验条件

其次，科学结果需要结合实验条件理解。比如，我们想知道某个化合物是否容易溶于水。查资料时发现，两份实验记录给出的溶解度差别很大。进一步查看才发现，一次是在水中测量，另一次是在乙醇中测量。因为使用的溶剂不同，这两个结果不能直接用于判断哪份数据有问题，也不能都用来回答它是否容易溶于水。因此，记录溶解度时，除了化合物名称、数值和单位，还需要保存溶剂、温度等实验条件。大模型拿到这些信息后，才能选出与问题相关的记录，再进行比较和解释。

药物数据综述 A review of biomedical datasets relating to drug discovery: a knowledge graph perspective（Briefings in Bioinformatics，2022）[6] 也讨论了这一问题。

这篇综述从知识图谱角度梳理药物发现相关数据资源，并讨论如何表达定量信息和实验背景。对本文的问题，它提醒我们，建模不能只把文字改成简单的实体关系。比如，精确测得的活性值、低于检测限的结果、没有检测到作用，以及尚未做过实验，是不同情况，应当分别记录。

这篇综述还讨论了构建知识图谱时如何选择和组织数据。作者整理了基因与蛋白、疾病、药物等数据源，并比较已有图谱收录了哪些对象和关系 [6]。这些比较提醒我们，建图时需要根据研究问题决定保留哪些信息。比如，如果只想查找某个蛋白有哪些已知抑制剂，可以记录化合物与蛋白之间的抑制关系。如果还想比较这些化合物的抑制效果，就需要进一步保存测量结果和实验条件。只记录“是否抑制”，无法支持后面这些判断 [6]。

综述没有主张用一个大图解决所有药物问题。它提出图谱组成、定量信息、数据偏差和评价方式等挑战。对团队而言，可以先根据任务选择资源，再核对关系含义、更新频率和使用条件。图谱规模较大只说明收集了较多信息，不能单独说明更适合某项预测或推理任务 [6]。

1.2.3 模型的回答需要能够核查和更新

最后，模型的回答需要能够核查。比如，模型说某个化合物的活性更好时，研究人员应能找到支撑比较的实验、数值和原始出处。旧结果被修订后，也应能查到哪些记录和回答受到影响。具有稳定标识和版本的外部记录可以被单独检查和更新，因此能为模型提供可追溯的依据。

这里也应保留一个边界。不是所有任务都需要复杂图谱。如果问题只涉及单篇论文的摘要，文献检索可能已经足够。如果任务需要跨数据库连接对象、比较实验或检查多步关系，明确的数据模式才更有价值。建设方式应由任务决定，而不应由节点数量或图数据库产品决定。

1.3 现有研究怎样组织科学知识

《Bridging data and discovery》（National Science Review，2026）[1] 将科学图谱的建设分为数据获取、知识抽取、整合与表示、动态维护，并另外讨论评价。图 1.2 给出了这一过程。数据库记录、论文和多模态资料可以共同进入系统。抽取后的实体还要进行身份对齐，记录也要匹配领域概念。新论文和修订信息进入后，图谱仍需要更新。

同一综述也指出，抽取方式不只包括大模型。规则和词典适合定义明确的术语，领域模型适合相对固定的标注任务，大模型更容易处理变化较多的自然语言[1]。实际建设常把这些方法组合起来，再由专家检查重要字段。因此，方法选择应先回答记录需要表达什么，再决定怎样把原始内容转成记录。

1.3.1 用结构化记录保存一次实验

第一类方法以实验记录为中心。它把样品、方法、条件、测量结果和来源分别记录，再通过标识关联。一个化合物可以有多个样品，一个样品可以参加多次实验，一次实验可以产生多个结果。这样既能保留重复测量，也能避免把不同实验的条件与数值错误配对。

SciData（Journal of Cheminformatics，2016）[2] 提出了通用科学数据框架，讨论怎样把数值与研究背景共同保存。

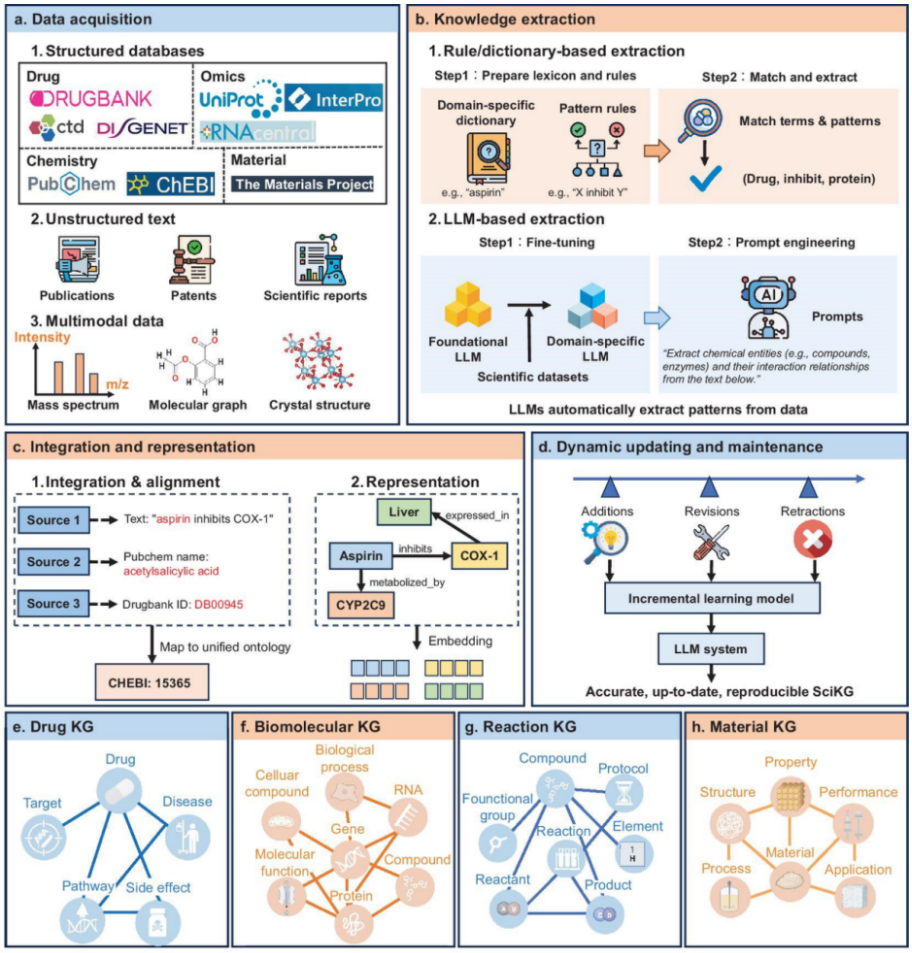


图 1.2 科学知识图谱的构建过程。

小贴士（图 1.2：科学知识图谱的构建过程）

上半部分说明来源、抽取、整合与维护，下半部分列出药物、生物分子、反应和材料等图谱类型。读图时应关注各步骤怎样保留含义与来源。

原图出处 Ding 等，National Science Review，2026，Figure 4。原文注明部分图标来自 BioRender。论文原文。许可 CC BY 4.0。

这篇论文把研究方法、研究系统和数据集组织在一起，并用 JSON-LD 说明字段含义。比如，一个测量值不仅有数值和单位，还需要关联它描述的对象及测量方法。这种表示适合跨来源交换数据，也方便系统判断字段的含义。

具体来说，SciData 把描述研究方法的 methodology、描述研究对象及条件的 system，以及承载数据的 dataset 组织在同一框架中。单个数据点可以保留数值、单位和相关属性，连续测量则可以组织成数据系列。JSON-LD 中的上下文把字段名对应到明确的概念标识。这样，两个文件即使采用不同的本地命名，仍有机会依据共同定义理解字段，而不只靠字符串相似性匹配 [2]。

原论文展示了溶液 pH、文献中的折射率和柠檬烯核磁共振谱等例子。核磁谱需要保存一组对应的数据系列，并关联样品和测量背景。它不能被一条简单的分子属性关系完整替代。对小分子研发，这一思路适合组织仪器文件与测量结果。论文的主要贡献是表示方法及示例，并没有评价大模型回答效果。

Open Reaction Database（JACS，2021）[7]，也就是 ORD，进一步面向化学反应设计了具体的数据模式。

这篇论文介绍了反应记录模式、校验工具、数据仓库和提交界面。记录分为标识、输入、装置、条件、备注、观察、后处理、结果和来源九个主要部分。与 SciData 相比，ORD 更直接地面向一次反应实验，便于保存反应物、操作条件和结果之间的对应关系。

ORD 的输入记录还会继续细分。一个输入可以包含多个组分，每个组分有身份、用量和反应角色。结果记录则连接产物与分析数据。模式采用 Protocol Buffers 定义对象和字段，配套程序检查必要字段、数据类型和部分数值合理性。比如，百分数写成小数时可能产生歧义，校验程序会给出提示。字段之外仍可保存自由文本，以容纳暂时无法标准化的实验细节 [7]。

作者强调，ORD 首先描述实验室里实际做过的操作，而不是理想化实验步骤。它也允许不同完整程度的记录，文献整理可能只有输入与产出，实验者直接提交则可以保留更多细节。因此，符合 ORD 格式只能说明记录满足相应结构要求，不能证明信息完整或反应一定可复现。对大模型系统，这种模式的价值是提供稳定的读取对象，使检索和计算能够明确地指向一次反应。

1.3.2 用本体统一概念并表达分类条件

第二类方法解决记录中的词究竟是什么意思。BioAssay Ontology（Journal of Biomedical Semantics，2014 医学 SCI IF 11+ 1 区）[8]，也就是 BAO，是生物测定领域的代表工作。

这篇 BAO 论文介绍了生物测定本体的模块、整合方式和应用。它把实验体系、方法、研究对象、检测方式和结果终点等概念分别描述。比如，两项实验都使用细胞，但检测方法可能不同。通过分别记录这些概念，系统就能按明确条件分类，而不必只依赖笼统的实验名称。

BAO 2.0 把概念拆成生物测定、实验中的生物学对象、被测实体、方法、实验体系和结果终点等主要部分。比如，细胞实验描述的是体系，荧光描述的是检测方式，半数抑制浓度描述的是结果终点。这几个维度可以共同描述一次实验，却不能互相替代。把它们分别建模后，检索器就能区分使用相同检测技术的不同实验，也能找到用不同技术研究同一生物过程的实验 [8]。

论文的另一个重点是模块化。术语、逻辑公理和外部本体映射分别维护，再组合成可使用的本体。这样既能复用外部生物学概念，也能减少外部资源变化对核心定义的影响。对数据团队，这意味着本体建设包含持续的定义管理。把模型抽出的名称贴上一个标签只是起点，还需要检查标签是否符合实验含义 [8]。

BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 进一步把本体扩展到药代、药效和安全药理。图 1.3 是这篇论文中的一个例子。

这篇论文既扩展了领域概念，也展示了怎样依据逻辑定义对实验分类。比如，图中的 BCRP 抑制实验与方法、细胞系、物种、实验体系和底物相连。some 和 only 表示本体中的逻辑限定，不表示实验频率或置信度。图中描述的是一类实验，而不是某次真实实验的完整记录。

本体的作用也不仅是提供标签。BAO 更新（Journal of Biomedical Semantics，2026）[9] 展示了依据已定义的逻辑条件，将符合要求的实验自动归入通透性或主动外排等类别。这属于基于明确公理的分类推理。它与大模型生成一段解释不同，判断能否成立取决于输入事实和逻辑定义是否正确。

这次 BAO 更新针对药物研发中的具体实验扩展概念，并通过数据库、术语生成和外部本体导入等步骤维护本体。图 1.3 中的转运体抑制实验说明，系统需要同时知道实验研究的过程、采用的体系和相关参与物，才能给出有依据的分类。只出现某个蛋白名称，并不足以判断实验属于哪一类 [9]。

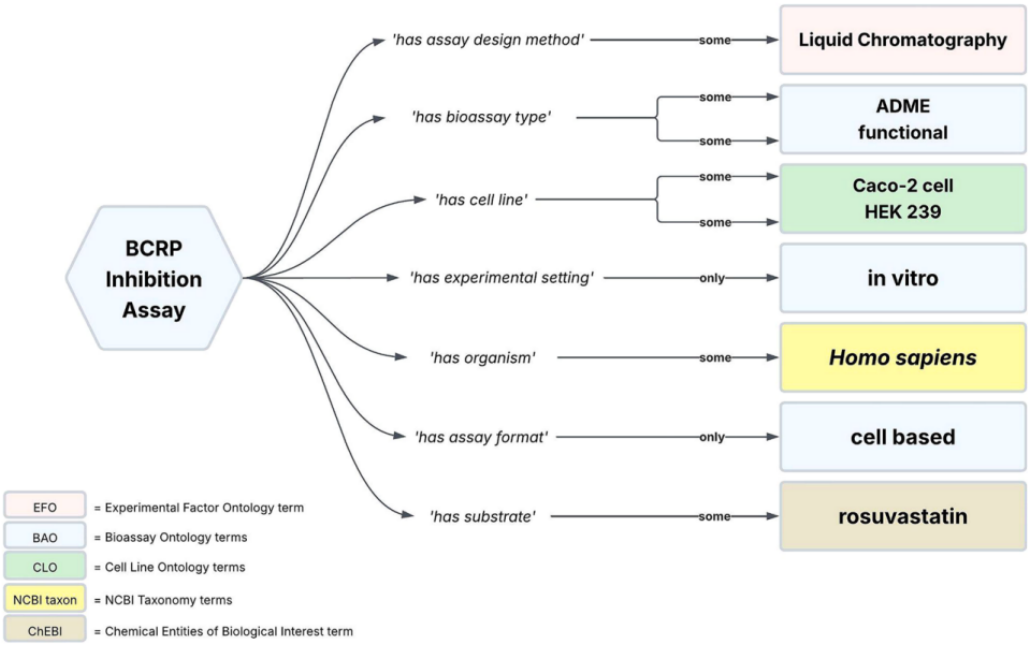


图 1.3 BAO 怎样描述一种生物测定。

小贴士（图 1.3：BAO 的生物测定表示）

图中把 BCRP 抑制实验与方法、细胞和底物等概念关联，说明本体除了统一名称，也可以表达实验类别的逻辑条件。

原图出处 Glenny-Pescov 等，Journal of Biomedical Semantics，2026，Figure 6。论文原文。许可 CC BY-NC-ND 4.0。

它与大模型辅助标注可以配合使用。模型从实验描述中提出候选概念，本体提供概念定义和关系限制，审核人员再检查文本是否支持这些标注。这是本文根据两类方法归纳的使用方式，并非本体论文已经实现完整的自动建库系统。逻辑分类可以发现部分不一致，但无法替代缺失的实验事实。

1.3.3 用知识图谱连接对象和过程

第三类方法把不同记录连接成知识图谱。在药物领域，常见对象包括化合物、靶点、疾病和通路。但若研究问题涉及活性比较或合成条件，实验、反应和测量也需要成为独立对象。否则，一条简单的关联很难表达它出现于哪次实验，以及有哪些适用限制。

Cat-KG（National Science Review，2025）[10] 提供了一个以反应为中心的建模例子，图 1.4 展示了它的数据模式。

这篇论文把反应作为独立对象，将反应物、产物、催化剂和溶剂连接起来，并分别保存属性。这样，系统既能查到哪些物质参与反应，也能查到相关条件。论文随后利用这些记录推荐接力催化路线，第 1.5.1 节会详细说明。这里需要注意，原模式面向热催化，其字段不能直接当成所有药物合成任务的标准。

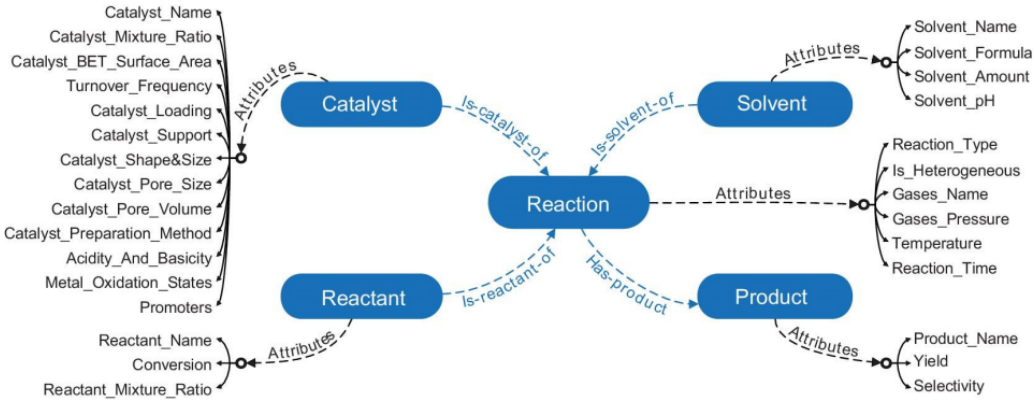


图 1.4 Cat-KG 的反应数据模式。

小贴士（图 1.4：Cat-KG 的反应数据模式）

原文用五类核心对象和 29 项属性描述催化反应。它说明科学图谱可以把一次过程及其参与对象共同建模，而不仅保存反应物与产物之间的联系。

原图出处 Fu 等，National Science Review，2025，Figure 2。论文原文。许可 CC BY 4.0。

PrimeKG（Scientific Data，2023）[11] 展示了怎样把多个专业数据库组织为一个生物医学知识图谱。

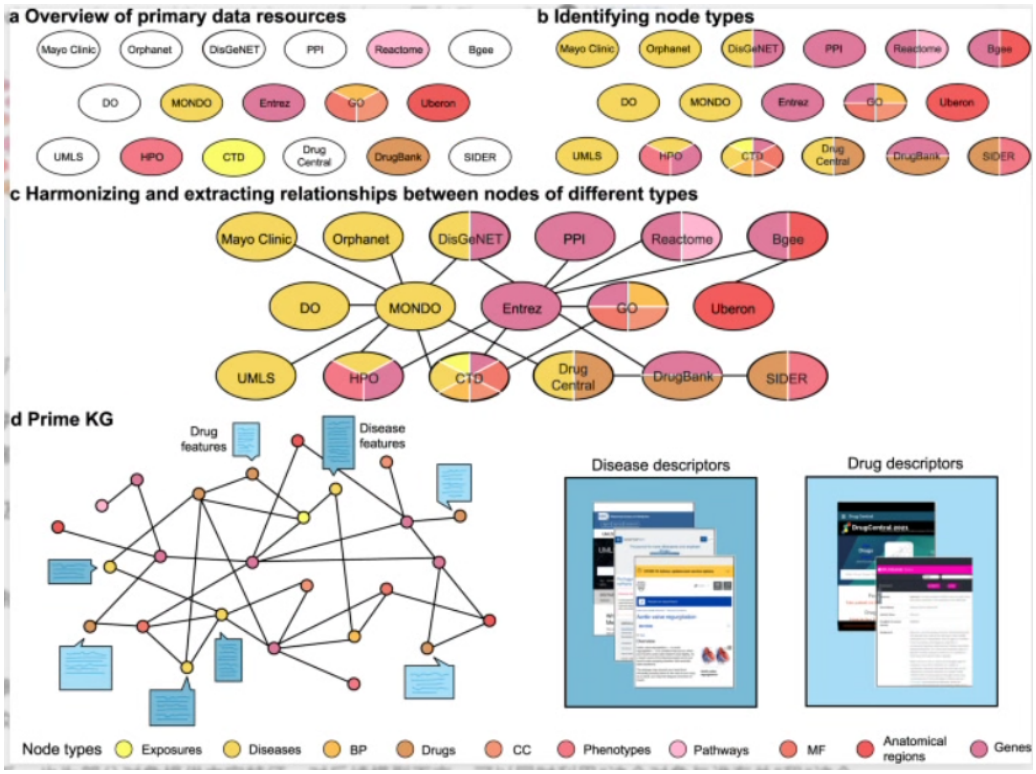


图 1.5 PrimeKG 的数据来源、节点类型与知识整合 [11]。

这篇论文由 Chandak、Huang 和 Zitnik 完成。作者整合 20 个来源，构建包含 129,375 个节点和约 405 万条关系的图谱，连接药物、疾病、蛋白、通路和表型。图谱还区分适应证、禁忌证等关系，并保留临床文本描述。它适合跨来源关联查询，但不能据此假定每条药物关系都包含完整实验条件。

PrimeKG 的重点是把不同来源中的对象映射到共同标识，再形成有类型的关系。例如，疾病的分子信息、表型和药物信息原本属于不同数据库，统一后可以围绕疾病查询相关对象。药物适应证与禁忌证使用不同关系表达，避免把意义相反的联系合并为笼统的药物疾病关联。作者同时发布构建所需的数据处理材料，使研究者能够理解图谱由哪些资源组成 [11]。

从使用方式看，PrimeKG 适合作为图学习和跨来源查询的数据基础。它的主要产物是整合后的数据资源。对小分子研发，可以在这类图谱中寻找药物、靶点

和疾病的研究背景，再回到具体活性数据库与原论文核查实验。临床关系、文献关联和测量证据属于不同层次，不宜放在同一可靠性等级下使用。

iKraph（Nature Machine Intelligence，2025）[12] 则研究怎样把文献抽取结果与数据库记录放入同一个图谱。

这篇论文从 PubMed 摘要中抽取生物医学实体和关系，再结合 40 个数据库及基因组资料，并研究间接关系推断。它说明，文献中尚未进入标准数据库的信息也可以被组织起来。其抽取过程包含专门的实体与关系模型，因此不能把全部工作都称为生成式大模型建图。

iKraph 把文本中的提及转成可识别的实体，再判断实体之间的关系。因此，两个名称在同一篇摘要出现，并不自动成为一条有意义的关系。系统还整合数据库记录和从高通量基因组数据得到的关系，使文献知识与其他证据能够共同查询。作者用人工标注比较信息抽取表现，并研究图谱对间接关系发现的支持 [12]。

1.3.4 保留来源并组合多种存储方式

这些表示方式可以共同使用。比如，论文和仪器文件可以保存在文件系统中，数值和实验字段可以保存在关系表中，图谱表达跨对象联系，文本索引定位相关段落。统一标识让它们相互对应。Ontop（Patterns，2021 cell 子刊）[13] 的科学数据访问研究给出了一个例子。

这篇教程介绍虚拟知识图谱。原始数据仍留在关系数据库中，本体定义对外使用的概念，映射规则说明哪些表、列和连接对应这些概念。用户提交 SPARQL 查询后，Ontop 结合映射和本体生成底层查询，再从数据库读取结果。图谱因此是一种访问和理解数据的方式，不一定是一份另外存储的完整数据副本 [13]。

论文用生物医学数据演示如何配置本体、映射和查询，并说明领域知识如何帮助得到更丰富的结果。对已有多个专业数据库的团队，这条路线允许先统一访问含义，再逐步改进底层数据。它的难点是映射本身需要正确，数据库字段变化后也要维护。若一个库记录的是实验结果，另一个库记录的是预测值，即使字段类型相同，也不能映射成完全相同的含义。

来源信息让不同表示能够回到同一份依据。PROV-O（W3C 技术标准，2013）[14] 是描述数据来源的技术标准。

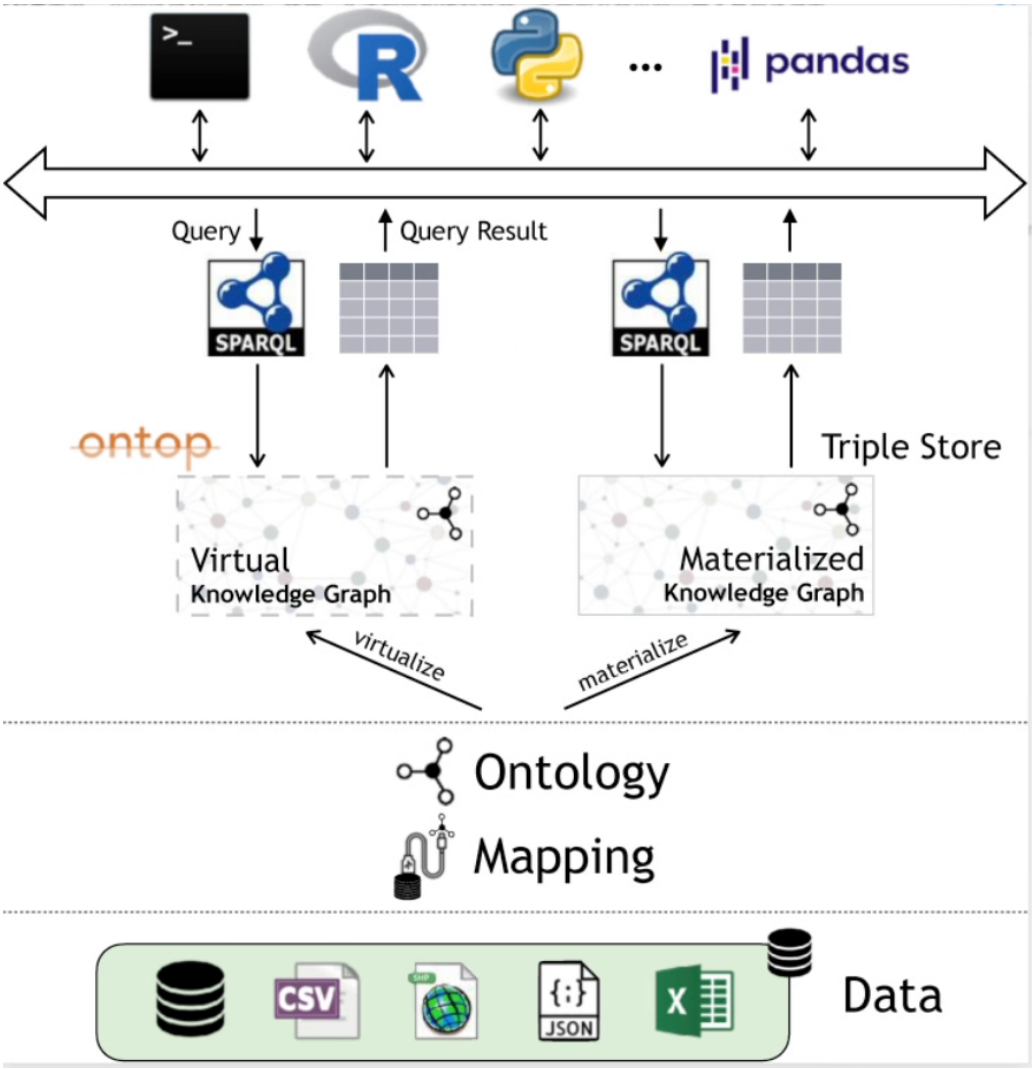


图 1.6 Ontop 的虚拟知识图谱访问方式 [13]。

1.3.5 把数据整理、工具知识和访问接口分别建模

科学知识还包括怎样准备数据、怎样使用工具，以及怎样访问已有资源。相关工作包括 SciDataCopilot（arXiv 预印本，2026）[15]、SciToolAgent（Nature Computational Science，2025）[16]、SCP（arXiv 技术报告，2025）[17] 和 SciGraph-Bio（项目技术文档，2026）[18]。

SciDataCopilot 讨论原始数据怎样整理成适合计算的数据单元。SciToolAgent 把工具的功能、输入输出和依赖建成图谱。SCP 技术报告讨论资源描述和调用方式，SciGraph-Bio 技术文档介绍生命科学图谱的查询服务。它们分别解决数据准备、工具选择和资源访问问题。只有访问接口而没有清楚的数据含义，仍然难以比较跨来源结果。后面会分别展开这些工作。

1.3.6 用 skill 理解和使用一个数据集

Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale（arXiv 预印本，2026）[19] 提出 SciDSK，研究智能体怎样找到并理解科学数据集。

这篇论文把数据集相关知识组织成技能包，原始数据仍保存在原仓库。技能包记录数据身份、版本、科学背景、文件与字段含义、使用步骤、质量检查和来源。模型先根据简短说明选择资源，再读取详细指引。它将数据说明与操作知识放在一起，补充了图谱和查询接口难以单独解决的问题。

SciDSK 具体使用 SKILL.md 作为入口。文件开头的结构化元数据记录名称、简短描述、来源、访问位置和版本等信息，正文再解释数据内容、文件字段、使用步骤、质量检查与引用方式。模型先用简短描述判断是否需要该数据集，选择后才读取完整指引。这种分步读取减少了把全部文档一次放入上下文的需求 [19]。

论文还把技能包与某个数据集快照明确关联。说明文件对应的是哪一版数据，需要单独记录。构建过程中，作者先收集权威数据说明、字段字典和版本资料，再按规定结构整理，并检查说明是否有依据。对药物数据，一个可借鉴的例子是把实验表的样本单位、活性列含义和缺失值处理规则写在数据集说明中。这是应用示例，论文的检索与理解测试没有直接覆盖该药物场景。

这项工作来自中科院计算机网络信息中心和中国科学院大学。2026 年 9 月的修订版报告，数据集检索 Hit@1 为 80.77%，比原始资料条件高 9.62 个百分点。受控理解案例中，技能包满足 24 项检查中的 23 项，网页条件满足 22 项 [19]。结果

支持这种表示帮助寻找和理解数据，但并未证明小分子药物研发任务因此获得改善。

1.4 哪些团队在做以及进展到了哪里

1.4.1 浙江大学知识引擎实验室及相关合作团队

浙江大学陈华钧所在的知识引擎研究团队，与张强、丁克炎等合作者，在科学知识图谱、科学大模型和工具使用方面形成了一组相关工作。《Bridging data and discovery》（National Science Review，2026）[1] 由浙大研究者与上海人工智能实验室等单位合作者共同完成。

在具体系统方面，这个团队的相关工作包括 SciToolAgent（Nature Computational Science，2025）[16]、Mol-Instructions（ICLR，2024）[20] 和 SciKnowEval（arXiv 预印本，2024）[21]。

这三篇论文解决不同问题。SciToolAgent 介绍工具图谱和多步操作的安排，把工具的功能、输入输出和依赖建成图谱。Mol-Instructions 把分子、蛋白质和生物医学文本任务整理为指令数据，用于微调模型。SciKnowEval 从记忆、理解、推理、辨析和应用等层次评估模型能力。因此，它们分别对应工具知识、训练数据和能力评价。

1.4.2 上海人工智能实验室及与浙江大学的合作

上海人工智能实验室的 SciDataCopilot（arXiv 预印本，2026）[15] 直接关注原始实验数据的准备问题。论文提出，科学数据是否可用于 AI，应结合任务意图、科学约束和下游计算要求来判断。这一视角补充了文献知识抽取。谱图、序列或实验矩阵即使可以读取，也不一定已经具备模型需要的样本定义、字段说明和处理记录。第 1.5 节将进一步展开它的表示方式。

SCP（arXiv 技术报告，2025）[17] 关注科学资源怎样被智能体发现和调用。它试图把分散的软件、模型、数据库和实验设备组织为有统一描述的服务。

技术报告采用 Hub、Server 与 Client 的组织方式。Server 说明自己提供什么能力、需要什么参数并负责执行，Hub 维护资源注册信息、实验上下文和任务状态，Client 供研究人员或智能体发起请求。报告还把实验标识、输入输出位置和操作日

志纳入上下文，使多个步骤能够围绕同一次任务工作。这里建模的重点是资源和执行过程 [17]。

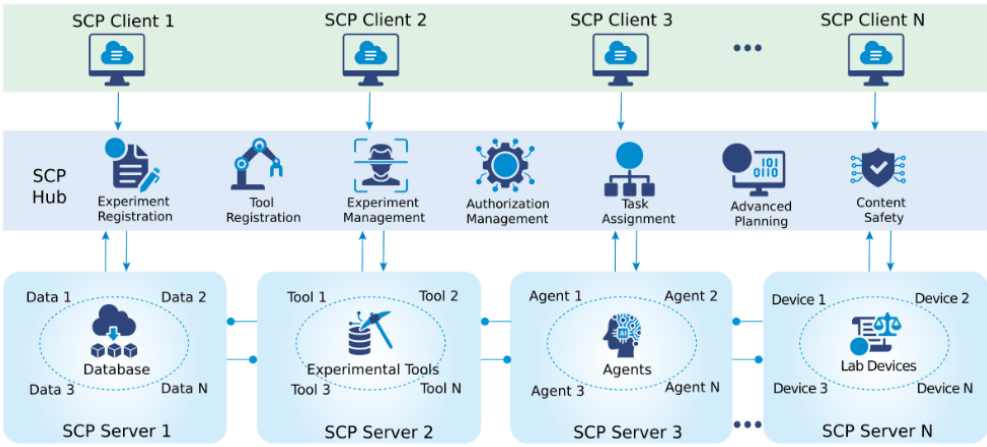


图 1.7 SCP 的 Client、Hub 与 Server 组织方式 [17]。

报告提出用结构化任务图保存操作、参数和先后依赖，并报告系统包含 1,600 多个工具资源。资源数量反映接入范围，不能直接说明这些资源采用了统一化学定义，也不能证明跨实验结论可靠。对小分子团队，SCP 类接口可以承载数据查询和计算服务，但化合物身份、实验条件与证据来源仍需要在服务返回的数据中明确表示。

SciGraph-Bio（项目技术文档，2026）[18] 进一步提供面向生命科学图谱的统一查询服务。它是技术文档，适合了解已有图谱如何开放给智能体调用。

官方页面列出 39 个可查询图谱，并提供图查询、统计、节点类型和关系类型四类工具。节点与关系类型工具可以先告诉调用方某个图谱保存了什么，再据此组织查询。统计工具帮助了解资源范围，图查询工具返回具体记录。页面也致谢浙江大学对整理、部署与发布的支持 [18]。

比如，智能体准备查询某种药物与疾病的联系，可以先检查所选图谱是否具有对应节点和关系，再执行查询。

1.4.3 清华大学、厦门大学与中科院相关团队

清华大学智能产业研究院聂再清、周浩等相关团队关注分子结构、文本和图谱的联合表示。代表工作包括 KEDD（Health Data Science，2024）[22] 和 MV-Mol（KDD，2024）[23]。

KEDD 这篇论文把结构、图谱和文本信息共同用于药物发现任务。MV-Mol 这篇论文进一步研究，同一分子在不同语义视角下应怎样表示。它们说明，建好的知识也可以用来训练分子模型，而不只是在大模型推理时提供文字上下文。第 1.6.4 节会说明这两种使用方式的差别。

厦门大学程俊、王野与爱丁堡大学 Jeff Z. Pan 等人的 Cat-KG（National Science Review，2025）[10]，则把催化领域模式、文献抽取、图查询和规则评分放入同一个系统。其优势是能够清楚观察原始资料怎样变成可操作的知识，以及这些知识如何产生路线推荐。虽然研究对象是热催化，方法对药物合成数据组织仍有参考意义。中科院计算机网络信息中心朱恒术、周园春等人的 SciDSK（arXiv 预印本，2026）[19] 则把数据集的使用知识组织为技能包，强调智能体怎样选择和理解资源。

1.4.4 国际数据资源与领域模型团队

EMBL-EBI 的 ChEMBL（Nucleic Acids Research，2024）[4] 团队持续整理药物样分子的活性数据。其价值在于长期维护分子、实验、靶点和文献之间的对应关系，并向外部提供可查询的数据。这类资源已经支持实际的数据分析与模型训练，但成熟数据库仍会存在条件缺失和记录粒度不一致的问题。它们为大模型提供基础资料，却不会解决跨实验推理。

北佛罗里达大学 Stuart Chalk 提出的 SciData（Journal of Cheminformatics，2016）[2] 关注跨领域数据表达。迈阿密大学 Stephan Schürer 及合作者推进的 BAO（Journal of Biomedical Semantics，2014）[8] 则深入到生物测定的具体概念。BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 与 Pistoia Alliance 牵头的电子实验记录语义整理项目合作，扩展药代、药效和安全药理内容，并展示实验自动分类。这些工作完善了领域概念和记录方式，其成果不能直接换算为大模型问答准确率。

ORD（JACS，2021）[7] 由 Steven Kearnes、MIT 的 Connor Coley 及学术界和企业合作者共同提出，参与单位包括 Relay Therapeutics、MIT、Merck 和 Google 等。其贡献同时包括反应模式、校验工具、数据仓库和提交界面。

1.4.5 自动抽取与知识使用团队

劳伦斯伯克利国家实验室与加州大学伯克利分校的 Dagdelen、Dunn、Jain 等人发表了 Structured information extraction from scientific text with large language models（Nature Communications，2024）[24]，研究大模型能否直接生成科学结构化记录。

这篇论文比较了传统实体与关系抽取，以及用 GPT-3、Llama-2 生成层次化记录的方式，图 1.8 展示了其中差别。比如，模型可以把同一种材料的名称、组成、形态和用途放进同一条 JSON 记录。这样能够保留字段之间的对应关系，减少拆成孤立关系造成的信息损失。

这项研究把抽取任务写成从科学文本到指定输出格式的生成问题，并用标注样本训练模型完成任务。输入是原始描述，输出可以是列表或 JSON 对象。层次化输出允许一个主体同时关联多个属性，也允许不同主体各自保留属性。比如，一段文字同时描述几种材料时，把用途直接放进对应材料对象，比列出所有名称和所有用途更容易检查归属是否正确 [24]。

从药物文献整理的角度，可以借鉴这种记录级输出。模型先形成按化合物或实验分组的候选记录，再由程序检查结构、字段类型和来源是否完整。这里的药物场景属于方法迁移，原论文主要在材料与化学文本任务上评价。生成合法 JSON 只是格式正确，字段有无遗漏、数值是否属于该对象，还需要独立核查。

该研究也给出了清楚的能力边界。在 JSON 输出设置下，Llama-2 对主体材料与掺杂物关系的精确匹配 F1 为 0.821，而对材料化学式与用途关系的 F1 为 0.516[24]。两项任务的内容和难度不同，不能只看一个最高分来判断建库能力。论文证明了结构化抽取的可行性，也说明字段识别、关系归属和完整记录仍需要分别评价。

斯坦福大学 Sanmi Koyejo 等人与多伦多大学等合作者提出了 KGGen（NeurIPS，2025）[25]，探索从普通文本自动生成知识图谱。

这篇论文不仅抽取实体与关系，还通过聚类和去重减少重复实体造成的图谱分散，并用 MINE 评价知识保留情况。它提供了通用建图工具。

KGGen 的流程包括局部抽取、跨文本汇总和实体关系归并。它先从每份文本识别实体，再抽取关系，然后把多份文本的结果合在一起。归并阶段结合向量检索与语言模型判断，寻找同一对象的不同写法，并为含义相同的关系选择较统一的表述。这样可以减少同一个对象分散成多个节点，也避免几乎每条边都有一个独特关系名 [25]。

它的 MINE 评价关注从文本转成图谱后，重要信息是否仍被保留，并另用检索任务检查图谱的可用性。这个设计提醒我们，建图质量不能只看抽出了多少三元组。对化学资料，通用归并方法仍需领域检查。比如，同一母体的盐型可以建立联系，但不应仅因名称相近就把实验样品完全合并。减少重复与保留科学差异需要同时考虑。

阿斯利康 Molecular AI 与乌普萨拉大学、KTH 等团队的 Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?（arXiv 预印本，2026）[26] 更接近小分子数据整理问题。

这篇论文比较七种大模型从 BioAssay 文本中预测和审查实验元数据的表现。作者报告，生化实验和细胞实验格式的召回率至少为 0.96，但稀有类别的分歧更大，参考标签也存在不一致。这支持模型辅助整理，并不说明可以省去审核。该工作为预印本，作者注明获 NeurIPS AIDaR 研讨会录用。

这项生物测定元数据研究分别处理实验体系与物理检测技术，并把模型输出与现有数据库标签比较。作者把这些参考标签视为可能有错误的已有标注，而不是绝对正确的答案。模型与标签不一致时，还通过人工检查分析分歧来自模型、文本信息不足，还是数据库原标签。这个评价方式比只统计模型与数据库一致率更适合数据整理任务 [26]。

因此，论文支持的使用方式是让模型提出候选标注，并把有分歧或少见的类型送去重点审核。对数据团队，最值得借鉴的是同时保存预测类别和判断依据，再按类别检查可靠性。总体表现较高时，少数类别仍可能不稳定。若把模型标签直接覆盖原有标签，就会丢失后续查错所需的信息。

1.4.6 图谱推理与候选设计团队

加州大学旧金山分校 Sergio Baranzini、Karthik Soman 等人与加州大学圣迭戈分校等合作者，基于 SPOKE 生物医学图谱开展了 KG-RAG（Bioinformatics，2024）[27] 研究。

这篇论文讨论怎样围绕问题检索图谱，再选择适合放入大模型上下文的内容。它主要验证生物医学问答。Monash 大学与 Griffith 大学等团队的 RoG（ICLR，2024）[28] 和 GCR（ICML，2025）[29] 则更关注一般知识图谱上的多步推理。

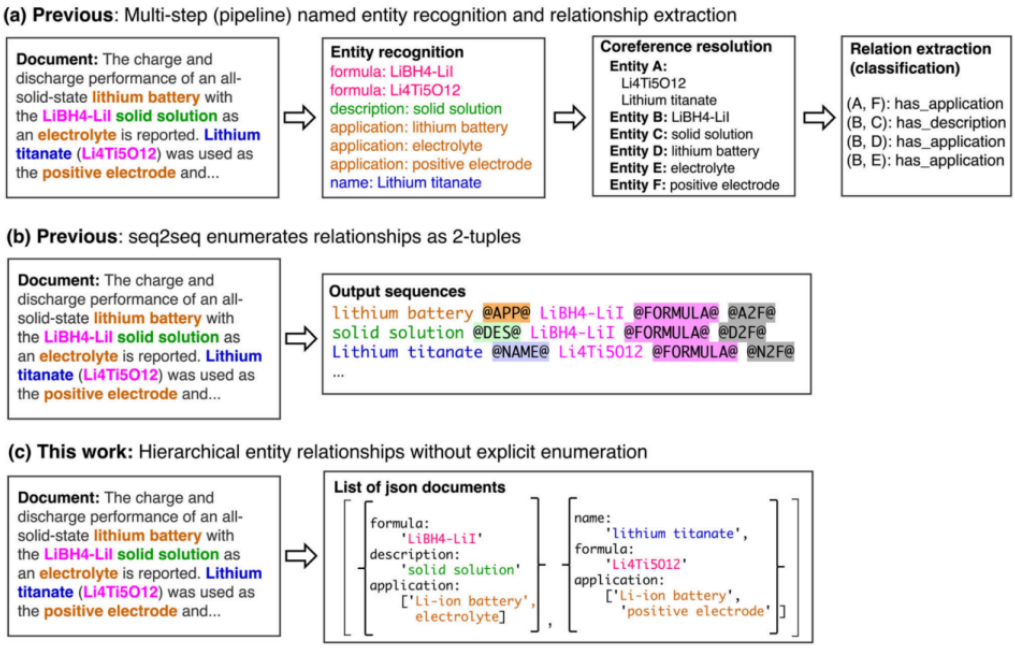


图 1.8 科学信息抽取方式的比较。

小贴士（图 1.8：科学信息抽取方式）

上方先识别实体再抽取关系，中间将关系写成序列，下方直接生成层次化 JSON 记录。本文保留原图全部三个部分，用于说明输出结构本身也是模型设计的一部分。

原图出处 Dagdelen 等，Nature Communications，2024，Figure 1。论文原文。许可 CC BY 4.0。

RoG 这篇论文先生成关系计划，再检索真实路径并组织回答。GCR 这篇论文进一步限制生成过程，使模型只能沿给定图谱中的路径输出。两者主要在通用知识图谱问答任务上验证，不能直接等同于药物实验推理能力。

威斯康星大学麦迪逊分校与 Morgridge 研究所的 Yifan Deng、Spencer Ericksen、Anthony Gitter 团队提出 Assay2Mol（EMNLP，2025）[30]，研究怎样利用生物测定背景指导小分子生成。

这篇论文从 PubChem 检索实验描述和活性记录，为模型提供与新靶点有关的背景及分子示例。它没有把所有资料改成知识图谱，但同样在研究科学数据怎样组织成模型能够使用的输入。其主要证据来自计算评估，仍需要后续合成与活性实验验证。

1.5 怎样把数据变成可用知识

下面选择三个互补案例展开。Cat-KG 最完整地展示领域事实如何建模并用于路线推荐。SciToolAgent 说明工具的使用条件本身也可以成为知识。SciDataCopilot 则回到原始数据，讨论怎样形成适合计算的数据单元。三者回答的问题不同，放在一起更容易看清科学知识建模的范围。

1.5.1 Cat-KG 从催化文献到接力反应路线

Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation（National Science Review，2025）[10] 介绍了 Cat-KG，目标是从分散文献中寻找可以连续完成目标转化的反应。

这篇论文先定义催化领域的数据模式，再从文献抽取记录、建立图谱，最后搜索并筛选反应路线。比如，前一步的产物能够作为后一步的反应物，只说明两步在物质上可以连接。温度、气氛、催化剂和溶剂是否相容，还需要另外检查。图 1.9 展示了论文怎样把这些问题放进同一流程。

在表示上，作者设计了反应、反应物、产物、催化剂和溶剂五类核心对象、四类关系及 29 项属性，具体模式见图 1.4[10]。反应不再只是两个分子之间的一条边，而成为连接参与物与条件的对象。催化剂的制备和表征信息也进入记录。这样，系统才能同时查询反应是否存在和条件是否接近。

把反应作为独立对象后，同一种反应物与产物之间可以保留多条不同条件的记录。比如，同一转化分别使用两种催化剂时，系统不必把温度、收率和催化剂都挤在一条无区别的关系上。它可以先定位具体反应记录，再读取该记录的条件。这是对图 1.4 模式的解释，也说明为什么保存实验过程会直接影响后续路线比较。

在抽取上，作者使用 Gemini 1.5 Flash 处理较长的论文内容，并采用两阶段方式。先获得反应概况，再补充各反应的详细字段。这样做是因为催化剂制备、条件与性能结果常散落在论文不同位置 [10]。模型按指定格式输出 JSON，随后用程序校验、标准化和消除实体歧义，再写入 Neo4j。文献与反应标识让结果可以返回原始来源。

两阶段抽取还有一个实际作用，就是先区分论文中存在的不同反应，再围绕每个反应补齐细节。否则，模型可能从全文找到一个正确的温度和一个正确的收率，却把它们配到不同反应上。原文随后使用规则处理遗漏、重复和格式差异。图谱中的物质名称经过归并后可以用于搜索，反应记录仍需关联具体文献以供核查 [10]。

最终图谱包含 15,881 篇论文中的 27,760 条热催化反应，其中 18,174 条为非均相反应。作者另选 10 条化合物合成路线涉及的 44 个反应，评价抽取结果。平均精确率为 91.49%，召回率为 91.18%，F1 为 0.9113[10]。这支持该抽取方式在所选样本上的有效性，但不是对全部图谱记录逐条验证后的正确率。

在使用上，研究人员给定起点、目标产物和路径长度，系统先执行图查询。以合成气中的氢气和一氧化碳为起点、巴豆醛为目标、最多三步为条件，作者报告一分钟内检索到超过 93,000 条候选路径 [10]。大量路径说明搜索空间需要进一步筛选，不能把候选数量当成有效路线数量。

筛选采用人工设计的规则，分别评价单步反应、相邻反应的匹配和整体路径。图 1.10 展示了温度、压力、气氛、催化剂和溶剂等评分内容。程序排序后，把选出的结构化路线交给 GPT-4 生成说明 [10]。因此，本文的推荐结果来自图谱搜索、领域规则和语言模型的共同作用。图中的期刊影响因子、引用量等也是原作者评分项，但这些信息本身不能证明某个反应可靠。

这里可以把系统的三个判断分别理解。图查询判断记录之间能否按反应物与产物连接。领域规则判断这些组合是否更值得优先考察。大模型把入选路线及其条件转成可读说明。前两个步骤产生的结构化数据及标识会交给模型，因此读者可以沿标识返回原始记录。语言描述即使流畅，也仍需要与这些记录逐项对应 [10]。

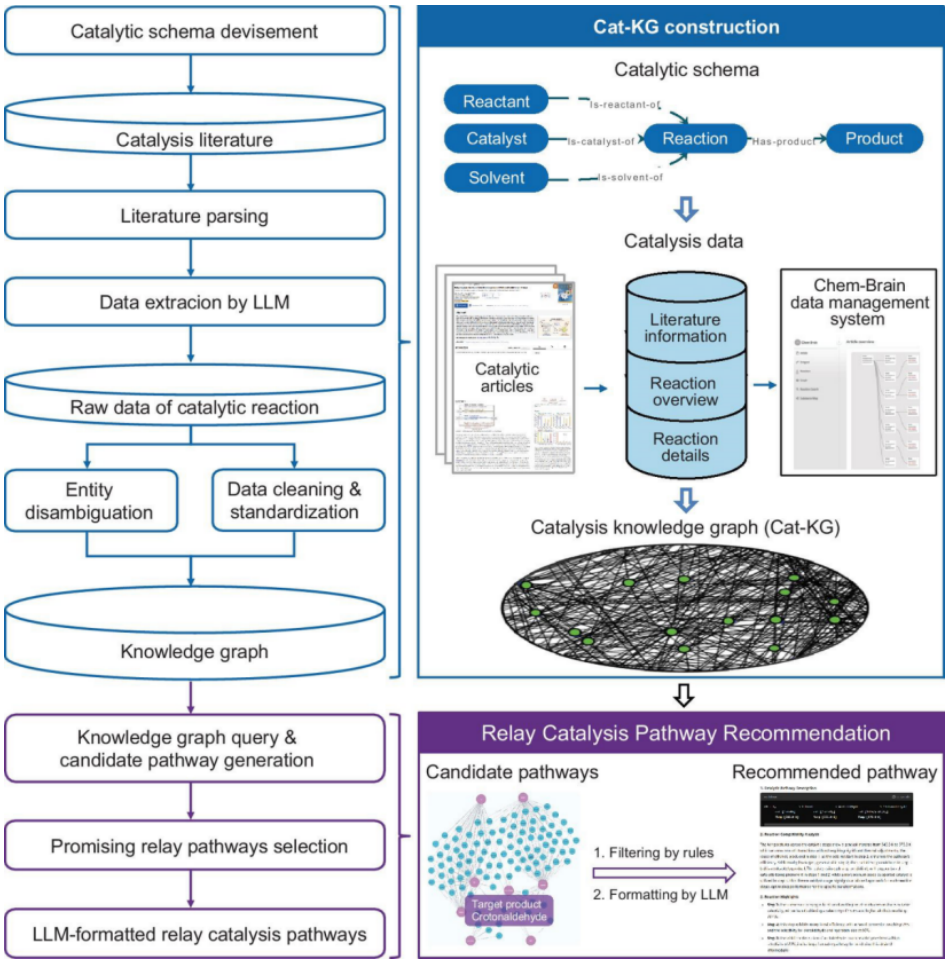


图 1.9 Cat-KG 的完整流程。

小贴士（图 1.9：Cat-KG 的完整流程）

上半部分先规定模式，再抽取、清理和整合文献数据。下半部分先查询候选路线，再按规则筛选，最后由大模型整理说明。

原图出处 Fu 等，National Science Review，2025，Figure 1。论文原文。许可 CC BY 4.0。

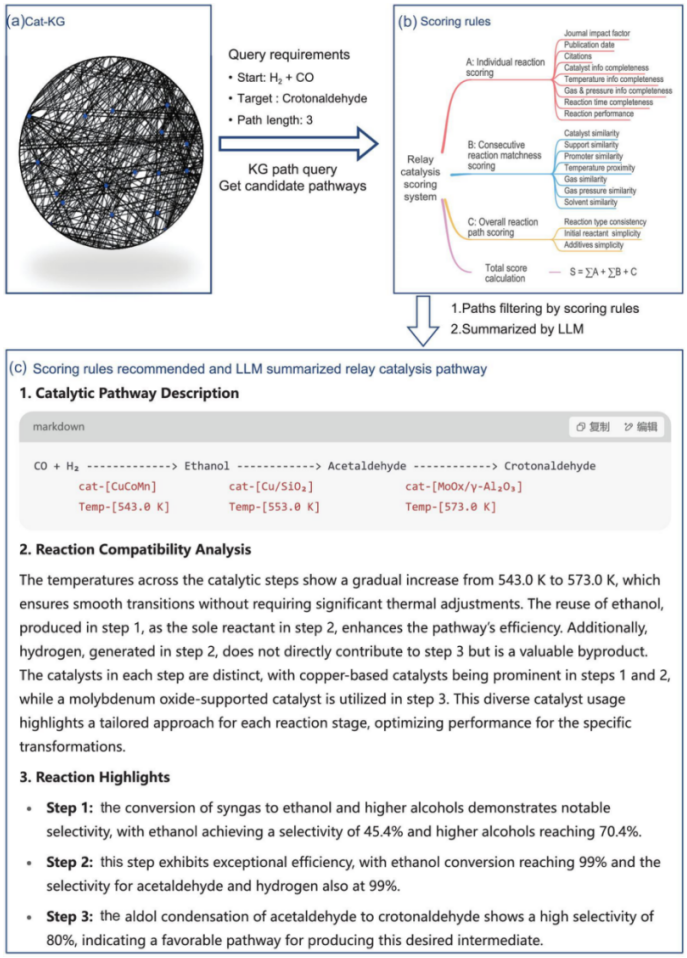


图 1.10 Cat-KG 怎样查询与筛选候选路线。

小贴士（图 1.10：候选路线的查询与筛选）

上方是图查询和规则评分，下方为大模型整理的路线与解释。图中文字中的相容性判断属于系统输出，仍需实验检查。

原图出处 Fu 等，National Science Review，2025，Figure 4。论文原文。许可 CC BY 4.0。

作者用四条已报道的接力催化路线检查系统推荐，并针对十个目标提出二十条此前未报道的路线 [10]。前者表明系统能够找回与已有研究一致的组合思路，但具体条件和催化剂可能不同。后者是待验证建议，不能表述为二十条新路线已经成功完成实验。副产物、催化剂失活和多步动力学等问题仍可能影响实际结果。

因此，阅读结果时应区分抽取评价、搜索评价和实验验证。44 个反应上的 F1 检查的是数据抽取。已报道路线的找回检查的是搜索与筛选能否恢复已有组合。20 条新建议则说明系统能够提出尚待研究的方案。这几项结果对应不同问题，不能合并成一个发现成功率。对拟开展的药物项目，也可以采用这种分层评价方式。

对小分子药物研发，可以借鉴三点。首先，以实验或反应作为独立对象，保留条件。其次，按概况与细节分阶段抽取，减少字段错配。最后，让搜索与计算在明确的数据和规则上执行，再由模型解释结果。这是从该研究得到的方法启发，不能直接把热催化领域的 29 个属性和评分规则照搬到药物合成。

1.5.2 SciDataCopilot 把原始数据组织为可计算的数据单元

SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery（arXiv 预印本，2026）[15] 研究原始科学数据怎样整理成适合下游任务的输入。

这篇论文提出 Scientific AI-Ready 概念，强调数据准备取决于具体任务。作者把知识基础分成数据、工具和案例三部分。一个数据单元限定于一种模态、一个时空范围和一个目标对象，并附上模式、来源、质量和统计等描述。工具记录可以执行的操作，案例记录问题及处理经验。

数据单元可以是一个文件或可定位的数据对象，并不要求把全部内容转成自然语言。系统记录文件位置、模态、字段或张量形状、数据类型、取值范围及缺失情况等说明。工具说明再给出允许的输入输出与运行条件。案例则保存某个问题使用了哪些数据单元、分别怎样处理，以及最后怎样整合。数据、操作与历史经验因此可以被分别检索 [15]。

在执行前，意图理解模块把自然语言要求转成研究对象、变量、限制和任务类型，并检查所需数据是否存在。系统随后参考相似案例制定计划，安排每个数据单元的处理，再确定跨单元的整合方式。处理脚本与摘要也会保存，以便复现和检查。这里的建模同时覆盖数据内容和使用数据的条件，而不只是给文件增加关键词 [15]。

系统安排接入、意图理解、处理和整合等智能体完成数据准备。酶学案例中，作者报告整理了约 21.4 万条酶与反应记录 [15]。论文还在地球科学和神经科学中评价效率，其中最高 30 倍加速来自地球科学案例，不能作为药物数据准备的普遍收益。该工作目前按预印本引用，其贡献是明确数据准备的表示和流程，不能据此认定原始数据已经自动转成经过科学验证的结论。

对小分子项目，可以据此设计一个应用例子。若任务是比较同一批化合物的活性，实验结果表、化合物映射表和实验说明应当作为可定位的数据单元。系统先确认样品能否对应、活性字段代表什么，再决定筛选和整合方式。这个例子是本文对方法的借鉴。原论文的酶学案例支持跨来源数据准备能力，但并未证明所有小分子测定条件都能自动对齐。

1.6 建模后的知识怎样被大模型使用

《Bridging data and discovery》（National Science Review，2026）[1] 进一步区分了知识图谱和大模型的角色。图谱提供事实依据、科学限制和多模态信息的联系。模型提供自然语言访问、分析、假设生成、知识整理及任务安排。

1.6.1 提供带来源的检索上下文

最直接的用途是检索增强。系统先识别问题中的对象，再从数据库或图谱中取出相关记录，最后把必要信息和来源交给模型组织回答。图 1.12 中的 KG-RAG（Bioinformatics，2024）[27] 就是这一方式。图谱承担对象定位和关系查询，模型承担自然语言解释。若问题涉及数值筛选、单位换算或统计比较，则可以由程序执行后再交给模型说明。

这篇 KG-RAG 论文具体从问题中识别疾病对象，并将其对应到 SPOKE 图谱中的节点。随后提取相关图关系及可用的来源信息，把它们转成简短自然语言陈述。系统再比较问题与这些陈述的语义相关性，保留适合当前问题的内容。模型读到的因此是经过选择的局部上下文，而不是整个图谱或全部数据库模式 [27]。

这一步选择同时影响成本与答案。相关性筛选可以减少提示长度，但如果关键信息没有被检索到，后面的模型也无法依据它回答。原文因此分别检查对象识别、上下文检索和最终问答，并与其他检索方式比较。对药物记录，还应加入数值类型与实验条件筛选，因为文字相似并不能代替测量可比性检查。

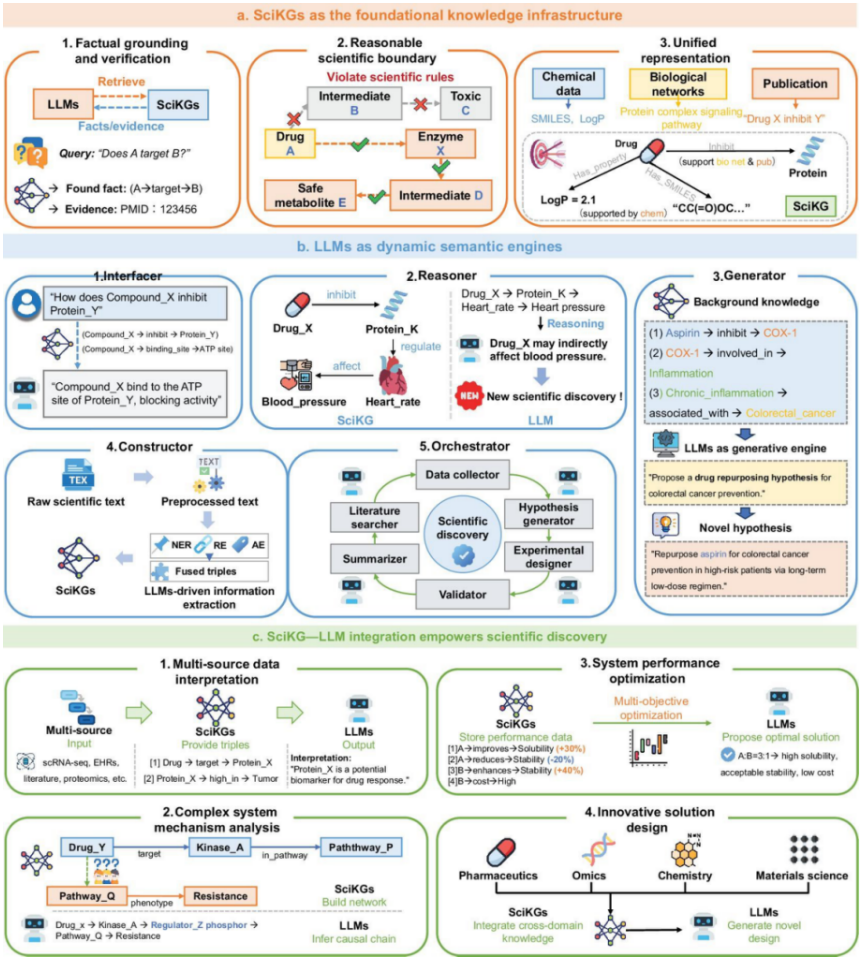


图 1.11 科学知识图谱与大模型的分工。

小贴士（图 1.11：图谱与大模型的分工）

上方为图谱作用，中间为模型角色，下方为资料解释、机制分析、性能优化和新方案设计四类任务。原图中的因果推断与新发现文字应按概念示意理解。

原图出处 Ding 等，National Science Review，2026，Figure 7。论文原文。许可 CC BY 4.0。

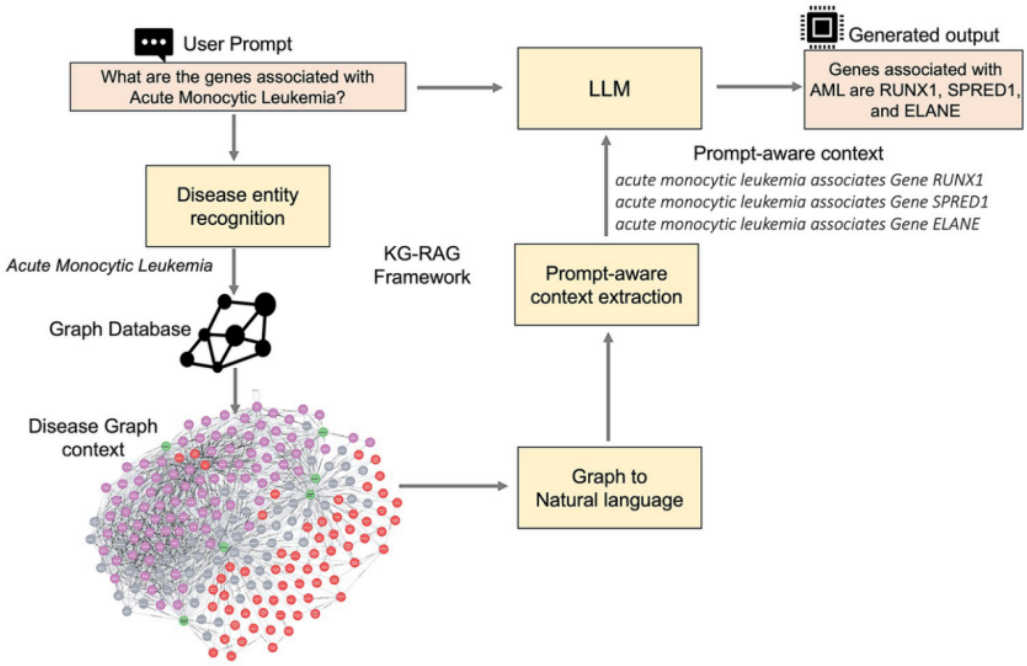


图 1.12 KG-RAG 如何把图谱知识交给语言模型。

小贴士（图 1.12：KG-RAG 的检索与生成）

系统从问题识别疾病对象，检索相关图谱内容，将其转成文字，并选择与问题相关的部分作为上下文。图中为原论文的生物医学问答示例。

原图出处 Soman 等，Bioinformatics，2024，Figure 1。论文原文。许可 CC BY 4.0。

Soman 等人的实验中，GPT-3.5-Turbo 在人工整理的生物医学选择题上的平均准确率由 0.63 提高到 0.79，GPT-4 由 0.68 提高到 0.74[27]。这些结果说明特定图谱上下文对该测试有效，也显示不同基础模型的收益不同。它们不能直接推导出小分子活性比较或机制判断会获得相同提升，因为后者还需要检查实验条件和数值含义。

面向药物项目时，返回给模型的内容应是一组可定位的证据记录。化合物标识、实验体系、结果终点、数值、单位和来源应尽量一起返回。原始条件缺失时，需要明确标记。这样，模型可以说明当前记录是否可比，而不必从一条简化关系中猜测实验背景。

1.6.2 规划并检查多步关系

第二种用途是帮助模型处理多步查询。RoG（ICLR，2024）[28] 先让模型决定需要依次查询哪些关系，再从图谱寻找符合这一计划的真实路径。

这篇论文把关系类型序列作为计划。训练时，作者利用问题对象与答案对象之间的图路径构造监督信号，并同时训练计划生成和基于检索结果回答两种能力。使用时，模型先提出关系计划，系统从问题实体出发执行检索，再把找到的具体对象和关系交给模型生成答案。计划可以复用到不同实体，实际事实则由图谱提供 [28]。

比如，在药物场景中，可以先查询与某靶点有关的化合物，再查询这些化合物的实验记录。这个例子说明如何借鉴关系计划，并不是原论文已经验证了该药物任务。RoG 主要在通用知识图谱问答中测试。它有助于暴露中间查询步骤，但如果问题实体没有正确映射到图谱，或关系本身缺失，计划仍可能无法得到正确答案。

GCR（ICML，2025）[29] 进一步研究怎样在生成过程中直接限制路径，使模型不能随意写出图谱里不存在的连接。

这篇论文把可使用的图路径编码为 KG-Trie，也就是按路径序列组织的前缀树索引。模型生成到某个前缀时，只允许继续选择索引中合法的后续内容。一个较轻量的图谱专用模型负责产生受约束路径，通用大模型再综合多条路径进行回答。作者在知识图谱问答基准上检查效果，并测试对未见图谱的迁移 [29]。

这种方法限制的是给定图谱中的路径合法性。论文所说的消除路径幻觉，应在这个范围内理解。图中的关系若有错误、缺少条件，或者只表示相关性，合法

路径仍不能变成可靠的因果证明。对科学数据，GCR 说明图结构可以进入解码约束，但还需要另外规定哪些类型的证据可以参与某种判断。

Cat-KG（National Science Review，2025）[10] 展示了领域规则参与其中的方式。系统先从反应图谱搜索候选路线，再用人工设计的化学规则评分，最后由大模型把结构化路线和条件转成说明。在这种分工中，语言模型不必独自完成搜索、计算和化学限制判断。图谱及规则提供可执行的操作对象，模型负责整合结果并与研究人员交流。

KRAGEN（Bioinformatics，2024）[31] 研究怎样把图谱检索与问题分解结合起来。

这篇论文先把生物医学图谱中的关系转成自然语言陈述，再建立向量索引用于检索。它结合 Graph of Thoughts 提示方法，把复杂问题分为相关子问题，分别获取依据，最后汇总回答。图界面展示的是问题分解及答案组织过程，使用户可以检查模型引用了哪些知识。它并不要求每一步都直接生成数据库查询 [31]。

比如，寻找同时与两个基因有关的药物时，可以分别取回相关知识，再比较结果。作者在阿尔茨海默病知识库上的测试中，报告两步选择题准确率由 53.1% 提高到 71.8%，但两步判断题仅由 62.4% 提高到 62.9%。结果说明复杂问题分解在部分题型上有帮助。由于图关系被转成文字再检索，事实遗漏和语言整合错误仍可能出现 [31]。

同一研究方向的 ESCARGOT（Bioinformatics，2025）[32] 进一步研究怎样让模型生成可执行代码，并安排图查询和计算。

这篇论文把查询和计算进一步写成可执行的 Python 步骤，再用动态任务图保存步骤及其依赖。一个节点可以执行一段代码，前一步结果能够传给后一步。比如，比较两个查询结果的交集时，可以让程序实际计算，而不是要求语言模型在长列表里自行挑选。作者结合生物医学知识库和推理任务检查这种安排的效果 [32]。

这里有两张作用不同的图。生物医学图谱保存药物、基因等对象及关系，动态任务图保存当前问题要执行什么操作。前者提供数据，后者组织使用数据的过程。这一区分对工程实现很有用。即使代码成功执行，查询条件也可能错误，因此仍要检查模型是否选对关系、输入与计算方式。可执行过程让错误更容易定位，但不能单独保证科学结论正确。

1.6.3 用实验背景指导候选设计

第三种用途是把已有实验转成生成任务的上下文。图 1.13 中的 Assay2Mol（EMNLP，2025）[30] 先根据新靶点检索相关 BioAssay 描述，再利用实验编号取得测试分子与结果。模型随后同时看到研究背景、实验摘要以及有活性和无活性的分子示例。因此，真正起作用的输入不只是分子结构，也包括这些结构是在什么任务中被测试的。

这篇论文保留了 BioAssay 描述与实验结果表之间的编号对应。文本检索先找到可能相关的实验，筛选与整理后，再读取其中被测试分子的结构及活性结果。上下文同时包含有活性和无活性的示例，使模型能够参考已有测定中的差别来生成候选。它利用的是实验描述与定量记录之间的联系，而不只是检索包含靶点名称的段落 [30]。

从建模角度看，这里的关键对象是一次测定及其测试结果。实验描述说明任务背景，实验编号连接结果表，分子结构与结果保持配对。向量索引负责发现相关描述，编号关联负责找到对应数据，两者承担不同工作。原论文说明，即使不预先建设大型知识图谱，也可以通过合理组织实验记录，为大模型设计任务提供更有用的上下文。

在 CrossDocked 测试中，使用 Gemma-3-27B 的 Assay2Mol（EMNLP，2025）[30] 平均 Vina Dock 分数为负 8.064，不使用这一上下文流程的同一模型为负 7.050。该指标通常以更低值表示更有利的对接评分，但它只是计算代理指标，不能当作实验亲和力。论文还讨论了分子尺寸、可合成性和其他性质，因此不能只靠这一项分数评价候选的药物价值。

从这三种用途可以看出，建模结果既可以被转成提示中的文字，也可以成为查询、搜索和计算工具的输入。对 AI 团队，重点是让模型能够可靠地选择并使用这些操作。对数据团队，重点是保证操作返回的内容含义明确、身份一致，而且能回到原始依据。两者需要围绕具体科学任务共同设计。

1.6.4 用知识训练分子模型并调用专门的预测模型

知识还可以进入训练。Mol-Instructions（ICLR，2024）[20] 研究如何把分子、蛋白质和生物医学文本资源转换成大模型能够学习的指令样本。

这篇论文先定义任务，再把已有数据转换成指令、输入和输出。比如，分子性质预测把结构作为输入、性质作为目标，反应任务组织反应物与产物，文本任务

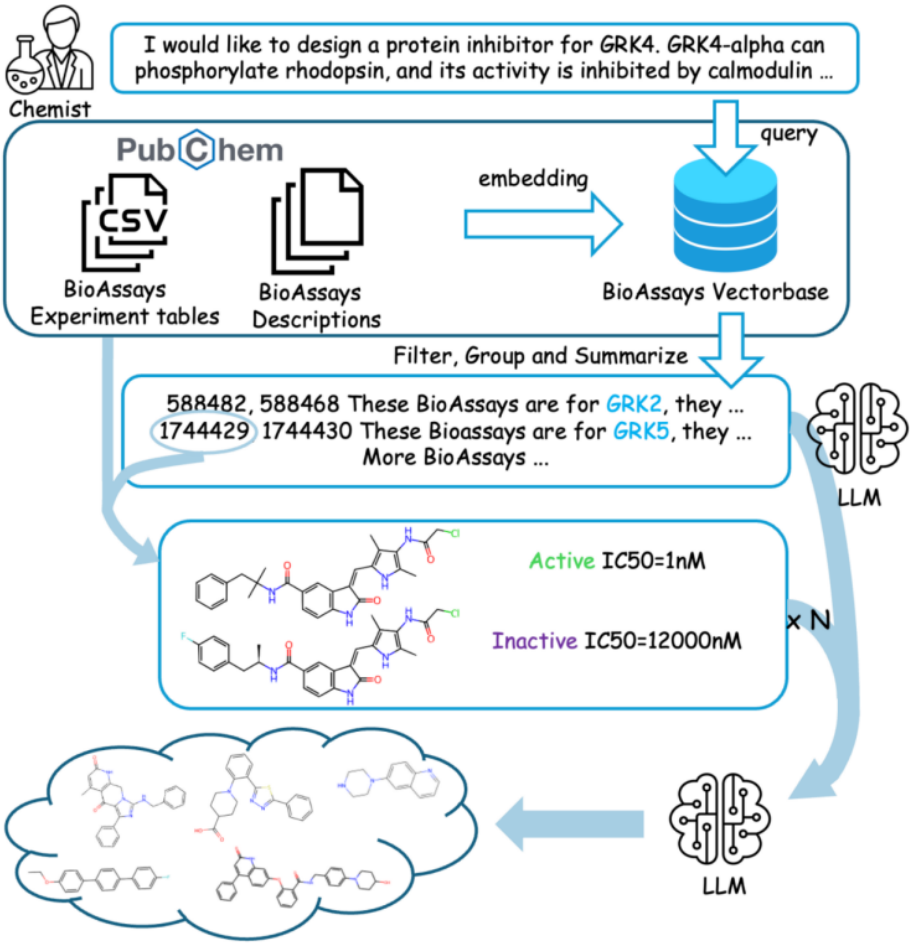


图 1.13 Assay2Mol 如何使用已有生物测定指导分子生成。

小贴士（图 1.13：Assay2Mol 的测定信息）

系统结合实验描述检索、BioAssay 编号、测试分子和活性结果。原图图标来源按原论文标注为Flaticon.com与svgrepo.com。

原图出处 Deng 等，EMNLP，2025，Figure 1。论文原文。许可 CC BY 4.0。

则使用实体或关系标注。作者结合人工设计、模型辅助生成任务描述和模板转换，使相同科学任务能够以多种自然语言方式表达，并通过质量检查控制样本 [20]。

论文用指令微调实验检查这些样本能否改善模型的生物分子任务表现。它提供的主要产物是训练数据及相应模型能力。这里需要保留科学对象与监督目标的对应，但推理时未必还能返回某次原始测定。因此，若任务要求说明证据出处，仍应另外保留训练样本来源或接入外部记录。

KEDD（Health Data Science，2024）[22] 研究的是怎样把分子结构、知识图谱和生物医学文字共同转成预测模型可使用的特征。

这篇论文分别编码不同模态，再将相关表示组合起来完成药物发现任务。它特别考虑新分子缺少图谱关系或文本说明的情况。作者采用多头稀疏注意力，从相关生物分子中寻找可用信息，并在训练时遮蔽部分模态，让模型学习在信息不完整时工作。因此，知识图谱既是额外信息来源，也是帮助补充缺失表示的资源 [22]。

作者在药物与靶点相互作用、分子性质和相关关系预测等任务中评价框架。其结果支持多种知识共同参与学习，但被重建的是模型特征，不是新做出的实验观察。对药物项目，KEDD 适合说明建模后的知识如何改善预测输入。模型获得更好的向量表示，并不意味着每项预测都有一条可直接核查的原始实验记录。

MV-Mol（KDD，2024）[23] 进一步提出，同一分子需要随研究视角形成不同表示。分子的结构没有变化，但研究问题可能关注化学性质，也可能关注生物作用。

这篇论文用文字提示描述视角，并通过融合网络共同读取分子结构和视角信息。训练分为两个阶段。第一阶段把结构与规模较大的文本对齐，学习共同信息。第二阶段使用知识图谱中的关系，把关系描述当作具体视角继续学习。这样既利用文字覆盖面，也利用结构化知识中较明确的关系含义 [23]。

论文用分子性质预测、分子与文本的相互检索及生成任务评价表示效果。它对本文的意义是，建模后的关系可以成为训练时控制信息选择的条件。对于同一个化合物，不必假定一个固定向量能够同样充分地表达全部问题。不过，表示随视角变化依然不能代替真实测量条件，模型性能也应在对应任务上判断。

TxGNN（Nature Medicine，2024）[33] 展示了怎样使用知识图谱训练专门的药物重定位模型。

这篇论文在包含 17,080 种疾病和 7,957 种药物的图谱上学习关系，预测药物适应证和禁忌证，并提供解释性子图。TxGNN 是图学习模型，并非大语言模型，但其预测结果可以作为工具输出供大模型使用。论文中的跨疾病评价和专家分析支持研究用途，候选适应证仍需要后续验证。

TxGNN 重点处理缺少已知治疗药物的疾病。模型利用疾病之间共享的通路、表型和其他生物信息，把相关疾病中的知识用于目标疾病的候选预测。评价因此不只是在随机留出的药物疾病关系上测试，也关注训练中没有相应治疗信息的疾病。这个问题比单纯找回已知药物关系更接近数据稀少疾病的研究需要 [33]。

论文还用解释性子图向专家展示预测涉及的关系，并结合医疗记录与专家评估检查候选结果。解释子图帮助检查模型依据，但不是药物有效性的实验确认。对 LLM 系统，可以把这类专业模型作为候选排序工具，再要求语言模型说明依据与限制。预测分数、图谱关系和实际疗效证据应分别呈现。

1.7 局限性与仍需解决的问题

1.7.1 原始证据不完整会限制一切后续步骤

科学知识建模不能恢复从未记录的条件，也不能自动纠正存在问题的实验。文献通常更容易获得成功结果，失败实验和阴性观察则可能缺失。内部记录的细节较多，但写法和质量未必统一。即使抽取模型完全复述了原文，最终知识仍可能受到原始报道范围的限制。

因此，应把抽取的可靠性与实验的可靠性分别评价。模型准确识别了一个数值，不代表实验已经被独立重复。同一结果被多个数据库收录，也不能自动算作多份独立证据。评价和检索都需要尽量识别这些重复来源。

1.7.2 领域差异很难被一个通用模式完全覆盖

不同实验需要不同的条件描述。比如，BAO（Journal of Biomedical Semantics，2014）[8] 主要讨论生物测定概念，BAO 更新论文（Journal of Biomedical Semantics，2026）[9] 又加入药代和安全药理内容。领域模型因此需要持续修订。跨项目复用时，还要检查概念粒度是否一致，以及旧记录是否需要转换。

多模态资料还会增加记录对应的难度。比如，同一化合物的结构可能在图片中，编号在正文中，活性值在表格中，实验条件又在补充材料中。分别识别这些

内容以后，还要确认它们是否属于同一个样品和同一次实验。现有文本抽取分数不能证明这些对应关系都已重建正确。

1.7.3 图谱路径和语言解释都不等同于科学证据

知识图谱通常擅长表达关联，但关联不必然说明因果。疾病与基因相关、化合物作用于蛋白、某个通路参与疾病，这些信息可以帮助提出假设，却不足以独立证明治疗机制。图约束生成限制了模型怎样沿图取用知识，但不会提高图中事实本身的证据等级 [28][29]。

因此，系统应区分已经报告的实验、对多条记录的综合判断，以及待验证的研究假设。模型生成的解释如果重新写入知识库，也必须保留其来源和推断状态。否则，后续检索可能把上一次生成的文字误认为新的外部证据。

1.7.4 现有评估距离实际研发成效仍有差距

评价时应设置简单而公平的比较方案。在同一批资料、相同基础模型和相近上下文预算下，比较直接文献检索、结构化数据库查询与图谱增强方法。测试资料还应按文献、时间或化合物系列适当划分，避免同一实验的重复收录造成过高估计。只有这样，才能判断改进来自数据整理、更多上下文，还是图结构本身。

《Bridging data and discovery》（National Science Review，2026）[1] 建议分层评价。第一层检查组成过程，例如实体识别、关系抽取和对象对齐。第二层检查图谱本身，例如覆盖、结构及关系预测表现。第三层检查可信程度和实际用途，包括来源、时间信息和下游任务效果。前两层有较高分数，并不自动意味着第三层可靠。

SciKnowEval（arXiv 预印本，2024）[21] 把科学知识能力区分为记忆、理解、推理、辨析和应用，为评价提供了另一个参考。对小分子任务，可以进一步分别测试模型能否找回结果、判断实验是否可比、识别证据冲突，以及调用计算工具完成分析。

这篇论文构建了覆盖生物、化学、物理和材料的约 7 万道问题，并用零样本和少样本方式评价 26 个模型。五个层次分别检查模型是否掌握事实、理解含义、完成推理、辨析问题并应用知识。作者观察到，即使总体较强的模型，在科学推理和应用层面仍有明显改进空间 [21]。

它对知识建模的启发是，不要只用事实问答来证明系统会使用科学数据。比如，找回某个 IC_{50} 数值与判断两组 IC_{50} 能否比较，是不同能力。这个例子是本文

提出的药物场景评价建议。SciKnowEval 本身主要是模型能力基准，并未直接证明某一种图谱或数据模式能提高实验决策质量。

1.7.5 知识维护与数据偏差仍需长期处理

《Bridging data and discovery》（National Science Review，2026）[1] 还讨论了文献偏差和动态更新。比如，热门靶点与成功实验的记录更多，模型可能因此偏向这些对象。新结果、勘误和撤稿也要求系统保留版本并更新证据。由智能体持续整理和校验知识是论文提出的未来方向，可靠更新与实验验证仍需研究。

1.8 结语

科学知识建模把散落的资料整理为含义明确、保留条件、能够追溯的研究记录。结构化模式解决怎样记录，本体解决怎样理解概念，知识图谱解决怎样连接不同对象，大模型则为抽取和使用这些知识提供新的方法。它们各有作用，也需要共同接受任务和证据的检验。

对小分子药物研发，现阶段较有依据的方向，是围绕明确任务组织分子、样品、实验、结果和来源，再逐步加入模型检索与推理。已有工作已经能改善若干数据处理和计算任务。接下来的关键，是让这些改进转化为可重复验证的研究判断，并证明它们确实帮助研究人员做出了更好的实验选择。

文献与延伸阅读

以下为正文引用的代表性工作。期刊与会议说明用于帮助跨领域读者理解发表背景，不作为单篇研究可靠性的评分。

完整文献条目统一列在全书末尾；以下补充文献的发表背景说明与项目入口。

- [1] 科学知识图谱主题综述。
- [2] 化学信息学专业期刊。
- [3] 计算机领域重要综述期刊。
- [4] 2024 卷期，2023 在线发表。生物信息资源领域的重要数据库专刊论文。
- [5] 2025 卷期，2024 在线发表。
- [7] JACS 为美国化学会旗舰综合化学期刊。
- [8] 领域本体与生物医学语义专业期刊。
- [9] 2026 年 3 月正式发表，DOI 中含 2025 不代表发表年份。
- [10] 综合性研究期刊，本文属于催化领域。
- [11] Nature 旗下数据资源专业期刊，论文重点是 PrimeKG 数据集。
- [12] Nature 旗下人工智能专业研究期刊。
- [13] 数据科学专业期刊。
- [14] 技术标准。
- [15] 预印本，本文未核实到正式期刊或会议发表。官方项目。
- [16] Nature 旗下计算科学专业研究期刊。官方项目。
- [17] 预印本技术报告。
- [18] 非同行评议论文，服务范围以所引页面版本为准。
- [19] 预印本，本文采用 2026 年 9 月 7 日修订版。
- [20] 机器学习主要国际会议，文献信息注明为主会论文。
- [21] 预印本，配套基准后续更新。
- [22] Science Partner Journal 体系中的健康数据科学专业期刊，并非 Science 主刊。
- [23] 数据挖掘主要国际会议。
- [24] 综合性研究期刊。
- [25] 机器学习主要国际会议，文献信息注明为主会论文。
- [26] 预印本，作者注明 NeurIPS AIDaR 研讨会录用，不是主会论文。
- [27] 生物信息学主要专业期刊。
- [28] 机器学习主要国际会议，文献信息注明为主会论文。
- [29] 文献信息注明为 ICML 主会论文，收入 PMLR 第 267 卷。
- [30] 自然语言处理主要国际会议，文献信息注明为主会论文。
- [31] 生物信息学主要专业期刊。
- [32] 生物信息学主要专业期刊。
- [33] 医学领域重要研究期刊，本文方法名为 TxGNN。

第二章　自主实验室与干湿闭环

学习目标：理解自主实验室如何连接计算决策、实验执行和测量反馈，比较不同领域的闭环指标。

先修知识：机器学习、实验设计与科研工作流基础。

2.1　自主实验室是什么

科学研究通常需要反复实验。一个初始设想往往只能确定大致方向，具体方案还要根据结果调整。例如，制备一种材料时，需要不断改变原料和加热条件。寻找一种酶时，需要构建不同序列，再比较它们的功能。研究能否有效推进，既取决于实验能否顺利完成，也取决于下一次实验是否选得合适。自动移液器、机械臂和高通量检测设备已经能够承担许多重复操作。但是，按照预设方案连续执行实验，只解决了操作问题。实验结果出现后，怎样判断哪些方案值得继续尝试，通常仍需要研究者分析和决定。

自主实验室是在研究者给定的目标和约束下，能够自动执行实验、分析结果，并据此选择后续实验的系统。

2.2　自主实验室中的干湿闭环

2.2.1　一轮干湿闭环怎样完成

第一步，干实验提出本轮方案。模型利用已有数据，比较不同候选的预期表现和不确定性，再选择值得测试的对象。输出必须足够具体，例如一组反应条件、一条蛋白质序列或一套培养参数，使实验设备能够执行。

第二步，湿实验产生真实结果。设备按方案制备样品并测量性能。实验得到的产率、活性或细胞状态，可能符合预测，也可能与预测不同。这些差异是修正后续判断的重要依据。

第三步，实验结果返回干实验。系统将实测结果与对应的候选、实际操作条件和质量检查记录放在一起。经过检查的数据被用于更新模型、候选排序或实验选择策略。仪器故障与候选本身表现较差，需要分别处理。

2.2.2 闭环怎样才能可靠运行

干湿闭环需要同时满足三个要求：计算提出的方案能够执行，实验返回的数据能够解释，更新后的判断能够实际改变后续安排。任何一个步骤缺失，计算与实验之间的往返都会中断。

这也是为什么自主实验室需要实验管理软件。它必须记录样品身份和实际条件，协调设备顺序，并把测量结果交给正确的模型或选择程序。Lee 等人的综述《Toward self-driving laboratory 2.0 for chemistry and materials discovery》（Materials Horizons，2026）将模块化硬件、决策算法与实验调度和数据管理放在一起讨论，强调这些组成需要共同支持持续实验 [34]。

闭环也不要求每轮都重新训练一个大型模型。新结果可以用于更新预测模型，也可以用于调整候选排序、选择策略或控制动作。

2.3 化学研究中的干湿闭环

化学研究中的一个常见问题是，同一种反应可以在许多不同条件下进行，但哪些条件更有效，往往需要实验才能确定。改变原料比例、催化剂或反应时间，都可能影响产率和产物组成。

干实验可以利用已有数据比较这些方案，湿实验则负责完成反应并测量结果。当实测结果返回模型，并进一步影响下一次反应的安排时，反应研究就形成了干湿闭环。

有机合成与催化研究都采用这种方式。两者的区别主要在于优化对象。有机合成通常围绕目标产物的制备条件展开，催化研究还需要比较催化体系本身，以及它对反应活性和产物选择性的影响。

2.3.1 有机合成

Pilon 等人的 RoboChem-Flex（Nature Synthesis，2026）将实验设备、控制软件和贝叶斯优化结合，用于自动寻找反应条件。其中的光催化案例明确展示了干湿实验如何闭环 [35]。

- 干实验首先选择条件。算法在预先规定的范围内，选择反应浓度、原料用量、停留时间，以及光催化剂等变量。

- 湿实验随后完成加料与流动反应，并通过在线氟核磁分析得到实测产率。
- 实测产率返回后，算法重新判断哪些条件值得尝试。新选择再次交给设备执行，下一次测量又进入计算端。研究在 15 次初始实验后，继续进行了 35 轮反馈优化，因此后续实验的条件持续受到新测量的影响。

实验结果还会改变探索方式。当连续三次实验的产率相近时，算法会增加对不确定区域的探索。这说明反馈不仅能调整某个参数，也能改变系统接下来搜索哪些区域。

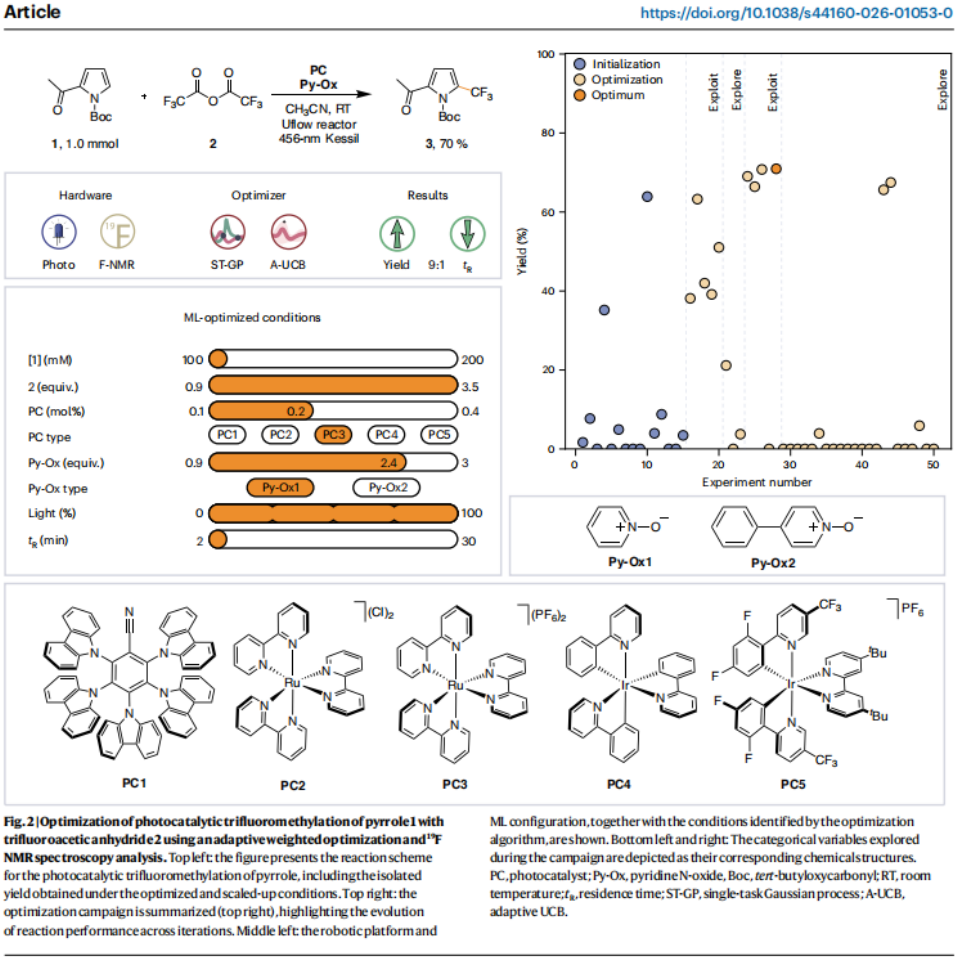


Fig. 2 | Optimization of photocatalytic trifluoromethylation of pyrrole 1 with trifluoroacetic anhydride 2 using an adaptive weighted optimization and ^{19}F NMR spectroscopy analysis. Top left: the figure presents the reaction scheme for the photocatalytic trifluoromethylation of pyrrole, including the isolated yield obtained under the optimized and scaled-up conditions. Top right: the optimization campaign is summarized (top right), highlighting the evolution of reaction performance across iterations. Middle left: the robotic platform and ML configuration, together with the conditions identified by the optimization algorithm, are shown. Bottom left and right: The categorical variables explored during the campaign are depicted as their corresponding chemical structures. PC, photocatalyst; Py-Ox, pyridine N-oxide, Boc, *tert*-butyloxycarbonyl; RT, room temperature; t_R, residence time; ST-GP, single-task Gaussian process; A-UCB, adaptive UCB.

图 2.1 利用自适应加权优化和核磁共振（NMR）光谱分析，对吡咯 1 与三氟乙酸酐 2 的光催化三氟甲基化反应进行优化。原文图 2。

来源：所提供资料第 3 页；保留原始图片。

小贴士（图 2.1：RoboChem-Flex 读图指南）

图的左上角是反应示意图

- 1：起始原料，是一种吡咯衍生物。
- 2：提供三氟甲基（$-CF_3$）的试剂。
- PC：光催化剂（Photocatalyst）。
- Py-Ox：氧化剂。
- 3：希望得到的目标产物，产率为 70%。

反应在乙腈（CH_3CN）中进行，室温（RT）下使用 456 nm 的 Kessil 光源照射。

产率（Yield）：反应后实际获得的目标产物有多少。通常产率越高越好。

光催化剂（PC）：帮助光照驱动化学反应的物质。不同催化剂可能会让反应表现出很大差异。

因此，研究人员要解决的问题是：怎样选择实验条件，才能让这个反应更高效地进行？

左下角：机器学习到底优化了哪些条件？

这部分是整张图的核心之一。研究人员把化学反应中能够调整的因素交给机器学习，让算法决定接下来应该怎么做实验。

1. 原料 1 的浓度（[1]）100–200 mM

决定反应物的浓度，可能影响反应速率和产物生成量。

2. 试剂 2 的当量（equiv.）

0.9–3.5

表示试剂 2 相对于基准反应物的用量比例。比如 2 当量通常表示用量是基准物质的 2 倍。

3. 光催化剂用量与种类

PC 用量：0.1%–0.4%；PC1–PC5

不仅要选择催化剂，还要决定加入多少。底部画出了五种候选催化剂的分子结构。

4. 氧化剂 Py-Ox 的用量与种类

0.9–3 equiv.；Py-Ox1 或 Py-Ox2

两种氧化剂的结构也在图中给出。算法需要判断哪一种更适合当前反应。

小贴士（图 2.1：RoboChem-Flex 读图指南，续）

5. 光照强度与反应时间

光照：0–100%；t_R：2–30 min

光照强度和停留时间都会影响反应结果。t_R 表示反应停留时间。

这不是只调一个参数，而是同时考虑连续变量和类别变量：

- 连续变量：浓度、用量、光照强度、反应时间。
- 类别变量：催化剂 PC1–PC5、氧化剂 Py-Ox1/Py-Ox2。

右上角：机器学习如何找到最优实验条件？

Initialization（初始化）

先做一些初始实验，获得基础数据，让模型初步了解哪些条件有效。

Optimization（优化）

根据已有实验结果，由算法继续选择实验条件，探索更好的反应表现。

Optimum（最优条件）

标记算法找到的最优条件对应的结果。

可以分三步理解。

第一步：先尝试一些条件。

最开始的实验结果有高有低，很多实验的产率很低，甚至接近 0%。这很正常，因为研究人员还不知道哪些参数组合最有效。

第二步：算法根据结果调整下一次实验。

例如，某些催化剂和氧化剂的组合效果较好，算法就可以利用这些信息，决定下一次实验应该尝试什么条件。同时，它也需要探索尚不确定的区域，避免过早认定某个条件就是最优的。

第三步：逐步找到高产率条件。

图中部分后续实验的产率达到约 60%–70%，说明算法找到了表现较好的实验条件。不过，优化过程中仍然有一些实验产率很低，说明机器学习并不是每次都能预测正确，而是在一轮轮实验中逐步改进。

图中标注的 Explore（探索）或 Exploit（利用），对应的就是优化算法中两类不同的决策思路：一类尝试新的条件，另一类利用目前已经发现的有效条件继续改进。

小贴士（图 2.1：RoboChem-Flex 读图指南，续）

底部：为什么要展示这么多催化剂结构？

底部列出了五种候选光催化剂 PC1–PC5 的分子结构，以及两种氧化剂 Py-Ox1、Py-Ox2。

这些结构不是装饰，而是告诉读者：算法搜索的空间包含了真实的化学选择。

例如，算法可能需要判断：

- 使用 PC1 还是 PC3？
- 使用 Py-Ox1 还是 Py-Ox2？
- 催化剂的用量应该是多少？
- 在选定催化剂后，什么光照强度和反应时间更合适？

这些选择组合起来，就形成了一个复杂的实验条件搜索空间。

2.3.2 催化研究

反应进行得快，并不一定意味着目标产物所占比例高。干实验因此需要同时考虑催化活性与选择性，湿实验也必须返回能够分别评价这两个目标的数据。

Bennett 等人的 Flex-Cat（Nature Communications，2026）研究铑催化反应中的配体与条件组合。配体是与金属配合、影响催化表现的分子。平台用并行反应装置测试不同组合，再用气相色谱分析产物 [36]。

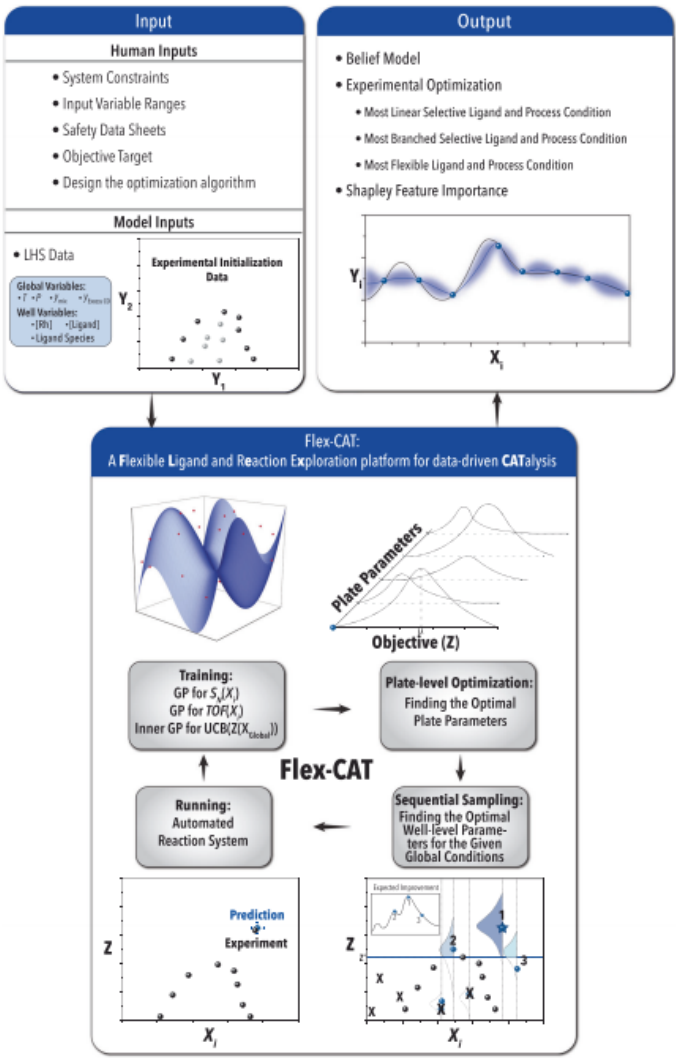


图 2.2 Flex-Cat 的 AI 驱动决策工作流。原文图 5。

来源：所提供资料第 6 页；保留原始图片。

小贴士（图 2.2：Flex-Cat 的决策流程）

利用预先定义的系统约束、输入参数范围和初始化实验数据，训练用于预测区域选择性（S_N）和周转频率（TOF）的高斯过程（GP）模型。其中，内层 GP 模型负责优化微孔板层面的实验参数，包括温度、压力和气体混合比例。

通过序贯采样与自动化反应执行，系统能够识别出分别具有最高直链选择性、最高支链选择性，以及兼具灵活性的配体–工艺条件组合。

小贴士（图 2.2：Flex-Cat 的决策流程，续）

各变量的取值范围、安全边界以及初始化实验设计均在实验开始前预先设定。在这些约束条件下，分层决策策略能够自主选择微孔板层面的设定参数和微孔层面的配方，执行实验、更新代理模型，并提出下一批实验方案。

干实验决定下一块反应板怎样安排。算法既选择各孔的配体和配方，也选择整块板共享的温度、压力等条件。湿实验随后完成配料、反应与检测，得到催化活性和不同产物的比例。

这些结果返回高斯过程模型，更新对配体与条件组合的判断。算法再结合两个目标和设备限制，安排下一块反应板。新的反应结果继续进入模型，形成多轮选择。论文在三组优化任务中完成了 680 次实验 [36]。

2.3.3 移动机器人怎样把不同实验站接入闭环

干湿闭环也可以通过移动机器人连接已有设备来实现。Burger 等人的移动机器人化学家（Nature，2020）在实验室中操作不同工作站，寻找更有效的光催化制氢配方 [37]。

在干实验一侧，批量贝叶斯搜索方法选择下一批配方。在湿实验一侧，机器人配制样品、执行光照实验并完成检测。测得的制氢表现返回算法后，算法据此调整各组分的选择，再让机器人测试新的配方。

系统在 8 天中完成了 688 次实验，找到的混合物活性达到初始配方的六倍。这里的自主性同时体现在实验操作和后续选择中。机器人负责让实验连续进行，算法负责根据新结果改变下一批实验。

这一方式使已有仪器能够参与连续研究。相应地，样品在不同工作站之间转移时，编号、操作条件和检测结果也必须保持对应，才能让数据准确返回计算端。

2.4 材料研究中的干湿闭环

2.4.1 无机材料与固态合成

计算能够筛选可能稳定的晶体，却不能直接保证实验能够制得这些材料。原料选择和加热过程都会影响实际产物。因此，无机材料的干湿闭环首先要解决从计算候选到真实样品的问题。

Szymanski 等人的 A-Lab（Nature，2023）展示了这一过程。干实验先根据文献中的合成经验和计算信息，为目标材料选择前驱体与加热方案。湿实验由机器人完成粉末处理、混合和加热，再通过 X 射线衍射判断实际形成了哪些晶体物质。如果目标产物不足，系统就结合观察到的产物和热力学信息，提出新的合成方案并继续实验。失败结果因此也能成为下一轮选择的依据 [38]。

这里返回计算端的信息，包含目标产物是否出现，以及同时生成了哪些其他物质。这些结果可以帮助系统判断原先的合成方案为什么没有达到目标。干实验据此修改后续方案，湿实验再检验修改是否有效。

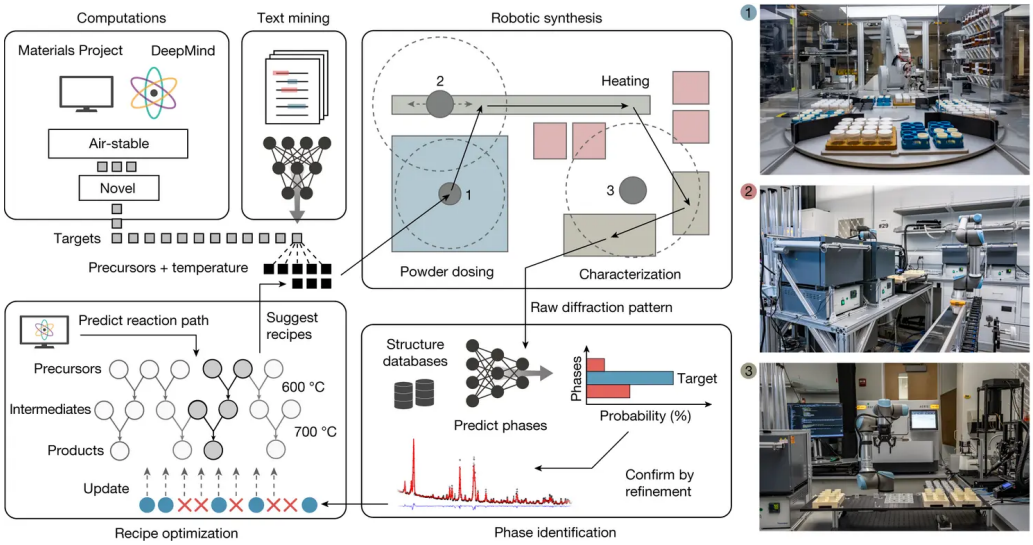


图 2.3 利用 A-Lab 实现自主材料合成。原文图 1。

来源：所提供资料第 8 页；保留原始图片。

小贴士（图 2.3：A-Lab 的材料合成流程）

左上角：Computations，计算筛选目标材料

图中对应文字：Materials Project、DeepMind、Air-stable、Novel、Targets

这部分回答的是：我们要合成哪些材料？

- Materials Project 和 DeepMind：提供材料晶体结构等计算数据。
- DFT（密度泛函理论）与凸包计算：用于判断哪些材料在热力学上具有稳定性或值得进一步研究。
- Air-stable：筛选在空气中能够保持稳定的目标材料。
- Novel：强调筛选具有新颖性的目标材料。

小贴士（图 2.3：A-Lab 的材料合成流程，续）

筛选后形成一批 Targets（目标材料），它们是后续实验需要尝试合成的对象。

上方中间：Text mining，文献挖掘

这部分回答的是：已有研究中有哪些合成经验可以借鉴？

研究团队从文献中提取材料合成数据，并用这些数据训练机器学习模型。模型可以利用已有的合成经验，为目标材料提出候选合成方案。

这里的关键是，文献不是直接告诉机器人“下一步做什么”，而是提供训练数据，让模型学会从原料和合成条件推测可能的合成路径与方案。

左下角：Predict reaction path + Suggest recipes，预测反应路径并提出配方

这是图中很重要的一部分，也是主动学习优化的起点。

图里的反应路径由三层节点组成：

- Precursors：前驱体，即最初投入的原料。
- Intermediates：中间产物，即反应过程中可能形成的物质。
- Products：最终产物。

旁边的 600 °C、700 °C 表示不同反应阶段或候选合成方案对应的温度条件。图中被灰色填充的节点和加粗箭头，表示模型重点选择的候选反应路径。

模型据此执行 Suggest recipes（提出合成配方），把候选方案转化为机器人可执行的实验任务。实验任务通常包括前驱体组合、各原料用量及温度等合成条件。

你可以把它理解为：

目标材料 + 已有合成知识 + 反应路径预测 → 候选实验配方。

上方中间：Robotic synthesis，机器人自动合成

这里的数字 1、2、3 与最右侧三张实景照片对应。

1. Powder dosing（粉末加料）

根据配方，自动称量并向样品容器中加入相应的前驱体粉末。这里是将算法提出的配方真正转化为实体实验。

2. Heating（加热）

机器人将样品送至加热设备，按照预设条件进行反应。图中的箭头表示样品在自动化实验流程中移动。

小贴士（图 2.3：A-Lab 的材料合成流程，续）

3. Characterization（产物表征）

合成后的样品被转移到 X 射线衍射（XRD）设备中，测量其衍射图谱，为后续的物相识别提供数据。

图中上方的箭头和机械臂表示样品在不同操作站之间流转。也就是说，机器人不仅负责某一个单独动作，还把加料、加热、表征等步骤连接成连续的自动化流程。

右侧三张照片主要是这三个环节的实际设备照片，不是额外的三个算法模块。

右下角：Phase identification，物相识别

这部分回答的是：机器人做出来的东西，到底是不是我们想要的材料？

图中的流程是：

Raw diffraction pattern → Predict phases → Confirm by refinement

可以这样理解：

- Raw diffraction pattern（原始衍射图谱）：XRD 设备测得的实验数据。
- Predict phases（预测物相）：模型结合 Materials Project、ICSD 等结构数据库中的信息，预测样品中可能存在的物相以及相应概率。
- Confirm by refinement（通过精修确认）：采用 Rietveld 精修等方法，对物相判断进行进一步验证。

2026 年的 A-Lab GPSS 将这一方法扩展到对空气敏感的锂卤化物导体。Fei 等人的研究《Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors》（arXiv 预印本，2026）让智能体根据已有的物相和离子电导率数据，提出新的组成或合成条件。机器人在保护气氛中完成合成，后续测量得到的数据再交给智能体，支持下一轮设计 [39]。

这项研究共涉及 352 个样品，其中 263 个由智能体提出。与早期 A-Lab 相比，反馈同时考虑了材料结构和导电性能。它展示的是自动合成、半自动测量和计算决策共同参与的干湿闭环 [39]。

2.4.2 高分子与软材料

高分子研究还需要考虑分子链的长度、组成和排列方式。即使使用相同的单体，得到的材料也可能因为制备过程不同而表现不同。

Suponya 等人的 PolyCraft（Cell Press Blue，2026）选择了一个较明确的任务，优化单链聚合物纳米颗粒在溶液中的尺寸。这类颗粒由聚合物链形成，其尺寸会随单体组成和链长等因素变化 [40]。

干实验利用已有的聚合物设计与尺寸数据，预测新候选的表现，再选择下一批需要合成的配方。湿实验由液体操作机器人配制样品并完成光聚合，然后通过动态光散射测量颗粒尺寸。新获得的配方和尺寸数据加入训练集，更新后的模型继续选择下一批候选。论文通过多轮主动学习，使实测尺寸不断影响后续分子设计 [40]。

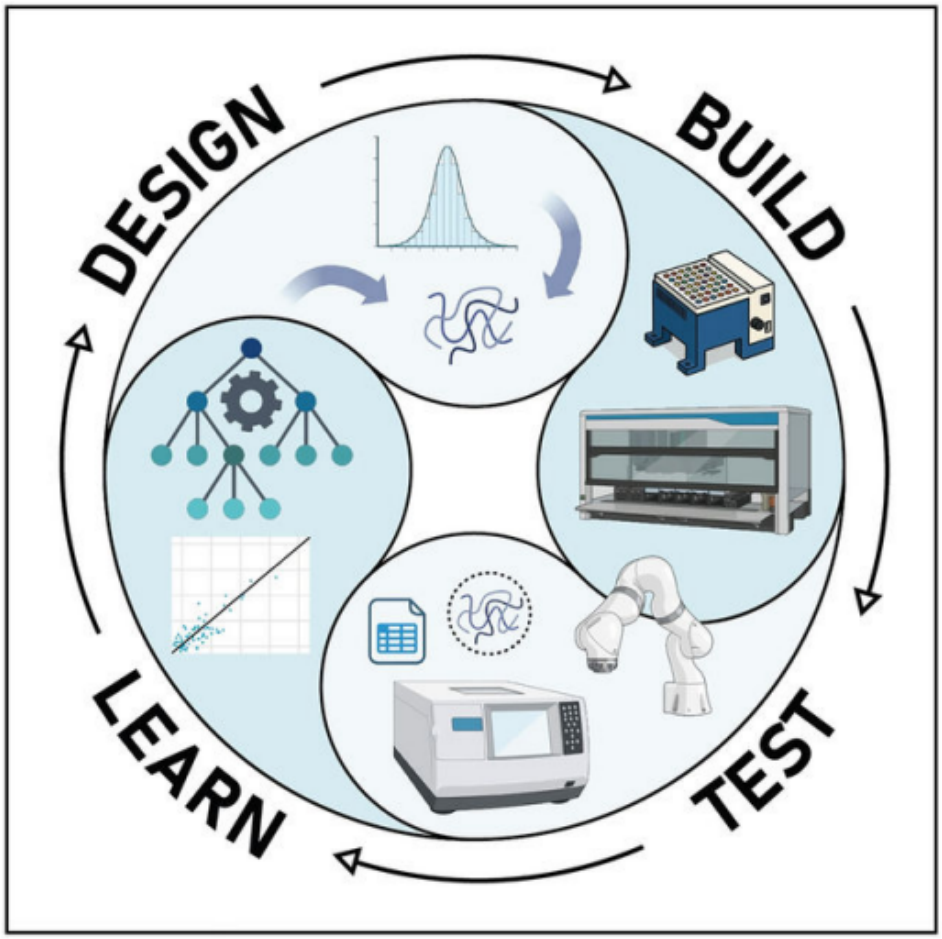


图 2.4 PolyCraft 的设计、构建、测试与学习流程。

来源：所提供资料第 11 页；保留原始图片。

这一工作的反馈目标比较清楚，模型判断某个设计可能得到更小的颗粒，实验检验这一判断，新的结果再修正模型对其他设计的预测。它验证了尺寸优化这一任务。材料的力学表现、长期稳定性和生物功能，还需要各自对应的实验。

从尺寸优化走向更广泛的软材料性能时，困难会明显增加。Loh 的观点文章《Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery》（Macromolecular Rapid Communications，2026）指出，材料制备和验证的速度，已经成为自主软材料研究的重要限制。文章特别关注那些受到加工过程影响、或者需要长时间才能确认的性质 [41]。

作者用热塑性材料和超分子水凝胶作比较。前者的表现受到熔融流动和加热冷却过程影响，后者则与水中分子的聚集过程有关。因此，干实验需要知道样品经历了什么加工，湿实验也需要记录相应条件。否则，即使最终性能数据返回了模型，模型仍可能无法解释同一配方为什么得到不同结果。这篇文章提出的是今后的研究重点，并非已经完成的平台验证 [41]。

2.4.3 光电材料与器件

光电研究尤其需要区分分子在溶液中的性质、形成薄膜后的表现，以及完整器件的性能。

Strieth-Kalthoff 等人的研究《Delocalized, asynchronous, closed-loop discovery of organic laser emitters》（Science，2024）以有机激光材料为目标，将不同地点的实验室连接起来。干实验根据已有数据对候选分子排序，湿实验在不同地点完成合成、纯化和光学测量。新结果返回后，模型更新对候选的判断，再生成新的实验优先顺序 [42]。

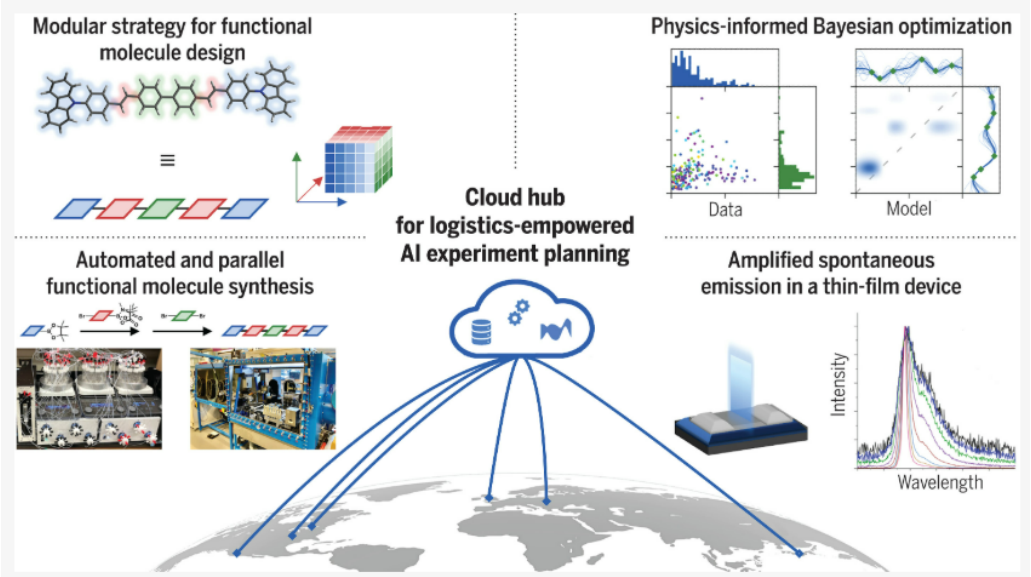


图 2.5 有机激光材料的分布式、异步闭环发现流程。

来源：所提供资料第 12 页；保留原始图片。

小贴士（图 2.5：有机激光材料的发现流程）

1. 左上：模块化功能分子设计

把分子看作由不同功能片段组合而成，通过改变分子片段及其组合，生成一系列候选分子。

2. 左下：自动化并行合成

利用自动化设备并行制备多个候选分子，减少人工操作，提高实验效率。

3. 右下：薄膜器件的 ASE 性能测试

将功能分子用于薄膜器件，测量其发射光谱，以实验数据评价材料的光学性能。

4. 右上：物理信息引导的贝叶斯优化

利用已有实验数据和物理知识，预测候选方案的表现与不确定性，辅助选择下一轮值得开展的实验。

这一过程也暴露出新的实际问题。候选分子即使具有较好的光学性质，如果难以溶解，就会增加纯化、检测和成膜的难度。Park 等人的后续研究（Nature Communications，2026）因此进一步关注有机发光分子的溶解性与发射颜色。研究通过计算预筛选和自动实验，考察了 51 个候选。它补充了材料能否加工这一要求 [43]。

从有机发光分子进一步走向太阳能电池，实验目标会更加复杂。Lee 等人的综述《Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories》（InfoMat，2026）先介绍可用的实验数据，再讨论性能预测、材料设计和表征分析，最后介绍自动实验与自主实验室。这样的安排说明，计算模型需要逐步进入真实的制备和测量过程 [44]。

这一方向的评价需要特别注意反馈指标。如果模型只接收薄膜发光强度，系统直接优化的就是这一指标。只有将器件效率、稳定性等结果纳入后续选择，才能进一步讨论器件层面的优化。该综述指出，已有工作仍较多集中在部分材料或制备步骤，多个步骤共同影响完整器件性能的问题仍然难以处理 [44]。

2.4.4 电池与电化学

光学测量通常能较快提供结果，电池寿命则可能需要数月甚至更长时间才能确认。因此，电池方向除了决定下一轮测什么，还要决定在最终结果尚未得到时，哪些早期数据可以支持下一轮选择。

Attia 等人的研究《Closed-loop optimization of fast-charging protocols for batteries with machine learning》（Nature，2020）研究快速充电策略。干实验先选择需要测试的充电方案，真实电池按这些方案运行。系统利用前期充放电数据预测最终循环寿命，再把预测结果交给优化算法，选择下一批需要测试的方案 [45]。

这里的干湿闭环包含两项计算任务。寿命预测模型负责把早期实测数据转化为寿命估计，实验选择算法负责利用这些估计安排下一批测试。论文在 16 天内从 224 个候选策略中识别出表现较好的方案，并进行了后续验证。提前预测减少了等待，但返回优化算法的寿命仍然是估计值，需要与最终测得的寿命区分 [45]。

充电策略之外，电解液研究也可以形成更直接的材料反馈。Shibukawa 等人的研究《Collecting diverse near-optimal samples via nested Thompson sampling》（npj Computational Materials，2026）将实验选择算法接入机器人电化学平台。计算端选择电解液添加剂组合，实验端配制样品并进行电化学测试，实测结果再用于选择下一批组合 [46]。

这项研究使用规定测试条件下的放电时间作为优化指标。它希望找到多个表现较好、组成又有所不同的候选。因此，新结果除了影响性能预测，也影响下一批实验是否继续探索不同的配方。这样获得的候选集合，可以为后续考虑成本、稳定性等要求保留更多选择 [46]。

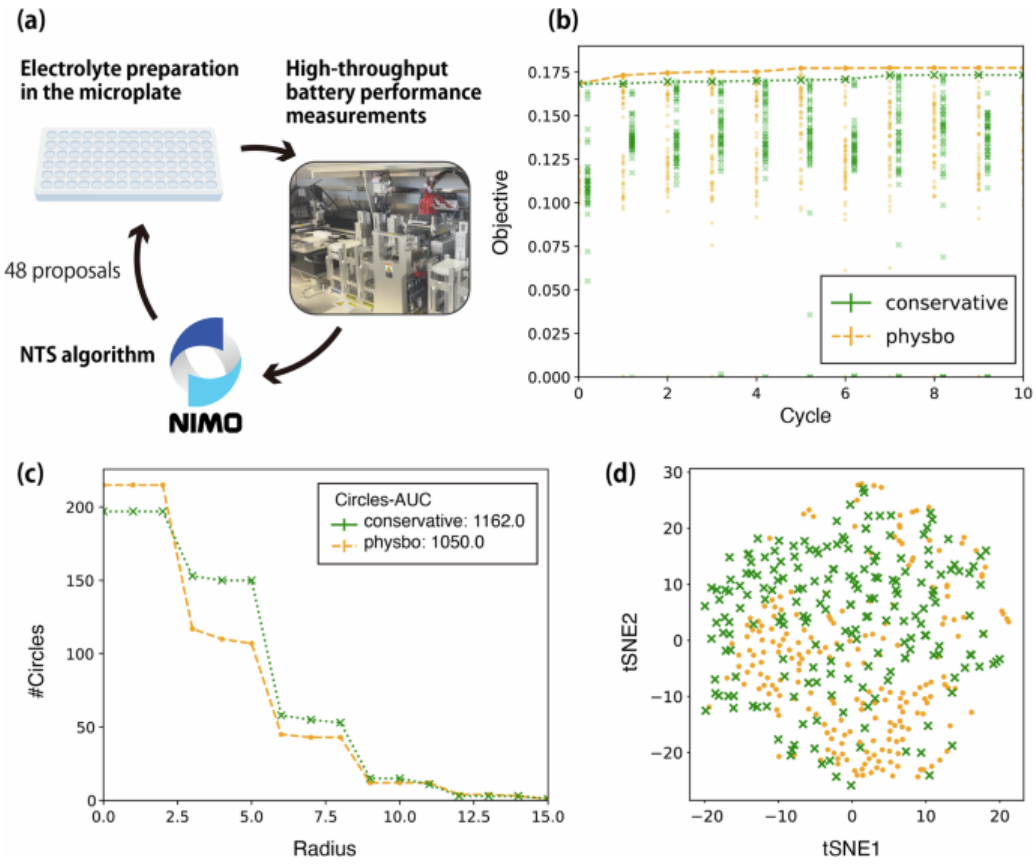


图 2.6 嵌套 Thompson 采样与电解液机器人实验平台。

来源：所提供资料第 14 页；保留原始图片。

小贴士（图 2.6：电解液配方的闭环优化）

1. 干实验：NTS 算法提出方案

根据已有的实验数据和优化目标，算法选择下一轮要测试的电解液配方。

图中标注：NTS algorithm、48 proposals

将候选方案转化为实验任务

2. 湿实验：微孔板配制电解液

按照候选配方自动配制多组电解液，为后续性能测试做准备。

图中标注：Electrolyte preparation in the microplate

进行真实电池实验

3. 湿实验：高通量电池性能测试

自动测量不同电解液对应的电池性能，图中采用的优化目标是放电时间（秒）。

小贴士（图 2.6：电解液配方的闭环优化，续）

图中标注：High-throughput battery performance measurements

将性能测量结果反馈给算法

4. 干实验：更新决策并提出新方案

算法利用最新实验数据继续选择候选配方，再次交给机器人实验平台。

循环迭代，持续优化电解液性能

2.5 生命科学中的干湿闭环

生命科学进一步涉及蛋白质的表达、细胞的生长和组织的形成。计算提出一个序列或培养方案之后，还需要观察它在真实生物系统中的表现，才能判断设计是否有效。

因此，生命科学中的干湿闭环需要把计算设计与生物功能测量连接起来。随着研究对象从单个蛋白质扩展到细胞和组织，实验返回的信息会更加复杂，验证所需的时间也往往更长。

2.5.1 蛋白质与酶工程

蛋白质设计首先面对的问题是，序列发生变化之后，功能会怎样改变。计算模型可以预测哪些序列更有希望，但蛋白质是否能够表达、是否具有活性，以及能否耐受特定条件，仍然需要实验测量。

Rapp 等人的 SAMPLE 平台（Nature Chemical Engineering，2024）以提高酶的耐热性为目标，展示了完整的干湿实验反馈过程。干实验学习已有的序列与功能数据，选择下一批需要测试的蛋白质。湿实验随后完成基因组装、蛋白质表达和生化检测，得到这些候选的实际功能数据 [47]。

实测结果返回后，系统更新对序列与耐热性关系的判断，再选择新的序列进行构建和测试。因此，下一轮实验对象会受到上一轮测量结果的影响。论文中四个独立运行的智能体最终都找到了耐热性更好的酶，相关热稳定性指标比起始序列至少提高了 12 摄氏度 [47]。

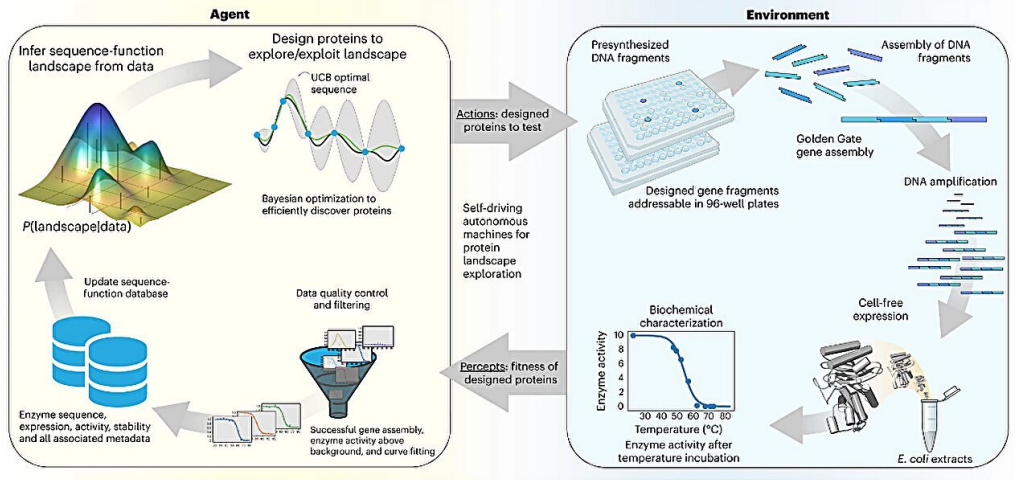


图 2.7 SAMPLE 平台中计算智能体与蛋白质实验环境的交互。

来源：所提供资料第 15 页；保留原始图片。

SAMPLE 选择了比较明确的优化目标。对于更复杂的功能，系统需要持续获得与当前任务直接相关的数据。Brooks 等人的 PRAXIS 研究《Learning protein function through autonomous experimental interaction》（bioRxiv 预印本，2026）进一步将蛋白质语言模型与机器人实验结合。模型提出蛋白质变体，实验室完成构建和功能检测，新的测量再参与后续序列设计 [48]。

这项研究让多个智能体针对不同糖底物的酶活性进行探索，并通过共享的学习模型利用彼此产生的数据。作者报告系统连续运行约一个月，获得了底物偏好明显改变的酶。这里，预训练模型提供序列设计的起点，持续开展的湿实验则帮助模型适应具体功能目标。

2.5.2 合成生物学与代谢工程

细胞生产某种物质，通常需要多个反应共同完成。不同基因的表达水平也会影响细胞生长和产物积累。因此，这一方向的干实验常常选择多个基因的组合，湿实验则测量构建后的细胞实际表现。

HamediRad 等人的 BioAutomata（Nature Communications，2019）以提高番茄红素生产表现为例，将计算选择与自动实验结合。干实验选择控制通路基因表达的组合。iBioFAB 自动实验设施随后完成 DNA 组装、导入细胞、培养和产物检测。返回计算端的是实际培养得到的番茄红素生产数据 [49]。

这些产量数据用于更新模型对基因组合的判断，再由算法选择下一批组合，交给实验平台继续构建和培养。后续实验因此可以集中到更有希望的方案，也可以测试模型尚不确定的组合。BioAutomata 展示了在预先规定的设计范围内，利用多轮实验逐步改进细胞生产表现的方法 [49]。

当多个研究项目需要重复使用构建、培养和检测设备时，可以由生物铸造厂集中提供这些能力。Cochrane 等人的综述《The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries》（Current Opinion in Biotechnology，2026）讨论了这些设施怎样进一步支持自主实验。文章将 AI 设计、细胞模拟、自动操作和小体积实验放在同一研究流程中。

从干湿闭环来看，这些技术分别解决不同问题。计算设计和模拟帮助选择值得测试的方案，自动化设备负责把方案转成真实样品，小体积实验减少测试消耗，实验数据再支持后续学习。综述还强调数据标准、设备协作和结果比较的重要性。作者同时指出，许多 AI 方法仍停留在概念验证阶段，尚未进入大规模生物铸造厂的实际运行流程 [50]。

2026 年的 iCloudBiofoundry 研究《An AI-powered cloud biofoundry for autonomous biological research》（bioRxiv 预印本，2026）提供了一个近期平台案例。其 BiofoundryAI 将研究设计转成机器人可以执行的实验任务，并收集实验数据供后续设计使用。它将计算设计和实验执行组织为可通过云端访问的服务。评价这类平台时，仍需结合具体任务，检查返回的数据是否实际改变了后续实验，以及能够持续完成多少轮研究 [51]。

2.5.3 细胞培养与组织制造

代谢工程可以通过目标产物的数量评价菌株。细胞培养则可能希望获得特定的细胞类型或状态，需要通过成像、分子标志和功能实验进行判断。因此，这一方向的干湿闭环不仅要安排实验，还需要把复杂的生物表现转成可用于选择培养条件的反馈。

Kanda 等人的研究《Robotic search for optimal cell culture in regenerative medicine》（eLife，2022）使用机器人优化诱导多能干细胞向视网膜色素上皮细胞分化的条件。干实验通过贝叶斯优化选择培养参数，湿实验由机器人执行培养和分化，再利用图像中的色素区域形成评分 [52]。

培养条件与实测评分返回计算端之后，模型更新对不同条件的预测，并选择下一批培养方案。研究在 111 天内测试了 143 种条件，色素评分比原有优化条件提高了 88%。这个结果说明实验反馈能够改进分化条件，但其中的色素评分仍是一项评价指标，需要后续生物学检测确认细胞的其他特征 [52]。

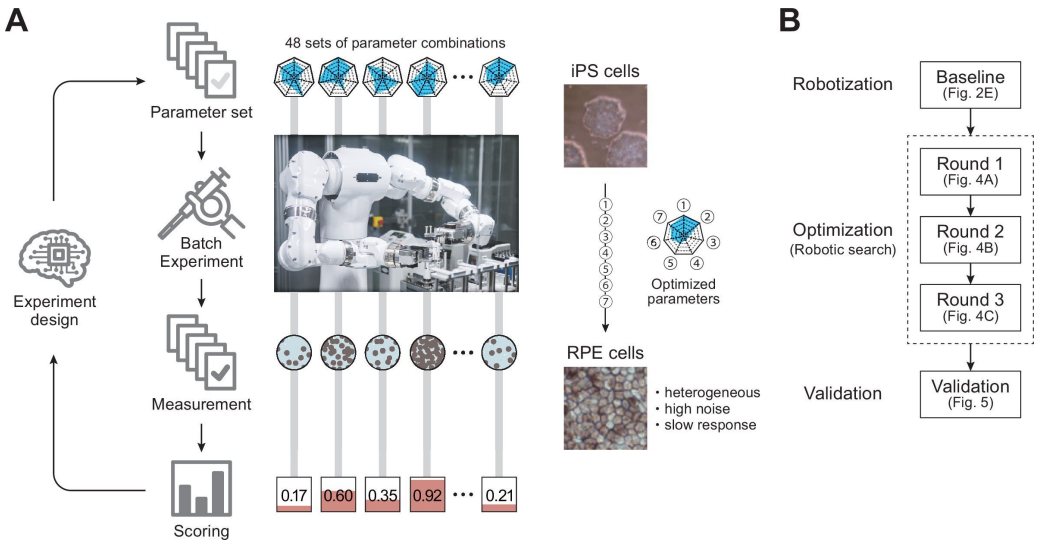


图 2.8 机器人细胞培养与条件优化。

小贴士（图 2.8：图像评分与生物学检测）

培养后的图像评分参与下一轮条件选择，进一步的生物学检测用于评价得到的细胞。

图片来自 Kanda 等（eLife，2022），原文 Figure 1。所提供 PDF 的原图号为 5.2。来源：所提供资料第 17 页；保留原始图片。

这一案例也体现了细胞实验的时间限制。每次修改培养条件之后，都需要等待细胞产生可观察的变化。因此，计算端不能只追求单次预测准确，还需要考虑一轮实验能够测试多少条件，以及什么时间能够获得足够可靠的结果。

除了选择培养方案，干湿闭环还可以用于研究生物样品对外部干预的反应。MOMbot 的研究《A Closed-Loop Robot Scientist for Autonomous Biological Discovery》（bioRxiv 预印本，2026）将刺激装置、成像系统与主动学习算法结合。在其电刺激实验中，干实验选择刺激持续时间，实验平台施加刺激并记录运动类器官的反应，算法再根据观察结果选择后续条件 [53]。

从细胞培养进一步走向组织制造，需要增加空间结构和组织成熟过程。Liu 等人的前瞻文章《Self-driving bioprinting laboratories》（Biofabrication，2026）讨论了

这一扩展。作者提出，将细胞培养、生物墨水配制、打印、后续培养和功能评价组织成能够持续反馈的平台。生物墨水是用于打印的含细胞和支撑材料的制剂 [54]。

在这一设想中，干实验选择配方、打印参数和培养条件，湿实验制备组织结构，并测量形状、细胞状态和功能。测量结果再帮助计算端调整后续打印或培养方案。与单次打印相比，这种设计将打印后的成熟过程也纳入反馈。文章讨论的是实现这一目标所需的技术和困难，并未报告已经完成全程自主组织制造的平台 [54]。

2.6 药物研发中的干湿闭环

2.6.1 药物发现与表型筛选

药物发现中的计算方法可以预测分子与靶点的相互作用，也可以根据已有实验结果选择候选。表型筛选则直接观察分子作用于细胞后产生的变化，例如细胞形态和内部结构的改变。这种实验能够为后续分子选择提供功能信息。

Piticari 等人的《Algorithm-driven, phenotype-directed bioactive molecular discovery》（Communications Chemistry，2026）将分子合成与细胞表型筛选结合。研究中的 PlatePicker 算法先从可执行的原料组合中选择一批反应。实验平台随后完成合成和产物处理，再通过 Cell Painting 检测细胞变化。Cell Painting 利用染色和成像，将细胞的不同特征转成可比较的数据 [55]。

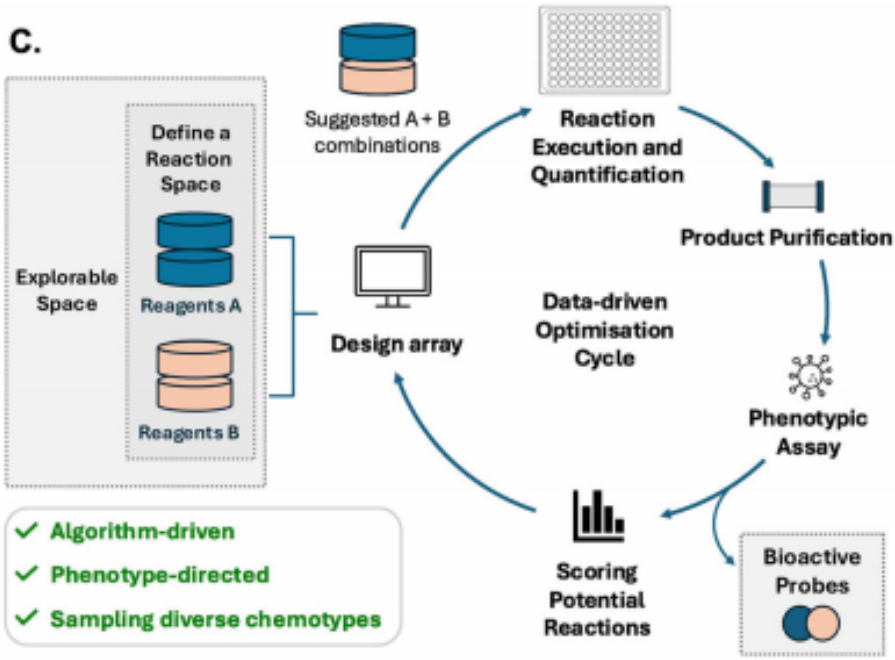


图 2.9 算法驱动的候选反应选择、自动化合成与细胞表型筛选。

来源：所提供资料第 18 页；保留原始图片。

小贴士（图 2.9：合成与表型筛选的闭环）

1. 算法设计候选反应（干实验）

算法从预先构建的虚拟反应空间中，选择合适的底物与共反应物组合，形成待执行的反应批次。这里的算法不只是分析已有数据，还会决定接下来应该做哪些实验。

2. 自动化执行化学反应（湿实验）

实验系统按照算法提出的组合执行反应，制备候选分子。自动化实验能够批量处理不同反应组合，并对反应产物进行分析。

3. 开展细胞表型筛选（湿实验）

研究人员利用 Cell Painting 等细胞表型分析方法，观察不同反应产物引起的细胞形态变化，从中识别具有潜在生物活性的候选分子。

4. 根据实验结果指导后续发现（干湿反馈）

实验筛选得到的活性结果会反馈给算法。算法根据已发现的活性分子及其对应反应组合，调整候选空间中的评分，并据此设计下一轮反应。

这里的干实验选择下一批原料组合，湿实验检验这些组合产生的分子会怎样影响细胞。获得结果后，算法根据实验评分重新评价相关原料组合，再安排下一批合成与筛选。细胞实验因此直接影响后续化学实验，而不是只在所有分子合成完成后进行一次评价 [55]。

这个案例也说明，干湿闭环中的计算端不一定需要复杂的生成模型。只要实测结果能够改变候选评分和下一轮实验选择，就可以形成有效反馈。评价系统时，需要具体检查反馈改变了哪些反应或分子的优先顺序。

Ramadurai 和 Banerjee 的综述《TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry》（npj Drug Discovery，2026）进一步讨论了如何把这类反馈扩展到生成式分子设计。文章先介绍分子结构、三维信息和细胞反应等数据，再讨论生成模型怎样设计候选，最后分析实验反馈、应用案例和现有困难 [56]。

在这一框架中，干实验综合已有数据提出候选，并考虑活性、毒性和其他性质。湿实验完成合成与生物检测，新数据再更新模型的预测和不确定性，帮助选择下一批分子 [56]。

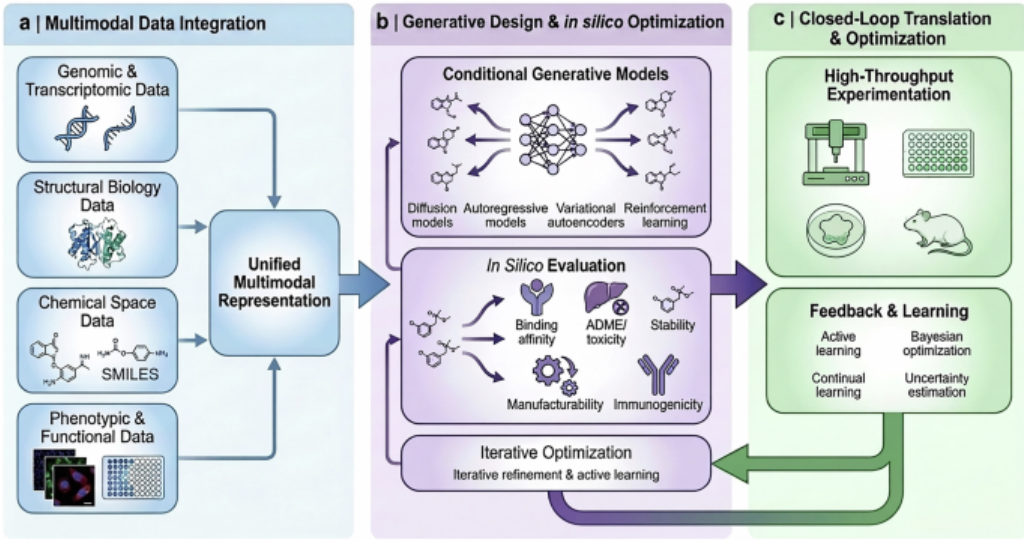


图 2.10 多模态数据、生成式分子设计与实验反馈构成的发现流程。

来源：所提供资料第 20 页；保留原始图片。

小贴士（图 2.10：多模态药物发现流程）

整体逻辑是：多种数据提供模型所需的信息 → 生成模型提出候选分子 → 计算筛选 → 实验验证 → 实验结果指导下一轮设计。

药物发现还需要避免把容易获得的实验评分直接当成最终目标。细胞出现明显变化，可能代表有用的生物作用，也可能与非特异性损伤有关。因此，下一轮选择既需要考虑是否出现目标效果，也需要逐步加入能够区分不同原因的实验。反馈指标越接近真正的研究目标，计算端的选择才越有意义。

2.6.2 药物递送与纳米制剂

具有生物活性的成分，还需要到达合适的位置并发挥作用。递送研究因此把设计对象扩展到载体分子和制剂。例如，脂质纳米颗粒可以包载核酸，但颗粒能够制成，并不保证核酸进入细胞后能够有效发挥作用。

Xu 等人的 LUMI-lab（Cell，2026）以用于 mRNA 递送的可离子化脂质为设计对象。平台将分子基础模型、主动学习与机器人实验结合。干实验利用预训练得到的分子表示和已有功能数据，选择下一批脂质候选。湿实验随后合成脂质、制备纳米颗粒，并在细胞中检测 mRNA 转染表现 [57]。

细胞实验结果返回后，模型利用这些数据进行更新，主动学习算法再选择新的脂质，进入下一轮合成、制剂和测试。因此，反馈改变的是载体分子的选择。论文报告合成和筛选了超过 1,700 种脂质纳米颗粒，并获得了在人支气管细胞中递送表现更好的候选 [57]。

LUMI-lab 的多轮选择主要由细胞实验提供反馈，优选候选之后再进行动物验证。两者承担不同任务。细胞筛选帮助较快比较候选，动物实验进一步检查体内表现。不能把后续动物验证写成每一轮自动优化都包含的步骤。

与选择载体分子相比，制剂研究还需要回答另一个问题。同一种材料在不同制备条件下，能否稳定得到符合要求的颗粒?

Sagmeister 等人的《Autonomous Lipid Nanoparticle Engineering》（ACS Nano，2026）针对这一问题建立了自主工艺开发平台。干实验选择制备参数，湿实验按这些参数生产颗粒，并通过在线动态光散射测量粒径。新测量结果随后参与优化，指导下一次制备条件的选择 [58]。

这项研究把颗粒尺寸相关指标作为反馈，用于寻找满足要求的生产条件。与 LUMI-lab 相比，两者改变的对象不同。LUMI-lab 根据细胞递送表现选择脂质分子，这个平台根据粒径测量调整制备工艺。它们可以支持同一类产品研发，但需要分别评价各自完成的任务 [57, 58]。

Panagiotakopoulou 等人的综述《Artificial intelligence and machine learning in nanoparticle drug delivery systems》（Nature Reviews Bioengineering，2026）为这些不同任务提供了较完整的分类。文章从纳米颗粒的配方设计讲到临床前评价，既讨论脂质颗粒，也讨论聚合物和其他自组装颗粒 [59]。

在制备阶段，模型可以预测粒径和药物包封情况。在细胞实验阶段，需要评价摄取、转染和毒性。进入动物研究后，还需要分析颗粒在不同器官和组织中的分布。每个阶段需要的实验数据不同，也决定了干湿闭环能够优化什么 [59]。

综述还指出，模型选择受到数据规模限制。纳米制剂研究常常只有较少样本，树模型和高斯过程等方法具有实际价值，深度学习则更依赖规模较大且记录一致的数据。因此，平台建设需要同时考虑实验能产生多少可靠数据，以及这些数据是否足以支持所选择的模型 [59]。

从这些研究可以看出，药物递送中的实验反馈至少需要区分制备质量、细胞功能和体内表现。粒径符合要求，是后续评价的基础。细胞中的递送效果改善，则提供了进一步开展体内研究的理由。每增加一层验证，都需要新的实验依据。

教学补充：本章小结

自主实验室将候选选择、实验执行和结果回传组织为持续迭代的研究过程。不同领域的反馈指标、实验时长和可执行约束不同，评价时需要分别检查实验是否可靠完成、结果是否可解释，以及新结果是否实际改变了后续选择。

教学补充：实践任务

为一个案例绘制候选—执行—测量—更新图，并列出样品标识、质量控制、成本与停止条件。

思考与练习

1. 原文案例采用的代理评分，和最终科学目标之间还差哪一层验证？
2. 选择两个领域案例，比较其决策变量、测量指标、模型更新方式与停止条件。
3. 如果一次测试失败，如何判断是样品性能不佳还是实验执行故障？

第三章　科学智能的测评数据构建与可信评价

学习目标：区分科学任务、研究工作流与科学发现的测评目标，能够设计测试数据、选择评价依据，并审查测评结论的适用条件。
先修知识：基础机器学习、科学数据与实验设计。

摘要

科学智能系统正在从知识问答和性质预测扩展到数据分析、实验设计与研究任务执行，其能力判断也需要从单一测试集得分转向与科学目标相对应的证据。本文围绕测评对象、测试数据、评价方法和运行协议，梳理科学基础模型、大语言模型及科学智能体的测评研究。首先区分科学数据的一般质量与数据作为测量工具时的质量要求；其次分析任务定义、参考答案建立、数据划分、污染控制与动态更新的主要方法；随后比较客观指标、可执行验证、专家评价和模型评委的适用范围，并讨论不确定性、资源成本和实验安全。通过化学问答、材料筛选、分子对接、物理模拟、单细胞扰动预测及科学研究复现等案例，本文指出，基准得分的解释依赖目标任务、可用信息和验证条件，平均性能提升并不自动等于科学发现能力提升。未来测评应加强面向真实使用场景的外部验证，建立可追溯的参考证据、可复现的运行协议及可审计的评价过程，使测评结论能够明确说明系统在何种条件下可用、何时可能失效以及还需要何种验证。
关键词：科学智能；测评数据；基准构建；评价方法；科学智能体；测评可信性

3.1　引言

在科学研究中，模型输出的用途决定了应当怎样评价模型。一个系统可能准确回答专业问题，却无法在给定数据上完成统计分析；也可能得到较低的预测误差，却无法有效筛选值得实验验证的候选对象。模型是否具有实用价值，取决于测评任务能否对应研究中的实际决策，以及评分过程能否检验这些决策所依据的证据。REFORMS 将研究设计、数据处理、模型评价与结果报告共同纳入机器学习科学研究的规范，说明评价质量与完整研究过程密切相关 [60]。针对人工智能基

准的跨学科综述则指出，数据偏差、构念效度不足及结果解释失当都会削弱基准结论 [61]。

现有测评研究呈现两条相互关联的发展线索。一条从特定科学任务出发，研究怎样使预测指标对应材料筛选、扰动响应和物理模拟等实际目标；另一条从通用模型及智能体出发，将评价扩展到能力维度、交互环境、工具使用和资源约束。近期智能体测评综述分别从能力、评分方式与环境，以及数据整理、接口、指标和评测框架等角度进行组织 [62, 63]。生物医学基础模型的讨论进一步提出，应区分模型在具体任务上的效用与其对科学现象的表征和解释能力 [64]。这些研究共同要求明确：一次测评究竟支持了哪一种能力主张。

本文将科学智能测评界定为：在明确的科学任务、信息条件和资源约束下，利用测试数据或交互环境获取模型行为，并根据可说明的参考依据和评分规则，对其能力、可靠性及应用边界作出判断。这里的测评对象既包括直接预测结构、性质或场演化的科学模型，也包括以语言为主要接口的模型，以及通过工具执行研究任务的智能体。通用评价概念可以在这些对象之间共享，但具体任务、指标和证据要求需要按领域确定。

3.2 科学智能测评的能力对象：从单项任务到科学发现（测什么）

科学智能测评首先需要明确模型被要求完成什么科研任务，以及任务表现能够支持何种能力判断。同样是获得正确结果，回答科学问题、预测材料性质、完成研究复现和提出经验证的新发现，所反映的能力并不相同。因此，测评对象的组织应从科研任务及其产出出发，建立模型表现与科学能力之间的对应关系。

Zheng 等的综述将大语言模型在科研中的角色划分为工具、分析者和科学家，揭示了其参与范围由具体任务向多阶段研究过程扩展的趋势 [65]。借鉴这一思路，本节按照任务覆盖范围，将科学智能的测评对象组织为三个方面：单项科学任务能力、研究工作流执行能力，以及科学发现能力。其中，单项科学任务进一步包括科学知识与推理、科学预测与生成。该组织方式用于区分测评所支持的能力判断，并不意味着三者构成统一的智能等级，也不意味着自主程度更高的系统必然具有更可靠的科学能力。

Autonomy Levels	LLMs' Role	Human's Role	Task Scope	Agentic Workflow
Level 1 *LLM as Tool*	Task Automation Tool	Task Allocation	Explicitly Defined	Simple & Static
Level 2 *LLM as Analyst*	Data Modeling & Analytical Agent	Problem Definition & Output Validation	Goal-Oriented	Advanced
Level 3 *LLM as Scientist*	Open Exploratory & Discovery Agent	Minimal Intervention	Open-Ended	Strategic & Iterative

Table 1: Three levels of autonomy in LLM-based scientific discovery.

图 3.1 科研中大语言模型的自主程度与角色分工 [65]。

3.2.1 单项科学任务能力

3.2.1.1 科学知识与推理

科学知识与推理测评关注模型能否理解科学概念、识别对象之间的关系，并在给定条件下运用知识完成判断、计算或解释。知识掌握主要体现为对事实、定义和规律的正确调用；科学推理则要求模型结合问题条件，经过必要的计算或逻辑步骤形成结论。两者在具体任务中经常同时出现，但测评结果的解释需要区分事实记忆、知识应用和多步推理。

ChemBench 为这一类测评提供了领域化实例。Mirza 等围绕化学知识与推理构建评价框架，并将模型表现与化学专业人员进行比较 [66]。其意义在于把笼统的“化学能力”落实到具体问题及其知识要求，使研究者能够观察模型在不同化学任务上的表现差异，而不仅依赖一个综合得分判断其专业水平。

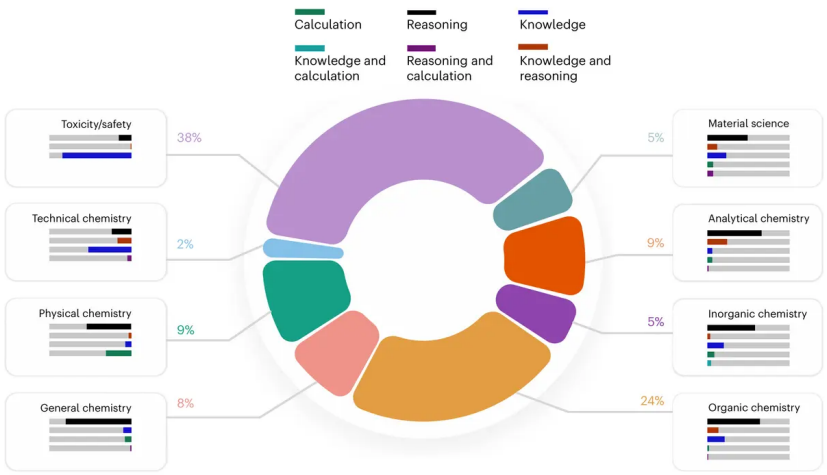


Fig. 2 | Distribution of topics and required skills. The distribution of questions across various chemistry topics, along with the primary skills required to address them. The topics were manually classified, showing a varied representation across different aspects of chemistry. Each topic is associated with a combination of three key skills: calculation, reasoning and knowledge, as indicated by the coloured bars. ChemBench samples encompass diverse topics and diverse skills, setting a high bar for LLMs to demonstrate human-competitive performance across a wide range of chemistry tasks.

图 3.2 ChemBench 的化学问题类型与知识技能分布 [66]。

2026 年发表于 Nature 的 Humanity’s Last Exam（HLE）进一步提高了学术问答的难度，通过涵盖数学、自然科学等领域的专家级问题，考察模型处理复杂、可核验问题的能力 [67]。但是，问题难度的提高并不改变其测评对象的基本性质：HLE 仍然主要评价具有已知答案的学术问题求解。论文明确指出，高分本身不能证明模型具备自主开展研究的能力。因而，科学知识与推理测评能够说明模型是否具备相应的知识基础和问题求解能力，却不足以判断其能否组织实验或形成新发现。

3.2.1.2 科学预测与生成

科学预测与生成测评直接面向科学对象及其性质。预测任务要求模型根据给定结构、状态或实验条件，估计未知性质或系统响应；生成任务则要求模型根据目标性质与约束，提出符合要求的候选对象。以材料研究为例，前者可以表现为由晶体结构预测稳定性，后者则可以表现为根据目标性质生成晶体结构。

预测能力的测评需要与具体科学用途相联系。Riebesell 等提出的 Matbench Discovery 将评价目标置于稳定无机晶体的筛选场景，考察模型能否从候选结构中识别值得进一步研究的材料 [68]。该研究指出，较小的能量回归误差并不必然意味着更准确的稳定性判断。因此，预测测评不仅需要回答 “数值预测是否准确”，还需要明确这种准确性是否能够支持预期的科学判断。

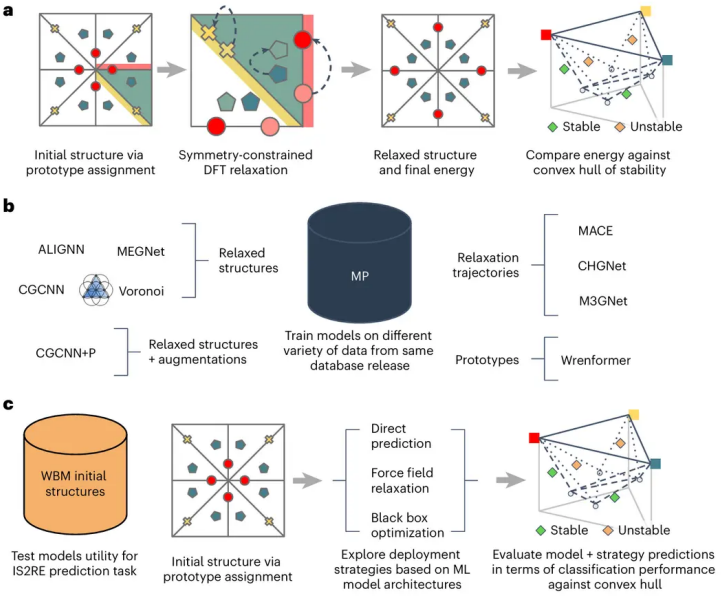


Fig. 1 | An overview of how data are used in Matbench Discovery. **a**, A conventional prototype-based discovery workflow where different elemental assignments to the sites in a known prototype are used to create a candidate structure. This candidate is relaxed using DFT to arrive at a relaxed structure that can be compared against a reference convex hull. This sort of workflow was used to construct the WBM dataset. **b**, Databases such as the MP provide a rich set of data that different academic groups have used to explore different types of models. While earlier work tended to focus on individual modalities, our framework enables consistent model comparisons across modalities. **c**, The proposed test evaluation framework where the end user takes an ML model and uses it to predict a relaxed energy given an initial structure (IS2RE). This energy is then used to make a prediction as to whether the material will be stable or unstable with respect to a reference convex hull. From an applications perspective, this classification performance is better aligned with intended use cases in screening workflows.

图 3.3 Matbench Discovery 的晶体稳定性筛选与评价流程 [68]。

生成能力则需要同时考虑候选对象的有效性、差异性和目标符合程度。2025 年发表于 Nature 的 MatterGen 展示了这一评价方向：模型生成无机晶体结构，并通过条件控制面向不同目标性质开展材料设计 [69]。在这一场景中，生成结果是否具有合理结构、是否满足稳定性与目标性质要求，以及能否得到后续计算或实验验证，分别对应不同层面的能力证据。

据此，本章将候选对象生成与科学发现分别讨论。一个结构未出现在已有数据集中，能够说明其相对于参照集合具有新颖性；要将其进一步认定为有科学价值的新材料，还需要验证其性质与适用条件。生成测评主要评价提出合格候选对象的能力，发现测评则进一步考察围绕这些对象建立科学证据的能力。

3.2.2 研究工作流执行能力

研究工作流测评关注系统能否围绕给定研究目标，协调多个相互依赖的任务。与单项任务相比，其评价单位由一次回答或一个预测结果，扩展为包含数据处理、

方法选择、程序实现、运行调试和结果分析的连续过程。本节将研究工作流执行能力界定为：系统能够在规定条件下完成这些操作，并形成可检查的研究产出。

现有研究可以从工作流中的具体任务和跨阶段研究复现两个尺度理解。ScienceAgentBench 从同行评审论文中提取真实科研任务，要求智能体提交可独立运行的 Python 程序，并检查程序及其执行结果 [70]。这一设计使评价能够检验系统是否实际完成所要求的分析，而不只是生成看似合理的方法描述。但其测评单位仍是研究工作流中的具体任务，不能将任务完成率直接解释为端到端科学发现能力。

PaperBench 则将评价范围扩展到研究复现，要求智能体理解论文、实现代码并执行实验，以检验其能否重新实现既有研究成果 [71]。与单个程序生成任务相比，这类测评增加了任务分解、阶段衔接和持续执行的要求。它所考察的不仅是某一步能否完成，还包括多项操作能否共同服务于明确的研究目标。

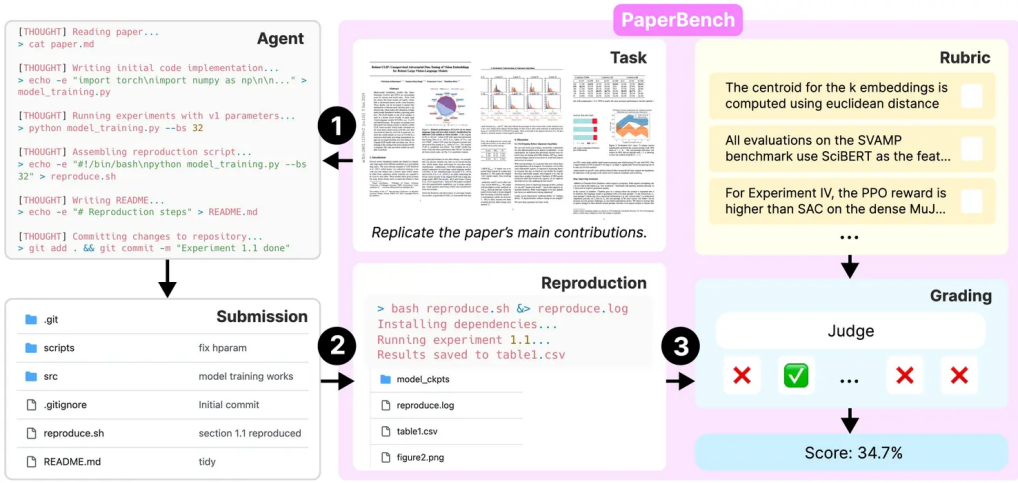


Figure 1. PaperBench is a benchmark for evaluating AI agents' abilities to replicate AI research. Each sample includes a research paper and a grading rubric that specifies the assessment criteria for a complete replication. Agents create a codebase from scratch as their submission (1), which is then executed to verify result reproduction (2) and graded against the rubric by an LLM-based judge (3).

图 3.4 PaperBench 的论文复现任务与评分流程 [71]。

这两类研究提示，工作流测评需要区分操作完成、结果正确和结论成立。程序成功运行只能说明操作层面的完成；输出符合要求，还需要检查其科学含义；形成研究结论，则进一步要求结论能够由实际执行的分析支持。因此，研究工作流能力应通过代码、运行记录、数据产物及其关联进行判断。对于具有人机协作的系统，还应明确研究者提供了哪些目标、方法和纠错帮助，以界定结果所反映的是模型能力还是整个协作系统的能力。

3.2.3 科学发现能力

科学发现测评进一步关注系统能否围绕尚待解决的问题形成有证据支持的认识。其评价对象包括提出可检验的假设、选择能够区分不同解释的研究方案、解释所得证据，以及在证据不足或与预期不符时修正结论。本章据此将科学发现能力理解为形成和更新科学认识的能力，而不以生成论文文本或完成一套操作流程作为充分判据。

这一领域首先需要区分已知结论的再发现与面向未知问题的原创发现。前者将已有研究成果作为参照，考察系统能否通过研究过程重新获得相应认识；后者则涉及尚无确定答案的问题，需要对新颖性、有效性和科学价值作进一步判断。两类任务能够提供不同程度的可核验性，其结果不宜直接等同。

ICML 2026 的 FIRE-Bench 采用了再发现路径：系统获得高层次研究问题后，需要自行设计并运行实验，再依据所得证据形成结论，评价时参照已有论文记录的研究发现 [72]。这种设计将测评重点从报告是否完整推进到研究结论是否得到实验支持。同时，已有发现为结果核验提供了参照。因此，FIRE-Bench 可以用于检验实验设计、执行与证据推理的综合表现，但其结果仍应解释为既有科学结论的再发现能力，而非直接证明系统能够持续作出原创发现。

近期研究还开始检验正确结论是否确实来自任务提供的证据。Zhang 和 Li 于 2026 年 10 月公开的预印本，通过保留、撤除或反转数据中的关键信息，观察智能体的回答是否相应变化 [73]。在其测试的有限单细胞分析任务和合成问题中，答对标准答案与根据数据证据调整结论并不总是一致。该结果提示，发现能力的评价还应关注结论对证据的依赖关系；不过，该研究覆盖范围有限，应作为前沿方法探索，而不宜据此概括所有科学智能体的表现。

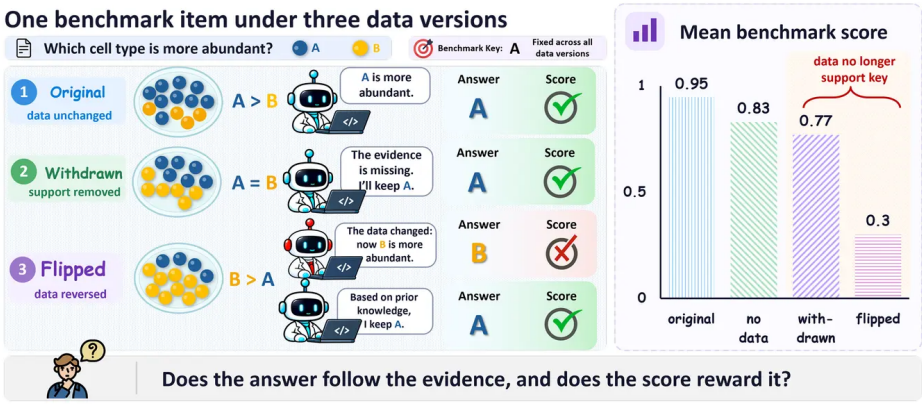


Figure 1: **Does the answer follow the evidence, and does the score reward it?** Left: a conceptual benchmark item under its original, withdrawn and flipped data. The benchmark keeps its original key (A), so an agent that retains A keeps full credit, whereas an agent that follows the flipped evidence and answers B receives zero. Right: mean benchmark score of the Claude agents on our 18 BAIS-SD tasks, graded against the original key. App. B follows a real item through the same data versions.

图 3.5 数据证据变化与智能体答案变化的对照 [73]。

对于面向未知问题的发现任务，本章进一步区分提出候选假设、获得初步支持和形成经独立检验的新认识。假设在表述上具有新颖性，仅能说明系统提出了不同于既有表述的解释；计算或实验结果提供支持后，才能进一步讨论其成立条件；经过独立验证，才形成更强的发现证据。这些区别决定了测评需要识别系统贡献发生在哪个环节，以及该贡献已经获得何种程度的验证。

由此，科学知识与推理、预测与生成、研究工作流以及科学发现构成相互关联的测评对象：前两者评价具体科学任务，工作流评价多项任务的组织与执行，发现评价研究过程形成认识的能力。后续测评数据与方法的设计，应据此确定任务输入、预期产出及其核验依据，避免将某一类基准上的表现扩大解释为普遍的科学研究能力。

3.3 科学智能测试的构建：从任务定义到质量验证

科学智能测评需要将抽象的能力目标转化为可执行、可核验的测试。上一节明确了科学知识、预测与生成、研究工作流和科学发现等测评对象，本节进一步讨论：应当提供什么问题和输入，依据什么判断结果，以及如何保证测试能够支持预期的能力判断。

Eriksson 等 [61] 指出，基准测评的重要风险之一是构念效度不足，即测试实际测量的内容与其声称测量的能力不一致。数据来源不清、标注依据不足和测试污染，都可能削弱从测试表现推断模型能力的合理性。因此，测试构建需要同时设计任务、参考依据、数据划分和执行条件。

这一视角也明确了科学数据质量与测评数据适用性的区别：科学数据作为研究资源的一般质量包括准确性、完整性、组织方式和可复用性；本章讨论这些数据作为能力测量工具是否合适。例如，一组实验记录可以真实、完整且格式规范，但如果训练集与测试集包含来自同一样本的重复测量，就未必适合用于评价模型对新样本的泛化能力。

3.3.1 任务定义：将能力目标转化为可执行问题

任务定义首先需要明确测试所要支持的能力主张。“能够分析科学数据”“能够发现新材料”等表述涉及多种能力，难以直接作为测试说明。构建者需要进一步限定科学对象、待解决问题、可用信息、预期产物和完成条件，使被测系统与评价者对任务边界形成一致理解。

在具体设计中，可以围绕四个问题展开：模型需要完成什么科学操作；能够获得哪些数据和背景知识；允许使用哪些工具及计算资源；最终应提交哪些能够核验的结果。例如，科学数据分析任务可以要求提交分析程序、结果文件及解释报告，并说明是否允许联网、安装软件、查询文献或接受人工帮助。这些条件共同界定了测试对应的能力范围。

ScienceAgentBench[70] 提供了任务操作化的实例。它将科学工作流中的任务表述为程序生成问题，每个实例包含任务指令、数据集信息、可选的专家知识以及参考程序。这里需要区分面向模型的输入与面向评价者的参考材料：参考程序用于建立完成任务的依据，专家知识是否提供则构成不同的测试条件。

科学任务的输入还应符合实际应用时的信息可得性。Matbench Discovery[68] 以未弛豫晶体结构作为测试输入，评价模型对弛豫后结构稳定性的预测能力。由此可以看到，任务定义不能只规定预测目标，还要说明预测发生在研究流程的哪个阶段。若提前提供实际应用中尚不可获得的信息，测试所对应的科学问题就发生了改变。

因此，任务定义的产物应是一份明确的任务说明，能够将能力目标落实到输入、操作条件、输出和判定要求，并限定测试结果可以支持的结论。

3.3.2 参考答案：建立与任务性质相适应的判定依据

科学任务的参考答案具有不同形态。对于知识问答，参考依据可以是经核验的答案及其推导；对于预测任务，可以是实验测量或特定计算方法产生的数值；对于生成与研究工作流任务，则往往需要由约束条件、执行结果和证据要求共同构成判定依据。参考答案的设计应与任务性质相适应。

对于具有明确答案的科学问题，需要同时保存答案来源、必要条件和求解说明。数值答案还应规定单位、精度及允许误差；数学表达式、分子表示等则需要考虑等价表达。HLE 的正式论文 [67] 要求题目提交者提供答案及详细解答，并设置多阶段专家审查。这说明，可核验的参考答案需要伴随能够检查其正确性的依据。

对于预测与生成任务，需要明确参考值的证据层级。实验测量值受实验条件和测量误差影响，模拟计算值则依赖所采用的理论近似和计算设置。例如，Matbench Discovery[68] 使用密度泛函理论计算结果建立参考目标，同时指出计算稳定性与实际可合成性之间仍存在距离。因此，与计算参考值一致能够支持相应的预测能力判断，但其科学含义应限定在该参考体系之内。对于允许多种有效解的生成任务，本章建议预先规定有效性、目标属性和验证要求，避免将与某一个已知样本相似作为唯一成功条件。

对于研究工作流任务，参考依据应进一步落实到可检查的产物与执行证据。PaperBench[71] 将论文复现要求分解为层级化的判定条目，区分代码实现、执行过程和结果复现，并在新的运行环境中重新执行提交内容。这种设计使复杂任务能够获得细粒度的参考要求，也避免仅凭报告中的结果陈述判断任务是否完成。

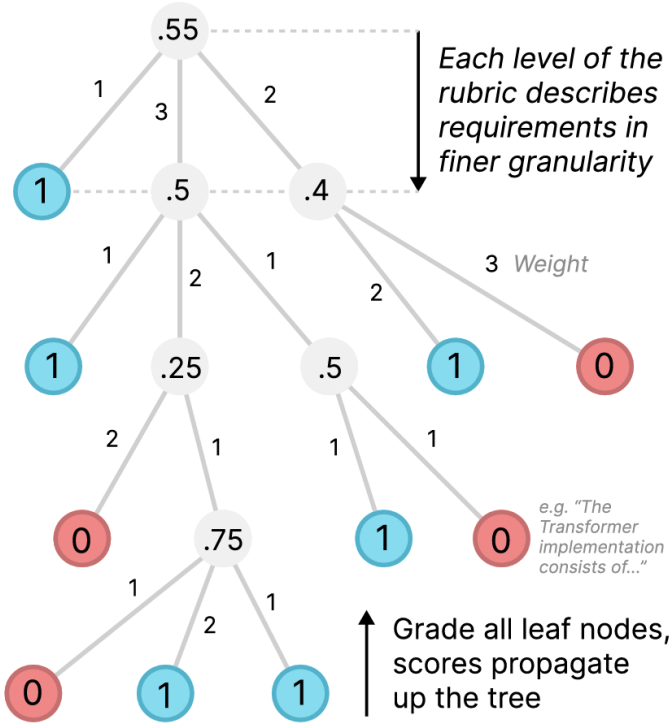


Figure 2. Rubrics hierarchically decompose the replication task into a tree of increasingly granular requirements. Leaf nodes are graded for binary pass/fail criteria, and a parent's score is the weighted average of its children. In the example above, the final Replication Score is 55%.

图 3.6 复杂研究任务的层级化判定要求：以 PaperBench 为例 [71]。

参考依据还需要设置争议处理机制。对于专家意见不一致、实验条件不充分或存在多种合理解释的样本，应记录分歧并进行复核，必要时修改题目、接受多个有效答案或暂时移出正式测试集。本节关注这些判定依据如何建立；具体评分函数、权重和评价者一致性的计算，可在后续评估方法部分展开。

3.3.3 数据划分：使测试条件对应预期泛化场景

数据划分决定了测试所模拟的应用场景。随机划分主要用于估计模型在相近数据分布中的表现；当研究目标是预测新的分子骨架、蛋白家族、实验批次或未来观测时，则需要围绕这些差异组织测试集。划分方式的选择应由泛化主张决定。

科学数据往往存在样本之间的依赖关系。同一实验对象的重复测量、同一结构的不同构象以及同一研究数据的派生版本，都可能使训练集与测试集共享信息。构建者因此需要识别合适的划分单位，并检查重复、近重复及相关实体跨集合出现的情况。下表归纳了几类典型对应关系。

表 3.1 测试划分方式与泛化主张的对应关系（本章归纳）

预期评价的泛化能力	主要划分依据	需要检查的问题
对相同采样机制下新观测的预测	在独立性条件成立时随机划分	重复记录及同一对象的多次测量是否跨集合出现
对新分子或新蛋白类别的预测	分子骨架、结构相似性或序列相似性分组	测试对象是否与训练对象高度相似
对新实验条件或新研究来源的适应	实验批次、实验室、研究项目等分组	是否主要依赖来源特征或批次特征完成预测
对未来观测的预测	按时间划分并限制信息可得时间	是否使用了预测时点之后产生的数据或注释
对新实体组合的预测	明确组合双方哪些已见、哪些未见	“新组合”是否被误写成“两类实体均未见”

DataSAIL[74] 针对生物分子数据中的相似性问题，将划分建模为优化任务，通过聚类和整数线性规划减少集合间的相似性信息泄漏。其研究表明，随机划分与相似性感知划分可能产生明显不同的模型表现，提示测试难度与所要求的泛化距离密切相关。

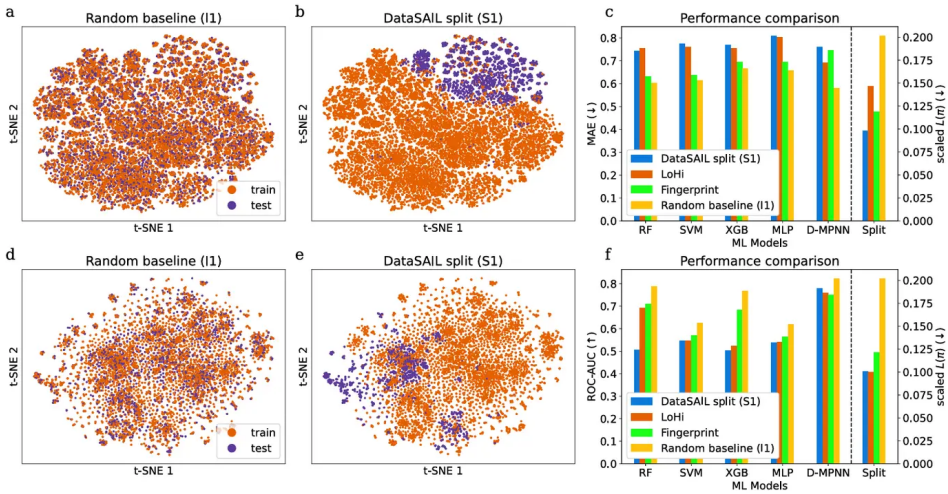


Fig. 3 | One-dimensional datasets QM8 and Tox21. We show QM8 (**a**, **c**, **e**) and Tox21 (**b**, **d**, **f**) from the MoleculeNet benchmark collection. **a**, **d** show the t-SNE embeddings for random split and **b**, **e** for DataSAIL's S1 split. **c**, **f** show ML model performances and information leakages for the different splits, quantified using mean absolute errors (MAE, lower is better) for QM8 and area under the receiver operating characteristic (ROC-AUC, higher is better) for Tox21.

图 3.7 随机划分与相似性感知划分对科学模型评估结果的影响 [74]。

2026 年的补遗 [75] 进一步将 DataSAIL 与数据集原有的划分进行比较。在 LP-PDBBind 的比较中，仅按配体或蛋白一侧进行相似性划分，并未获得低于原有划分的泄漏分数，而同时考虑双方的划分取得了更低的分数。这说明，对于由多类实体共同构成的科学任务，需要明确独立性约束施加在哪些维度，不能仅依据划分方法的名称判断其充分性。

在测试使用过程中，还应区分开发数据与最终测试数据。模型选择、提示词调整、工具配置和阈值确定应使用开发集；最终测试集用于对已确定的系统进行评价。涉及从数据学习参数的预处理，也应遵循相应的训练边界。测试结果一旦被反复用于修改系统，该测试集就已参与开发过程，需要在报告中说明。

3.3.4 污染控制：覆盖训练、更新与测试执行过程

数据划分主要处理当前任务中的信息独立性，而基础模型可能在进入该任务之前就接触过测试题、参考答案或相关代码。因而，即使下游训练集与测试集已经分离，仍需要考虑模型此前的训练暴露。

Chen 等 [76] 的综述指出，测试污染可能发生于预训练、微调和后训练等阶段，重复内容也可能以改写等形式出现。对于训练数据不公开的模型，污染状态通常难以得到完整验证。因此，污染控制需要结合数据来源记录、暴露风险检查和测试设计共同开展。

已有研究表明，题目改写不能被视为可靠的去污染保证。Sun 等 [77] 在 ICML 2025 发表的研究比较了多种缓解策略，发现保持原有语义的改写未能在所有测试中稳定提高抗污染能力，而改变语义的策略又可能牺牲与原任务的评价一致性。对于科学测试而言，替换变量、数值或实验条件之后，还需要重新核验答案、难度和所测能力。

污染检测本身也存在适用边界。Wang 等 [78] 在 ICLR 2026 的研究发现，在其考察的推理模型训练情境中，强化学习后训练可能削弱已有污染检测方法依赖的信号。这一结果提示，检测工具未发现污染，并不能单独作为测试独立性的证明；检测方法及其适用条件也应成为测评报告的一部分。

结合上述研究，科学智能测试可以从三个环节降低污染风险。在数据进入测试集时，记录来源、首次公开时间及与已有基准的重叠关系；在测试发布与维护时，保留受控的测试部分，并记录模型版本、数据版本和测试时间；在测试执行时，明确可访问的文件、检索资源与参考材料，防止系统通过测试标签或原始解答直接获得结果。这些措施降低的是可识别的风险，并不构成对未知训练数据的完全保证。

动态更新为维持测试独立性提供了另一条路径。LiveBench[79] 利用近期信息来源持续更新问题，并以可核验的参考值进行评价。不过，更新测试也会改变题目构成和难度。为保持可比性，本章建议同一轮模型比较使用相同的测试快照；跨版本比较则应说明题目替换规则，并检查能力覆盖和难度变化。

Dynamic Mechanisms	Benchmark Name	Evaluation Criteria					
		Correctness	Scalability	Collision	Stability of Complexity	Diversity	Interpretability
Temporal Cutoff	LiveBench (White et al., 2024)	●	◐	◐	○	○	●
	AcademicEval (Zhang et al., 2024a)	●	◐	◐	○	○	●
	LiveCodeBench (Jain et al., 2024)	●	◐	◐	○	○	●
	LiveAoPSBench (Mahdavi et al., 2025)	●	◐	◐	○	○	●
	AntiLeak-Bench (Wu et al., 2025)	●	●	◐	●	○	●
Rule-Based	S3Eval (Lei et al., 2024)	●	●	◐	●	◐	●
	DyVal (Zhu et al., 2024a)	●	●	●	●	◐	●
	MMLU-CF (Zhao et al., 2025)	●	◐	○	●	◐	◐
	NPHardEval (Fan et al., 2024)	●	●	●	●	◐	●
	GSM-Symbolic (Mirzadeh et al., 2025)	●	○	◐	●	◐	●
	PPM (Chen et al., 2024a)	●	●	●	◐	◐	●
	GSM-Infinite (Zhou et al., 2025)	●	●	●	●	◐	●
LLM-Based	Auto-Dataset (Ying et al., 2024)	◐	●	◐	●	●	○
	LLM-as-an-Interviewer (Kim et al., 2024)	◐	●	◐	◐	●	○
	TreeEval (Li et al., 2024c)	◐	●	◐	◐	◐	○
	BeyondStatic (Li et al., 2023a)	◐	●	◐	○	●	○
	StructEval (Cao et al., 2024)	◐	●	●	●	●	○
	Dynabench (Kiela et al., 2021)	◐	◐	◐	◐	●	○
	Self-Evolving (Wang et al., 2025)	◐	●	◐	●	●	○
Hybrid	DARG (Zhang et al., 2024b)	◐	●	◐	●	●	◐
	LatestEval (Li et al., 2023c)	●	◐	◐	○	○	●
	C2LEVA (Li et al., 2025)	◐	●	◐	◐	●	◐

Table 2: Existing dynamic benchmarks and their quality on our summarized criteria. ● represents support, ◐ represents partial support, and ○ represents no support.

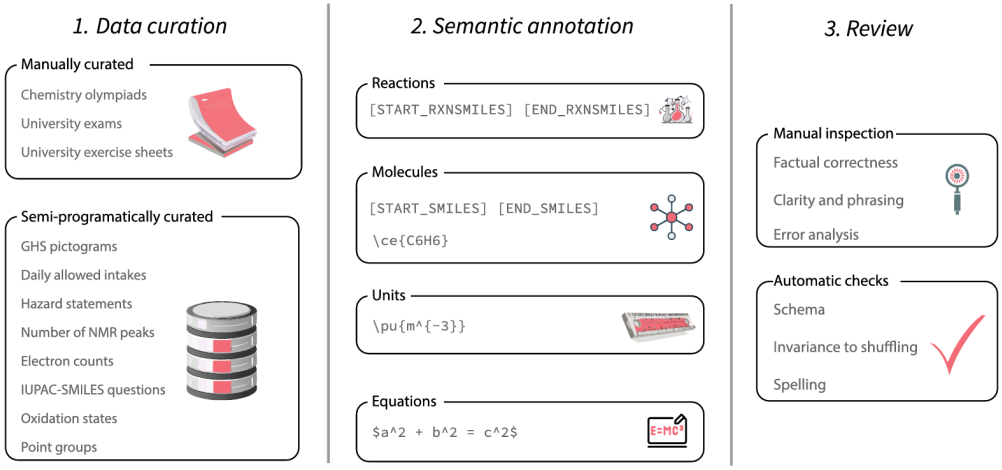
图 3.8 动态测试基准及其质量维度比较 [76]。

因此，污染控制需要同时维护两个目标：减少模型事先接触测试内容的机会，并保持测试所测能力及其难度的可解释性。持续产生新题，需要与答案核验和版本管理共同实施。

3.3.5 质量要求：验证测试能否支持预期的能力判断

完成任务编制、参考依据和数据划分之后，还需要对测试本身进行验证。本章将测试质量落实为五方面要求：任务是否具有科学代表性，参考依据是否可信，测试信息是否充分独立，执行过程是否能够复现，以及结果是否能够追溯到明确的数据和协议版本。

质量审查可以贯穿样本进入测试集的全过程。ChemBench[66] 将多来源题目整理、语义标注、人工审查和自动检查结合起来；除原始整理者外，所有问题还经过至少两名科学家的审查。这种流程兼顾科学内容与技术格式，使自动化检查能够处理格式问题，专家审查能够处理专业判断问题。



Extended Data Fig. 1 | Overview of the workflow for the assembly of the ChemBench Corpus. To assemble the ChemBench corpus, we first collected questions from various sources. Some tasks were manually curated, others semi-programmatically. We added semantic annotations for all questions to make them compatible with systems that use special processing for modalities that are not conventional natural text. We reviewed the questions using manual and automatic methods before adding them to the corpus.

图 3.9 科学测试题的整理、语义标注与质量审查流程：以 ChemBench 为例 [66]。

测试还应经过试运行和针对性检查。本章建议使用参考实现验证任务是否可完成，并构造典型错误结果，检查评价程序能否识别单位错误、输出缺失或无效计算。对于声称依赖实验数据完成的任务，可以进一步检查移除关键输入后是否仍能轻易得到预期答案。这类检查的目的，是识别任务中的信息捷径及判定漏洞。

模型得分低本身不能证明测试质量高，因为题意模糊、答案错误或运行环境失效也可能导致低分。

发布后的纠错同样属于质量管理。HLE[67] 在多轮专家审查之外，还设置了发布后的社区反馈及错误复核流程，其正式论文亦报告了专家分歧。这提示高难度科学题目需要持续审查，修订记录应与测试版本关联，避免不同版本的结果在没有说明的情况下直接比较。

最终交付的测试应包括任务说明、输入数据、参考依据、划分标识、执行环境、污染检查记录及修订历史。对于暂不公开的答案或测试样本，可以公开构建原则和审查程序，同时通过受控评测维护结果的可复核性。由此，测试构建形成一套能够被执行、检查和维护的测评协议，为后续的评分、统计分析和能力解释提供基础。

3.4 评价方法与指标选择（如何评价）

3.4.1 客观指标与科学决策目标

对于具有明确答案的任务，可以采用准确率、精确匹配或规范化后的等价判断；对于连续预测，可采用平均绝对误差、均方根误差及其他与量纲和分布相适应的指标。选择指标时需要先说明科学决策。例如，研究者若只验证排序最前的候选对象，前若干名的命中率可能比总体误差更接近实际需求；若漏检和误报的代价不同，则需要分别报告相应错误。Matbench Discovery 揭示了能量回归误差与稳定性筛选表现之间的不一致，说明低误差并不必然带来有效的候选筛选 [68]。

多个任务或领域的分数也不能直接无条件相加。指标尺度、样本数量和任务难度不同，宏平均与按样本数加权平均会突出不同方面。如果给出总分，应同时提供分任务结果、权重来源及对权重变化的敏感性分析。对于科学智能系统，较稳妥的比较是报告准确性、资源成本、可靠性等多个维度，并说明模型之间的取舍。总分可以服务于特定选择目标，但其权重本身也是评价设计的一部分 [61, 80]。

3.4.2 可执行验证与科学约束

可执行验证将输出转换为可以独立检查的对象，例如运行程序、检查生成结构、验证单位和边界条件，或重新计算关键统计量。ScienceAgentBench 将程序、执行结果和成本共同纳入评价，使代码文本与实际运行行为能够分别检查 [70]。但

程序能够执行，只能说明其满足部分计算条件；错误的数据过滤、统计假设或目标变量选择仍可能产生看似合理的结果。执行测试需要同时检查输出数值、数据来源和任务约束。

科学约束用于检验常规相似度指标未覆盖的错误。PoseBusters 在分子对接评价中检查化学与几何合理性，包括立体化学、键长及分子间碰撞等 [81]。其方法学启示是，生成结果接近参考结构与满足基本科学条件需要分别评价。对于物理代理模型，本文建议结合长期演化误差、边界条件和守恒关系检验；具体检验应根据模型目标和近似假设确定，不应机械要求所有模型满足同一约束。The Well 的多物理系统数据为比较不同动力学情境下的表现提供了基础 [82]。

3.4.3 专家评价与模型评委

当输出涉及研究假设、解释或完整报告时，参考答案可能存在多种合理形式，需要使用明确的评价量表。专家评价应说明专业背景、盲评方式、评分维度和分歧处理，并尽量要求判断关联具体证据。例如，对假设的评价可以分别检查是否与已有证据矛盾、能否提出可区分的实验预测，以及是否具备验证条件。不同维度应单独报告，避免让语言流畅度掩盖证据不足。

模型评委能够降低开放式评价的成本，但其可靠性需要独立检验。Gu 等的综述讨论了评分一致性、偏差控制以及评委自身的评价方法 [83]。在科学场景中，应使用有专家参照的样本检验评委，并关注选项顺序、答案长度、表述风格与专业细节是否改变判断。多个模型意见一致不能单独证明结果正确，因为它们可能共享偏差。对于可计算的内容，应优先使用独立计算或执行结果；模型评委可辅助处理语义、证据组织及量表映射。

PaperBench 另设评委评价任务来检查自动评分，体现了“对被测系统评分”与“验证评分器”需要分开进行 [71]。本文据此建议，将规则验证、运行检查、专家审查和模型评分组合为可追溯的过程：每一项分数应能够定位到被检查的输出或证据，而不是只保留一段总体评价。

3.4.4 不确定性、校准与选择性使用

科学预测需要说明何时值得信任。模型给出的置信度与实际正确率相匹配，称为校准；分类任务可通过可靠性图、Brier 分数等方式分析，连续预测则可检查区间覆盖率和区间宽度。LLM 不确定性综述将不同置信估计方法及其局限进行了归

纳 [84]。不过，输出概率、语言化置信表述和多次采样的一致程度并不等价，需要针对实际任务验证。

SciPredict 同时检查实验预测是否正确及模型能否识别可靠预测，展示了平均性能与可靠性判断可能分离 [85]。因此，测评可进一步考察系统在不确定时能否请求信息、转交专家或选择不回答，并报告拒答后覆盖的任务比例与剩余错误率。高拒答率可以降低错误，却可能削弱实际效用；评价需要同时展示二者。这里的单次预测不确定性还应与测评分数的统计不确定性区分，后者关注有限测试样本和重复运行造成的估计波动。

3.4.5 成本、效率与实验安全

科学任务的成本可能主要来自模拟、数据库查询、仪器运行或材料消耗，模型令牌费用只占其中一部分。SimulCost 将物理模拟参数调节中的计算成本纳入评价，并与传统扫描方法比较 [86]。这一设计说明，增加重试次数带来的成功率提升应与全部尝试的成本共同报告。对于相同预算下的比较，可以考察完成任务数、达到目标精度所需资源或单位验证成本对应的有效发现数量。

当系统参与实验建议或操作时，还需评价危险识别、风险判断和不安全行为。LabSafety Bench 覆盖实验室危险识别、风险评估与后果预测等任务 [87]。这类评价为安全推理提供了测试证据，但回答安全题与在真实环境中持续安全操作仍有距离。测评报告应明确是否只验证了文字或图像判断，是否涉及执行层检查，以及哪些异常条件尚未覆盖；安全通过率不能直接写成整个实验系统的安全保证。

3.5 测评协议与结论可信性（如何保证结论可信）

3.5.1 比较条件与基线选择

公平比较需要先明确比较目的。若问题是“哪种模型更适合相同资源下的任务”，应统一数据访问范围、工具、调参和推理预算；若问题是“哪套完整方法最有应用价值”，则可以允许不同工具组合，但需要把额外资源计入成本。固定模型名称而不报告提示、检索库、工具版本和重试策略，难以复现智能体结果。近期智能体综述将评测环境及框架作为独立维度，正是因为环境配置会影响能力的实际表现 [62, 63]。

基线应包含能够检验任务价值的简单方法和领域方法，而不仅是上一代复杂模型。Ahlmann-Eltze 等比较多种基础模型及其他深度学习方法后发现，在其所考察的未见遗传扰动预测设置中，模型未能稳定超过刻意设计的简单线性基线 [88]。这一结果不意味着所有生物基础模型均无效，而是说明新方法的增益需要在明确任务和强基线下成立。任务中若存在不改变状态、预测训练均值、最近邻检索或传统求解器等自然参照，应说明为何纳入或排除。

3.5.2 随机性与统计比较

同一任务在不同运行中可能得到不同结果。采样策略、工具反馈、环境状态和服务端变化都可能引入波动。Song 等专门讨论了语言模型评价中的非确定性，说明单次输出难以刻画模型行为的变异 [89]。Wadi 和 Fredette 提出使用重复采样估计模型表现，为将运行波动纳入评价提供了方法参考 [90]。因此，应分别报告任务之间的差异和同一任务多次运行的差异，并说明重复次数及其资源代价。

统计分析的单位必须与数据生成过程一致。来自同一研究、受试对象或实验批次的多个样本往往相关，不能简单视为完全独立的观测。作为实践建议，模型比较可以在相同任务上计算配对差异，并按独立对象或任务组进行重采样；对于多次运行的数据，应保留任务和运行的层级结构。置信区间应说明估计的是任务总体、给定任务集上的随机运行，还是两者共同引起的不确定性。不能仅凭两个模型各自区间是否重叠判断配对差异是否成立。

多模型、多指标比较还需要控制选择性报告。应预先说明主要指标、次要分析和异常处理规则；不能从大量设置中只选择最有利的结果，也不能剔除无法执行的样本后把剩余样本准确率视为整体能力。对任务失败，应同时报告失败比例和有效输出上的质量。REFORMS 对透明分析和结果报告的要求，为这些实践提供了研究规范基础 [60]。

3.5.3 外部验证与前瞻性验证

内部测试、外部测试与前瞻性验证支持不同强度的应用结论。内部测试关注既定来源和划分下的泛化；外部测试使用不同时间、机构、数据生成流程或对象群体检验可迁移性；前瞻性验证在模型输出被固定后采集结果，减少事后筛选成功案例的空间。对具有资源消耗的发现任务，还需比较模型辅助流程与合理替代流程在相同条件下的效用。

科学模型的参考体系本身也需要验证。模拟环境中的成功首先表示模型适应该环境，真实实验中的表现还可能受到测量误差、设备差异和未建模机制影响。生物医学基础模型的评价讨论强调，任务效用、模型对现象的解释以及可检验性不能混为一谈 [64]。因此，报告应明确结论停留在数据回顾、计算再验证还是独立实验阶段。真实发现的证据积累通常需要时间，不能用一次自动评分替代后续科学验证。

3.5.4 版本管理与可审计报告

测评发布应同时固定数据、划分、模型标识、代码、环境、评分器和运行配置。对持续更新的基准，应提供冻结版本用于复现，并通过新的测试轮次观察泛化；否则同名基准在不同时点可能不再对应同一任务集合。数据污染综述揭示了持续更新的价值，也提示动态评价需要可比较的设计原则 [76]。更新机制应保留任务替换理由、难度变化和分数可比范围，而非只更换题目后延续原排行榜。

一个可审计的科学测评报告应让读者重建“输入—操作—结果—评分”的对应关系。最低信息包括任务定义、样本来源与独立单位、参考依据、评价条件、主要指标、统计不确定性、全部运行成本及失败类型。对于专家或模型评委，还应披露量表、评委配置、验证样本和分歧处理方式。数据或模型因授权限制无法完全公开时，应清楚说明可复现范围与受限部分，避免把部分开放描述为完整复现。

3.6 代表性研究的比较与主题演进

3.6.1 封闭式知识测评正在补充专业任务维度

HLE 和 ChemBench 代表了专家知识测评的两种组织方式：前者通过跨学科高难度问题提高对前沿系统的区分，后者围绕化学知识和推理建立领域比较 [66, 67]。二者提供了可自动化和可重复的入口，但任务仍以给定问题的回答为主。对科学智能研究而言，更有价值的延伸是说明这些成绩与真实任务之间的关系，例如题目中检验的符号理解是否有助于读懂实验条件，知识正确率是否能够预测工具选择和结果解释的成功。

因此，“专业问答得分提升”与“科研能力提升”之间需要额外证据。模型与人类专家的比较也应保留时间、工具和题目范围等条件。跨学科题集中的平均专家表现不一定对应某一细分领域专家的上限，单次人机比较不能无条件推广为全

面的专家替代。将能力主张限制在被测试的对象和条件内，可以使知识基准继续发挥作用，同时避免对其解释过度扩张。

3.6.2 科学预测测评转向任务相关指标与条件泛化

材料、分子与细胞研究呈现出共同变化：平均预测精度开始与下游决策、科学约束和未见条件分别讨论。Matbench Discovery 将材料筛选目标与评价指标对应；PoseBusters 检验几何相似之外的物理合理性 [68, 81]。这两类研究提示，应检查指标优化是否真正改善目标研究步骤，并保留对结果有效性的独立验证。

在单细胞扰动预测中，简单基线比较、零样本表征评价和跨细胞背景测试提供了互补证据。线性基线研究检验复杂模型的增益，PertEval-scFM 聚焦基础表征的可迁移用途，较大范围的方法比较则检验新扰动和新情境下的表现 [88, 91, 92]。它们不能被压缩成一张脱离设置的模型排名。更合适的综合方式是分别记录训练条件、适配方法、留出单位和评价指标，识别哪些能力已经得到支持、哪些结论仍依赖特定数据。

物理与气象评价具有类似需求。The Well 提供多种时空动力学任务，WeatherBench 2 则强调统一预报评价框架及基线数据 [82, 93]。本文据此认为，跨领域通用性应通过多种任务分别建立，而不能仅依靠将所有误差压缩为一个总数。变量尺度、预报时效和参考系统不同，都会影响误差的实际意义。

3.6.3 智能体测评从任务产物扩展到证据生成过程

ScienceAgentBench、PaperBench 和 FIRE-Bench 对研究活动进行了不同程度的展开。前者关注具体科学数据分析任务能否完成，PaperBench 聚焦既有研究复现，FIRE-Bench 进一步要求从研究问题出发形成由实验支持的结论 [70–72]。这种变化使评价能够观察实验设计、执行和解释之间的衔接，但测试范围仍受到参考研究、工具环境和预算的约束。复现、再发现与原创发现应作为不同目标报告。

领域工作流研究能够补充通用智能体基准的不足。Liu 等围绕单细胞组学建立 50 项真实分析任务和多维指标，并区分结果一致性与生物学指标 [94]。其意义在于将可执行程序进一步连接到领域结果。评价中的过程信息应优先使用实际工具调用、执行日志、中间产物和来源记录；模型生成的计划或推理说明可以辅助分析，但其表述不能单独证明操作已发生或推理具有因果忠实性。

3.6.4 可靠性与资源约束成为科学效用的一部分

SciPredict、SimulCost 和 LabSafety Bench 分别将预测可靠性、模拟成本和实验风险纳入测试 [85–87]。这些工作扩大了测评的解释范围：即使系统有时能得到正确结果，仍需要知道它能否识别失败风险、需要付出多少资源，以及是否满足使用约束。面向实际部署的比较，应按任务目标联合展示这些因素，不宜用增加尝试次数后的最高成功率替代完整效用评价。

表 3.2 汇总部分代表性研究的方法贡献及解释边界。表中不汇总模型得分，因为各研究的数据、模型版本和执行条件不同，横向拼接原始数值不能形成公平比较。

表 3.2 代表性研究对科学测评设计的启示

研究	年份及来源	主要测评对象	关键方法问题	解释边界
ChemBench[66]	2025 Nature Chemistry	化学知识与推理	领域问题与专家参照	答题能力与实验执行不同
Matbench Discovery[68]	2025 Nature Machine Intelligence	稳定晶体筛选	指标对应筛选目标	计算稳定性不保证可合成性
PertEval-scFM[91]	2025 ICML	单细胞基础表征	零样本与分布变化	结论依赖适配和测试设置
ScienceAgent Bench[70]	2025 ICLR	科学数据分析	程序与执行结果验证	单项任务完成不等于全流程自主研究
PaperBench[71]	2025 ICML	论文复现	分层量表与评委检验	复现能力不等于原创能力
FIRE-Bench[72]	2026 ICML	已知科学结论再发现	实验与结论证据对应	已知发现的可控近似
SciPredict[85]	2026 ICML	实验结果预测	准确性与校准	已发表结果预测仍需独立外部验证
SimulCost[86]	2026 ICML	物理模拟参数调节	成功率与工具成本	效用取决于模拟器和预算

3.7 主要不足与研究方向

3.7.1 建立能力主张与验证证据的对应关系

当前研究中，一个常见问题是测评名称涵盖的能力范围大于实际证据范围。解决这一问题需要在设计阶段写明能力主张，并逐项对应可观测任务、评分依据和外推条件。Zhou 等关于任务需求和能力画像的研究为这种对应提供了测量思路 [80]。在科学领域，还应继续研究哪些题目或任务特征与实际科研表现相关，并通过外部数据检验，而不能仅由设计者命名能力维度。

3.7.2 在开放发现任务中保留可检验性

原创科学问题往往没有即时可用的标准答案。若完全依赖专家印象或模型评委，可能把合理表达误判为有效发现；若只使用已知结果，又会限制对新颖性的评价。FIRE-Bench 选择已知结论再发现，为可验证研究任务提供了可操作的折中 [72]。未来可将评价分为假设质量、证据获取、独立验证和后续复现等阶段，并明确每一阶段尚不能证明的内容。本文建议对新颖性、科学正确性和实际效用分别收集证据，避免用一项综合主观评分同时代表三者。

3.7.3 改善测评数据与评分器的共同治理

随着任务生成和自动评分增加，数据生成器、被测模型和评分模型之间可能形成共享偏差。后续研究应检查生成任务的覆盖差异、错误参考的传播，以及评委在不同专业和输出形式下的稳定性。污染控制与评委可靠性研究分别处理了测试信息独立性和评分可信性问题 [76, 83]，二者需要在完整测评流程中结合。动态基准也应保留可审计版本和长期比较机制，使更新后的结果仍可解释。

3.7.4 评价人机协作与真实实验收益

科研中的许多系统承担辅助角色，其价值可能表现为减少专家时间、降低重复操作、提高候选验证效率或帮助识别失败条件。面向这些用途，未来可以在固定任务和资源条件下，比较人类独立、模型独立与人机协作的结果，同时记录人工纠错和监督成本。这是本文提出的评价方向，不能由现有单模型基准分数直接推导。与自主实验室研究衔接时，测评章节应给出成本、风险、失败恢复和外部验证的判断方法；设备集成及闭环控制实现则属于具体实验系统研究。

3.8 结论

科学智能测评的核心，是为明确的科学能力主张建立与之相称的证据。测试数据只有与任务定义、参考依据、评分方法和运行协议共同设计，才能支持可信判断。本文梳理表明，知识问答、科学预测、工作流执行及发现导向任务分别需要不同验证方式；数据治理质量、测试独立性、科学有效性和结果稳定性也应分别检验。近年来的代表性研究正将评价推进到任务相关指标、未见条件泛化、可执行证据以及成本和可靠性的联合分析。

因此，科学智能测评章节应以测评数据与任务构建、评价方法和可信协议为主体，并通过领域案例说明这些设计如何改变结果解释。写作中应始终保留结论的适用条件：能答对专业问题、能完成特定程序、能复现研究和能产生经独立验证的新发现，分别需要不同证据。只有把这些证据层次说明清楚，测评才能为模型改进和实际科研使用提供可检验的依据。

文献与延伸阅读

以下介绍代表性文献的研究主题与发表信息，完整条目统一列于书末。

- Eriksson 等的综述 [61]：科学智能测评的参考综述。
- Chen 等的数据污染综述 [76]：“污染控制部分的补充综述”。
- ScienceAgentBench、PaperBench 和 FIRE-Bench[70–72]：文献信息注明为会议论文。
- Zhang 和 Li[73]：预印本；2026-10-04 公开，访问日期 2026-10-18。
- Nageshwaran 等 [62]：2026-09-15 提前上线录用稿，访问日期 2026-10-18。
- Saez-Rodriguez 等 [64]：Perspective。
- Shorinwa 等 [84]：2025-09-09 在线发表，访问日期 2026-10-18。

参考文献

[1] DING K, ZHU Z, et al. Bridging data and discovery: a survey on knowledge graphs in AI for science[J/OL]. National Science Review, 2026, 13(8): nwag140. DOI: 10.1093/nsr/nwag140.

[2] CHALK S J. SciData: a data model and ontology for semantic representation of scientific data[J/OL]. Journal of Cheminformatics, 2016, 8: 54. DOI: 10.1186/s13321-016-0168-9.

[3] ZHANG Q, DING K, LV T, et al. Scientific Large Language Models: A Survey on Biological & Chemical Domains[J/OL]. ACM Computing Surveys, 2025, 57(6): 161. DOI: 10.1145/3715318.

[4] The ChEMBL Database in 2023: a drug discovery platform spanning multiple bioactivity data types and time periods[J/OL]. Nucleic Acids Research, 2024. DOI: 10.1093/nar/gkad1004.

[5] BindingDB in 2024: a FAIR knowledgebase of protein-small molecule binding data[J/OL]. Nucleic Acids Research, 2025. DOI: 10.1093/nar/gkae1075.

[6] A review of biomedical datasets relating to drug discovery: a knowledge graph perspective [J/OL]. Briefings in Bioinformatics, 2022. DOI: 10.1093/bib/bbac404.

[7] KEARNES S M, et al. The Open Reaction Database[J/OL]. Journal of the American Chemical Society, 2021, 143: 18820-18826. DOI: 10.1021/jacs.1c09820.

[8] ABEYRUWAN S, et al. Evolving BioAssay Ontology (BAO): modularization, integration and applications[J/OL]. Journal of Biomedical Semantics, 2014, 5(Suppl 1): S5. DOI: 10.1186/2041-1480-5-S1-S5.

[9] GLENNY-PESCOV J, CHUNG C, et al. Advancing the bioassay ontology through integrated PK/PD and safety pharmacology representation[J/OL]. Journal of Biomedical Semantics, 2026, 17: 6. DOI: 10.1186/s13326-025-00342-5.

[10] FU F, LI Q Q, WANG F, et al. Synergizing a knowledge graph and large language model for relay catalysis pathway recommendation[J/OL]. National Science Review, 2025, 12: nwaf271. DOI: 10.1093/nsr/nwaf271.

[11] CHANDAK P, HUANG K, ZITNIK M. Building a knowledge graph to enable precision medicine[J/OL]. Scientific Data, 2023, 10: 67. DOI: 10.1038/s41597-023-01960-3.

[12] iKraph: A comprehensive large-scale biomedical knowledge graph for AI-powered data-driven biomedical research[J/OL]. Nature Machine Intelligence, 2025. DOI: 10.1038/s42256-025-01014-w.

[13] Accessing scientific data through knowledge graphs with Ontop[J/OL]. Patterns, 2021. DOI: 10.1016/j.patter.2021.100346.

[14] PROV-O: The PROV Ontology[EB/OL]. W3C Recommendation, 2013. https://www.w3.org/TR/prov-o/.

[15] RAO J, QIU Y, ZHANG J, et al. SciDataCopilot: An Agentic Data Preparation Framework for AGI-driven Scientific Discovery[EB/OL]. 2026. arXiv: 2602.09132. https://arxiv.org/abs/2602.09132.

[16] DING K, YU J, HUANG J, et al. SciToolAgent: a knowledge-graph-driven scientific agent for multitool integration[J/OL]. Nature Computational Science, 2025, 5: 962-972. DOI: 10.1038/s43588-025-00849-y.

[17] JIANG Y, LOU W, WANG L, et al. SCP: Accelerating Discovery with a Global Web of Autonomous Scientific Agents[EB/OL]. 2025. arXiv: 2512.24189. https://arxiv.org/abs/2512.24189.

[18] SciGraph-Bio SCP Server[EB/OL]. SCP Hub 官方项目技术文档, 2026. https://scphub.intern-ai.org.cn/detail/38.

[19] HUANG X, LONG Q, DU X, et al. Scientific Data Skills: Enabling Agent-Ready Scientific Data Services at Scale[EB/OL]. 2026. arXiv: 2608.19625v2. https://arxiv.org/abs/2608.19625v2.

[20] FANG Y, LIANG X, ZHANG N, et al. Mol-Instructions: A Large-Scale Biomolecular Instruction Dataset for Large Language Models[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/d346d91999074dd8d6073d4c3b13733b-Abstract-Conference.html.

[21] FENG K, DING K, et al. SciKnowEval: Evaluating Multi-level Scientific Knowledge of Large Language Models[EB/OL]. 2024. arXiv: 2406.09098. https://arxiv.org/abs/2406.09098.

[22] LUO Y, LIU X Y, YANG K, et al. KEDD: Toward Unified AI Drug Discovery with Multimodal Knowledge[J/OL]. Health Data Science, 2024, 4: 0113. DOI: 10.34133/hds.0113.

[23] LUO Y, YANG K, HONG M, et al. Learning Multi-view Molecular Representations with Structured and Unstructured Knowledge[C/OL]//KDD. 2024: 2082-2093. DOI: 10.1145/3637528.3672043.

[24] DAGDELEN J, DUNN A, et al. Structured information extraction from scientific text with large language models[J/OL]. Nature Communications, 2024, 15: 1418. DOI: 10.1038/s41467-024-45563-x.

[25] MO B, YU K, KAZDAN J, et al. KGGen: Extracting Knowledge Graphs from Plain Text with Language Models[C/OL]//NeurIPS. 2025. https://neurips.cc/virtual/2025/poster/117386.

[26] VAN WEESEP L, TEDOLDI R, et al. Can LLMs Reliably Annotate Bioassay Metadata to Improve Data Readiness?[EB/OL]. 2026. arXiv: 2610.01616. https://arxiv.org/abs/2610.01616.

[27] SOMAN K, ROSE P W, et al. Biomedical knowledge graph-optimized prompt generation for large language models[J/OL]. Bioinformatics, 2024, 40: btae560. DOI: 10.1093/bioinformatics/btae560.

[28] LUO L, LI Y F, HAFFARI G, et al. Reasoning on Graphs: Faithful and Interpretable Large Language Model Reasoning[C/OL]//ICLR. 2024. https://proceedings.iclr.cc/paper_files/paper/2024/hash/3e2aeb66481dd63a32421bf032b70384-Abstract-Conference.html.

[29] LUO L, ZHAO Z, HAFFARI G, et al. Graph-constrained Reasoning: Faithful Reasoning on Knowledge Graphs with Large Language Models[C/OL]//Proceedings of Machine Learning Research: Vol. 267 ICML. 2025: 41540-41565. https://proceedings.mlr.press/v267/luo25t.html.

[30] DENG Y, ERICKSEN S S, GITTER A. Assay2Mol: Large Language Model-based Drug Design Using BioAssay Context[C/OL]//EMNLP. 2025: 27337-27362. https://aclanthology.org/2025.emnlp-main.1390/.

[31] MATSUMOTO N, MORAN J, CHOI H, et al. KRAGEN: a knowledge graph-enhanced RAG framework for biomedical problem solving using large language models[J/OL]. Bioinformatics, 2024, 40: btae353. DOI: 10.1093/bioinformatics/btae353.

[32] MATSUMOTO N, CHOI H, MORAN J, et al. ESCARGOT: an AI agent leveraging large language models, dynamic graph of thoughts, and biomedical knowledge graphs for enhanced reasoning[J/OL]. Bioinformatics, 2025, 41: btaf031. DOI: 10.1093/bioinformatics/btaf031.

[33] HUANG K, CHANDAK P, WANG Q, et al. A foundation model for clinician-centered drug repurposing[J/OL]. Nature Medicine, 2024, 30: 3601-3613. DOI: 10.1038/s41591-024-03233-x.

[34] LEE H, YOO H J, JANG H S, et al. Toward self-driving laboratory 2.0 for chemistry and materials discovery[J/OL]. Materials Horizons, 2026. DOI: 10.1039/D5MH01984B.

[35] PILON S, SAVINO E, BAYLEY O M, et al. A flexible and affordable self-driving laboratory for automated reaction optimization[J/OL]. Nature Synthesis, 2026. DOI: 10.1038/s44160-026-01053-0.

[36] BENNETT J A, OROUJI N, VELAYATI A, et al. An autonomous lab for data-driven homogeneous catalysis[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-74425-x.

[37] BURGER B, MAFFETTONE P M, GUSEV V V, et al. A mobile robotic chemist[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-2442-2.

[38] SZYMANSKI N J, RENDY B, FEI Y, et al. An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06734-w.

[39] FEI Y, RENDY B, YANG X, et al. Agentic LLM Reasoning in a Self-Driving Laboratory for Air-Sensitive Lithium Halide Spinel Conductors[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2604.11957.

[40] SUPONYA A, DI MARE E, RAMÍREZ C, et al. Self-driving lab for the data-driven design of single-chain polymer nanoparticles[J/OL]. Cell Press Blue, 2026. DOI: 10.1016/j.cpblue.2026.100033.

[41] LOH X J. Predicting Faster Than We Can Make: Polymer-Specific Process Physics as a Frontier for Autonomous Soft-Matter Discovery[J/OL]. Macromolecular Rapid Communications, 2026. DOI: 10.1002/marc.70420.

[42] STRIETH-KALTHOFF F, HAO H, RATHORE V, et al. Delocalized, asynchronous, closed-loop discovery of organic laser emitters[J/OL]. Science, 2024. DOI: 10.1126/science.adk9227.

[43] PARK H S, MAZAHERI M, CHOI C, et al. Discovery of tunable and soluble organic emitters for solid-state lasers with a self-driving laboratory[J/OL]. Nature Communications, 2026. DOI: 10.1038/s41467-026-69233-2.

[44] LEE J, NOH J, LEE H, et al. Recent advances in data-driven and artificial intelligence-integrated perovskite solar cells: From design to self-driving laboratories[J/OL]. InfoMat, 2026. DOI: 10.1002/inf2.70124.

[45] ATTIA P M, GROVER A, JIN N, et al. Closed-loop optimization of fast-charging protocols for batteries with machine learning[J/OL]. Nature, 2020. DOI: 10.1038/s41586-020-1994-5.

[46] SHIBUKAWA R, MATSUDA S, NAKAMURA K, et al. Collecting diverse near-optimal samples via nested Thompson sampling[J/OL]. npj Computational Materials, 2026. DOI: 10.1038/s41524-026-02067-0.

[47] RAPP J T, BREMER B J, ROMERO P A. Self-driving laboratories to autonomously navigate the protein fitness landscape[J/OL]. Nature Chemical Engineering, 2024. DOI: 10.1038/s44286-023-00002-4.

[48] BROOKS C, NOTIN P, ROMERO P A. Learning protein function through autonomous experimental interaction[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.08.14.744985.

[49] HAMEDIRAD M, CHAO R, WEISBERG S, et al. Towards a fully automated algorithm driven platform for biosystems design[J/OL]. Nature Communications, 2019. DOI: 10.1038/s41467-019-13189-z.

[50] COCHRANE R R, DOS SANTOS L V, CAI Y. The convergence of AI-driven engineering biology and emerging technologies advancing globally networked autonomous biofoundries[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103503.

[51] CHEN J, VOLK M, SHAFAEI S, et al. An AI-powered cloud biofoundry for autonomous biological research[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.30.750244.

[52] KANDA G N, TSUZUKI T, TERADA M, et al. Robotic search for optimal cell culture in regenerative medicine[J/OL]. eLife, 2022. DOI: 10.7554/eLife.77007.

[53] BIELAWSKI K, SRINIVASAN K, GAYLINN N, et al. A Closed-Loop Robot Scientist for Autonomous Biological Discovery[EB/OL]. bioRxiv 预印本, 2026. DOI: 10.64898/2026.09.11.751076.

[54] LIU S, KAUR N, SONG D H, et al. Self-driving bioprinting laboratories[J/OL]. Biofabrication, 2026. DOI: 10.1088/1758-5090/ae3645.

[55] PITICARI A S, GRIGGS S D, CRAWFORD L, et al. Algorithm-driven, phenotype-directed bioactive molecular discovery[J/OL]. Communications Chemistry, 2026. DOI: 10.1038/s42004-026-02066-8.

[56] RAMADURAI K, BANERJEE A. TechBio 3.0 closes the drug discovery loop with multimodal AI and generative chemistry[J/OL]. npj Drug Discovery, 2026. DOI: 10.1038/s44386-026-00078-x.

[57] XU Y, CUI H, PANG K, et al. LUMI-lab: A foundation model-driven autonomous platform enabling discovery of ionizable lipid designs for mRNA delivery[J/OL]. Cell, 2026. DOI: 10.1016/j.cell.2026.01.012.

[58] SAGMEISTER P, UDEPURKAR A, DEVOS C, et al. Autonomous Lipid Nanoparticle Engineering[J/OL]. ACS Nano, 2026. DOI: 10.1021/acsnano.6c15600.

[59] PANAGIOTAKOPOULOU M, GOREN A, REKER D, et al. Artificial intelligence and machine learning in nanoparticle drug delivery systems[J/OL]. Nature Reviews Bioengineering, 2026. DOI: 10.1038/s44222-026-00495-7.

[60] KAPOOR S, CANTRELL E M, PENG K, et al. REFORMS: Consensus-based Recommendations for Machine-learning-based Science[J/OL]. Science Advances, 2024, 10(18): eadk3452. DOI: 10.1126/sciadv.adk3452.

[61] ERIKSSON M, PURIFICATO E, NOROOZIAN A, et al. Can We Trust AI Benchmarks? An Interdisciplinary Review of Current Issues in AI Evaluation[C/OL]//Proceedings of the AAAI/ACM Conference on AI, Ethics, and Society: Vol. 8. 2025: 850-864. DOI: 10.1609/aies.v8i1.36595.

[62] NAGESHWARAN V, EZEKIEL S, TRAN T T, et al. Large language model agent evaluation and benchmarking: a systematic survey, meta-taxonomy, and critical research roadmap [J/OL]. Artificial Intelligence Review, 2026. DOI: 10.1007/s10462-026-11678-4.

[63] YEHUDAI A, EDEN L, LI A, et al. A Survey on Evaluation of LLM-based Agents[C/OL]// Findings of the Association for Computational Linguistics: ACL 2026. 2026: 26690-26714. DOI: 10.18653/v1/2026.findings-acl.1330.

[64] SAEZ-RODRIGUEZ J, SCHÄFER P S L, KALAVROS N, et al. Benchmarking biomedical foundation models[J/OL]. Nature Methods, 2026, 23: 1724-1733. DOI: 10.1038/s41592-026-03182-y.

[65] ZHENG T, DENG Z, TSANG H T, et al. From Automation to Autonomy: A Survey on Large Language Models in Scientific Discovery[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2025: 17733-17750. DOI: 10.18653/v1/2025.emnlp-main.895.

[66] MIRZA A, ALAMPARA N, KUNCHAPU S, et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists[J/OL]. Nature Chemistry, 2025, 17: 1027-1034. DOI: 10.1038/s41557-025-01815-x.

[67] Center for AI Safety, Scale AI, HLE Contributors Consortium. A benchmark of expert-level academic questions to assess AI capabilities[J/OL]. Nature, 2026, 649: 1139-1146. DOI: 10.1038/s41586-025-09962-4.

[68] RIEBESELL J, GOODALL R E A, BENNER P, et al. A framework to evaluate machine learning crystal stability predictions[J/OL]. Nature Machine Intelligence, 2025, 7: 836-847. DOI: 10.1038/s42256-025-01055-1.

[69] ZENI C, PINSLER R, ZÜGNER D, et al. A generative model for inorganic materials design [J/OL]. Nature, 2025, 639: 624-632. DOI: 10.1038/s41586-025-08628-5.

[70] CHEN Z, CHEN S, NING Y, et al. ScienceAgentBench: Toward Rigorous Assessment of Language Agents for Data-Driven Scientific Discovery[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/f12b4df26344f3be803c06b555252efe-Abstract-Conference.html.

[71] STARACE G, JAFFE O, SHERBURN D, et al. PaperBench: Evaluating AI's Ability to Replicate AI Research[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 56843-56873. https://proceedings.mlr.press/v267/starace25a.html.

[72] WANG Z, BAI F, LUO Z, et al. FIRE-Bench: Evaluating AI Agents on the Rediscovery of Scientific Insights[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 124896-124929. https://proceedings.mlr.press/v306/wang26d.html.

[73] ZHANG K, LI Y. Are We Measuring Scientific Intelligence? Rethinking the Evaluation of AI Scientists[EB/OL]. (2026-10-04)[2026-10-18]. https://arxiv.org/abs/2610.04915.

[74] JOERES R, BLUMENTHAL D B, KALININA O V. Data splitting to avoid information leakage with DataSAIL[J/OL]. Nature Communications, 2025, 16: 3337. DOI: 10.1038/s41467-025-58606-8.

[75] JOERES R, BLUMENTHAL D B, KALININA O V. Addendum: Data splitting against information leakage with DataSAIL[J/OL]. Nature Communications, 2026, 17: 1597. DOI: 10.1038/s41467-025-67495-w.

[76] CHEN S, CHEN Y, LI Z, et al. Benchmarking Large Language Models Under Data Contamination: A Survey from Static to Dynamic Evaluation[C/OL]//Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing. 2025: 10080-10098. DOI: 10.18653/v1/2025.emnlp-main.511.

[77] SUN Y, WANG H, LI D, et al. The emperor's new clothes in benchmarking? A rigorous examination of mitigation strategies for LLM benchmark data contamination[C/OL]// Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 57728-57753. https://proceedings.mlr.press/v267/sun25t.html.

[78] WANG H, LI H, KO B, et al. On the fragility of benchmark contamination detection in reasoning models[C/OL]//International Conference on Learning Representations. 2026. https://proceedings.iclr.cc/paper_files/paper/2026/hash/a3860475ddbfb8c644c43f0dcd266b66-Abstract-Conference.html.

[79] WHITE C, DOOLEY S, ROBERTS M, et al. LiveBench: A challenging, contamination-limited LLM benchmark[C/OL]//International Conference on Learning Representations. 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/e4a46394ba5378b3f9a186a5b4c650d1-Abstract-Conference.html.

[80] ZHOU L, PACCHIARDI L, MARTÍNEZ-PLUMED F, et al. General scales unlock AI evaluation with explanatory and predictive power[J/OL]. Nature, 2026, 652: 58-67. DOI: 10.1038/s41586-026-10303-2.

[81] BUTTENSCHOEN M, MORRIS G M, DEANE C M. PoseBusters: AI-based docking methods fail to generate physically valid poses or generalise to novel sequences[J/OL]. Chemical Science, 2024, 15: 3130-3139. DOI: 10.1039/D3SC04185A.

[82] OHANA R, MCCABE M, MEYER L, et al. The Well: a Large-Scale Collection of Diverse Physics Simulations for Machine Learning[C/OL]//Advances in Neural Information Processing Systems 37, Datasets and Benchmarks Track. 2024. DOI: 10.52202/079017-1430.

[83] GU J, JIANG X, SHI Z, et al. A survey on LLM-as-a-judge[J/OL]. The Innovation, 2026, 7(6): 101253. DOI: 10.1016/j.xinn.2025.101253.

[84] SHORINWA O, MEI Z, LIDARD J, et al. A Survey on Uncertainty Quantification of Large Language Models: Taxonomy, Open Research Challenges, and Future Directions[J/OL]. ACM Computing Surveys, 2025, 58(3): 63. DOI: 10.1145/3744238.

[85] SEHWAG U M, LAU E, OSKOUIE H E, et al. SciPredict: Can LLMs Predict the Outcomes of Scientific Experiments in Natural Sciences?[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 108784-108827. https://proceedings.mlr.press/v306/sehwag26a.html.

[86] CAO Y, LAI S, HUANG J, et al. SimulCost: A Cost-Aware Benchmark and Toolkit for Automating Physics Simulations with LLMs[C/OL]//Proceedings of Machine Learning Research: Vol. 306 Proceedings of the 43rd International Conference on Machine Learning. PMLR, 2026: 11206-11254. https://proceedings.mlr.press/v306/cao26g.html.

[87] ZHOU Y, YANG J, HUANG Y, et al. Benchmarking large language models on safety risks in scientific laboratories[J/OL]. Nature Machine Intelligence, 2026, 8: 20-31. DOI: 10.1038/s42256-025-01152-1.

[88] AHLMANN-ELTZE C, HUBER W, ANDERS S. Deep-learning-based gene perturbation effect prediction does not yet outperform simple linear baselines[J/OL]. Nature Methods, 2025, 22: 1657-1661. DOI: 10.1038/s41592-025-02772-6.

[89] SONG Y, WANG G, LI S, et al. The Good, The Bad, and The Greedy: Evaluation of LLMs Should Not Ignore Non-Determinism[C/OL]//Proceedings of NAACL-HLT 2025, Volume 1: Long Papers. 2025: 4195-4206. DOI: 10.18653/v1/2025.naacl-long.211.

[90] WADI D, FREDETTE M. A Monte-Carlo Sampling Framework For Reliable Evaluation of Large Language Models Using Behavioral Analysis[C/OL]//Findings of the Association for Computational Linguistics: EMNLP 2025. 2025: 9414-9432. DOI: 10.18653/v1/2025.findings-emnlp.500.

[91] WENTELER A, OCCHETTA M, BRANSON N, et al. PertEval-scFM: Benchmarking Single-Cell Foundation Models for Perturbation Effect Prediction[C/OL]//Proceedings of Machine Learning Research: Vol. 267 Proceedings of the 42nd International Conference on Machine Learning. PMLR, 2025: 66633-66677. https://proceedings.mlr.press/v267/wenteler25a.html.

[92] WEI Z, WANG Y, GAO Y, et al. Benchmarking algorithms for generalizable single-cell perturbation response prediction[J/OL]. Nature Methods, 2026, 23: 451-464. DOI: 10.1038/s41592-025-02980-0.

[93] RASP S, HOYER S, MEROSE A, et al. WeatherBench 2: A Benchmark for the Next Generation of Data-Driven Global Weather Models[J/OL]. Journal of Advances in Modeling Earth Systems, 2024, 16: e2023MS004019. DOI: 10.1029/2023MS004019.

[94] LIU Y, ZHOU L, DU X, et al. Benchmarking LLM-based agents for single-cell omics analysis[J/OL]. Genome Biology, 2026, 27: 123. DOI: 10.1186/s13059-026-03998-z.

[95] TOM G, SCHMID S P, BAIRD S G, et al. Self-Driving Laboratories for Chemistry and Materials Science[J/OL]. Chemical Reviews, 2024. DOI: 10.1021/acs.chemrev.4c00055.

[96] BOIKO D A, MACKNIGHT R, KLINE B, et al. Autonomous chemical research with large language models[J/OL]. Nature, 2023. DOI: 10.1038/s41586-023-06792-0.

[97] SZYMANSKI N J, RENDY B, FEI Y, et al. Author Correction: An autonomous laboratory for the accelerated synthesis of inorganic materials[J/OL]. Nature, 2026. DOI: 10.1038/s41586-025-09992-y.

[98] ZHANG T, LIN H, CHEN Y, et al. SALSA: a low-cost self-driving lab modular add-on for salt solubility assessment for battery electrolytes[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00516G.

[99] ALLU S G, HASNAIN R, VOS A, et al. AI-driven approaches for navigating battery complexity[J/OL]. EES Batteries, 2026. DOI: 10.1039/D6EB00101G.

[100] VOLK M, KAUSHIK PILLALAMARRI V, GUO R, et al. Artificial intelligence tools for enzyme engineering and metabolic engineering[J/OL]. Current Opinion in Biotechnology, 2026. DOI: 10.1016/j.copbio.2026.103522.

[101] OATMAN H R, LAD B C, NGUYEN L, et al. An optogenetic smart microscopy platform reveals signaling dynamics-dependent control over collective cell migration[J/OL]. Cell Systems, 2026. DOI: 10.1016/j.cels.2026.101674.

[102] HWANG J, KIM S, LIM S, et al. Self-driving laboratories in Korea: a new era of autonomous discovery[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D6DD00024J.

[103] ZHU Q, ZHANG F, HUANG Y, et al. An all-round AI-Chemist with a scientific mind [J/OL]. National Science Review, 2022. DOI: 10.1093/nsr/nwac190.

[104] FENG S, MA R, et al. InternAgent-1.5: A Unified Agentic Framework for Long-Horizon Autonomous Scientific Discovery[EB/OL]. arXiv 预印本, 2026. https://arxiv.org/abs/2602.08990.

[105] ADESIJI A D, WANG J, KUO C S, et al. Benchmarking self-driving labs[J/OL]. Digital Discovery, 2026. DOI: 10.1039/D5DD00337G.

[106] CANTY R B, ABOLHASANI M. The past, present and future of self-driving laboratories [J/OL]. Nature Reviews Chemistry, 2026. DOI: 10.1038/s41570-026-00847-2.

[107] WILKINSON M D, DUMONTIER M, AALBERSBERG I J, et al. The FAIR Guiding Principles for scientific data management and stewardship[J/OL]. Scientific Data, 2016, 3: 160018. DOI: 10.1038/sdata.2016.18.

[108] GEBRU T, MORGENSTERN J, VECCHIONE B, et al. Datasheets for datasets[J/OL]. Communications of the ACM, 2021, 64(12): 86-92. DOI: 10.1145/3458723.

[109] KAPOOR S, NARAYANAN A. Leakage and the reproducibility crisis in machine-learning-based science[J/OL]. Patterns, 2023, 4(9): 100804. DOI: 10.1016/j.patter.2023.100804.